PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ
FACULTAD DE CIENCIAS E INGENIERÍA

APRENDIZAJE DE MÁQUINA (1INF02-1081)
Examen 2
(Ciclo de verano 2026)

Indicaciones generales:

- Duración: 3 horas.
- Materiales o equipos a utilizar: Con apuntes de clase y calculadora no programable.
- No está permitido el uso de ningún material o equipo electrónico adicional al indicado.
- **La presentación, la ortografía y la gramática influirán en la calificación.**
- **Resolver solo 4 preguntas.**

Puntaje total: 20 puntos

---

1. Considere un modelo de Mezcla de Gaussianas (GMM) con K=2 componentes, utilizado para segmentar clientes según su nivel de interacción con una plataforma en un espacio unidimensional. Se dispone de un mini-batch de N=4 clientes con los siguientes valores de interacción:

i	1	2	3	4
x_i	1	2	8	9

Después de ejecutar el "Paso E" (*Expectation*) del algoritmo EM, se obtienen las siguientes responsabilidades r_{ik} (probabilidad posterior de que el dato i pertenezca al clúster k):

Cliente	x_i	r_{i1}	r_{i2}
1	1	0.9	0.1
2	2	0.8	0.2
3	8	0.1	0.9
4	9	0.2	0.8

a) Calcule la "cantidad efectiva de puntos" asignados a cada clúster (N_1 y N_2), sumando las responsabilidades correspondientes. Con ello, determine los nuevos pesos de mezcla π_1 y π_2 del Paso M (*Maximization*). **(2 puntos)**

b) Calcule la nueva media para el primer componente gaussiano (μ_1) usando la fórmula del promedio ponderado: $\mu_1 = (1/N_1) \sum r_{i1} \cdot x_i$. **(2 puntos)**

c) Compare brevemente las responsabilidades del GMM con el enfoque de K-Means. ¿Qué ventaja ofrece el GMM al usar "asignación suave" (soft assignment) frente a la "asignación dura" (hard assignment) de K-Means? Justifique usando los datos de la tabla. **(1 punto)**

2. Considere un Autoencoder Variacional (VAE) donde el Encoder produce, para una imagen de entrada x, los parámetros de una distribución normal multivariada diagonal en un espacio latente de 2 dimensiones:

   Vector de medias (μ): [0.5, −0.1]

   Vector de desviaciones estándar (σ): [0.1, 1.2]

   La función de pérdida total del VAE se compone de dos términos: la pérdida de reconstrucción (MSE) y el término de regularización (Divergencia KL), que fuerza a que la distribución del espacio latente se aproxime a una normal estándar N(0, I). La fórmula de la Divergencia KL para una normal diagonal es:

$$D_{KL} = 0.5 \sum (\mu_i^2 + \sigma_i^2 - \ln(\sigma_i^2) - 1)$$

   Nota: *$\ln(0.01) \approx -4.60$ y $\ln(1.44) \approx 0.36$*

   a) Escriba la matriz de covarianza Σ de este espacio latente, asumiendo que las dimensiones son independientes. **(1 punto)**

   b) Calcule la Divergencia KL para esta muestra, mostrando el cálculo componente a componente (Dimensión 1 y Dimensión 2 por separado). **(2 puntos)**

   c) Si el error de reconstrucción (MSE) calculado por el Decoder es 1.5, ¿cuál es la pérdida total L (MSE+D_{KL}) de la red para esta muestra? **(1 punto)**

   d) Observe el valor de $\sigma_2 = 1.2$ frente a $\sigma_1 = 0.1$. ¿Por qué la primera dimensión recibe un castigo mucho mayor en la Divergencia KL que la segunda? Explique conceptualmente qué sucede cuando el modelo intenta colapsar la varianza a cero y cómo el término logarítmico lo previene. **(1 punto)**

3. En el procesamiento de lenguaje natural (NLP), palabras polisémicas como "Planta" tienen múltiples significados. Un modelo clásico asigna un único vector estático a la palabra, pero queremos generar un *embedding contextual* utilizando el Teorema de Bayes. Sabemos empíricamente que, en nuestro corpus, la palabra “Planta” significa *Fábrica* (F) el 40% de las veces y *Organismo Vegetal* (V) el 60%. Tenemos los siguientes embeddings pre-entrenados en $\mathbb{R}^2$:

$$E_F = (5, 0) \qquad E_V = (0, 5)$$

   Al analizar una nueva oración, observamos la palabra de contexto “hoja” (H). Sabemos por nuestro modelo de lenguaje que $P(H|F) = 0.1$ y $P(H|V) = 0.8$.

   a) Calcule la probabilidad marginal de la evidencia P(H) usando la Ley de Probabilidad Total. Luego, aplique el Teorema de Bayes para obtener las probabilidades posteriores P(F|H) y P(V|H). **(2 puntos)**

   b) Genere el nuevo embedding contextual esperado para la palabra “Planta” en esta oración, calculándolo como la suma ponderada de los embeddings base según sus probabilidades posteriores: $E_{context} = P(F|H) \cdot E_F + P(V|H) \cdot E_V$. **(2 puntos)**

   c) Explique didácticamente por qué este enfoque bayesiano resuelve la limitación de los embeddings estáticos tradicionales (como Word2Vec). **(1 punto)**

4. Considere un dataset bidimensional. Tiene los siguientes datos de entrenamiento (X_{train}):

i	1	2	3	4
x_i	(2, 2)	(−2, −2)	(1, 1)	(−1, −1)

Y un único dato de prueba: x_{test} = (4, −4).

a) Calcule la matriz de covarianza empírica Σ estrictamente sobre X_{train} (asegurando evitar el Data Leakage), usando $\frac{1}{N}\sum(x_i - \mu)(x_i - \mu)^T$. **(2 puntos)**

b) Determine el primer autovalor (λ_1) y su autovector asociado (u_1) normalizado a magnitud 1. Luego, proyecte el punto de prueba x_{test} sobre la primera componente principal (u_1) para obtener su valor escalar z. **(2 puntos)**

c) Si hubieras incluido x_{test} en el cálculo de la matriz de covarianza desde el principio, ¿por qué invalidaría metodológicamente tu evaluación del modelo? Explique el concepto de *Data Leakage* en este contexto. **(1 punto)**

5. Considere una red neuronal con 1 entrada (x), 1 neurona oculta (h) con activación Sigmoide σ(z), y 1 salida lineal (y). La función de pérdida es el Error Cuadrático ($J = \frac{1}{2}(y - t)^2$). Las ecuaciones de la red son:

$$z_1 = w_1 x + b_1 \qquad h = \sigma(z_1) = \frac{1}{1+e^{-z_1}} \qquad y = w_2 h + b_2$$

Parámetros iniciales: w_1 = 0, b_1 = 0, w_2 = 4, b_2 = −1. Se observa un dato de entrenamiento: entrada x = 2, objetivo t = 2. Recuerde que la derivada de la sigmoide es $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.

a) Realice el forward pass completo para encontrar el valor de z_1, h, y (predicción) y la pérdida J. **(2 puntos)**

b) Utilice la regla de la cadena para calcular el gradiente exacto del peso de la primera capa: $\partial J/\partial w_1 = (\partial J/\partial y)(\partial y/\partial h)(\partial h/\partial z_1)(\partial z_1/\partial w_1)$. Interprete el signo del resultado: ¿debe aumentar o disminuir w_1 para reducir el error? **(3 puntos)**

Profesor del curso: Rodrigo Uribe

San Miguel, 03 de marzo de 2026