Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería

1INF02 APRENDIZAJE DE MÁQUINA

Introducción al aprendizaje de maquina

Prof. Rodrigo Uribe

Organización de la Clase

(10 min) Presentación personal

(30 min) Organización del curso

(45 min) Origen e historia del aprendizaje de maquina



(10 min) Break

(30 min) Dinámica grupal

(45 min) Repaso de estadística, probabilidad

(10 min) Preguntas *Vibe Quest*

Acerca del Profesor (Rodrigo Uribe)



Ingeniero geoestadístico, especializado en inteligencia artificial aplicada a las ciencias geológicas, egresado del doctorado en Ingeniería en la PUCP

- Doctorado en Ingeniería (egresado) - PUCP
- Tesis doctoral: "Deep Neural Networks for Data-Driven Geological Modelling"
- Estudios profesionales en inteligencia artificial - Universidad de Stanford (EEUU)
- Maestría - Universidad Adolfo Ibáñez (Chile)

Recientemente escritor de ciencia ficción



IO: Un Mundo Libre de Políticos (IO (español) nº 1) (Spanish Edition)

Edición Kindle

Edición en Español | de A. R. Uribe (Autor) | Formato: Edición Kindle

Libro 1 de 1: IO (español)

Cuando no podemos existir sin nuestros dispositivos, ¿quién tiene realmente el poder?

En un futuro cercano, la Tecnodemocracia promete justicia y progreso al reemplazar a los políticos corruptos con un sistem tecnológico impecable. Pero esa perfección empezará a resquebrajarse.

Abigail, analista del Sistema, descubre una falla capaz de hacerlo colapsar desde dentro. Su hija, **Aga**, cuando se mudan a l ciudad, emprende un viaje para encontrarse a sí misma… y en el proceso se topa con el lado más oscuro de la sociedad que su madre intenta proteger.

A miles de kilómetros, en la Antártida, **Clarens** lidera una expedición que busca liberarse del control del Sistema junto a un misteriosa comunidad liderada por "ángeles". Cuando sus historias convergen, una lucha desesperada por la libertad pondr en riesgo sus vidas y el futuro de todos los ciudadanos de la Tecnodemocracia.

Un Mundo Libre de Políticos es una novela de ciencia ficción que mezcla acción, suspenso y una reflexión incisiva sobre la

Leer más

Libro 1 de 1	Idioma	Accesibilidad	Fecha de publicación	Edad de lectura
IO (español)	Español	Más información	4 Febrero 2026	De 13 a 18 años

Seguir al autor

Acerca de Ustedes

(lista de asistencia)



(Nombre) Nombre

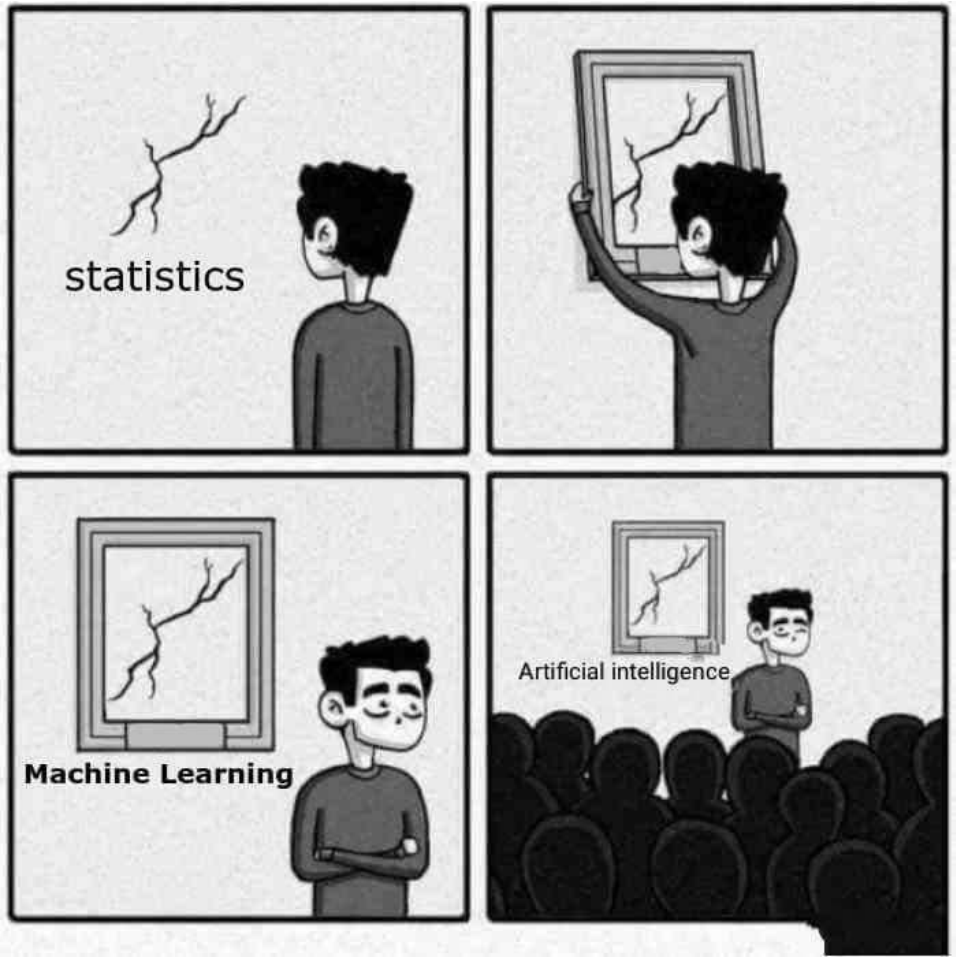
(Personal) Algo sobre ti

(Nivel PUCP) ¿Cuál es el nivel PUCP?

(Sobre el Curso) Pedido particular

+1 punto si hacen reír a alguien

Acerca del Curso



- El curso busca motivar y crear dinámicas de aprendizaje activo donde el estudiante construye conocimiento haciendo
- La estadística, el machine learning y la inteligencia artificial comparten los mismos fundamentos — este curso te dará las bases matemáticas y científicas para entender las tres
- Enfoque práctico-científico: no solo ejecutar código, sino entender qué hace, por qué funciona y cuándo usarlo
- Aprenderás a comunicar resultados como un científico de datos

¿Qué hace distinto este curso?



¡Sabemos que utilizan IA!

¿Quién ha utilizado IA para programar?
¿Es eso trampa?

¿Qué es *vibe coding*?



Andrej Karpathy 
@karpathy

Promote

There's a new kind of coding I call "vibe coding", where you fully give in to the vibes, embrace exponentials, and forget that the code even exists. It's possible because the LLMs (e.g. Cursor Composer w Sonnet) are getting too good. Also I just talk to Composer with SuperWhisper so I barely even touch the keyboard. I ask for the dumbest things like "decrease the padding on the sidebar by half" because I'm too lazy to find it. I "Accept All" always, I don't read the diffs anymore. When I get error messages I just copy paste them in with no comment, usually that fixes it. The code grows beyond my usual comprehension, I'd have to really read through it for a while. Sometimes the LLMs can't fix a bug so I just work around it or ask for random changes until it goes away. It's not too bad for throwaway weekend projects, but still quite amusing. I'm building a project or webapp, but it's not really coding - I just see stuff, say stuff, run stuff, and copy paste stuff, and it mostly works.

Vibe coding

From Wikipedia, the free encyclopedia



This article **may contain an excessive number of citations**. Please help remove low-quality or irrelevant citations. *(June 2025)* (*Learn how and when to remove this message*)

Vibe coding (or **vibecoding**) is an approach to producing software by using artificial intelligence (AI), where a person describes a problem in a few natural language sentences as a prompt to a large language model (LLM) tuned for coding. The LLM generates software based on the description, shifting the programmer's role from manual coding to guiding, testing, and refining the AI-generated source code.[1][2][3]

Advocates of vibe coding say that it allows even amateur programmers to produce software without the extensive training and skills required for software engineering.[4] The term was introduced by Andrej Karpathy in February 2025[5][2][4][1] and listed in the Merriam-Webster Dictionary the following month as a "slang & trending" noun.[6]

Thomas Wolf
@Thom_Wolf

we've seen nothing yet! hosted a 9-13 yo vibe-coding event w. @robertkeus this w-e (h/t @antonosika @LovableBuild)

takeaway? AI is unleashing a generation of wildly creative builders beyond anything I'd have imagined

and they grow up *knowing* they can build anything!



Vamos a utilizar *vibe coding*



El curso esta diseñado para que utilices estas herramientas para aumentar tu proceso de aprendizaje.



Organización del curso

+Científico/Aplicativo ⟷ **+Matemático/Teórico**

1.LABORATORIOS (Grupal) Peso 2	2.TAREA ACADÉMICA (Grupal) Peso 3			3.EXÁMENES (Individual) Peso 4
1.1.Crear productos científicos de alta calidad	2.1 Exploración interactiva de preguntas teóricas (vibe quest)	2.2 Participación activa en clase	2.3 Creación de ejercicios matemáticos (nivel PUCP)	3.1 Exámenes en base a los ejercicios nivel PUCP

Calificación del curso

VIII. EVALUACIÓN

Sistema de evaluación

N°	Codigo	Tipo de Evaluación	Cant. Eval.	Forma de aplicar los pesos	Pesos	Cant. Eval. Eliminables	Consideraciones adicionales	Observaciones
1	Pb	Práctica tipo B	5	Por Promedio	Pb=2	0		
2	Ta	Tarea académica	1	Por Evaluación	Ta1=3			
3	Ex	Examen	2	Por Evaluación	Ex1=2 Ex2=2			

Modalidad de evaluación: 2

Fórmula para el cálculo de la nota final

$$(2Pb + 3Ta1 + 2Ex1 + 2Ex2) / 9$$

Aproximación de los promedios parciales No definido

Aproximación de la nota final No definido

Organización del curso

+Científico/Aplicativo ⟵ ⟶ **+Matemático/Teórico**

1.LABORATORIOS (Grupal) Peso 2	2.TAREA ACADÉMICA (Grupal) Peso 3			3.EXÁMENES (Individual) Peso 4
1.1.Crear productos científicos de alta calidad	2.1 Exploración interactiva de preguntas teóricas (vibe quest)	2.2 Participación activa en clase	2.3 Creación de ejercicios matemáticos (nivel PUCP)	3.1 Exámenes en base a los ejercicios nivel PUCP

Objetivos de los laboratorios

1. **Aplicar los conceptos teóricos** mediante la generación de productos científicos tangibles (modelos, visualizaciones, análisis estadísticos) que demuestren comprensión profunda de los temas desarrollados en la teoría.
2. **Desarrollar competencias de programación** asistida por IA (vibe coding), utilizando herramientas como Claude, Copilot o ChatGPT para acelerar la implementación mientras se mantiene comprensión crítica del código generado.
3. **Interpretar y comunicar resultados** de manera científica, justificando decisiones metodológicas y limitaciones de los análisis realizados.
4. **Recibir retroalimentación** sobre la calidad técnica, claridad y rigor de los productos desarrollados, con calificación acorde a estándares científicos.
5. **Conectar los resultados obtenidos** con aplicaciones del mundo real, identificando contextos donde cada técnica sería apropiada o inapropiada.

Calificación en cada laboratorio

Cada laboratorio requiere 5 productos científicos. Cada producto se evalúa en escala de 1 a 4 mediante defensa oral.

Calificación	Descriptor	Criterio
4	**Excelente**	El alumno responde todas las preguntas, expone con claridad y demuestra comprensión profunda del producto científico y su contexto teórico
3	**Satisfactorio**	El producto está completo pero el alumno no puede defender en profundidad; quedan preguntas sin responder o explicaciones superficiales
2	**Mínimo**	Entendimiento básico; el producto existe y cumple los requisitos mínimos, pero con limitaciones evidentes en ejecución o comprensión
1	**Insuficiente**	Por debajo del mínimo; el producto está incompleto, incorrecto, o el alumno no puede justificar ningún aspecto del trabajo

¿Qué es un producto científico?

Un producto científico es un entregable tangible generado a partir del análisis de datos que podría formar parte de la sección de resultados de un artículo académico. Debe ser **reproducible, interpretable y capaz de comunicar hallazgos de forma clara y rigurosa**.

Características de un buen producto científico

- ✓ **Autoexplicativo**: incluye título, ejes etiquetados, leyenda y unidades…
- ✓ **Reproducible**: el código que lo genera está disponible y es ejecutable
- ✓ **Contextualizado**: muestra, por qué es relevante y permite extraer conclusiones
- ✓ **Técnicamente correcto**: metodología apropiada, sin errores de implementación

Lab 1: Modelado Estadístico Clásico

📊 Datasets a Utilizar

Old Faithful - statsmodels • Dist. bimodal, mezcla gaussiana

Iris - sklearn • ANOVA, discriminante bayesiano

Radon - PyMC • Modelo jerárquico, pooling parcial

mtcars - statsmodels • Impacto de priors

Tips - seaborn • Intervalos confianza vs credibilidad

🔬 Ejemplos de Productos Científicos

1. Dashboard comparación prior vs posterior
2. Forest plots: intervalos confianza vs credibilidad
3. Comparación AIC/BIC vs WAIC/LOO-CV
4. Análisis jerárquico con diagnósticos MCMC
5. Análisis de sensibilidad a priors

Bibliotecas: scipy.stats, statsmodels, pymc, arviz

Lab 2: Regresión, SGD y Clasificación

📊 Datasets a Utilizar

California Housing - sklearn • Regresión, convergencia SGD

Diabetes - sklearn • Double descent, polinomios

Titanic - Kaggle • Clasificación binaria

Iris - sklearn • SGD multiclase, fronteras decisión

Wine Quality - UCI • Regresión/clasificación

🔬 Ejemplos de Productos Científicos

1. Gráfico convergencia SGD (pérdida vs iter)
2. Curva double descent (error vs grado)
3. Matriz de confusión + métricas
4. Curvas ROC y Precision-Recall
5. Visualización árbol con Graphviz

Bibliotecas: sklearn.linear_model, sklearn.tree, graphviz

Lab 3: SVM y Métodos de Ensamble

📊 Datasets a Utilizar

Breast Cancer - sklearn/UCI • Alta dim., features

make_moons/circles - sklearn • Comparación kernels

Heart Disease - UCI • Mix categórico/continuo

Iris - sklearn • Multiclase, separabilidad

Wine Quality - UCI • Escalabilidad, desbalance

🔬 Ejemplos de Productos Científicos

1. Grid fronteras de decisión (kernels)
2. Visualización vectores de soporte
3. Gráfico importancia features (RF)
4. Curva boosting iterations vs accuracy
5. Curvas ROC comparando ensambles

Bibliotecas: sklearn.svm, sklearn.ensemble, xgboost

Lab 4: Tratamiento de Datos y Clustering

📊 Datasets a Utilizar

Titanic - Kaggle • Age 20%, Cabin 77% missing

Mall Customers - Kaggle • Clustering ideal (k=5)

Wine Quality - UCI • Outliers, scaling

Heart Disease - UCI • Missing real

make_blobs/moons - sklearn • Sintético

🔬 Ejemplos de Productos Científicos

1. Heatmap datos faltantes (missingno)
2. Comparación before/after imputación
3. Dashboard detección outliers
4. Elbow plot + silhouette + dendrograma
5. Impacto data augmentation en clustering

Bibliotecas: missingno, sklearn.cluster, scipy.cluster.hierarchy, sklearn.impute

Lab 5: Técnicas Avanzadas

📊 Datasets a Utilizar

Fashion-MNIST - torchvision • 784D, visual

Olivetti Faces - sklearn • 4,096D, eigenfaces

20 Newsgroups - sklearn • 34K feat., RAG

Gene Expression - UCI • 20,531 genes

MNIST - torchvision • Canónico VAE

🔬 Ejemplos de Productos Científicos

1. Scree plot + varianza acumulada
2. Proyección PCA 2D/3D con clusters
3. Grid reconstrucción autoencoder
4. Visualización espacio latente VAE
5. Demo RAG: heatmap + retrieval

Bibliotecas: sklearn.decomposition, torch, sentence-transformers, umap-learn

Resumen de Recursos

📦 Fuentes de Datasets

sklearn.datasets - Iris, Diabetes, Breast Cancer, California Housing, Olivetti, 20 Newsgroups

UCI ML Repository - Wine Quality, Heart Disease, Gene Expression

Kaggle - Titanic, Mall Customers, Fashion-MNIST

torchvision - MNIST, Fashion-MNIST

seaborn/statsmodels - Tips, Old Faithful, mtcars

PyMC examples - Radon Contamination

🛠️ Bibliotecas Sugeridas por Laboratorio

Lab 1: scipy.stats, statsmodels, pymc, arviz

Lab 2: sklearn.linear_model, sklearn.tree, graphviz

Lab 3: sklearn.svm, sklearn.ensemble, xgboost

Lab 4: missingno, sklearn.cluster, scipy.hierarchy

Lab 5: sklearn.decomposition, torch, sentence-transformers

Organización del curso

+Científico/Aplicativo ⟵ ⟶ **+Matemático/Teórico**

1.LABORATORIOS (Grupal) Peso 2	2.TAREA ACADÉMICA (Grupal) Peso 3			3.EXÁMENES (Individual) Peso 4
1.1.Crear productos científicos de alta calidad	2.1 Exploración interactiva de preguntas teóricas (vibe quest)	2.2 Participación activa en clase	2.3 Creación de ejercicios matemáticos (nivel PUCP)	3.1 Exámenes en base a los ejercicios nivel PUCP

Exploración interactiva (Vibe Quest)



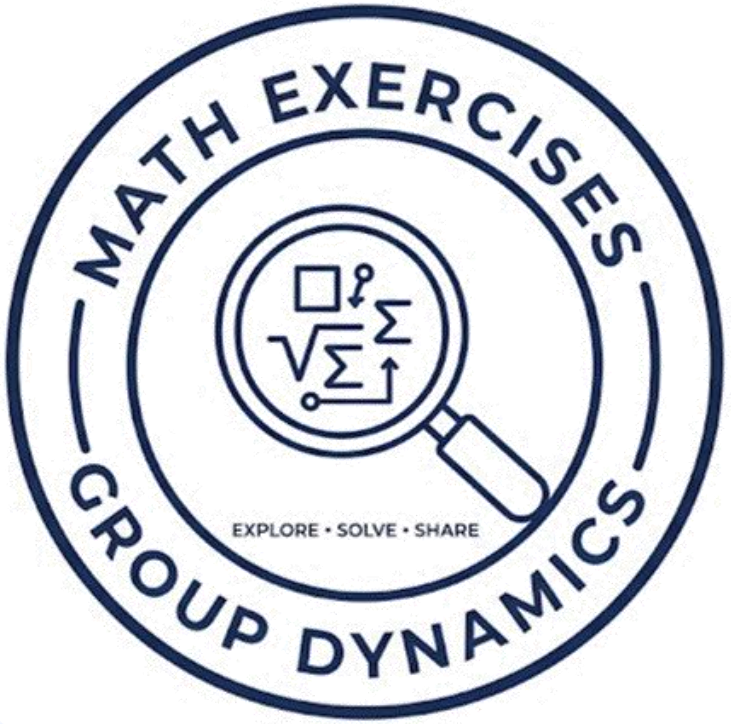
- Sólo responder a 1 pregunta de las preguntas abiertas dejadas al final de la clase.
- Máximo 2 puntos por clase.
- Crear código interactivo usando inteligencia artificial donde se expondrá el resultado a comienzos de la siguiente clase.
- Deben responder satisfactoriamente

Participación activa en clase



- Preguntar por cualquier tema relevante a la clase del día.
- Máximo 2 puntos (1 punto por participación) por clase.
- Incentivar participación para mantener la clase amena.
- Todos los grupos deberían tener 20 en participación.

Creación de ejercicios



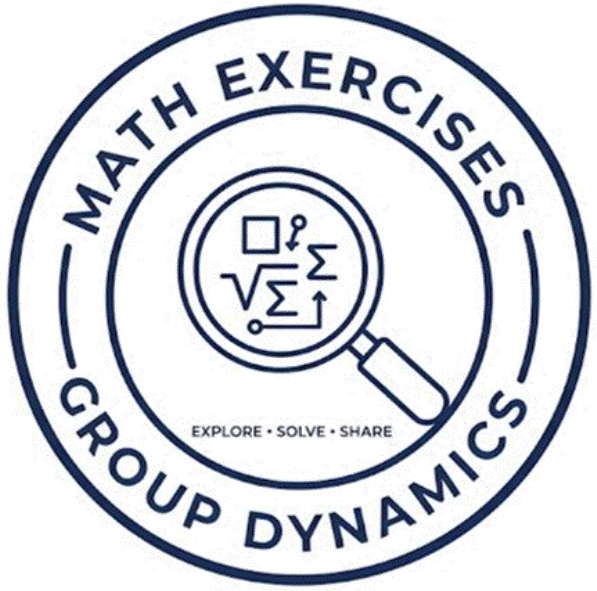
- Se habilita un foro para cargar ejercicios matemáticos relevantes.
- Máximo 2 ejercicios (equivale a 2 puntos) por clase.
- Punto adicional por la dinámica de grupo.
- Preguntas tipo examen nivel PUCP (serán utilizadas en los exámenes).

Organización del curso

+Científico/Aplicativo ⟷ **+Matemático/Teórico**

1.LABORATORIOS (Grupal) Peso 2	2.TAREA ACADÉMICA (Grupal) Peso 3			3.EXÁMENES (Individual) Peso 4
1.1.Crear productos científicos de alta calidad	2.1 Exploración interactiva de preguntas teóricas (vibe quest)	2.2 Participación activa en clase	2.3 Creación de ejercicios matemáticos (nivel PUCP)	3.1 Exámenes en base a los ejercicios nivel PUCP

Exámenes individuales



5 preguntas similares o combinadas a las presentadas clase a clase a nivel “PUCP”

Organización de las Clases

(10 min) Preguntas y consultas.

(30 min) Respuesta *Vibe Quest.*

(45 min) Introducción a la pregunta de la clase y desarrollo.



(10 min) Break

(45 min) Continuación y aplicaciones asociadas.

(30 min) Ejercicios y/o Dinámica.

(10 min) Preguntas *Vibe Quest.*

Desarrollo del Curso

Clase 1: Introducción al Curso y Repaso de Probabilidad e IA

Pregunta: ¿Qué es aprendizaje de máquina?

Esta lección establece los fundamentos conceptuales del curso. Se definirá el aprendizaje de máquina como un paradigma donde los sistemas mejoran su desempeño a partir de la experiencia (datos) sin ser programados explícitamente. Se repasarán conceptos esenciales de probabilidad y estadística que sustentan todos los algoritmos del curso. Los estudiantes comprenderán la diferencia entre programación tradicional y aprendizaje automático, así como el contexto histórico de la inteligencia artificial.

Clase 2: Mentalidad de Modelado

Pregunta: ¿Cómo se toman decisiones (modelado) con datos?

Esta lección establece los fundamentos conceptuales del curso. Se definirá el aprendizaje de máquina como un paradigma donde los sistemas mejoran su desempeño a partir de la experiencia (datos) sin ser programados explícitamente. Se repasarán conceptos esenciales de probabilidad y estadística que sustentan todos los algoritmos del curso. Los estudiantes comprenderán la diferencia entre programación tradicional y aprendizaje automático, así como el contexto histórico de la inteligencia artificial.

Laboratorio 1: Explorar soluciones estadísticas clásicas con código

Desarrollo del Curso

Clase 3: Regresión y Aproximaciones

Pregunta: ¿Cómo los modelos aprenden de equivocarse?

Se presentará la regresión lineal como el modelo fundacional del aprendizaje supervisado. Se explicará el concepto de función de pérdida y cómo el error guía el proceso de aprendizaje. Se introducirá el algoritmo de Descenso de Gradiente Estocástico (SGD) como mecanismo de optimización. Se discutirá el fenómeno de Double Descent y sus implicaciones para la complejidad del modelo. Los estudiantes comprenderán el ciclo fundamental: predicción, error, ajuste.

Clase 4: Clasificación Logística y Árboles de Decisión

Pregunta: ¿Cómo trazamos límites para tomar decisiones?

Se transicionará de problemas de regresión a problemas de clasificación. Se derivará la regresión logística como extensión natural para variables categóricas, introduciendo la función sigmoide y la interpretación probabilística. Se presentarán los árboles de decisión como modelos basados en particiones recursivas del espacio de características. Los estudiantes aprenderán a evaluar clasificadores mediante métricas como precisión, recall y curvas ROC.

Laboratorio 2: Explorar modelos básicos con código

Desarrollo del Curso

Clase 5: Perceptrón y Máquinas de Vectores de Soporte

Pregunta: ¿Cómo encontramos la mejor frontera de decisión?

Se introducirá el perceptrón como el clasificador lineal históricamente más relevante y precursor de las redes neuronales. Se derivarán las Máquinas de Vectores de Soporte (SVM) desde el principio de maximización del margen. Se explicará el truco del kernel para extender SVM a fronteras no lineales. Los estudiantes comprenderán por qué no basta con encontrar una frontera separadora, sino la óptima.

Clase 6: Métodos de Ensamble

Pregunta: ¿Cómo combinamos modelos de forma eficiente?

Se presentará el principio de que múltiples modelos combinados superan a modelos individuales. Se explicarán tres estrategias fundamentales: Bagging (agregación bootstrap), Boosting (aprendizaje secuencial) y Random Forests (combinación de ambos con árboles). Se discutirán las condiciones bajo las cuales los ensambles son más efectivos. Esta clase cierra el bloque de aprendizaje supervisado consolidando las técnicas más utilizadas en la industria.

Ex1: Problemas de Aprendizaje Supervisado y Tradicionales

Laboratorio 3: Explorar modelos utilizando aprendizaje supervisado

Desarrollo del Curso

Clase 7: Análisis Estadístico y Tratamiento de Datos

Pregunta: ¿Cómo mejoramos los datos que usa el modelo?

Se enfatizará que la calidad de los datos determina el techo del rendimiento de cualquier modelo. Se cubrirán técnicas de análisis exploratorio, detección y tratamiento de valores atípicos, imputación de datos faltantes, normalización y estandarización. Se introducirán métodos de codificación para variables categóricas. Los estudiantes desarrollarán un flujo de trabajo sistemático para preparar datos antes del modelado.

Clase 8: Modelos de Clustering y Declustering

Pregunta: ¿Cómo agrupamos datos sin etiquetas previas?

Se introducirá el aprendizaje no supervisado como paradigma donde no existen etiquetas de referencia. Se presentarán los algoritmos de clustering más relevantes: K-means, clustering jerárquico y DBSCAN. Se discutirán métricas de evaluación interna como silhouette score e inercia. Los estudiantes comprenderán las aplicaciones prácticas del clustering en segmentación y descubrimiento de patrones.

Laboratorio 4: Explorar el impacto del tratamiento y aumentación de datos

Desarrollo del Curso

Clase 9: Reducción de Dimensionalidad

Pregunta: ¿Cómo simplificamos datos sin perder información?

Se abordará el problema de la alta dimensionalidad y sus efectos negativos en los algoritmos de aprendizaje. Se derivará el Análisis de Componentes Principales (PCA) como técnica de proyección lineal que maximiza la varianza retenida. Se discutirán criterios para seleccionar el número de componentes. Los estudiantes aplicarán PCA para visualización y como preprocesamiento para otros modelos.

Clase 10: Autoencoders, Embeddings y RAGs

Pregunta: ¿Cómo aprenden las máquinas representaciones útiles?

Se introducirá el concepto de aprendizaje de representaciones como alternativa a la ingeniería manual de características. Se explicarán los autoencoders como redes neuronales que aprenden compresiones no lineales. Se presentarán los embeddings como representaciones vectoriales densas de entidades discretas. Se discutirá la arquitectura RAG (Retrieval-Augmented Generation) y su relevancia en sistemas modernos de IA. Los estudiantes comprenderán cómo las representaciones aprendidas potencian aplicaciones actuales.

Laboratorio 5: Explorar modelos utilizando técnicas avanzadas

Desarrollo del Curso

Clase 11: Otros Esquemas de Aprendizaje

Pregunta: ¿Qué otras opciones existen y cuándo aplicarlas?

Se ampliará el panorama más allá del aprendizaje supervisado y no supervisado tradicional. Se introducirá el aprendizaje semi-supervisado para escenarios con etiquetas escasas. Se presentará una visión general del aprendizaje profundo y las arquitecturas de redes neuronales. Se discutirá brevemente el aprendizaje por refuerzo. Los estudiantes desarrollarán criterios para identificar qué paradigma aplicar según las características del problema.

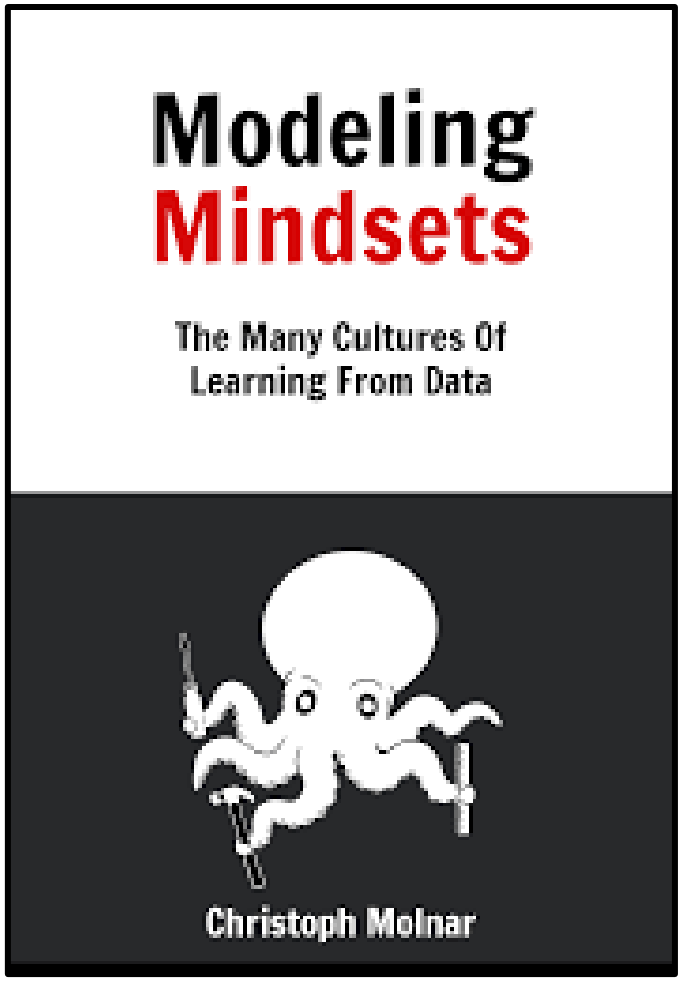
Clase 12: Perspectivas, Consideraciones Éticas y Juramento Tecnocrático

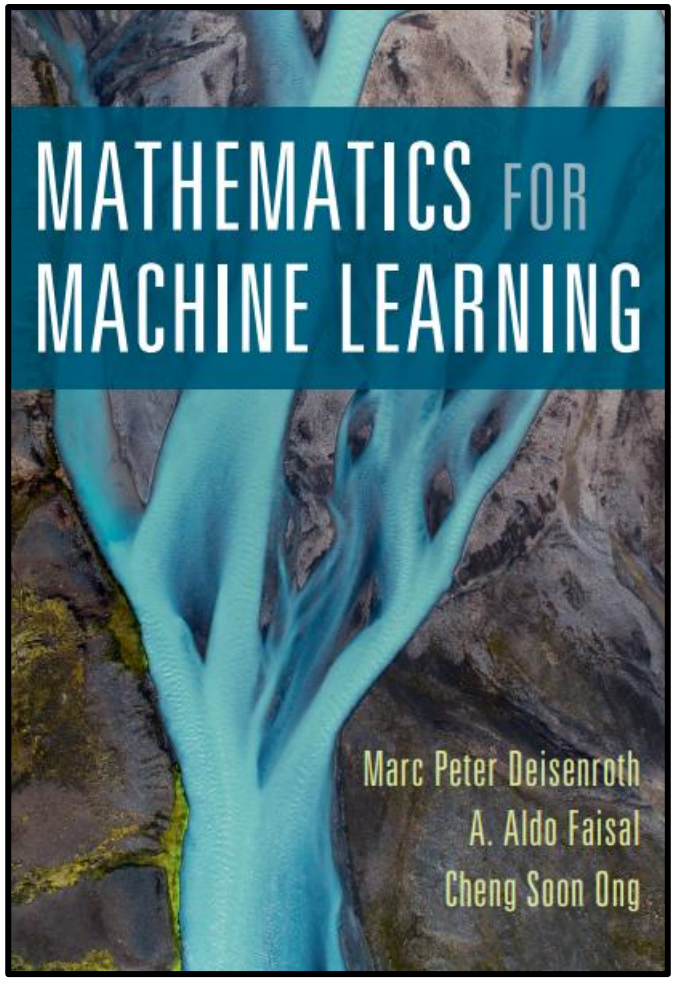
Pregunta: ¿Cuál es nuestra responsabilidad al crear estos modelos?

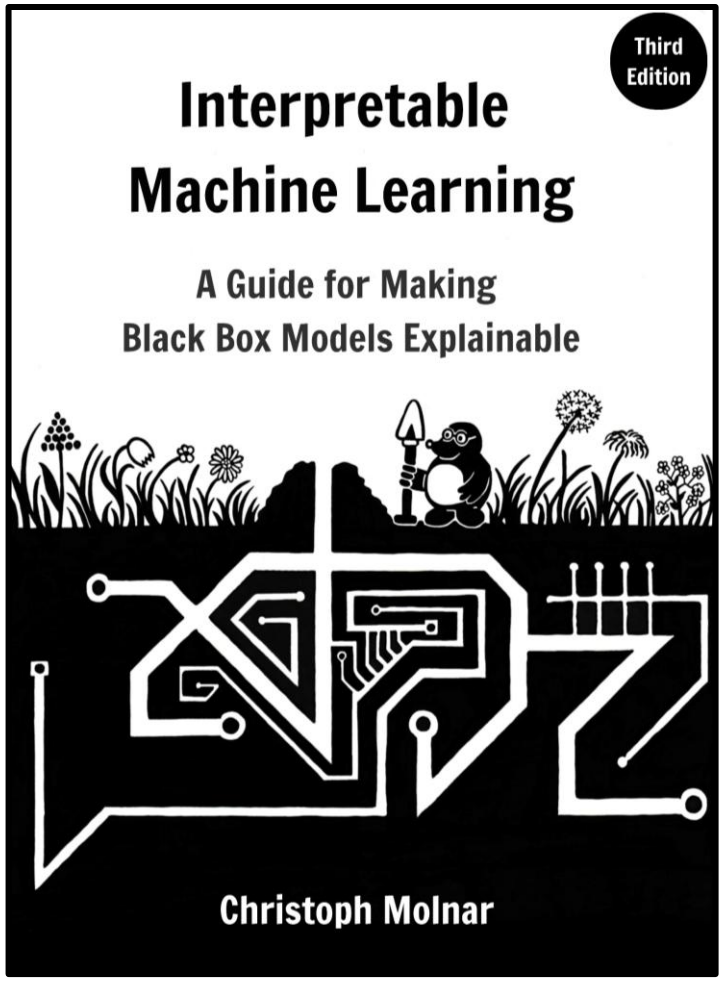
Se abordarán las implicaciones éticas y sociales del aprendizaje de máquina. Se discutirán temas de sesgo algorítmico, equidad, transparencia y explicabilidad. Se analizarán casos de estudio donde los modelos han tenido consecuencias no intencionadas. Se presentará el concepto de juramento tecnocrático como marco de responsabilidad profesional. Los estudiantes reflexionarán sobre su rol como creadores de sistemas que impactan decisiones sobre personas.

Ex2: Problemas del Curso Completo

Libros recomendados







Formación de Grupos y Asignación de Delegado



Objetivo Principal del Curso



- Entender el POR QUÉ:
  - Cada clase se guía por una pregunta fundamental que invita a reflexionar
  - Exploración interactiva mediante IA (Vibe Quest) para profundizar en los conceptos
- Entender el CÓMO:
  - Laboratorios prácticos de desarrollo de código
  - Resolución guiada de problemas matemáticos

¡Hacer trampa es inaceptable!

XI. POLÍTICA CONTRA EL PLAGIO

Para la corrección y evaluación de todos los trabajos del curso se va a tomar en cuenta el debido respeto a los derechos de autor, castigando severamente cualquier indicio de plagio con la nota CERO (00). Estas medidas serán independientes del proceso administrativo de sanción que la facultad estime conveniente de acuerdo a cada caso en particular. Para obtener más información, referirse a los siguientes sitios en internet

www.pucp.edu.pe/documento/pucp/plagio.pdf



Sobre Justificaciones



Justificar antes de empezar las clases avisando al delegado o directamente conmigo, en caso sea muy urgente (alguien estuvo en coma) se harán excepciones

¡COMUNICAR ANTES!

¿Preguntas sobre el funcionamiento?

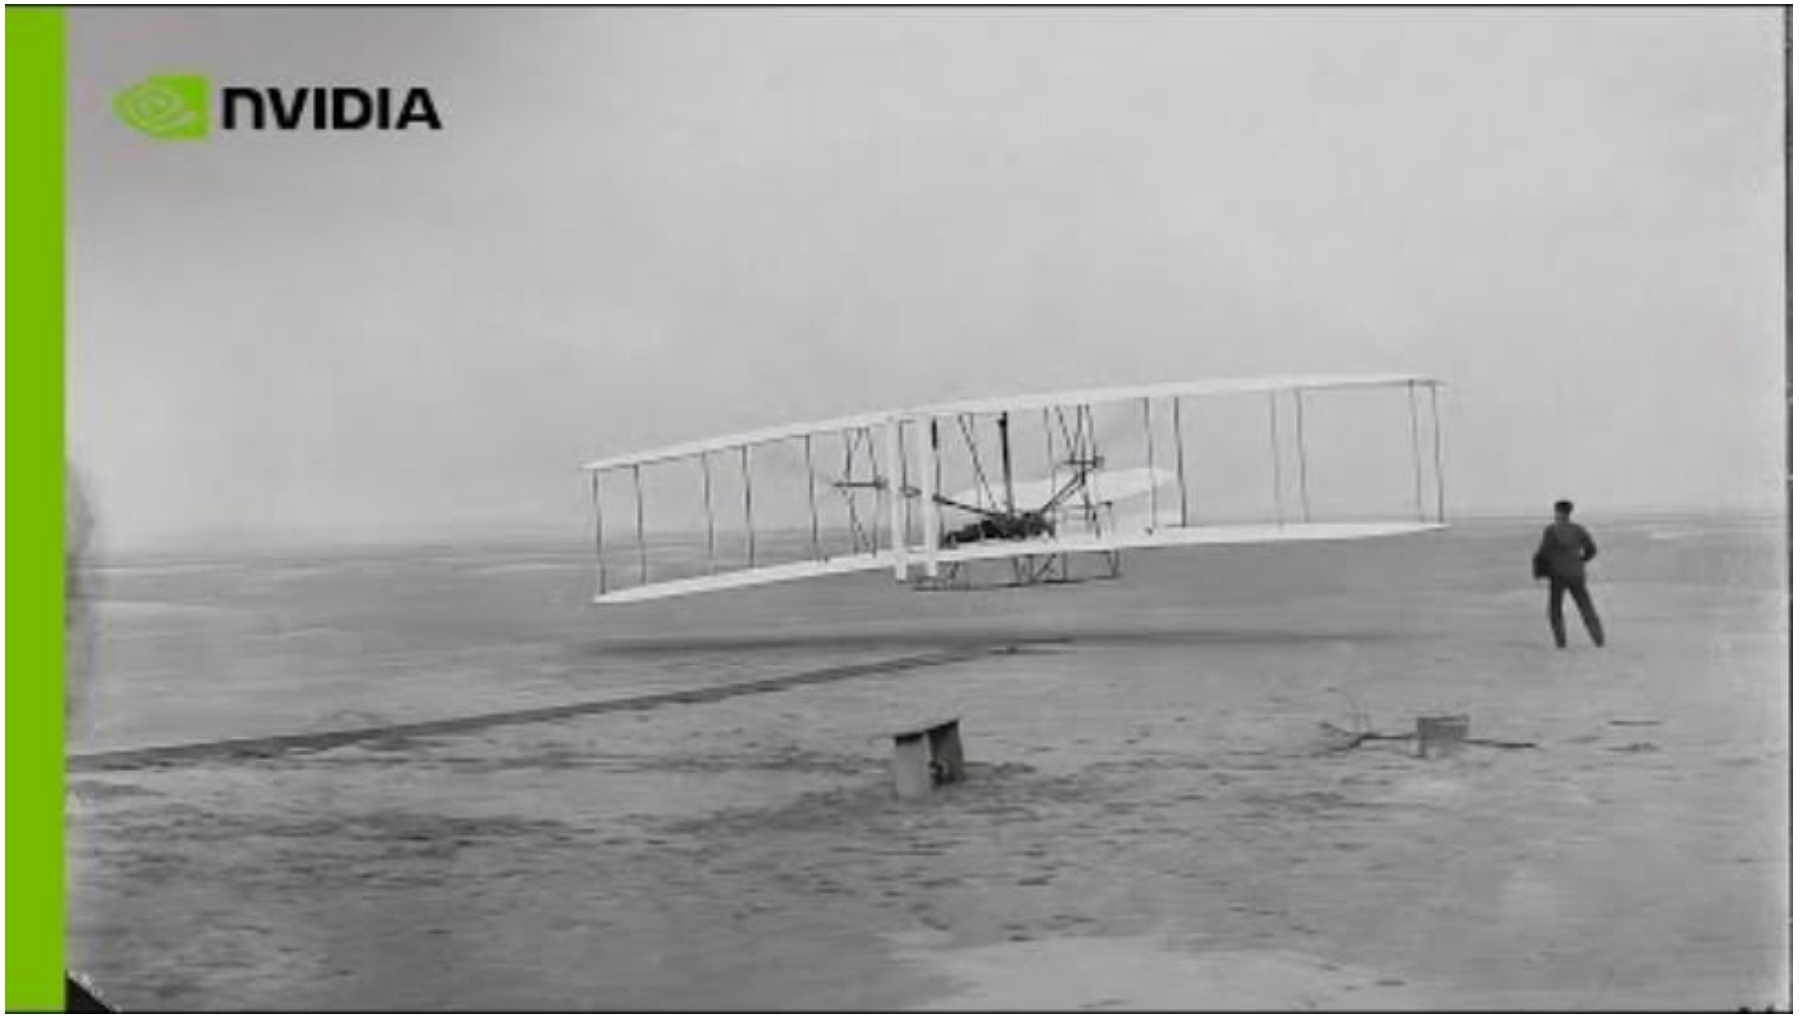


Pregunta Fundamental:

¿Qué es aprendizaje de máquina?

(pero antes…)

La era de la “IA”



https://www.youtube.com/watch?v=r6RT0JJgRIc

¿Qué es Inteligencia Artificial (IA)?

II. PLANES CURRICULARES DONDE SE DICTA EL CURSO

ESPECIALIDAD	ETAPA	NIVEL	CARÁCTER	REQUISITOS
INGENIERÍA MECATRÓNICA	PREGRADO EN FACULTAD	0	ELECTIVO	Cred.en Especialidad : 160.00
INGENIERÍA ELECTRÓNICA	PREGRADO EN FACULTAD	0	ELECTIVO	1INF62 INTELIGENCIA ARTIFICIAL APLICADA [07]
INGENIERÍA INFORMÁTICA	PREGRADO EN FACULTAD	0	ELECTIVO	1INF24 INTELIGENCIA ARTIFICIAL [07]

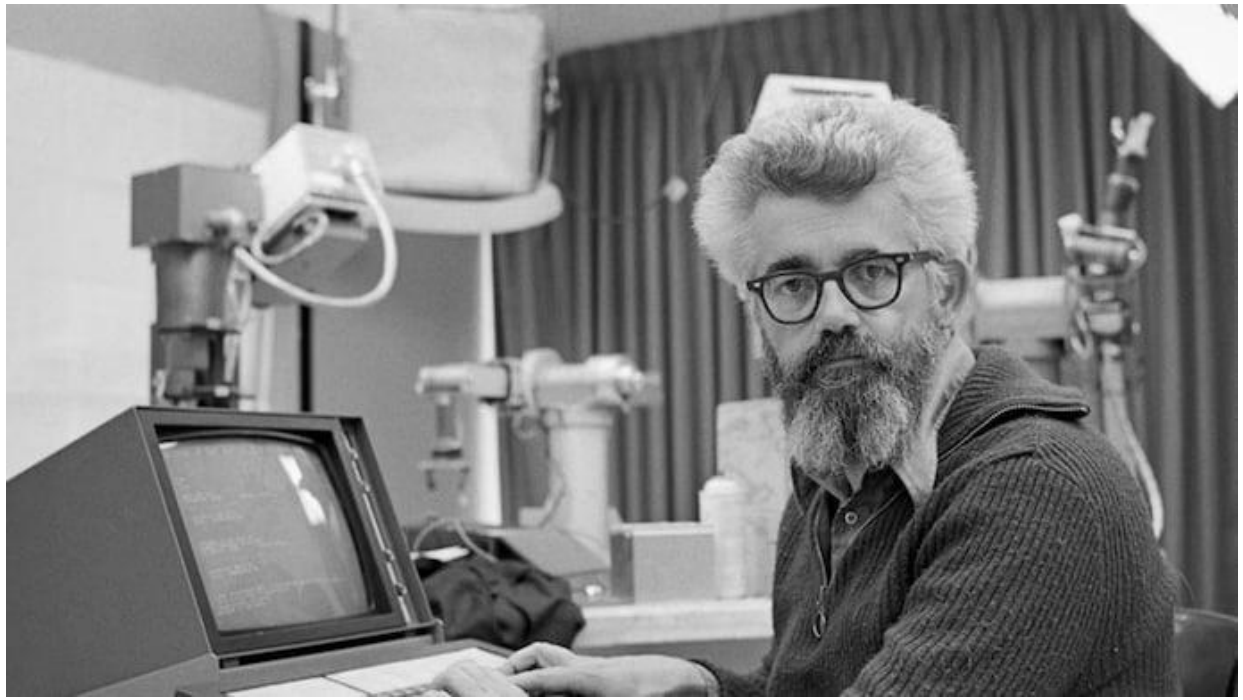
1956: El inicio de la inteligencia artificial...

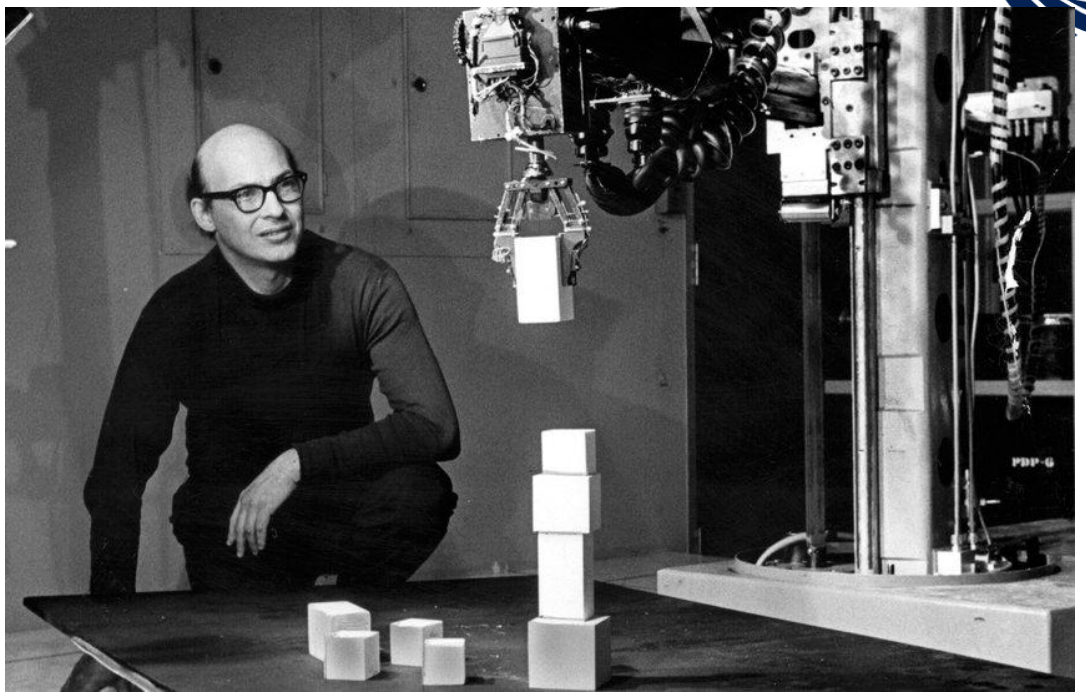
A PROPOSAL FOR THE

DARTMOUTH SUMMER RESEARCH PROJECT

ON ARTIFICIAL INTELLIGENCE

J. McCarthy, Dartmouth College
M. L. Minsky, Harvard University
N. Rochester, I. B. M. Corporation
C. E. Shannon, Bell Telephone Laboratories





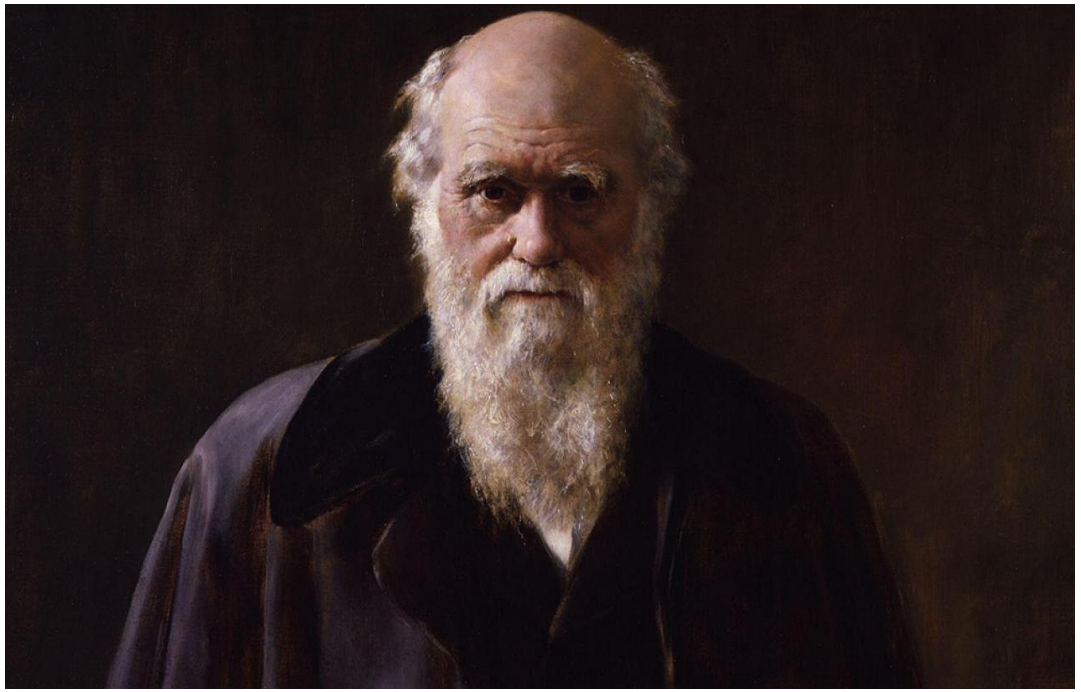
McCarthy (parafraseado):
"La IA es la ciencia y la ingeniería de hacer que las máquinas realicen tareas que nunca han visto antes y para las que no han sido preparadas de antemano."

Minsky:
"La IA es la ciencia de crear máquinas capaces de realizar tareas que requerirían inteligencia si fueran realizadas por humanos."

Ambas perspectivas representan visiones divergentes sobre la naturaleza de la inteligencia



John Locke:
"La inteligencia como una habilidad general de aprendizaje (Tabula Rasa)."



Charles Darwin:
"La inteligencia como una colección de habilidades específicas para tareas."

Una analogía sencilla





Atribuir '**inteligencia**' a un programa de comportamiento específicos es un error común. Es como seguir caminos de cosas que parecen '**inteligentes**', pero en esencia, no hay nada realmente '**inteligente**' en ellas, solo siguen instrucciones predefinidas.

Ejemplos de esto



Entonces... ¿Es esto Inteligencia Artificial?



Si, pero no siempre funciona...



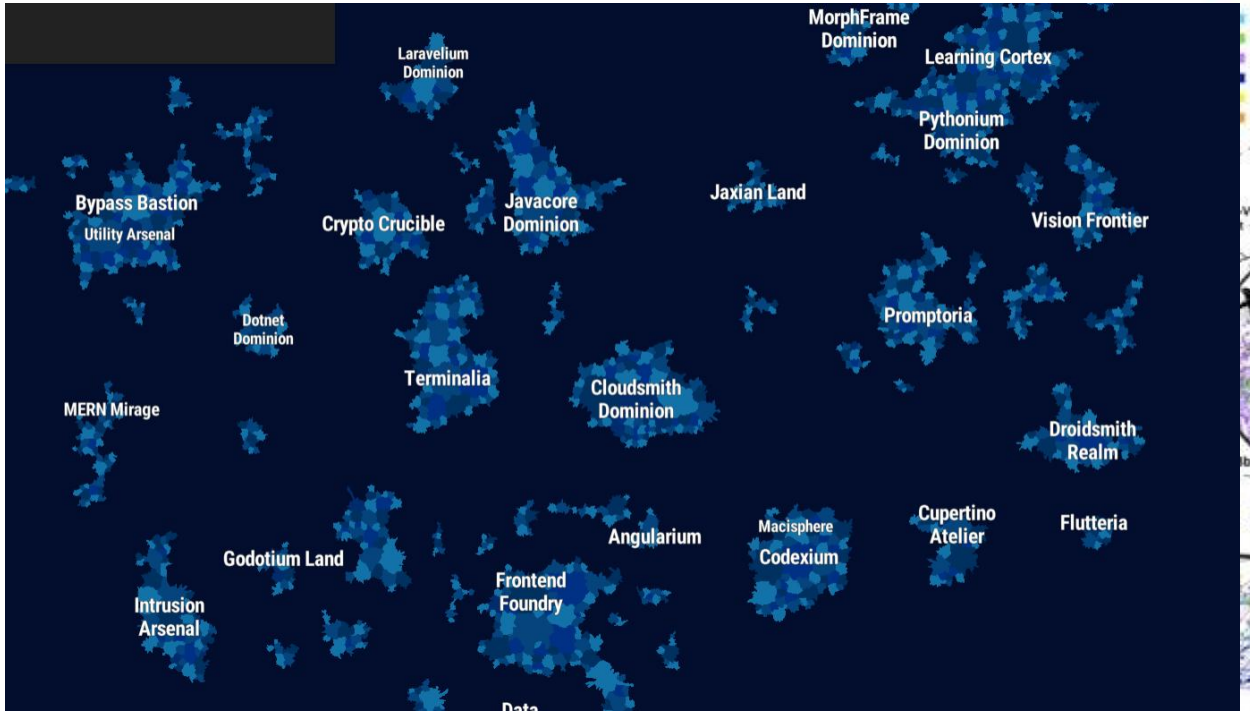
Samuel fue un pionero en este campo, desarrollando en 1952 un programa de computadora capaz de jugar a las damas, que mejoraba su desempeño jugando contra sí mismo y aprendiendo de cada partida. Fue el primero en mencionar:

Machine Learning

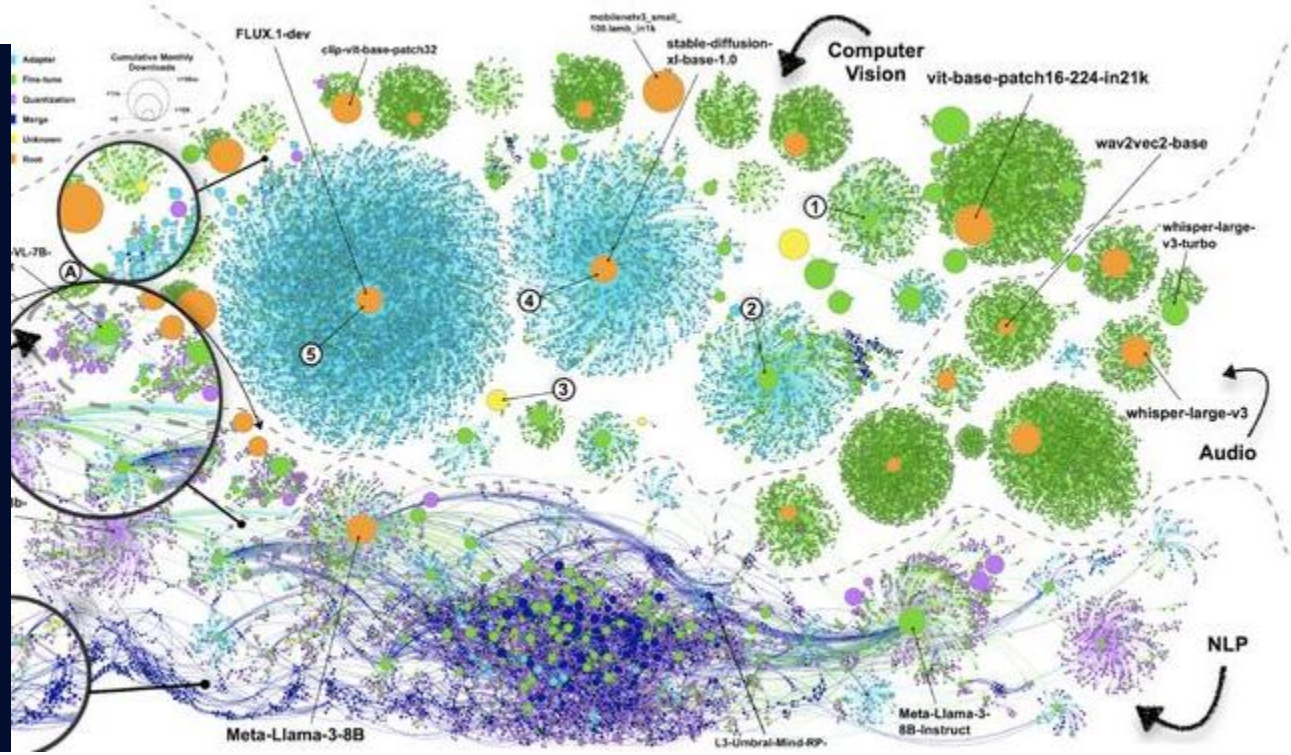
Arthur Samuel:

“El campo de estudio que da a las computadoras la capacidad de aprender sin ser explícitamente programadass"

Evolución del Software



Github Atlas (Software 1.0)



HuggingFace Model Atlas (Software 2.0)

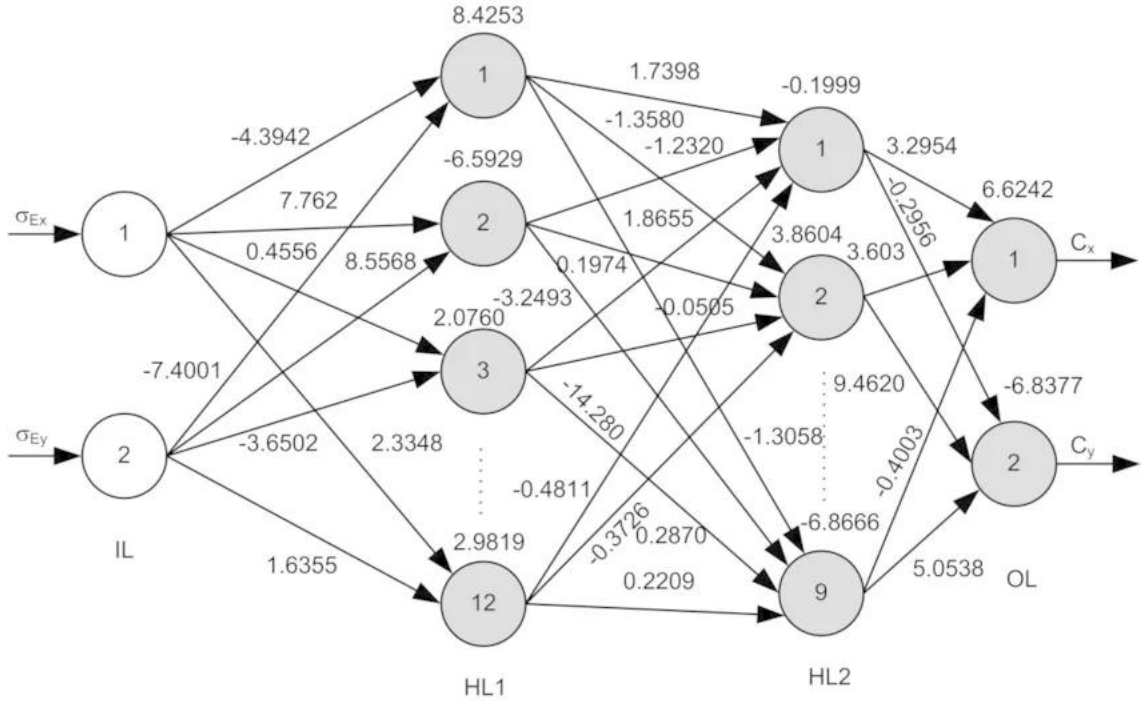
https://anvaka.github.io/map-of-github/#1.92/0.86/7.12

https://huggingface.co/spaces/Eliahu/Model-Atlas

Software 1.0 = code



Software 2.0 = weights



Finalidad de ML

Software 1.0

computer code

programs

computer



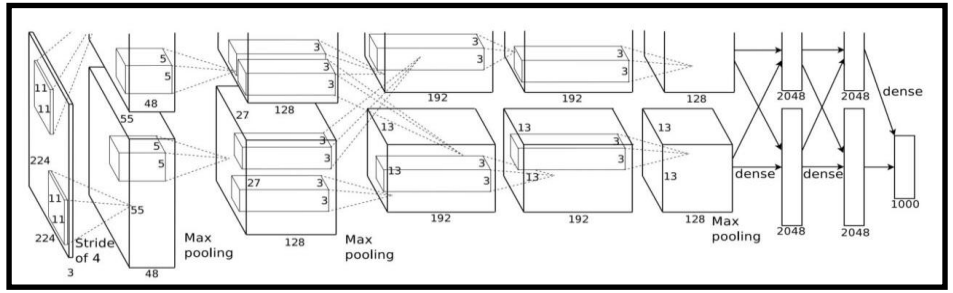
became programmable in **~1940s**

Software 2.0

weights

programs

neural net



fixed function neural net

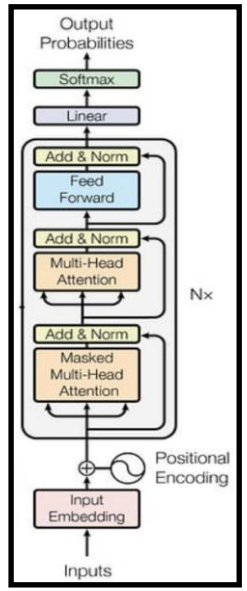
e.g. AlexNet: for image recognition (**~2012**)

Software 3.0

prompts

programs

LLM



LLM = programmable neural net!

~2019

Ejemplo: Clasificación de Sentimientos

Software 1.0

```python
def simple_sentiment(review: str) -> str:
    """Return 'positive' or 'negative' based on a tiny keyword lexicon."""
    positive = {
        "good", "great", "excellent", "amazing", "wonderful", "fantastic",
        "awesome", "loved", "love", "like", "enjoyed", "superb", "delightful"
    }
    negative = {
        "bad", "terrible", "awful", "poor", "boring", "hate", "hated",
        "dislike", "worst", "dull", "disappointing", "mediocre"
    }

    score = 0
    for word in review.lower().split():
        w = word.strip(".,!?;:")          # crude token clean-up
        if w in positive:
            score += 1
        elif w in negative:
            score -= 1

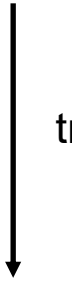
    return "positive" if score >= 0 else "negative"
```

Software 2.0

10,000 positive examples

10,000 negative examples

encoding (e.g. bag of words)



train binary classifier

parameters

Software 3.0

You are a sentiment classifier. For every review that appears between the tags
<REVIEW> … </REVIEW>, respond with **exactly one word**, either POSITIVE or NEGATIVE (all-caps, no punctuation, no extra text).

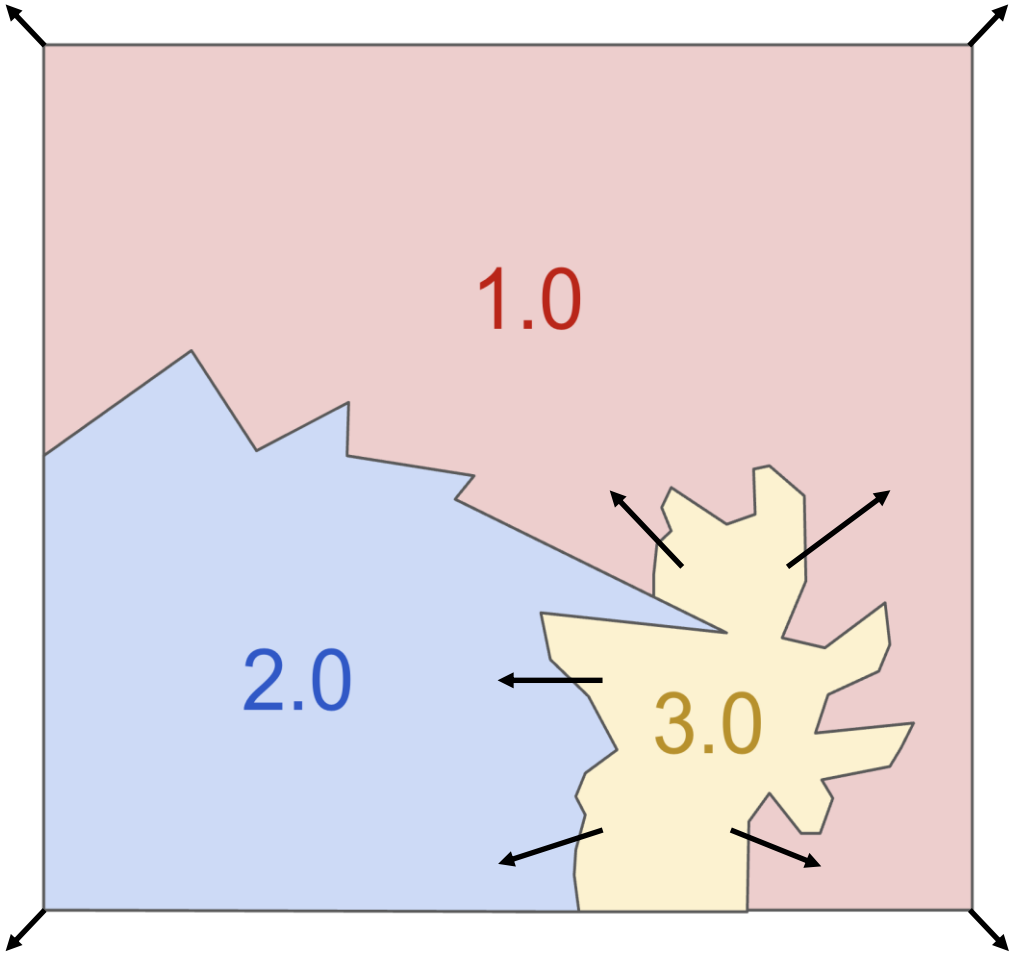
Example 1
<REVIEW>I absolutely loved this film—the characters were engaging and the ending was perfect.</REVIEW>
POSITIVE

Example 2
<REVIEW>The plot was incoherent and the acting felt forced; I regret watching it.</REVIEW>
NEGATIVE

Example 3
<REVIEW>An energetic soundtrack and solid visuals almost save it, but the story drags and the jokes fall flat.</REVIEW>
NEGATIVE

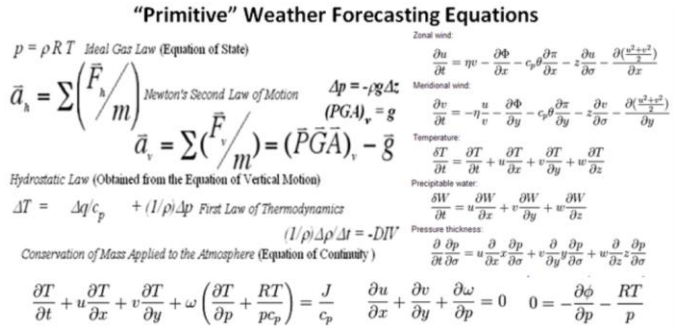
Now classify the next review.

Una gran cantidad de software será desarrollado



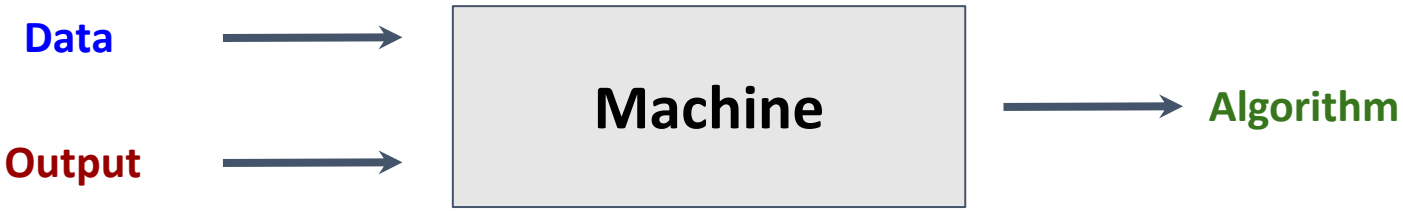
Traditional Programming



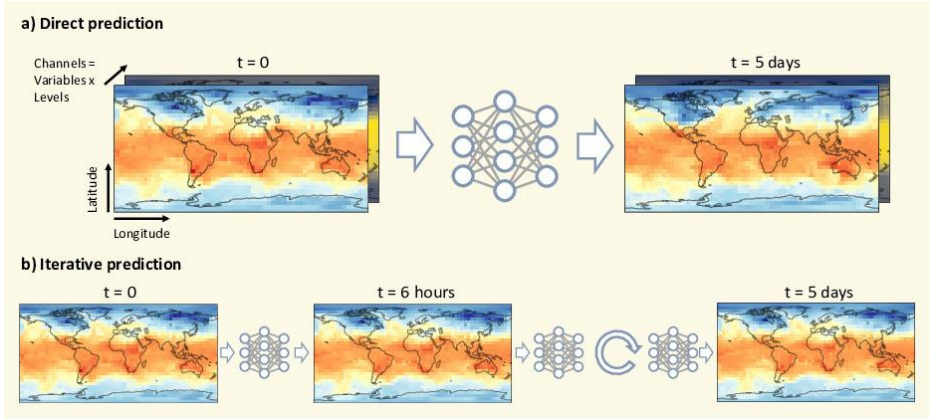


https://www.iweathernet.com/educational/history-weather-forecasting

Machine Learning

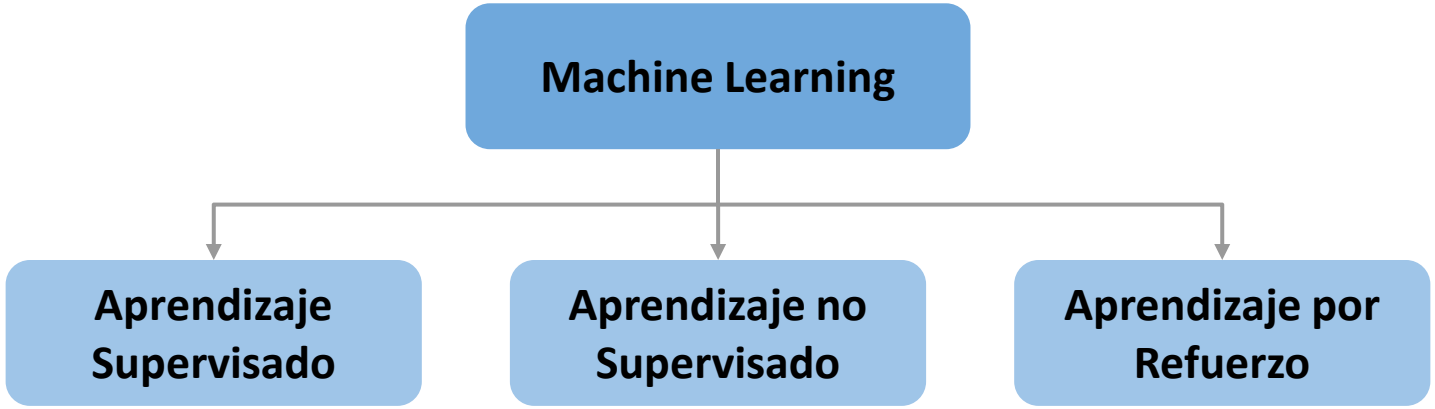


Los algoritmos de machine learning usan métodos computacionales para aprender directamente de la data, sin estar explícitamente programados.



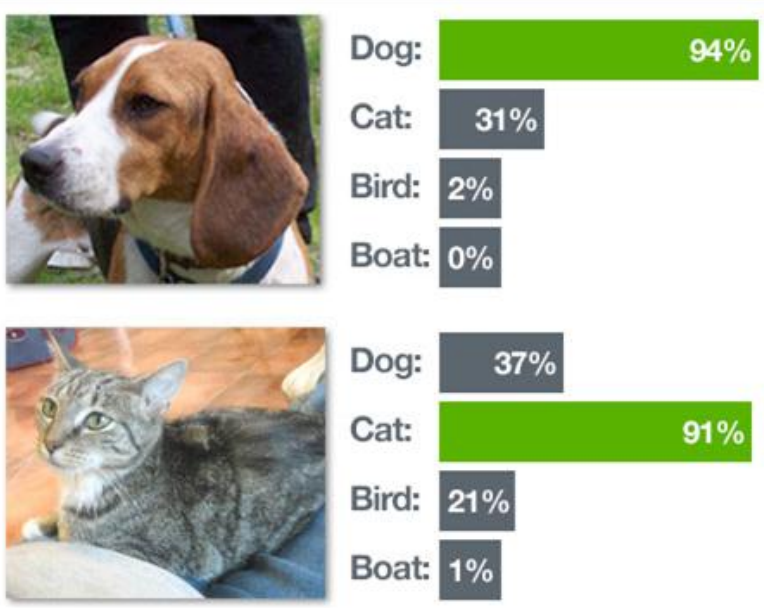
https://raspstephan.github.io/blog/weatherbench/#

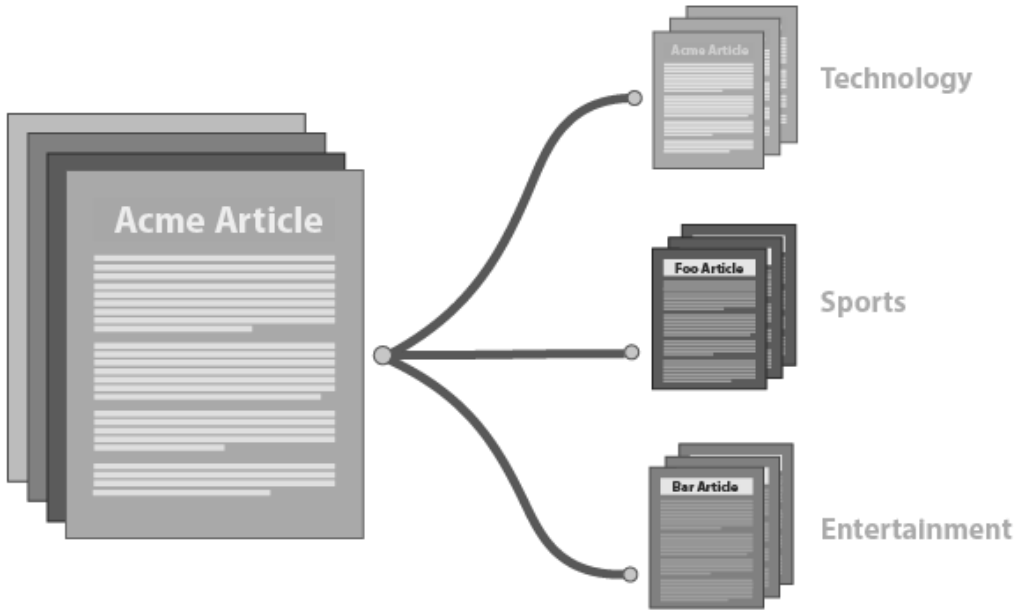
Aplicaciones de Machine Learning



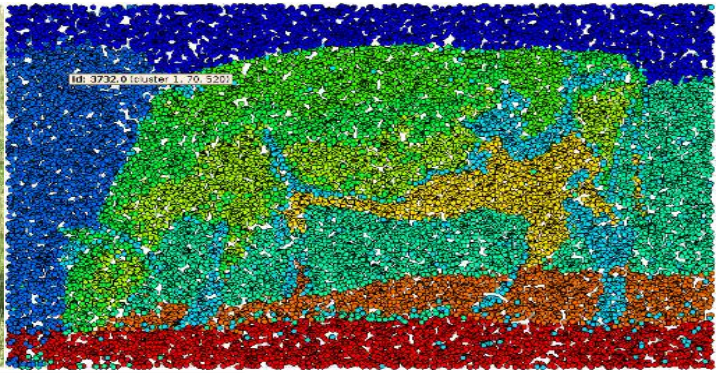
Aprendizaje Supervisado







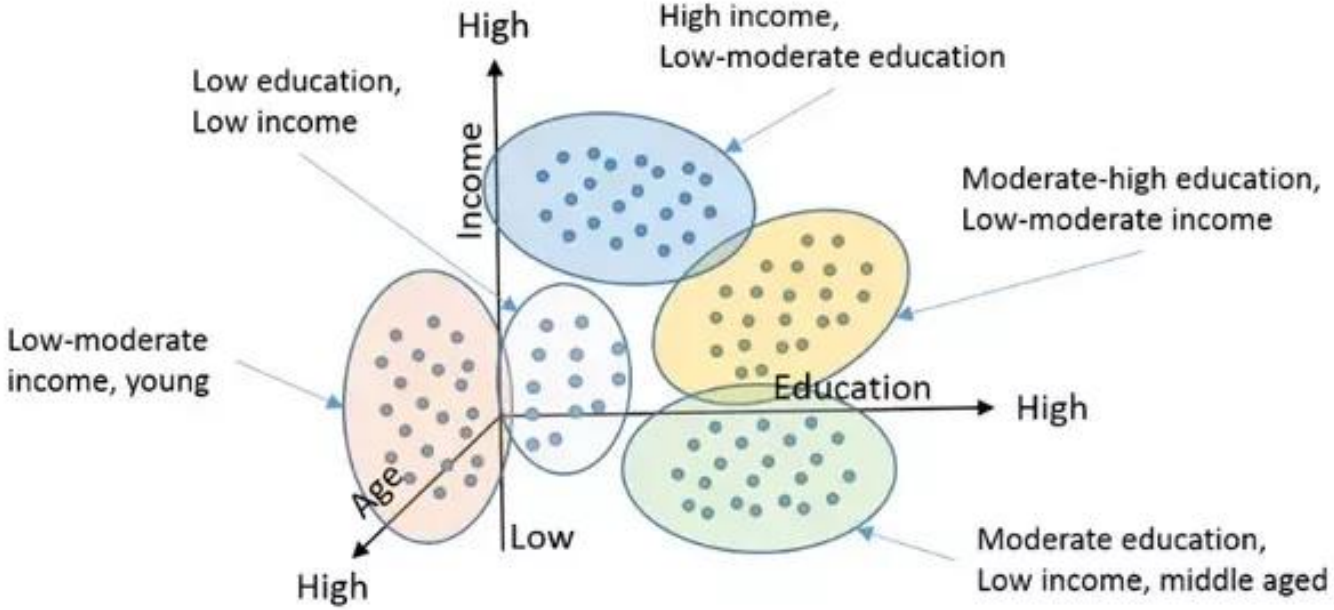


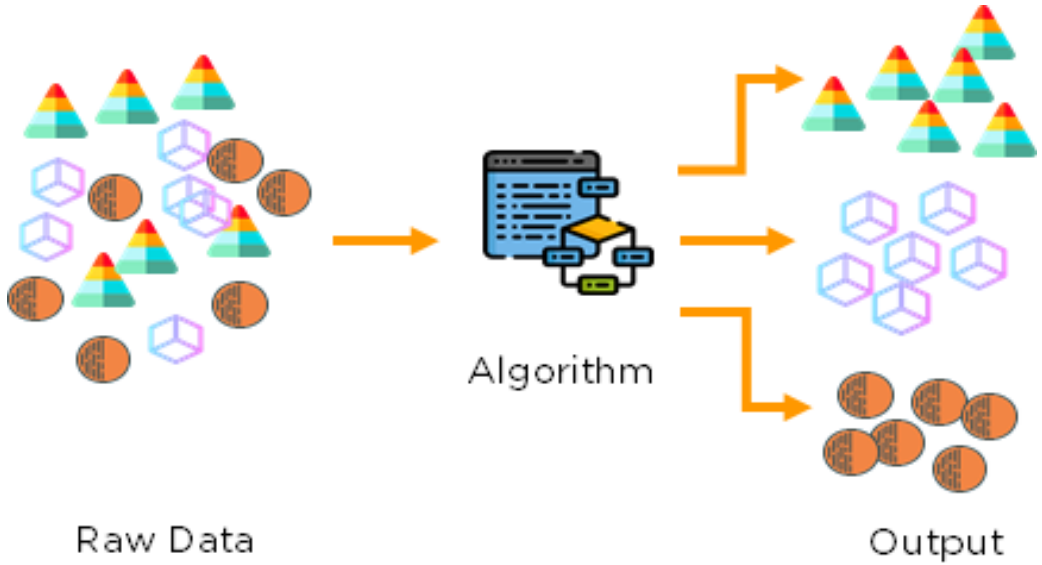


Aprendizaje Supervisado

Aprendizaje no Supervisado

Aprendizaje por Refuerzo



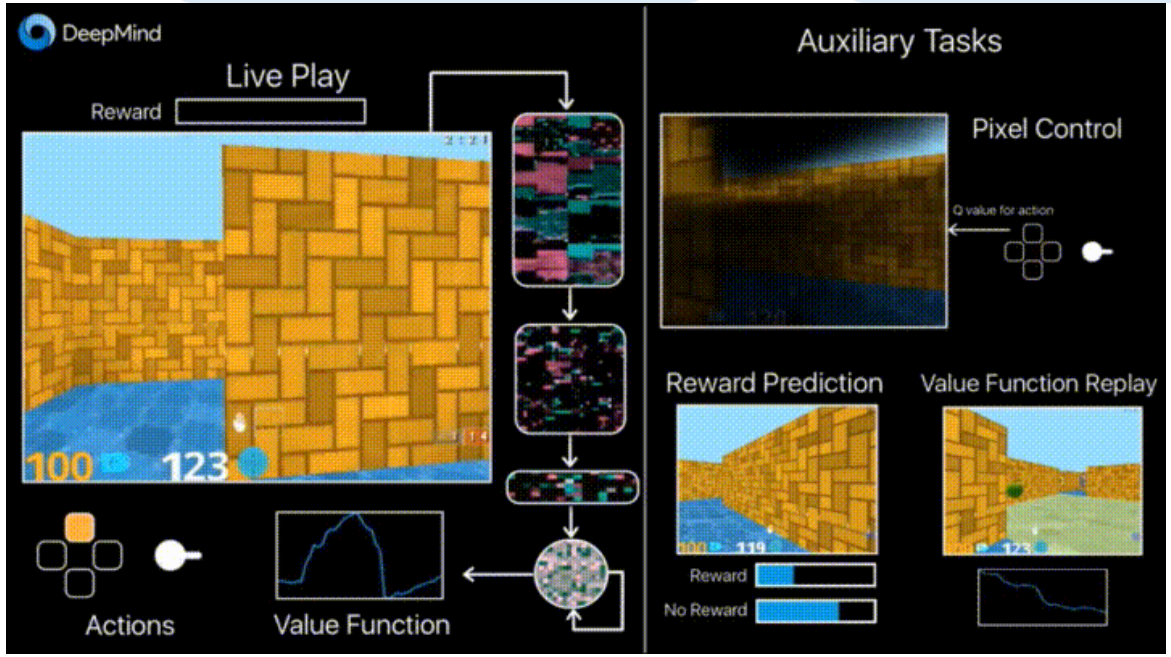


Machine Learning

Aprendizaje Supervisado

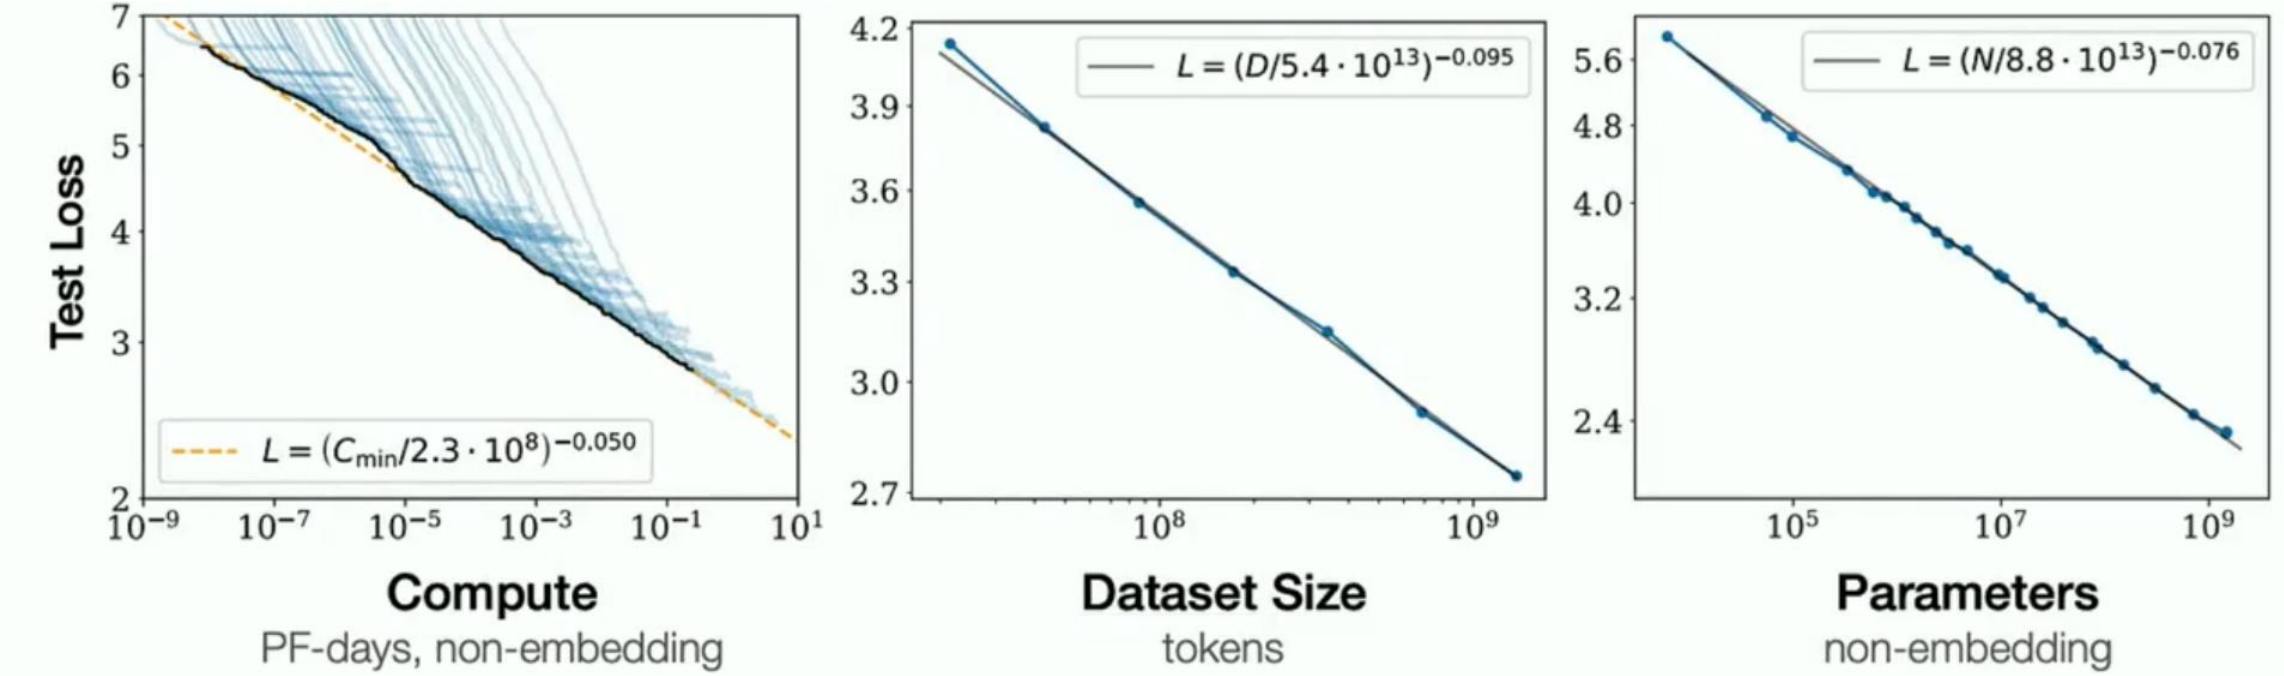
Aprendizaje no Supervisado

Aprendizaje por Refuerzo



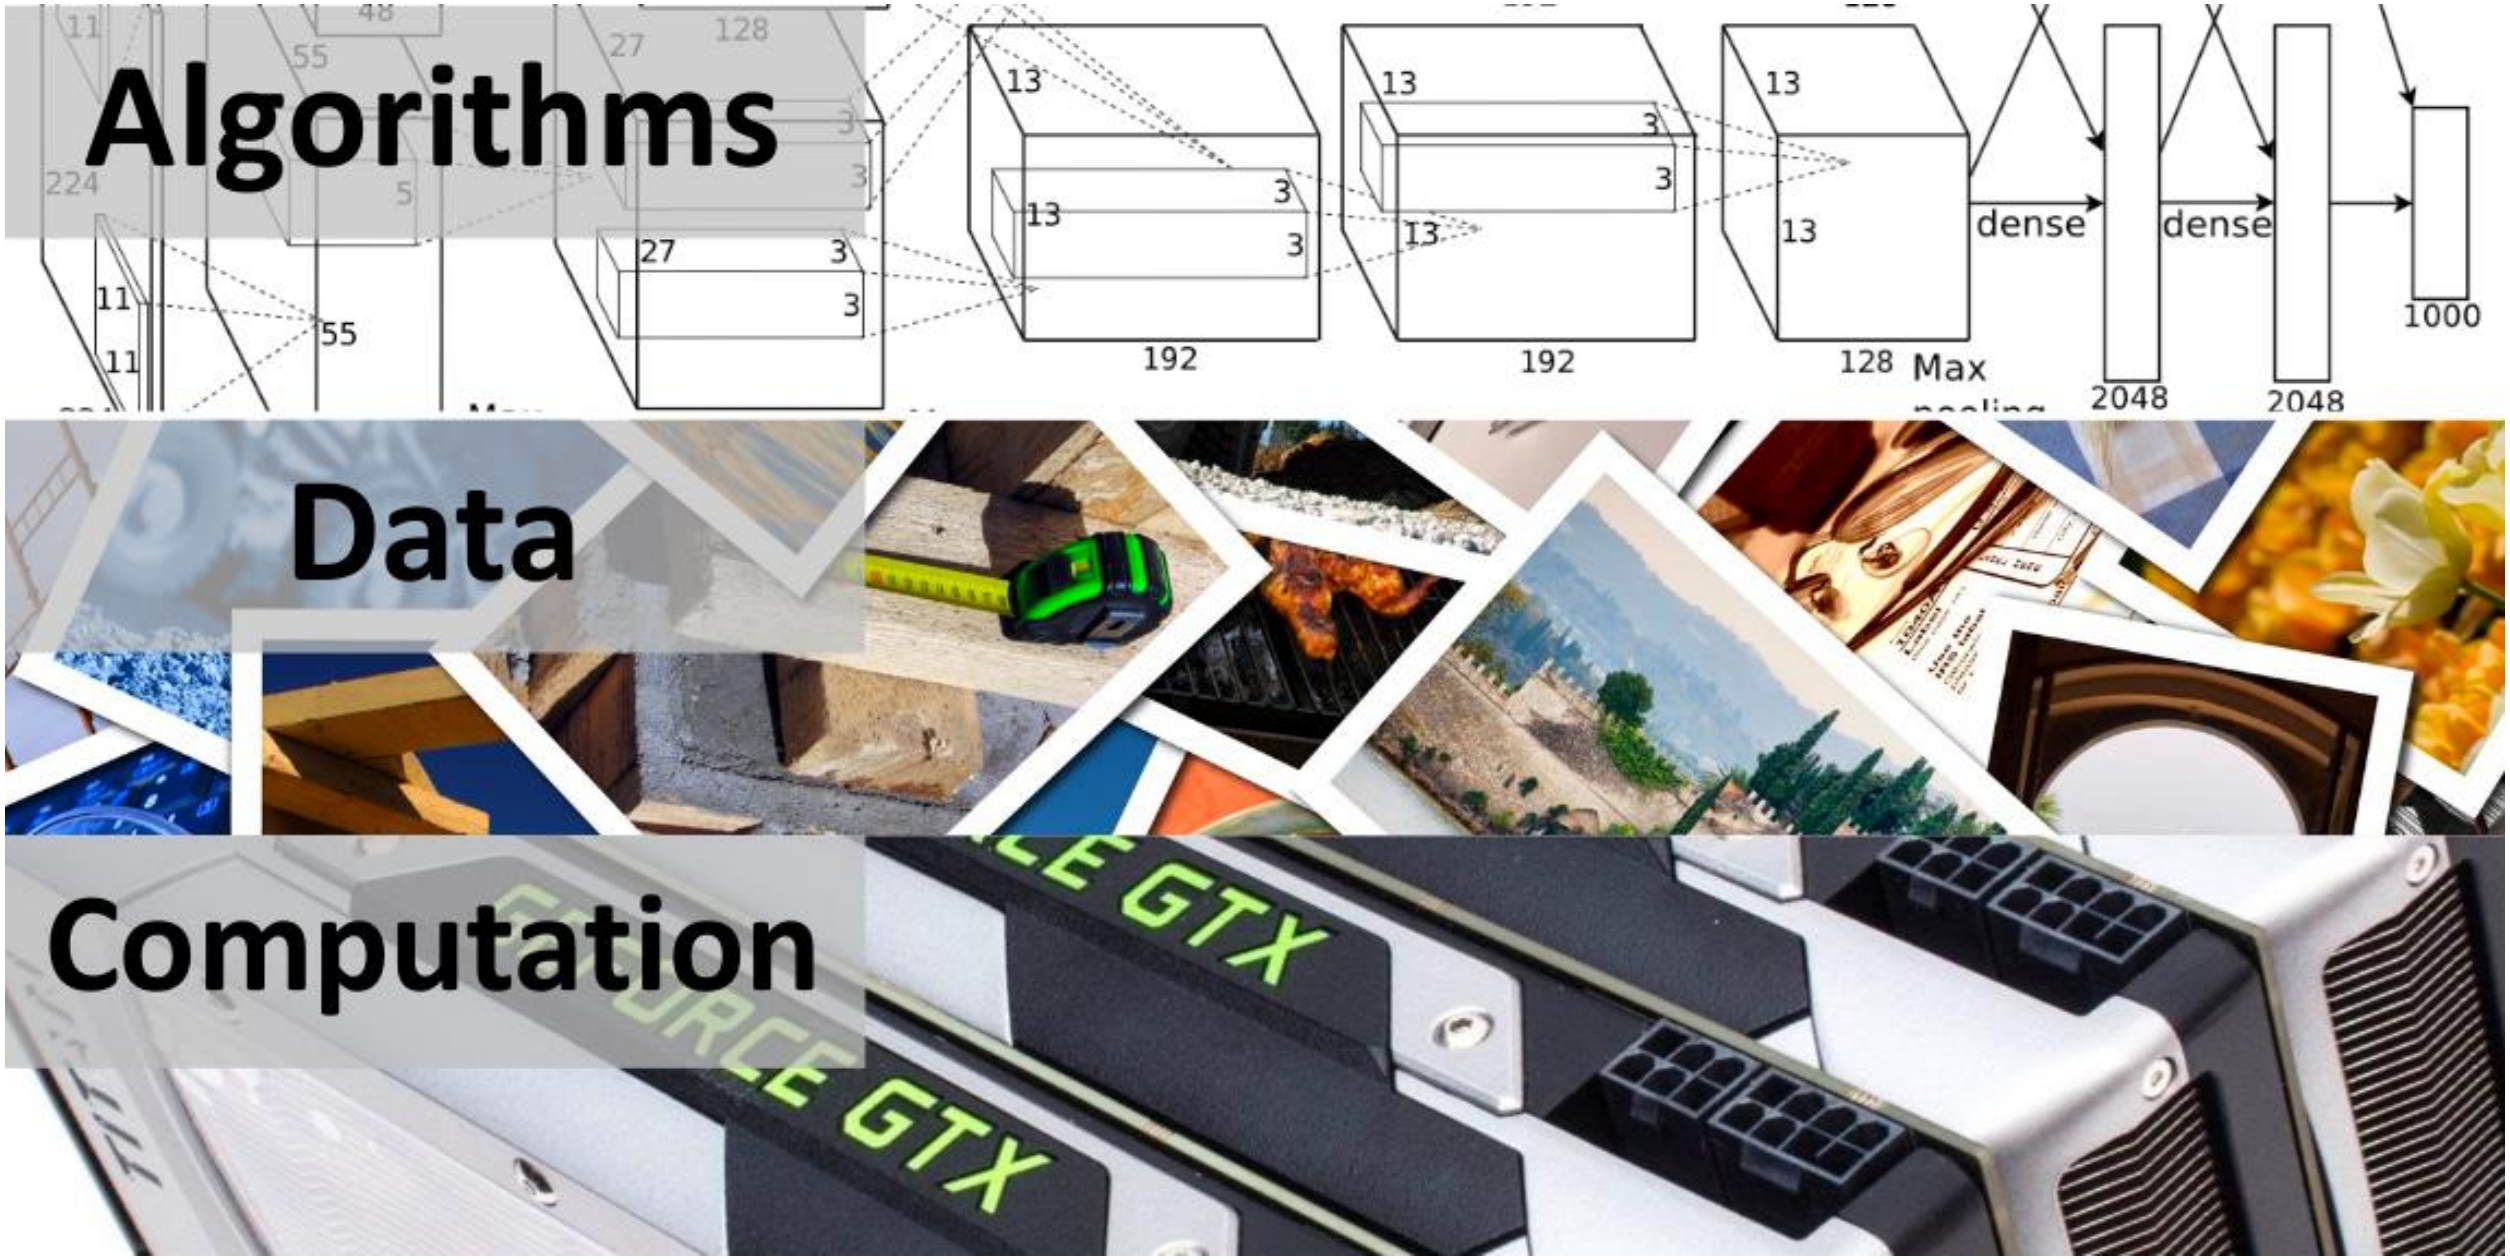


¿Qué cambió recientemente?



Ley de escalamiento: más cómputo + más datos + más parámetros = ¡mejores resultados!

(Base del Aprendizaje Profundo)


Algorithms
Data
Computation
224
11
55
11
11
48
55
27
128
5
3
3
27
3
3
13
13
3
3
192
13
13
3
3
192
13
13
128
Max
dense
2048
dense
2048
1000

Tendencias en dispositivos (2026)



25 000 USD
NVIDIA H100 (68 TOPS)
(2022)

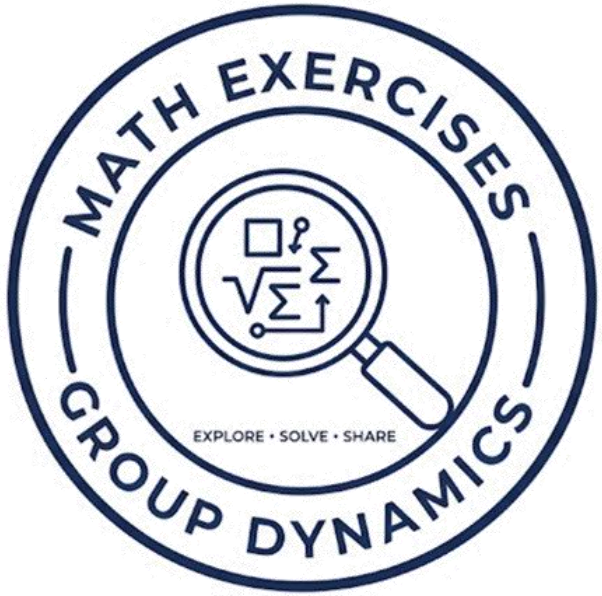


250 USD
jetson nano super (67 TOPS)
(2026)

(10 min) Break



Dinámica Grupal: Encuentra la regla...



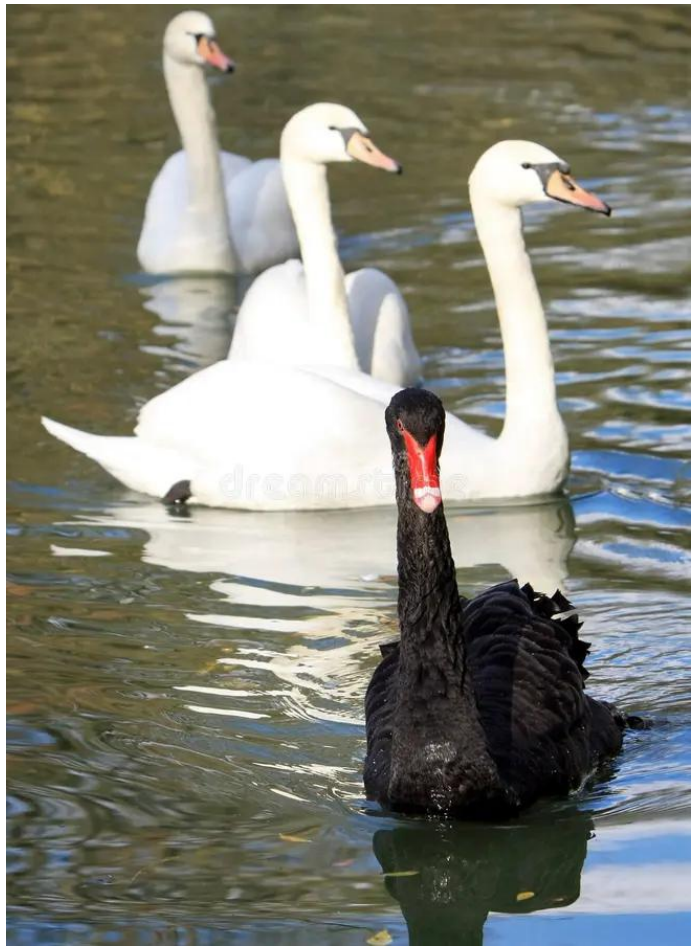
Voy a darles tres números. Una secuencia de tres números que obedecen a una regla que tengo en mente y quiero que intenten descubrir cuál es esa regla.

1. Primero proponen su propio conjunto de tres números
2. Les diré si siguen mi regla o no
3. Luego pueden adivinar cuál es la regla

Secuencia inicial: 2, 4, 8

El problema de la inducción

- "Cisne Negro" es un evento improbable, de alto impacto y solo predecible retrospectivamente
- Por muchos cisnes blancos que observemos, nunca podemos probar que "todos los cisnes son blancos“
- Basta un solo cisne negro para refutar la teoría



El modelo científico

- Las teorías científicas nunca pueden ser probadas como definitivamente correctas
- Solo pueden ser falsadas (criterio de Popper)
- La ciencia avanza no por verificación absoluta, sino por eliminación de teorías falsas
- La ciencia es la creencia en la evidencia



¿Es una teoría científica “verdad”?
¿Dónde están esos límites?

¿Cómo podemos afirmar algo?

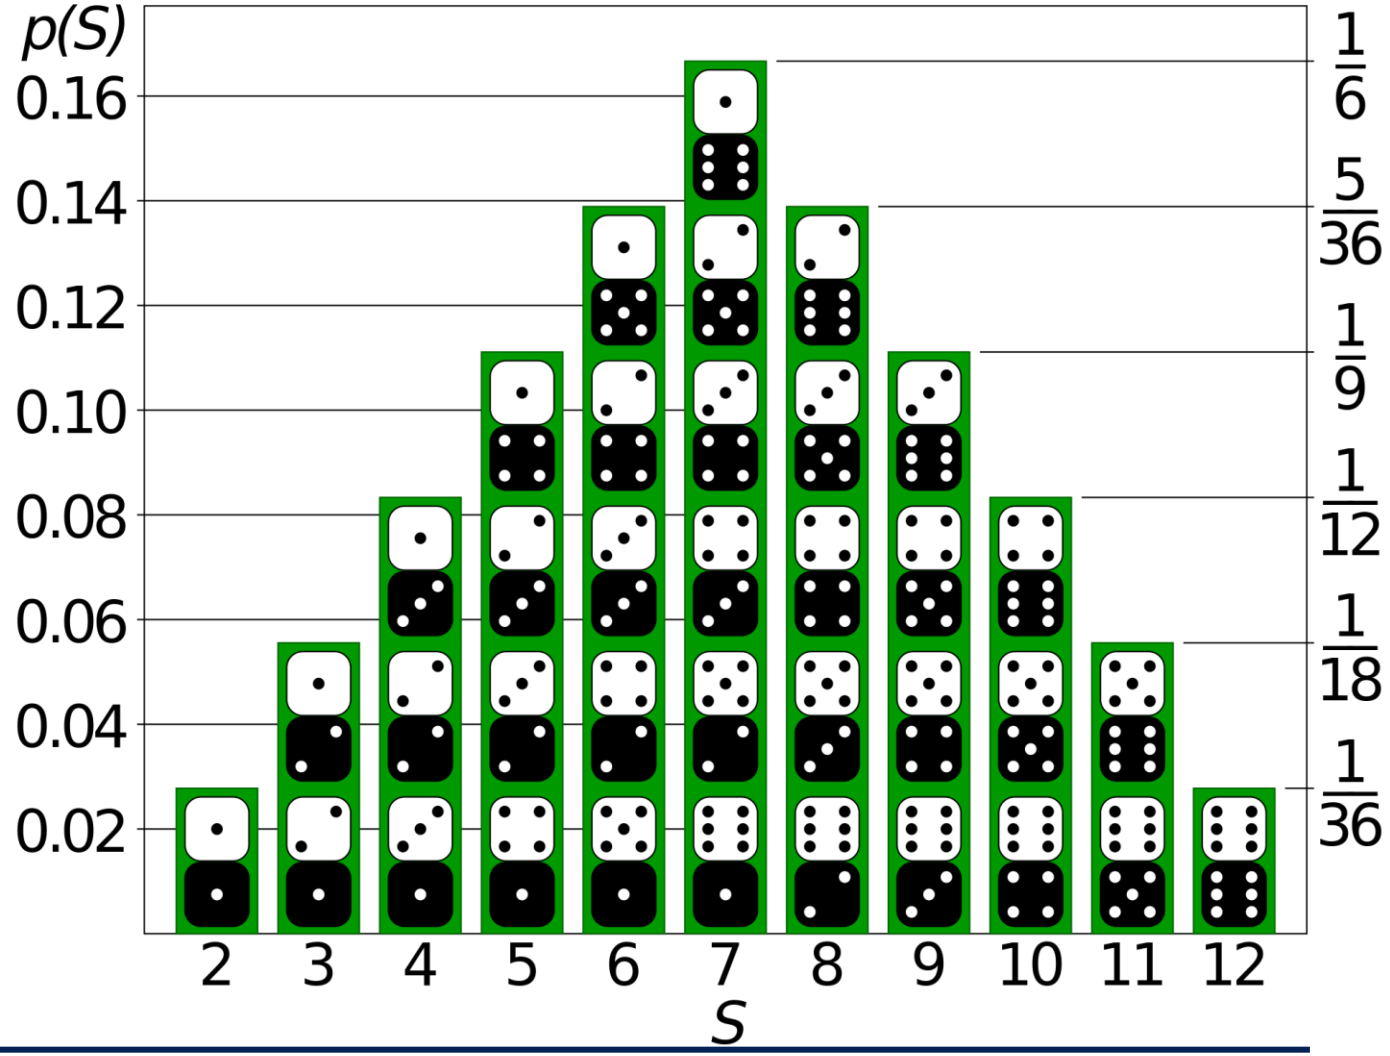


https://www.youtube.com/watch?v=JAS2MjcDrco

¿Qué es probabilidad?

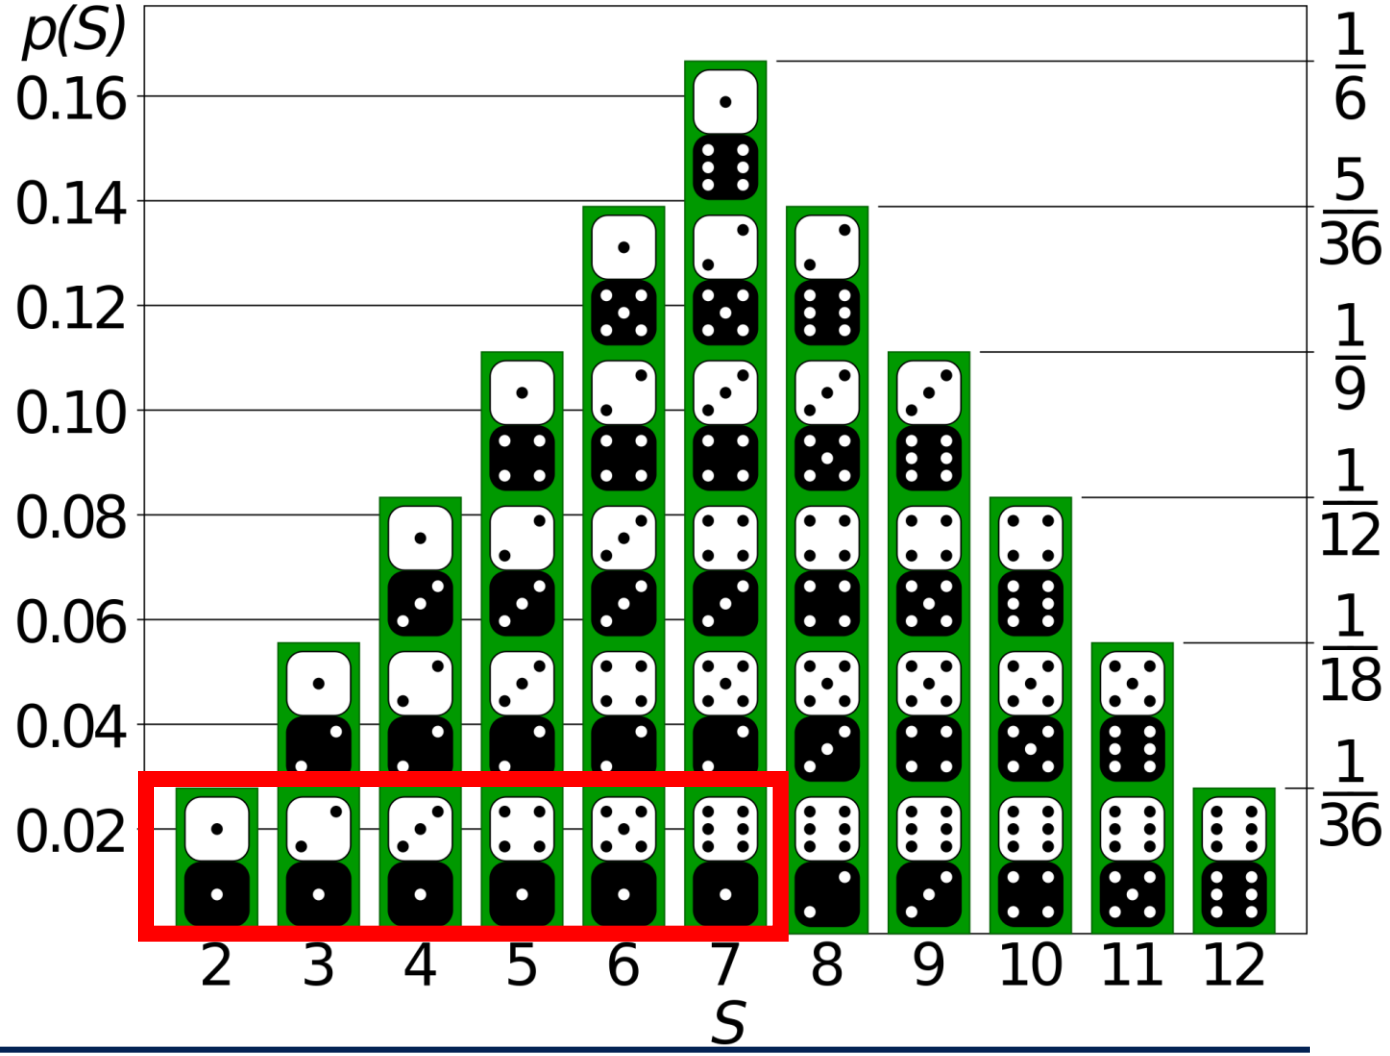
Definición formal de probabilidad

- La probabilidad de un **evento aleatorio** calcula como:
  - $P(A) = \frac{resultados\ deseados}{resultados\ totales}$
- **Eventos Independientes**: la ocurrencia de uno no afecta al otro.
  - $P(A \text{ y } B) = P(A) \times P(B)$
- **Eventos Mutuamente Excluyentes**: no pueden ocurrir al mismo tiempo.
  - $P(A \text{ y } B) = 0$
- **Probabilidad Condicional**: probabilidad de A dado que B ya ocurrió.
  - $P(A|B) = P(A \text{ y } B) / P(B)$



Ejemplo de probabilidad condicional

- La probabilidad de un **evento aleatorio** calcula como:
  - P(A) = $\frac{resultados\ deseados}{resultados\ totales}$
- **Eventos Independientes**: la ocurrencia de uno no afecta al otro.
  - P(A y B) = P(A) × P(B)
- **Eventos Mutuamente Excluyentes**: no pueden ocurrir al mismo tiempo.
  - P(A y B) = 0
- **Probabilidad Condicional:** probabilidad de A dado que B ya ocurrió.
  - P(A|B) = P(A y B) / P(B)

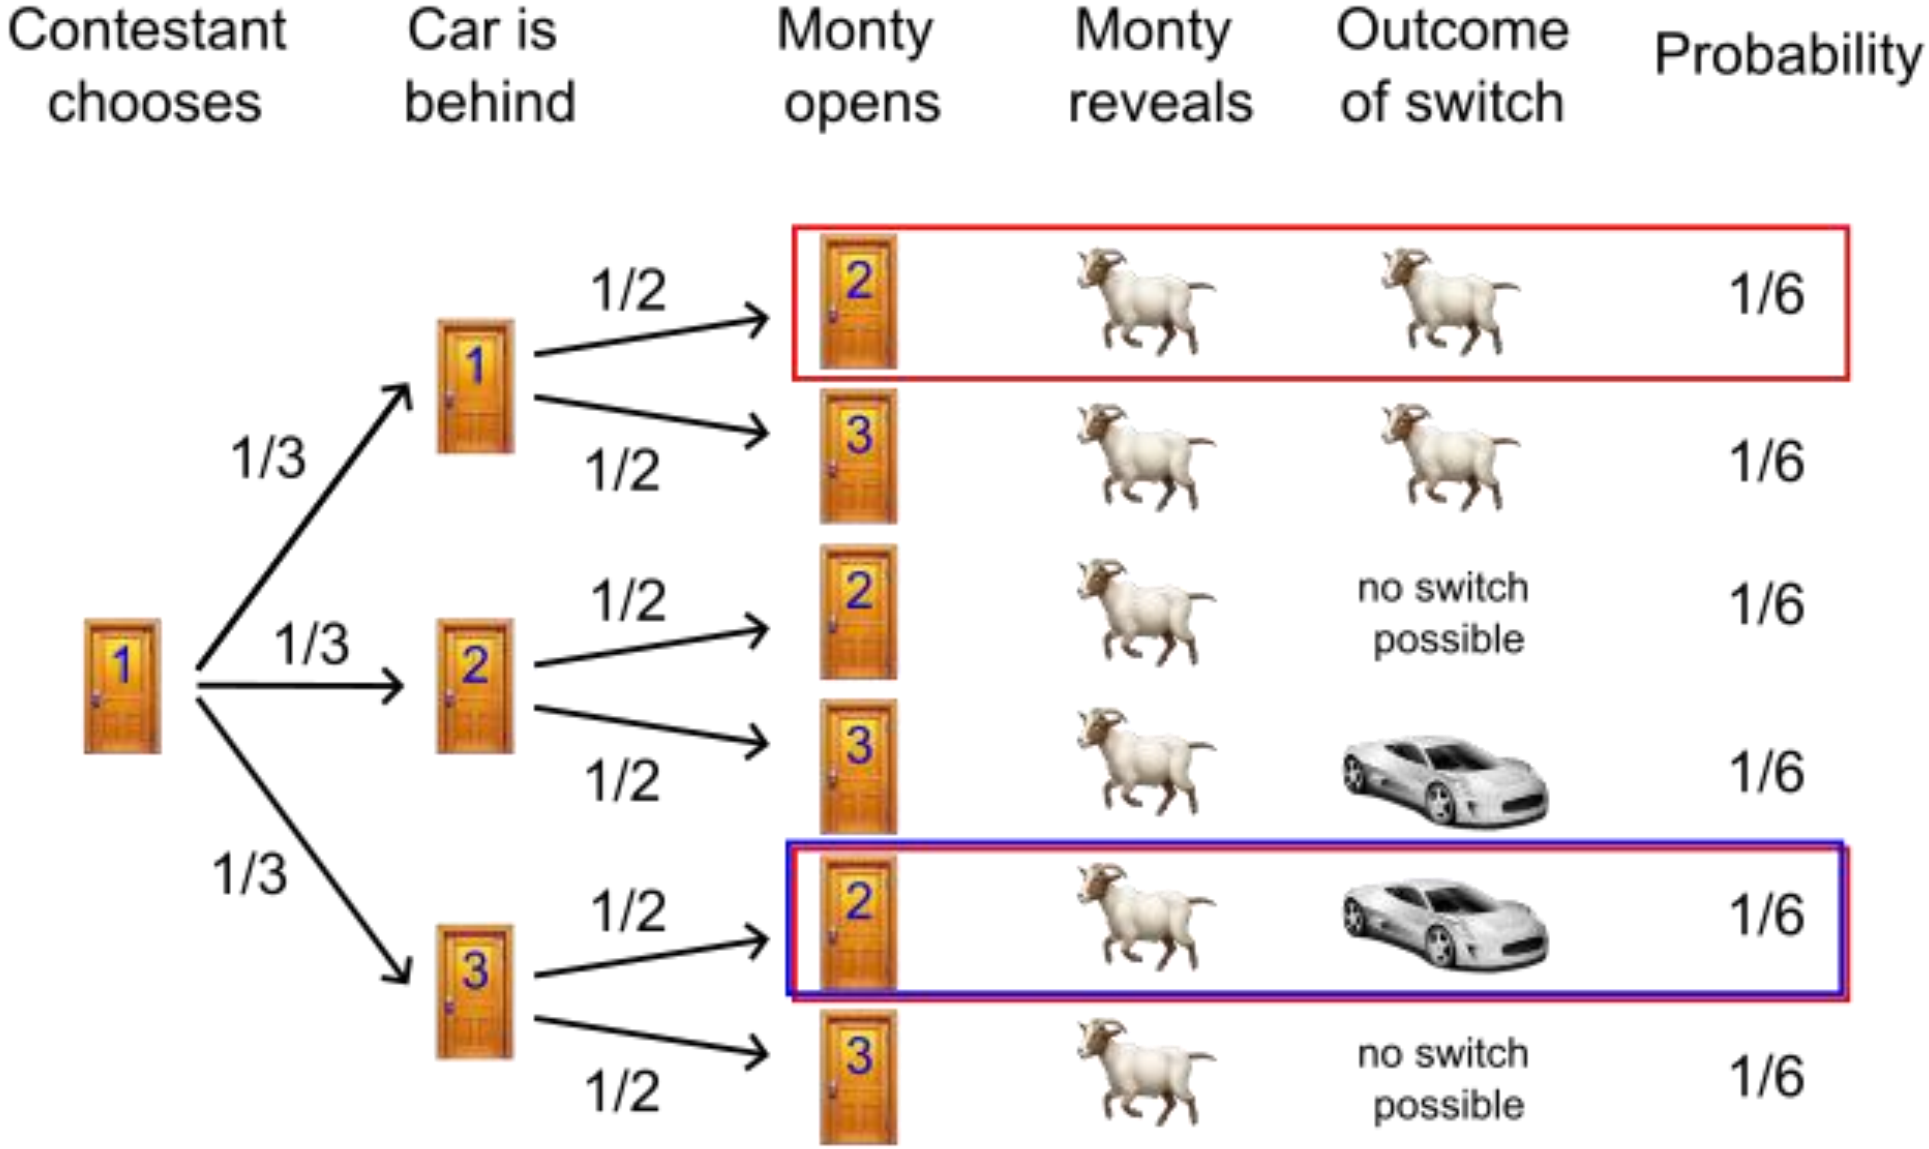


Ejercicio 1: El problema de Monty Hall

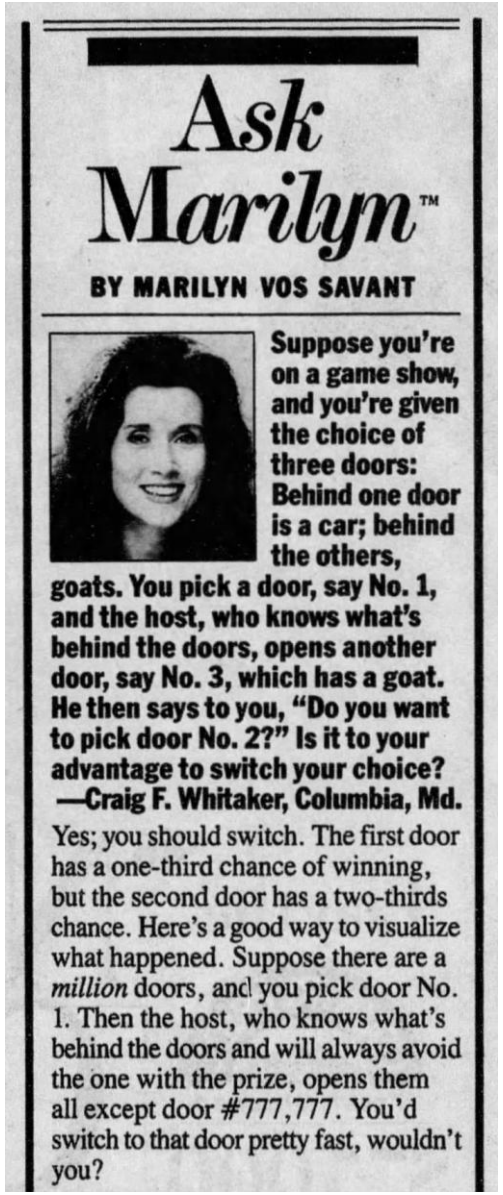
EVENTOS DEPENDIENTES

"Supongamos que estás en un concurso de televisión y te dan a elegir entre tres puertas: Detrás de una puerta hay un coche; detrás de las otras, cabras. Eliges una puerta, digamos la N.º 1, y el presentador, que sabe lo que hay detrás de las puertas, abre otra puerta, digamos la N.º 3, que tiene una cabra. Entonces te dice: "¿Quieres elegir la puerta N.º 2?". ¿Te conviene cambiar tu elección?"




Contestant chooses
Car is behind
Monty opens
Monty reveals
Outcome of switch
Probability
1
1/3
1/3
1/3
1
2
3
1/2
1/2
1/2
1/2
1/2
1/2
2
3
2
3
2
3
1/6
1/6
no switch possible
1/6
1/6
1/6
no switch possible
1/6

Una historia de discriminación



Ask Marilyn™

BY MARILYN VOS SAVANT

Suppose you're on a game show, and you're given the choice of three doors: Behind one door is a car; behind the others, goats. You pick a door, say No. 1, and the host, who knows what's behind the doors, opens another door, say No. 3, which has a goat. He then says to you, "Do you want to pick door No. 2?" Is it to your advantage to switch your choice?
—Craig F. Whitaker, Columbia, Md.

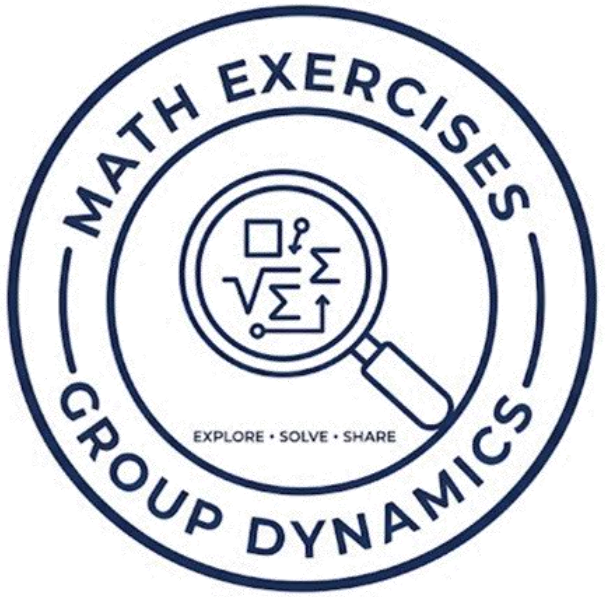
Yes; you should switch. The first door has a one-third chance of winning, but the second door has a two-thirds chance. Here's a good way to visualize what happened. Suppose there are a *million* doors, and you pick door No. 1. Then the host, who knows what's behind the doors and will always avoid the one with the prize, opens them all except door #777,777. You'd switch to that door pretty fast, wouldn't you?



The Time Everyone "Corrected" the World's Smartest Woman

Ejercicio 2: ¿Es Steve un granjero o un bibliotecario?

SESGO COGNITIVO

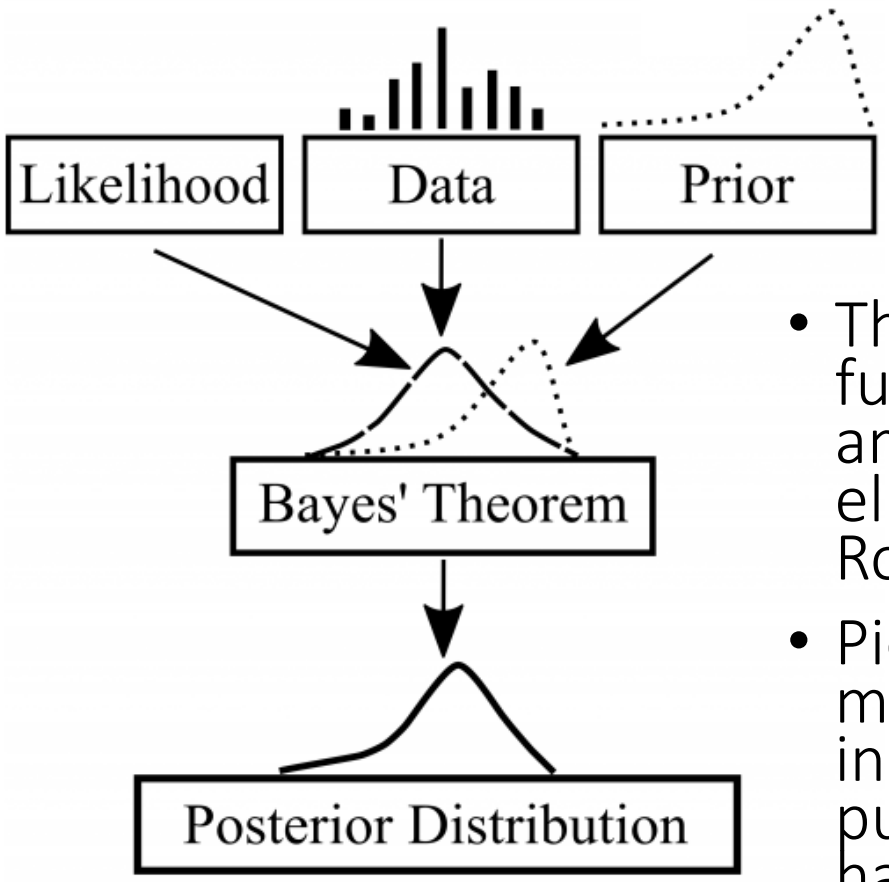


"Steve es muy tímido y retraído, invariablemente servicial, pero con muy poco interés en las personas o en el mundo de la realidad. Un alma mansa y ordenada, tiene necesidad de orden y estructura, y pasión por el detalle."

$$(N_G : N_B = 20 : 1) \quad P(E|B) = 0.40 \quad P(E|G) = 0.10$$


10
200

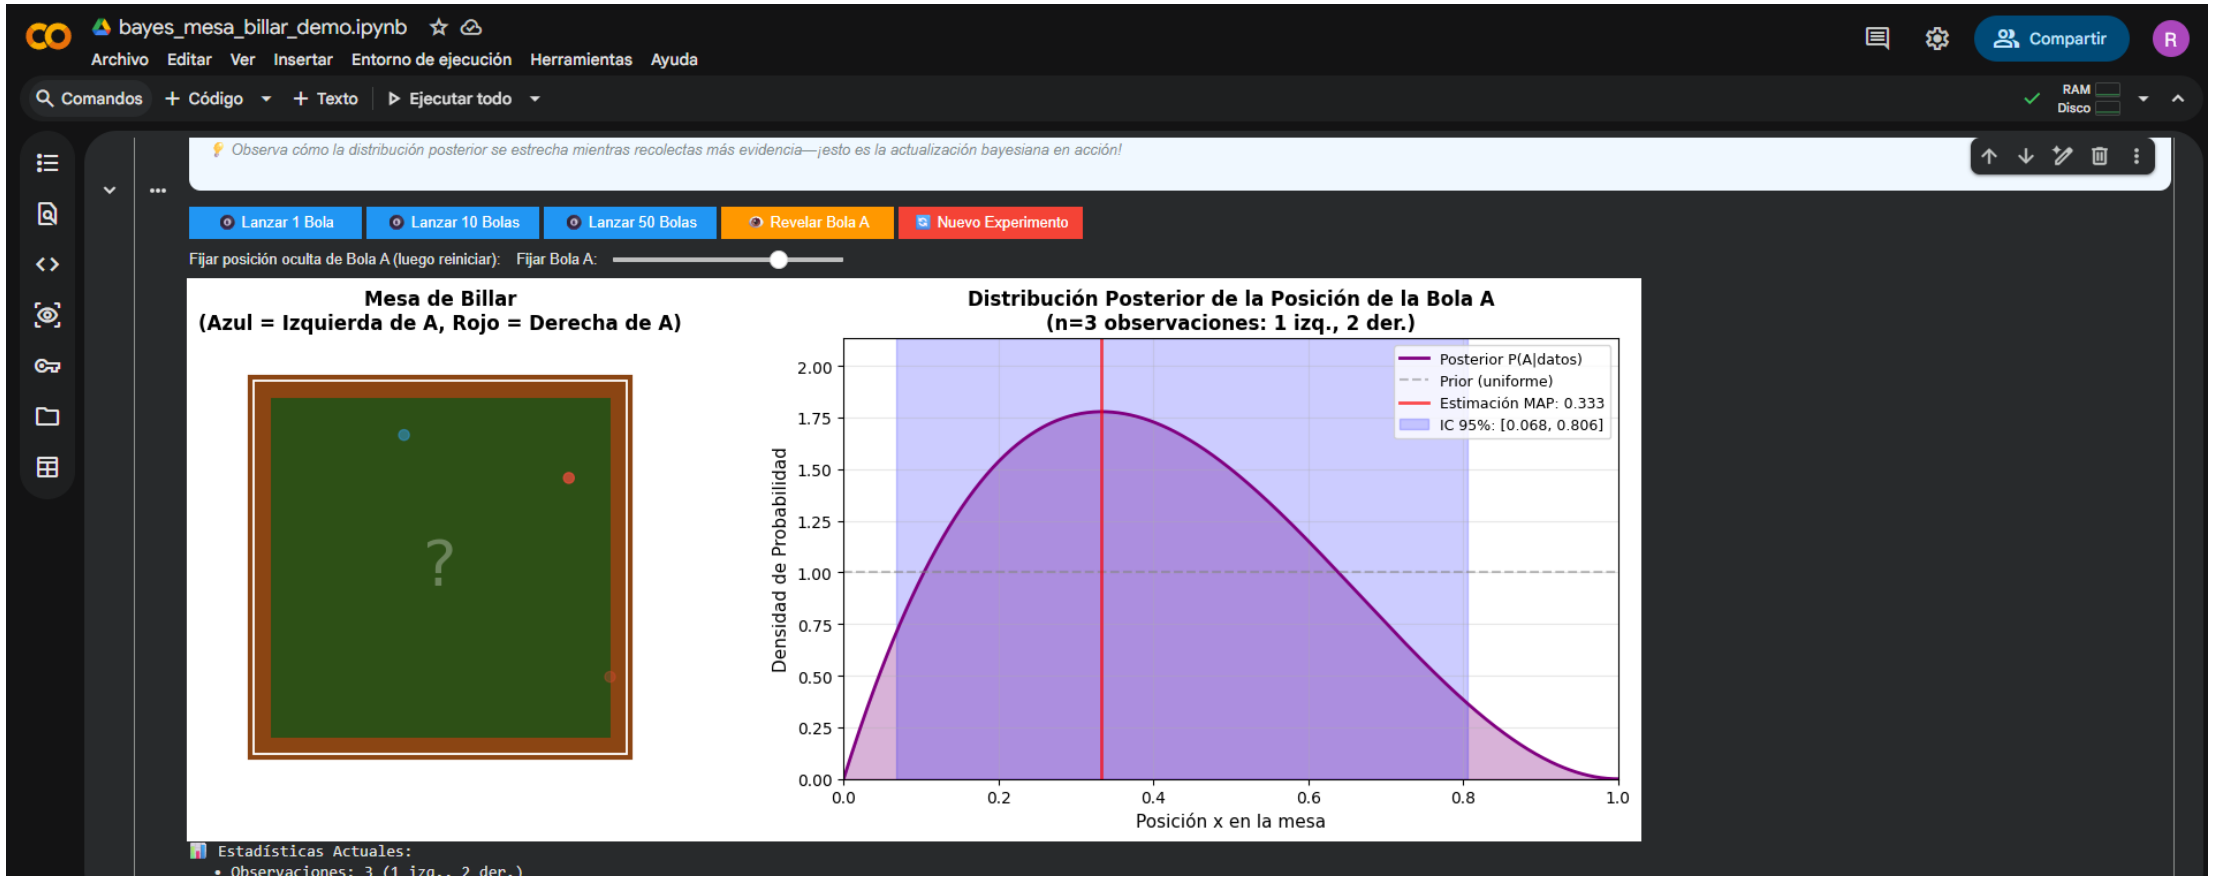
Teorema de Bayes



$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}$$

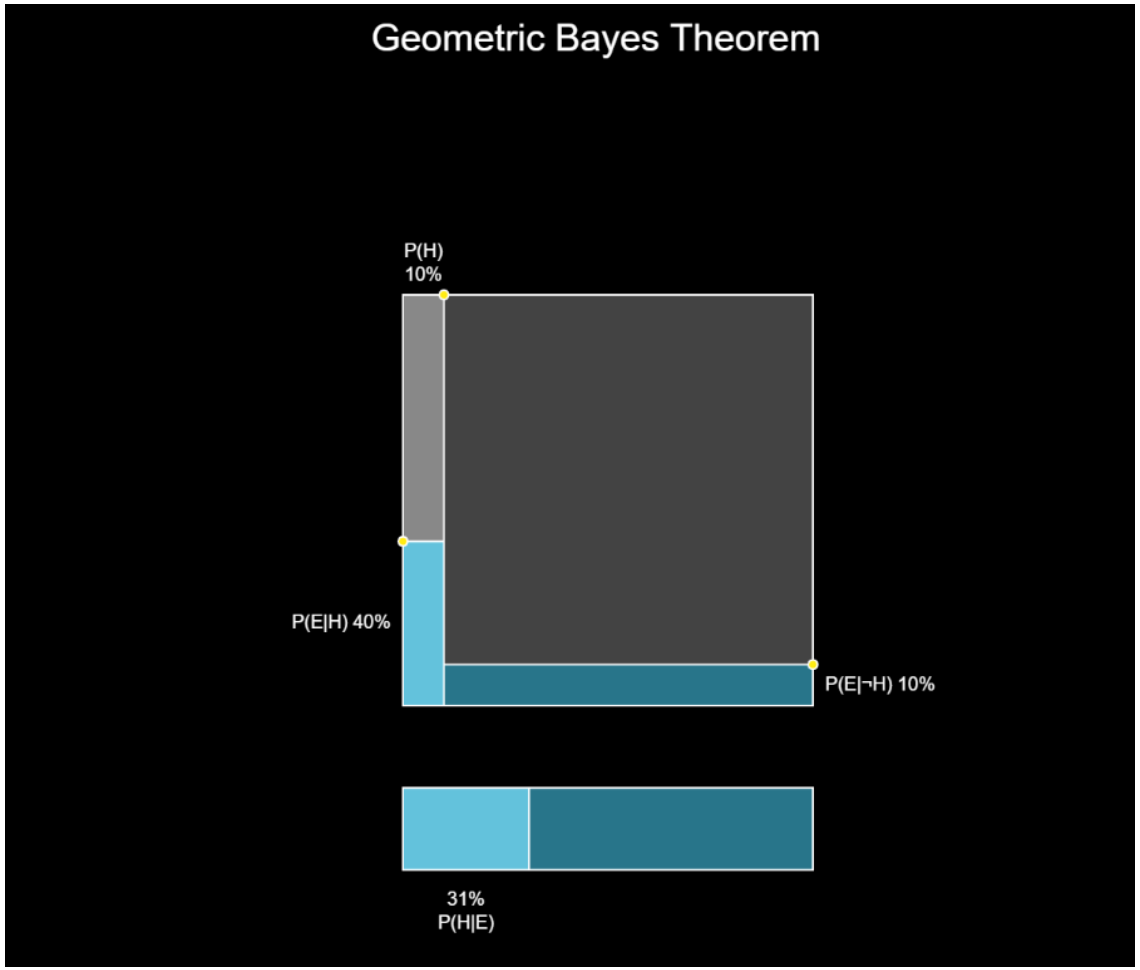
- Thomas Bayes nunca publicó su teorema, sus notas fueron editadas y publicadas póstumamente por su amigo Richard Price, quien trabajó dos años editando el manuscrito, añadió ejemplos y lo presentó ante la Royal Society en 1763.
- Pierre-Simon Laplace hizo el verdadero trabajo — el matemático francés redescubrió independientemente el mecanismo de Bayes y lo publicó en 1774, desarrollándolo durante 40 años hasta convertirlo en una herramienta matemática completa.

¿Qué problema resolvió Bayes? (Demo interactivo)



https://colab.research.google.com/drive/14w0SfS0VGa91mdLyEOGqxfIvr8eHmwj1?authuser=4#scrollTo=l5fBVNpoKAwr

Bayes interactivo



https://www.skobelevs.ie/BayesTheorem/

Preguntas Vibe Quest



SPARSE BUT SMART: RESOLVIENDO PROBLEMAS CLAVE DE LA IA EN GEOLOGÍA

Rodrigo Uribe-Ventura, Yoan Barriga-Berrios, Jorge Barriga-Gamarra, Patrice Baby, and Willem Viveen

Presented by Rodrigo Uribe-Ventura



PUCP | GRUPO DE INVESTIGACIÓN EN GEOLOGÍA SEDIMENTARIA

2026-01-13

1956: The beginning of “Artificial Intelligence”

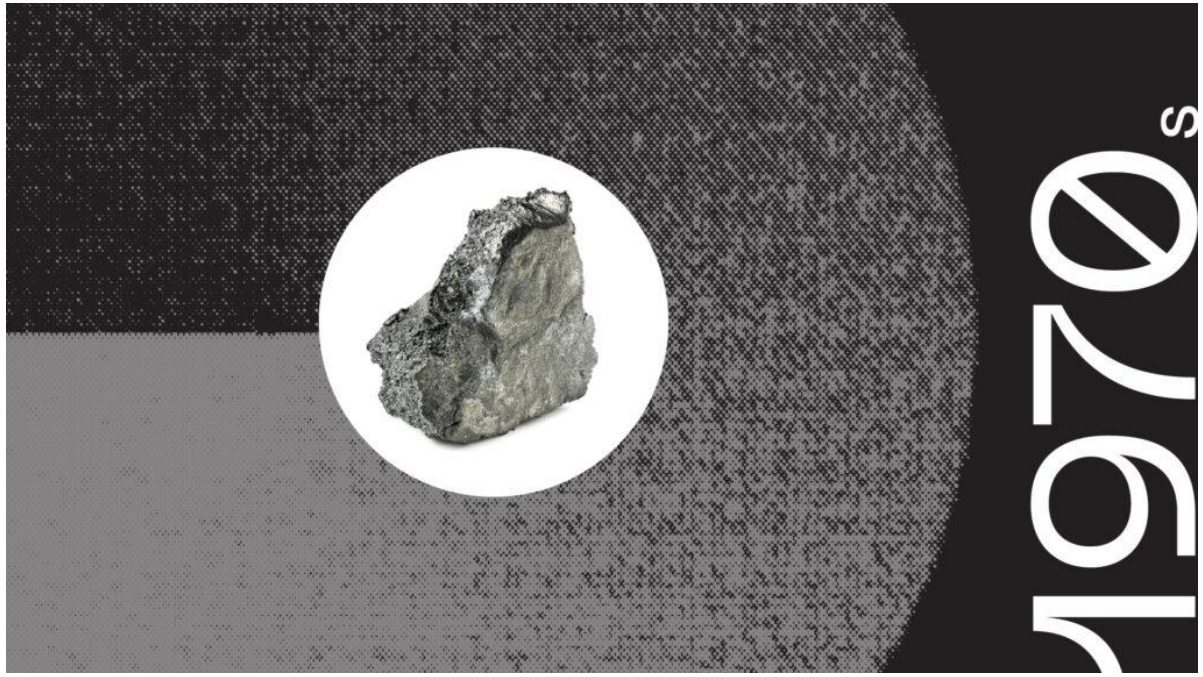
A PROPOSAL FOR THE

DARTMOUTH SUMMER RESEARCH PROJECT

ON ARTIFICIAL INTELLIGENCE

J. McCarthy, Dartmouth College
M. L. Minsky, Harvard University
N. Rochester, I. B. M. Corporation
C. E. Shannon, Bell Telephone Laboratories

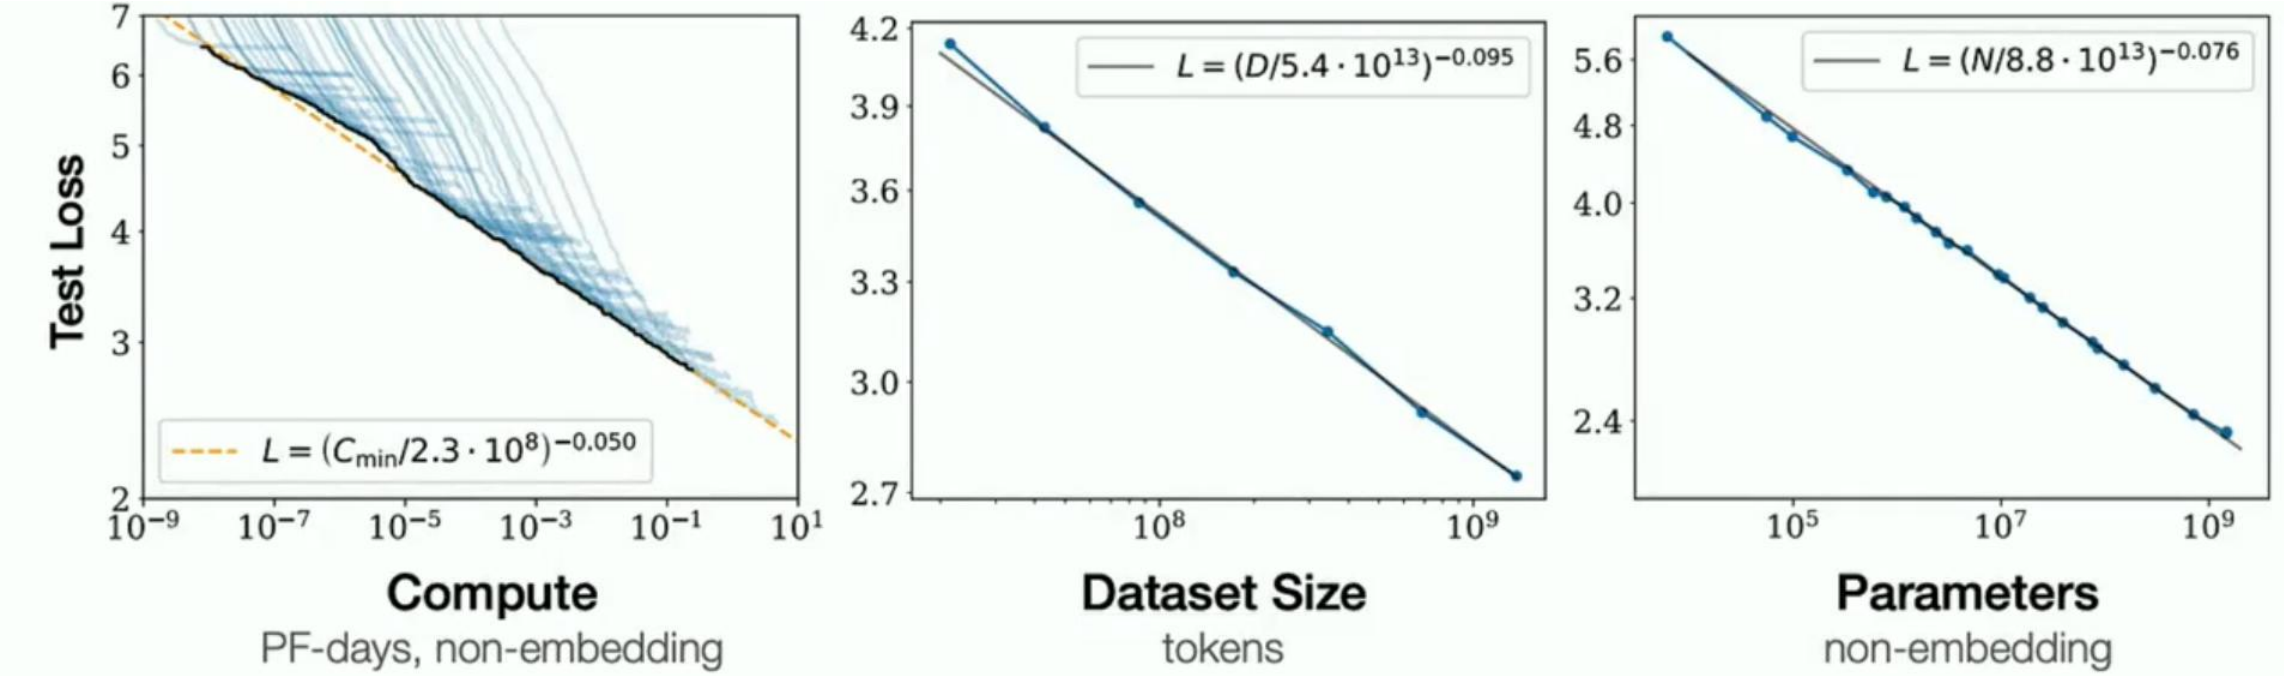
1970s: Artificial Intelligence in Geology



PROSPECTOR computer-based expert system
Developed by SRI for the U.S. Geological Survey in the late early 1970s, to aid in **mineral exploration**.



What changed?



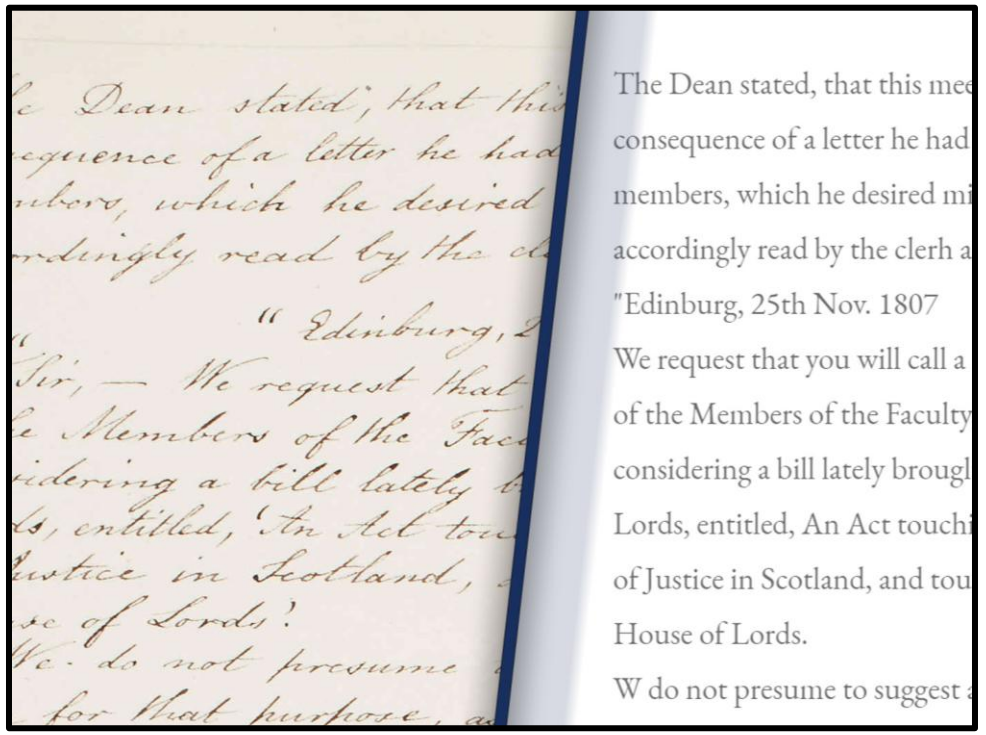
Scaling law: **more** compute + **more** data + **more** parameters = **better results!**

(Basis of Deep Learning)

This makes all the difference



1990s: Basic digit recognition



2025: Perfect historical document transcription

Deep Learning Problems in Geology

Three common challenges that limit deep learning applications in geology:

1. Data Scarcity (Not enough data)

Collecting geological data is expensive and logistically difficult

2. Data Sparsity (Data is not dense)

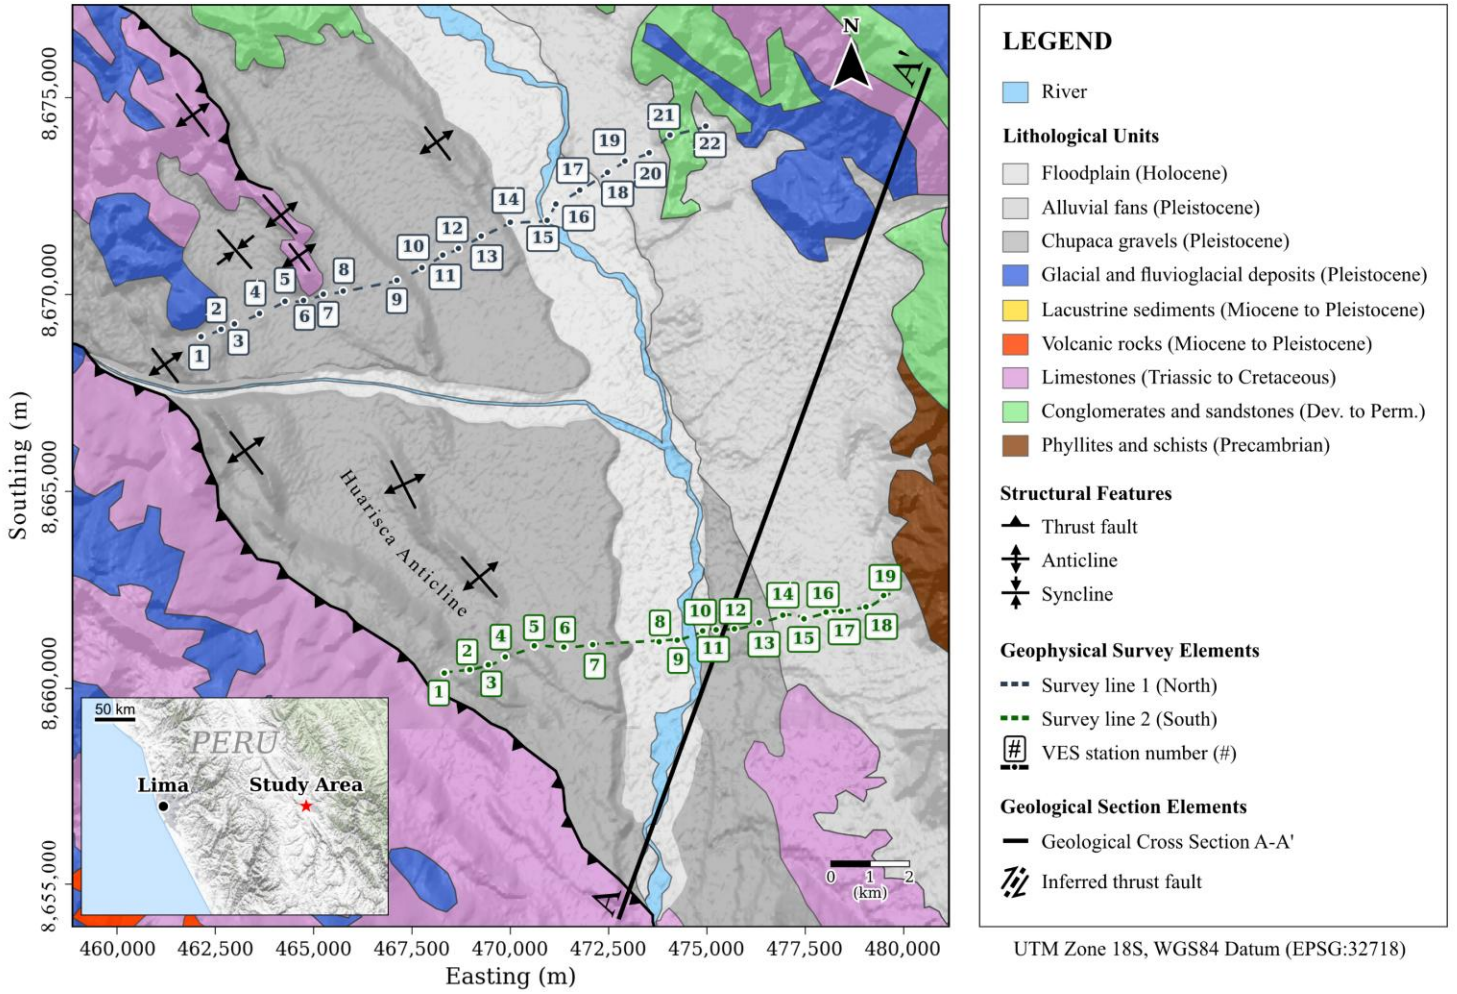
Measurements are irregularly sampled and non-uniform

3. Model Selection (What model to use)

Conventional architectures aren't optimized for geological data

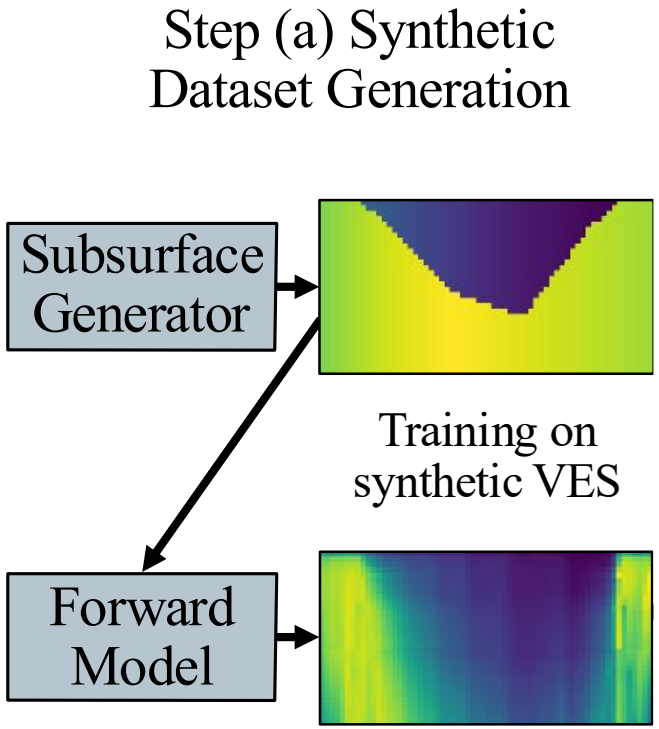
Our study area: Huancayo Basin



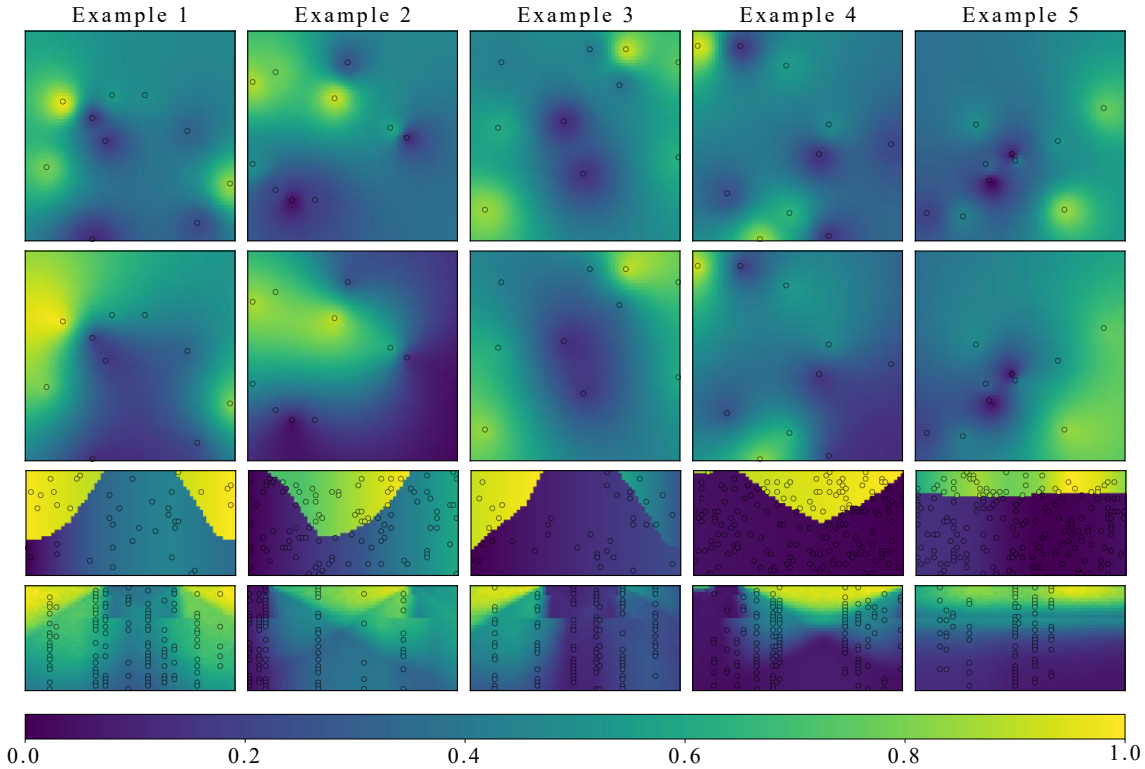


Key Innovations of Our Methodology

1. Data Scarcity (Not enough data)



2. Data Sparsity (Data is not dense)



3. Model Selection (What model to use)

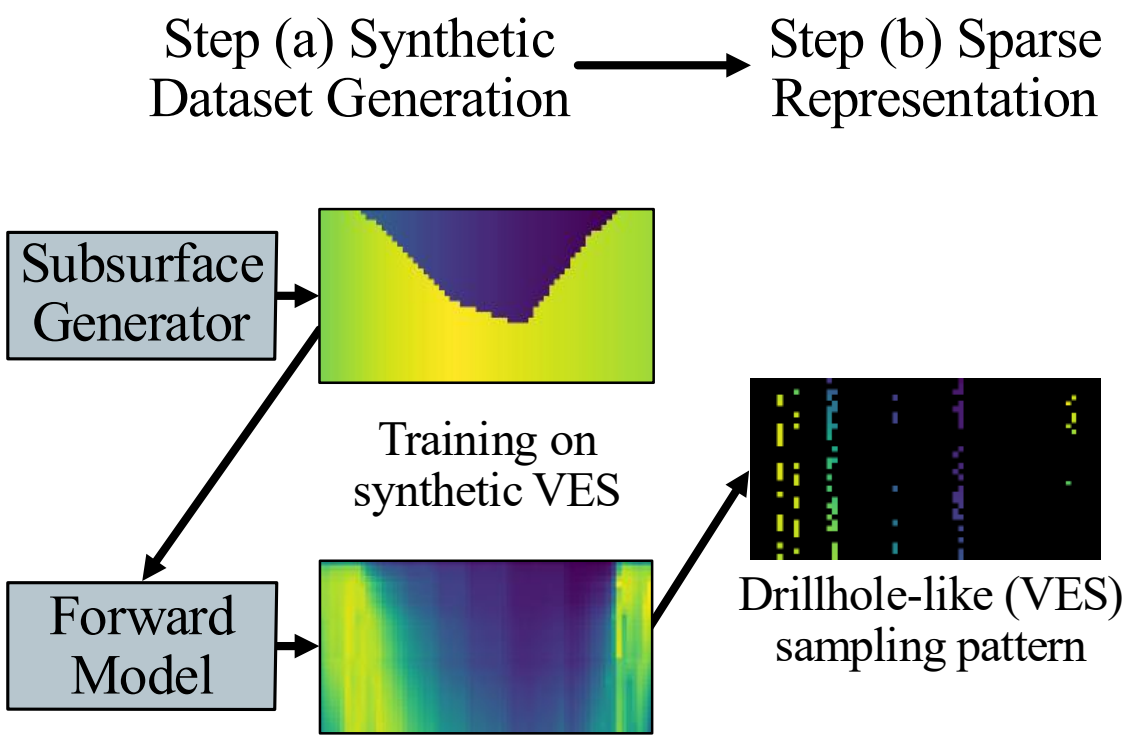
- We create realistic subsurface models using parametric functions
- This approach eliminates dependence on large real-world datasets
- Transfer learning enables the model to learn efficiently from these synthetic examples

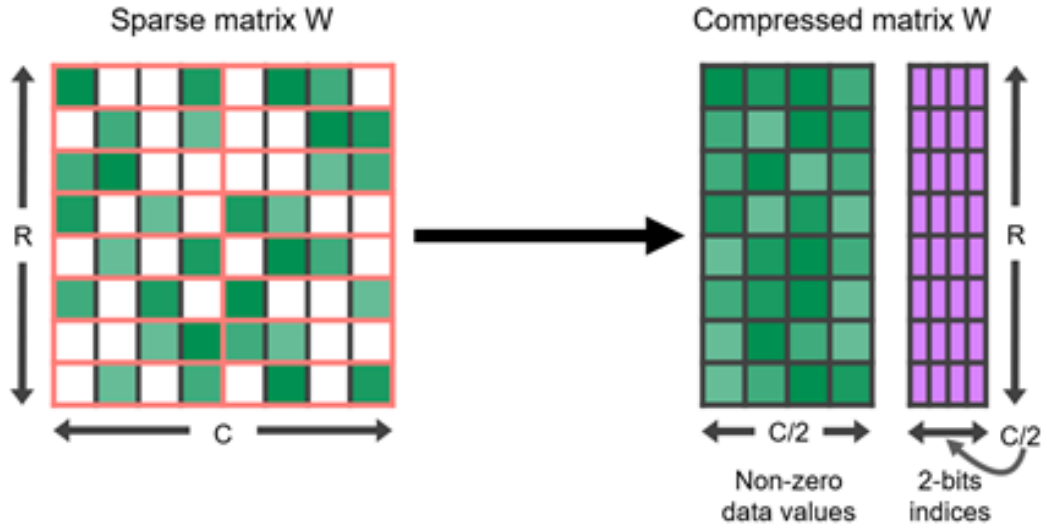
Key Innovations of Our Methodology

1. Data Scarcity (Not enough data)

2. Data Sparsity (Data is not dense)

3. Model Selection (What model to use)





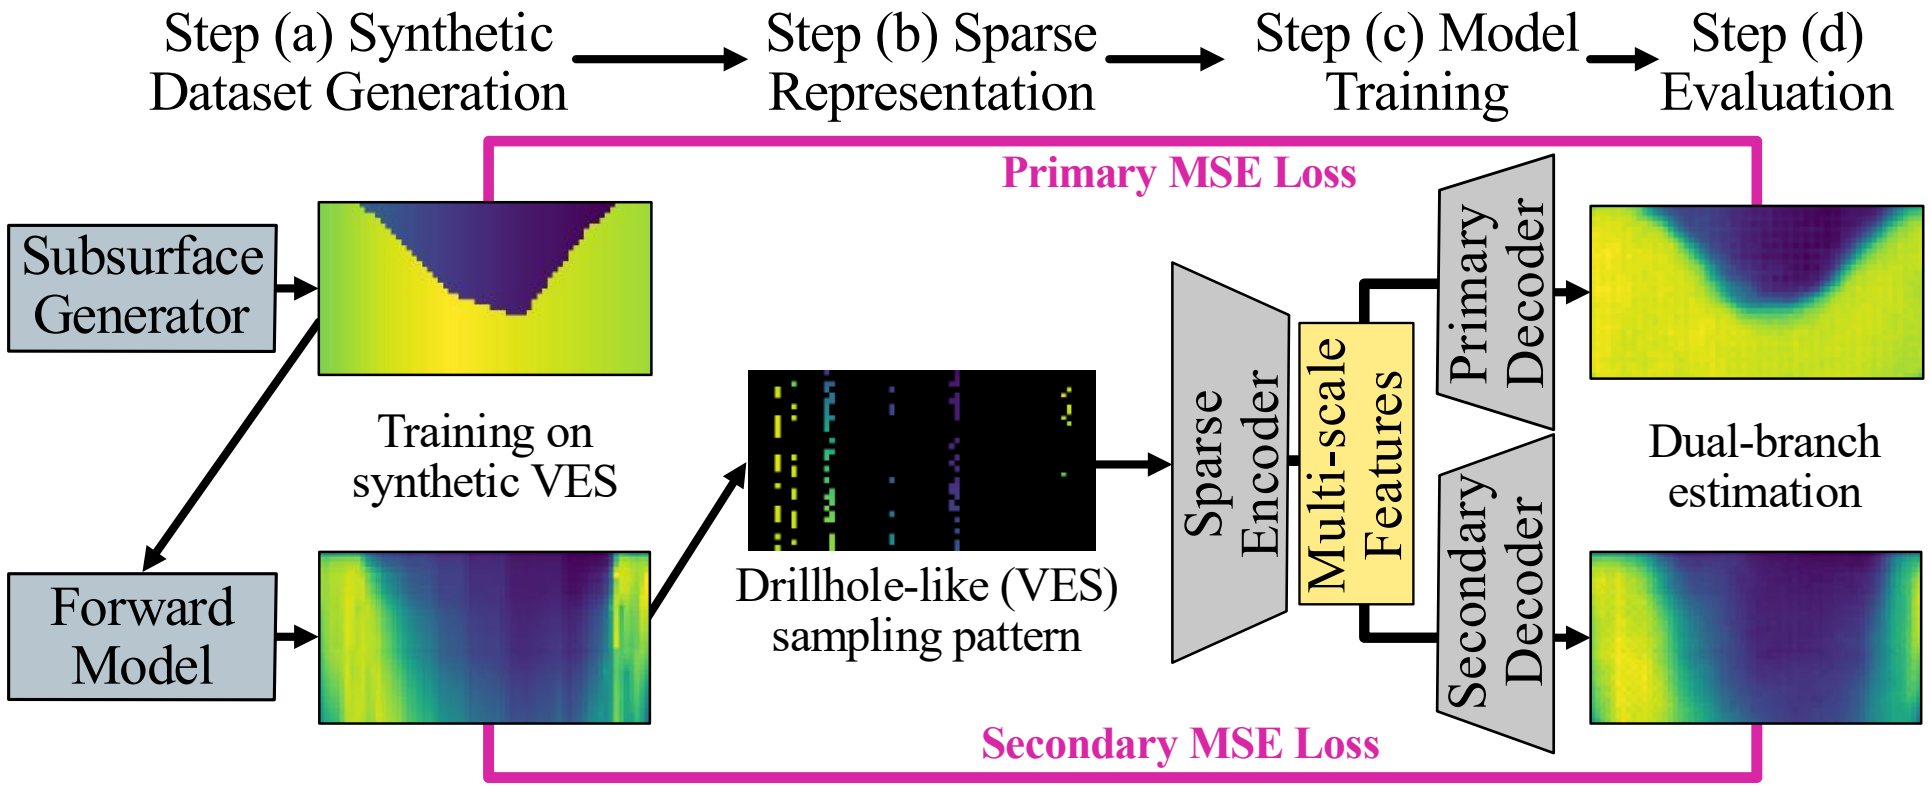
- Our sparse tensor approach dramatically reduces computational requirements
- This representation preserves spatial relationships crucial for geological interpretation

Key Innovations of Our Methodology

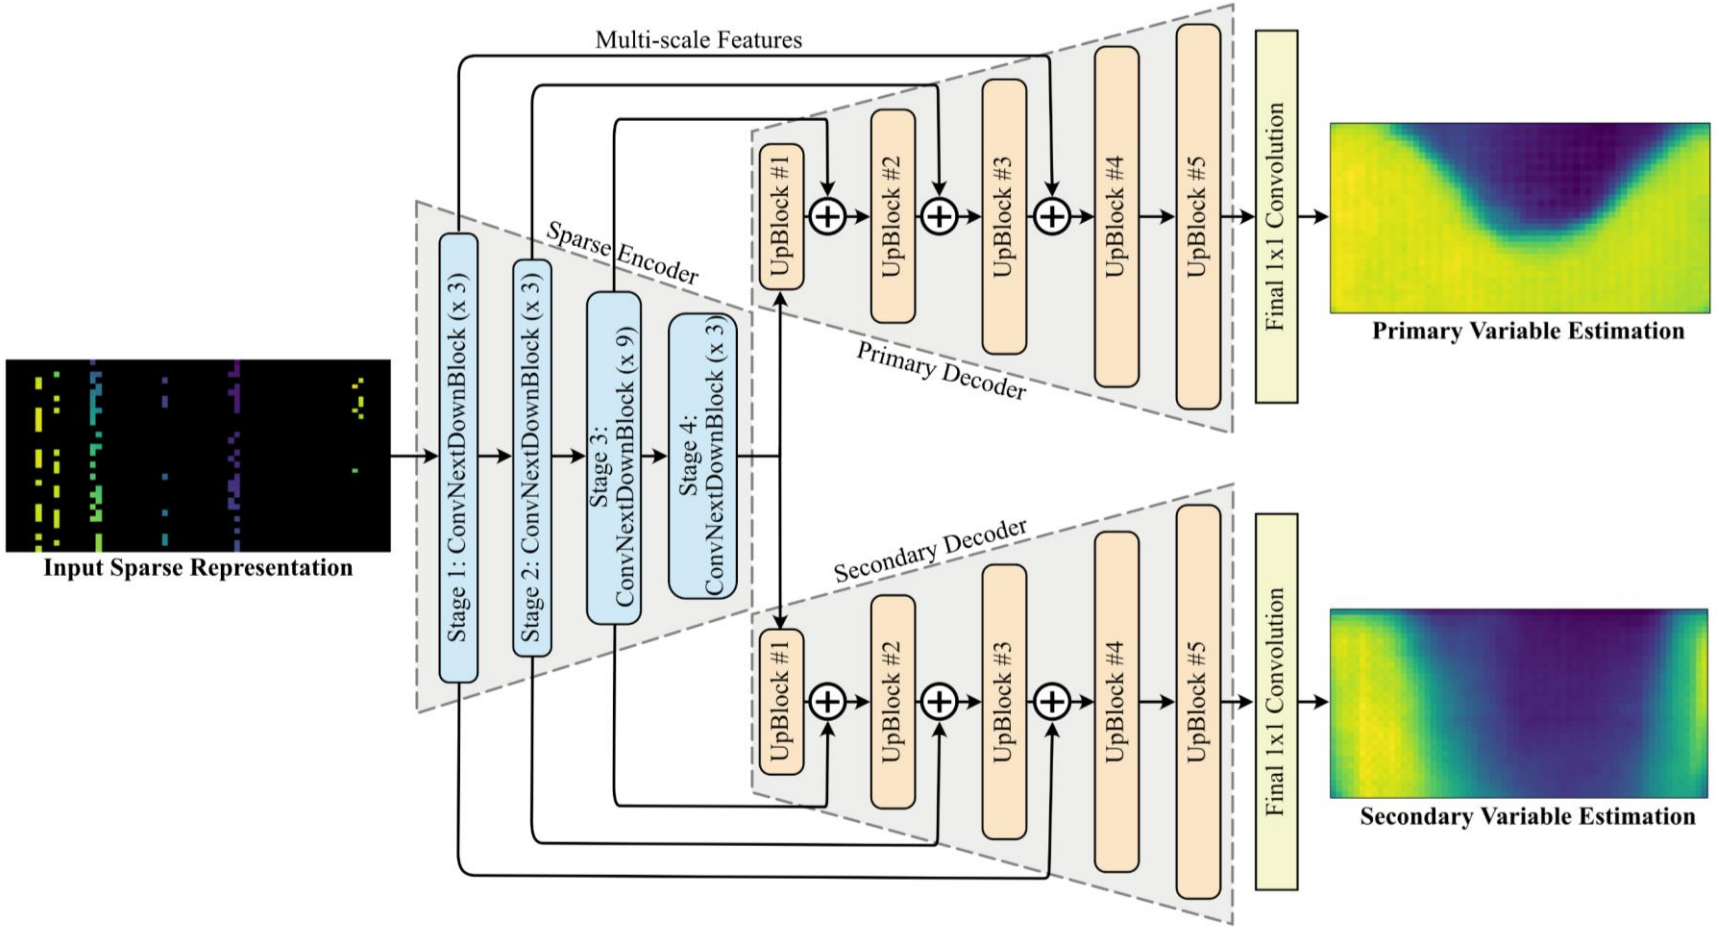
1. Data Scarcity (Not enough data)

2. Data Sparsity (Data is not dense)

3. Model Selection (What model to use)

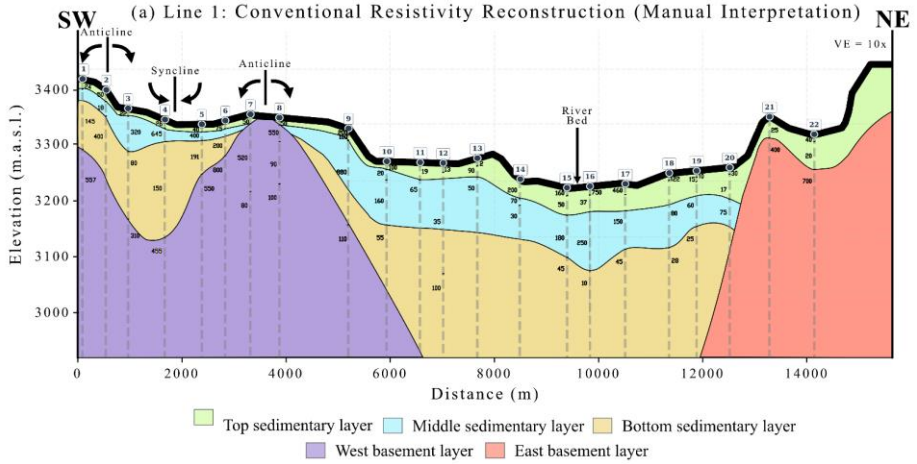


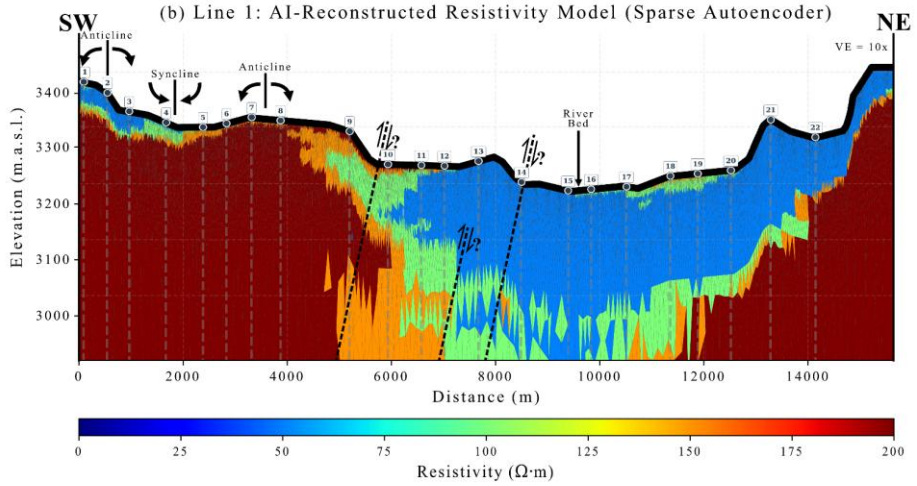
Sparse Autoencoder for Subsurface Reconstruction

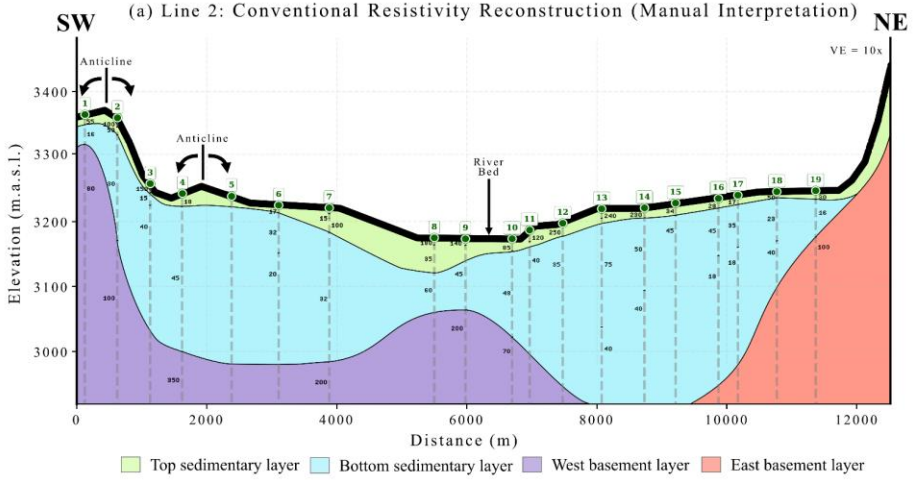


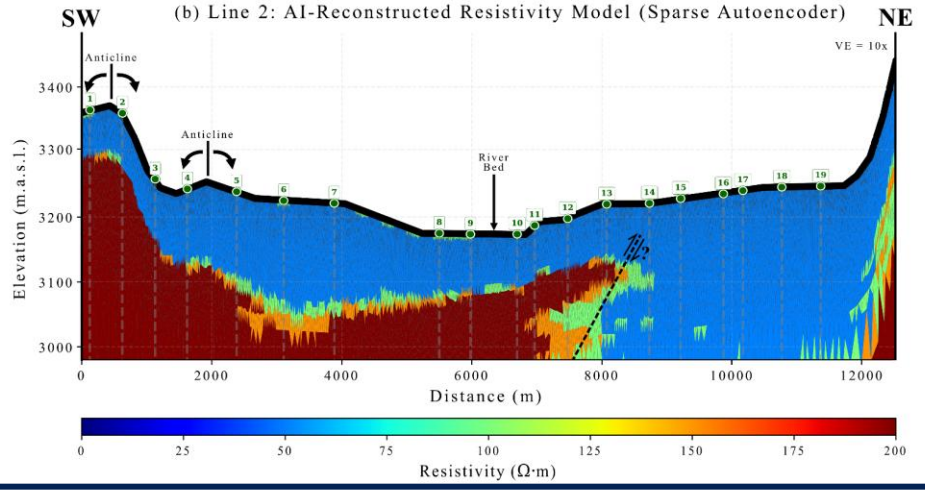
- Dual-branch sparse convolutional autoencoder with shared encoder
- Primary branch reconstructs subsurface resistivity distributions
- Secondary branch simultaneously estimates VES response patterns
- Multi-scale feature extraction capturing features at different resolutions
- This architecture efficiently learns from limited, sparse geological data

Results: Huancayo Basin Application

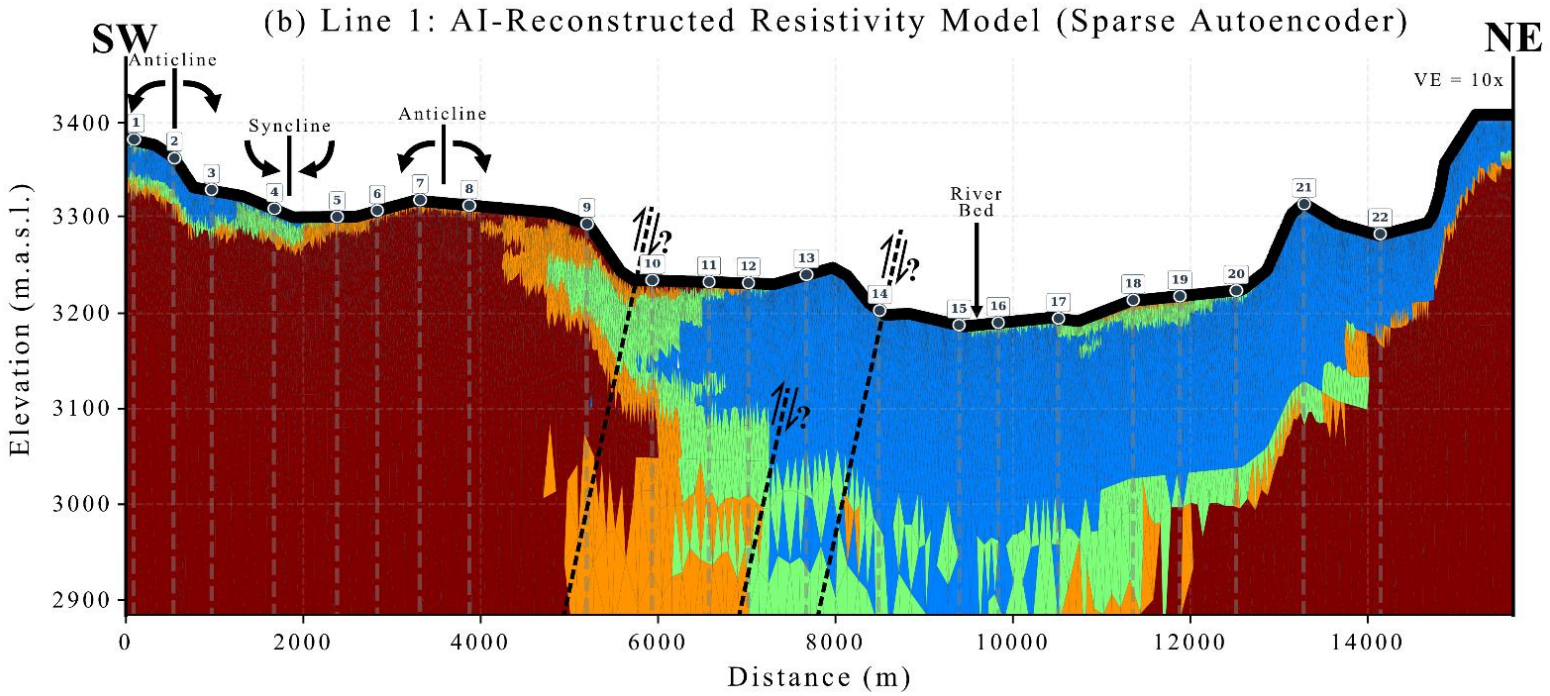








Results: Huancayo Basin Application





AI-reconstructed resistivity section previously unmapped features including:

- Basement-sedimentary contact with significant depth variation
- Three thrust faults controlling basin geometry
- Anticline-syncline structures affecting sedimentary layers

These structures align with field observations (images b-e)

Solving Deep Learning Problems in Geology

1. Data Scarcity (Not enough data)

Data-efficient deep learning approach thought simulations



2. Data Sparsity (Data is not dense)

Sparse representation thought sparse tensors



3. Model Selection (What model to use)

Dual-branch architecture enabling reconstruction of primary and secondary variables



Thank You!

ELSEVIER

Computers & Geosciences

Volume 204, October 2025, 105981



AI-based geological subsurface reconstruction using sparse convolutional autoencoders

Rodrigo Uribe-Ventura [a], Yoan Barriga-Berrios [a], Jorge Barriga-Gamarra [b], Patrice Baby [a c], Willem Viveen [a]

Show more

+ Add to Mendeley Share Cite

https://doi.org/10.1016/j.cageo.2025.105981 ↗ Get rights and content ↗

Key contributions of our work:

- ✓ Successful real-world application revealing new geological insights
- ✓ Trained model completes geological interpretation in minutes, replacing weeks of expert manual analysis

For more information:
https://doi.org/10.1016/j.cageo.2025.105981