Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería



1INF02 APRENDIZAJE DE MÁQUINA

Mentalidad de Modelado (Parte 1)

Prof. Rodrigo Uribe

Organización de las Clases

(10 min) Preguntas y consultas.

(30 min) Respuesta *Vibe Quest.*

(45 min) Introducción y mentalidad estadística basado en probabilidad.



(10 min) Break

(45 min) Mentalidad Frecuentista, Bayesiana y de Aprendizaje de Maquina.

(30 min) Ejercicios con distintas mentalidades.

(10 min) Preguntas *Vibe Quest.*

Respuestas del Vibe Quest

- ¿Qué sucede matemáticamente con la distribución posterior P(A|B) si el prior es extremadamente informativo frente a una evidencia débil, versus un prior difuso (no informativo)? Explora computacionalmente el punto de inflexión donde la evidencia observada (los datos) logra 'vencer' a un prior fuertemente sesgado, y visualiza cómo se actualizan estas creencias. (ejemplo dados cargados)
- Una prueba con 99% de precisión suena casi perfecta, pero ¿lo es realmente? Investiga computacionalmente la paradoja de las pruebas diagnósticas: ¿bajo qué condiciones un resultado positivo es prácticamente inútil y cuándo es confiable? ¿Qué implicaciones tiene esto para la toma de decisiones en salud pública o seguridad?
- Muchos errores en razonamiento probabilístico surgen de asumir independencia donde no existe. ¿Cómo podrías visualizar y cuantificar el error que cometemos cuando tratamos eventos dependientes como independientes? Explora escenarios donde esta suposición incorrecta lleva a conclusiones dramáticamente equivocadas.

Clase 1:

¿Qué es aprendizaje de máquina?

(Computadoras aprendiendo de datos automáticamente)

Recordar de la clase pasada:
¿Dónde están los límites de la ciencia?

La probabilidad es importante, pero:
¿Cómo hallamos la probabilidad en la realidad?

¡Usamos Datos!

¿Se pueden tomar decisiones con 1 dato?



(1 dato puede ser sumamente costoso)

Clase 2:

¿Cómo se toman decisiones (modelado) con datos?

¿Para qué necesitamos datos?

Cada día, las personas utilizan datos para:

- Predicción
- Automatización
- Ciencia
- Toma de decisiones

Ejemplos Prácticos

- Identificar pacientes propensos a efectos secundarios de medicamentos
- Descubrir cómo el cambio climático afecta a las colmenas
- Predecir qué productos estarán agotados

Cada Dato Cuenta una Historia

- El paciente con ID 124 tuvo acné
- La colonia de abejas 27 se redujo durante la sequía de 2018
- Aquel martes, la harina se agotó

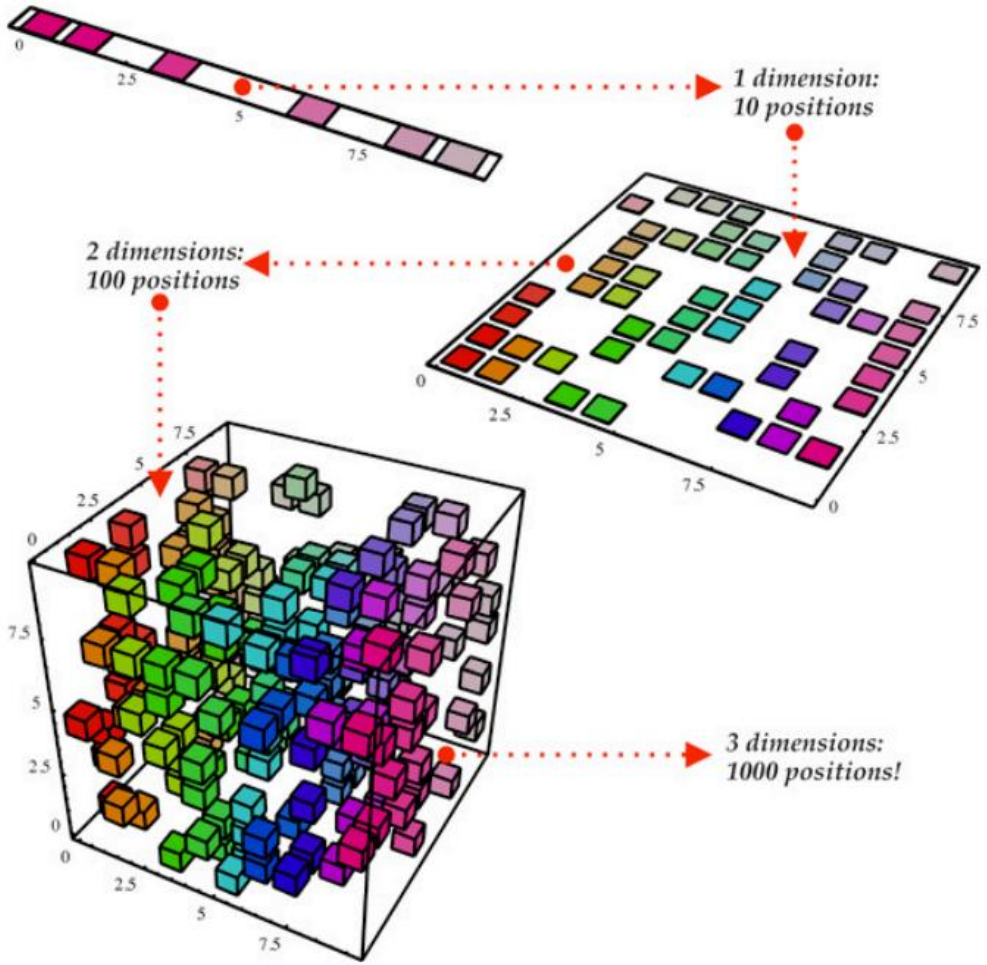
El Problema con los Datos en Bruto

Los datos por sí solos no son suficientes:

- Son ruidosos y de alta dimensionalidad

- La mayor parte de la informació es irrelevante

- Es difícil obtener conocimientos solo con esfuerzo humano



Los datos por si solo no nos sirve ¿Qué necesitamos?

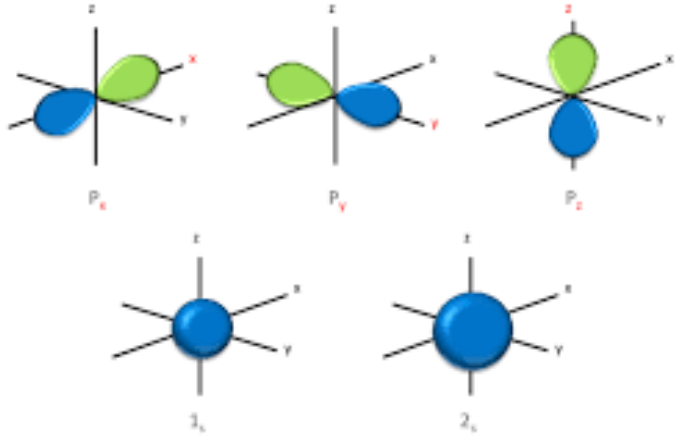
¡Modelos!

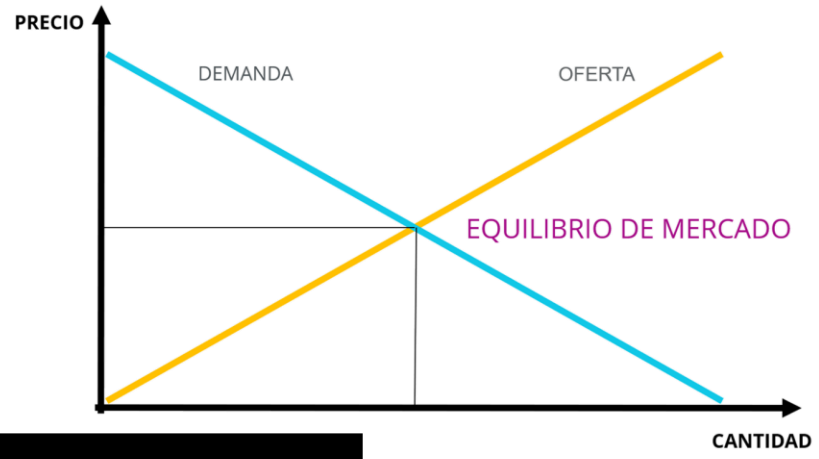


¿Puedes demostrar que estos modelos son correctos o “verdad”?

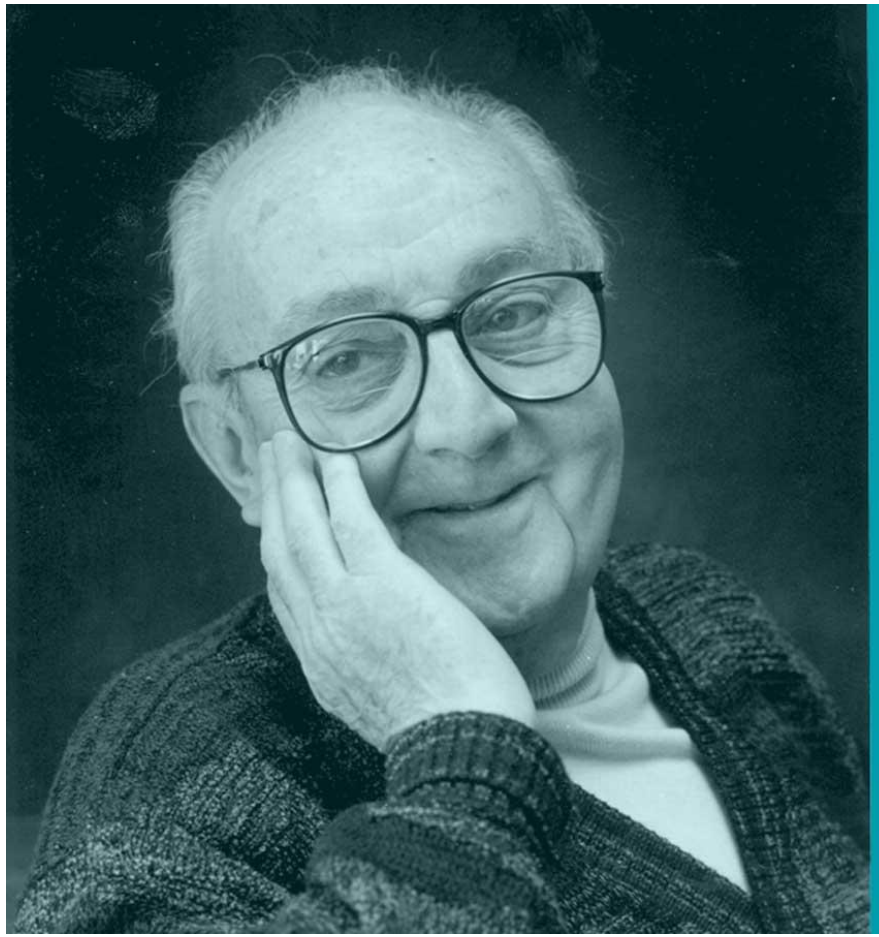








+1 punto por cada defensa



"All models are wrong, but some are useful."

George Box

El Rol de los Modelos

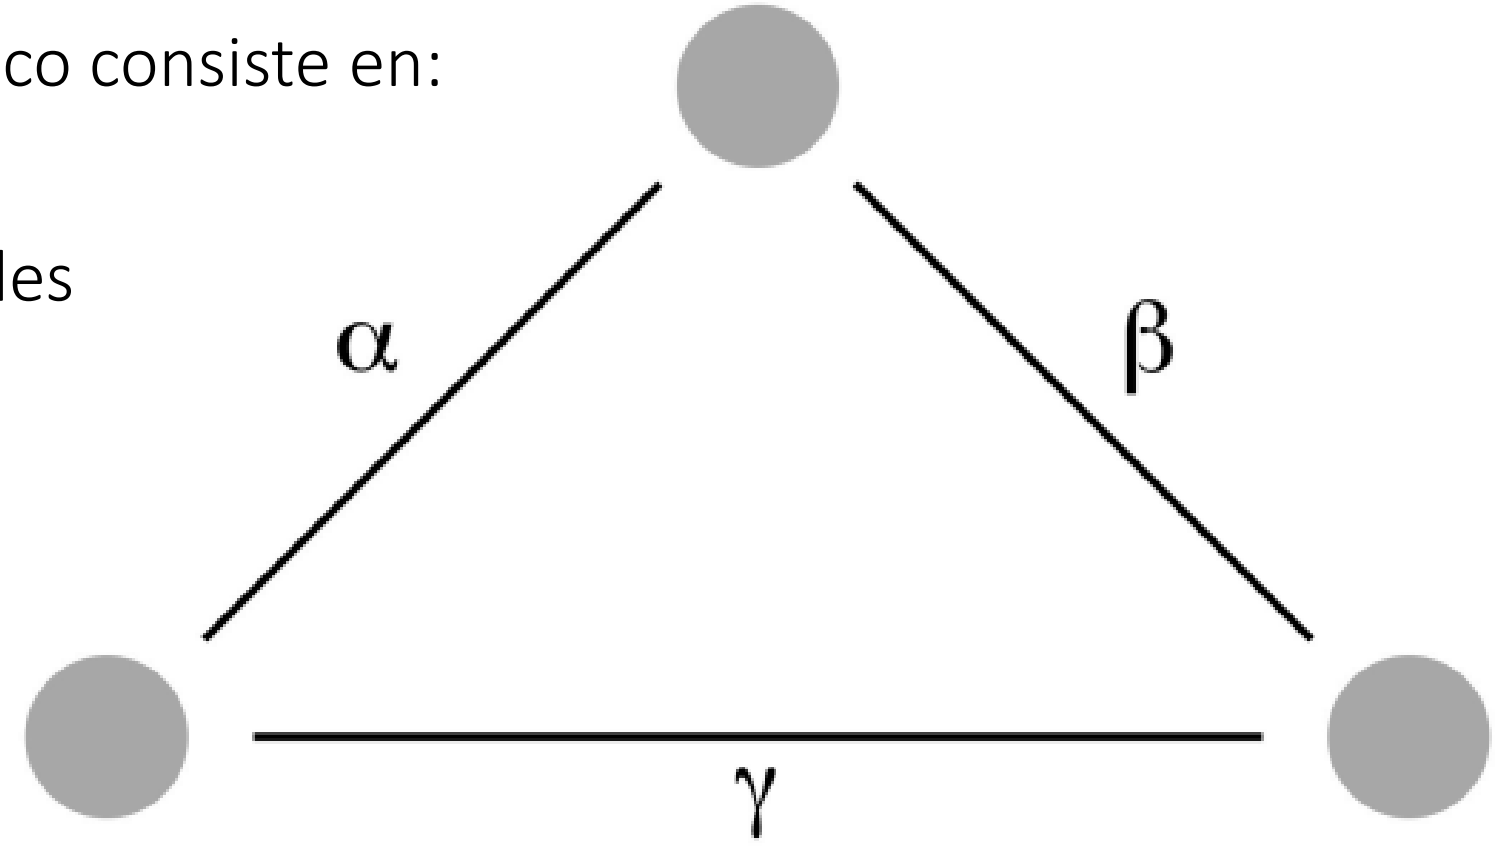
Los modelos simplifican y representan aspectos del mundo, permitiendo:

- Hacer predicciones
- Aprender sobre el mundo
- Probar teorías
- Tomar decisiones
- Comunicar resultados

Definición de Modelo

Un modelo matemático consiste en:

- Variables
- Funciones aprendibles



¿Qué Son las Variables?

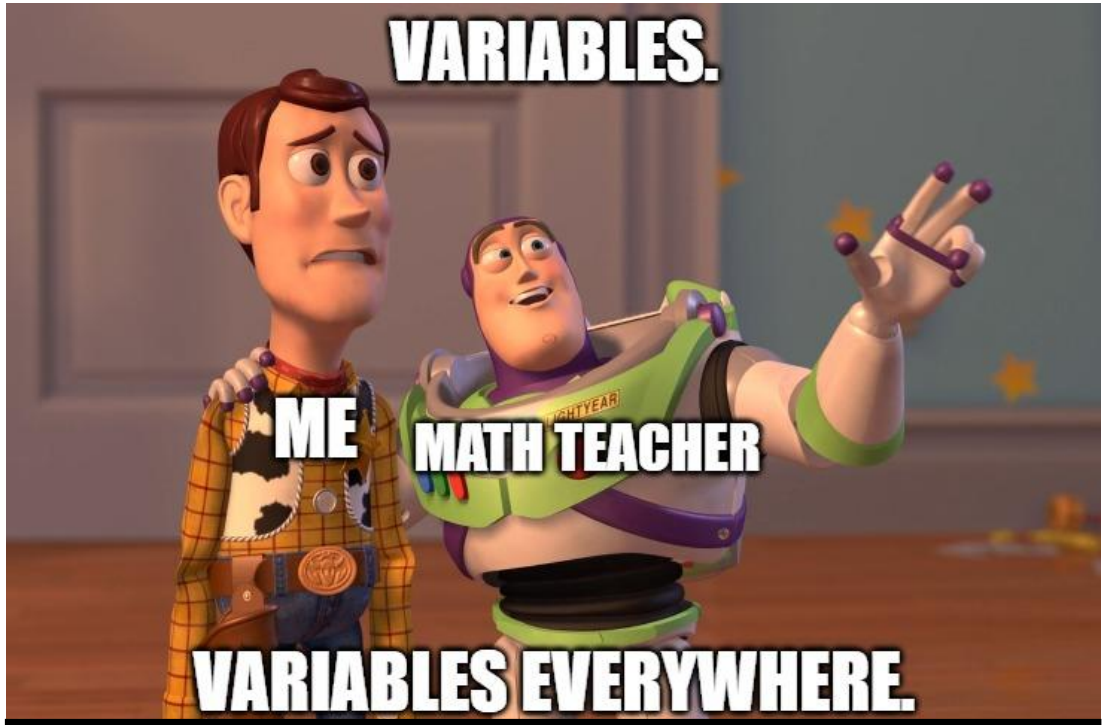
Las variables representan aspectos de los datos y del modelo:

- Variable numérica → presión arterial de un paciente
- Variable tridimensional → colores de un píxel
- Variable abstracta → felicidad
- Variable de agrupación → clusters de datos

Nombres de las Variables

Las variables tienen diferentes nombres según el contexto:

- Variables aleatorias
- Covariables
- Predictores
- Variables latentes
- Características (features)
- Objetivos (targets)
- Resultados (outcomes)



+1 punto por explicar que quiere decir algún nombre y en que contexto se usa



Las Funciones Relacionan Variables

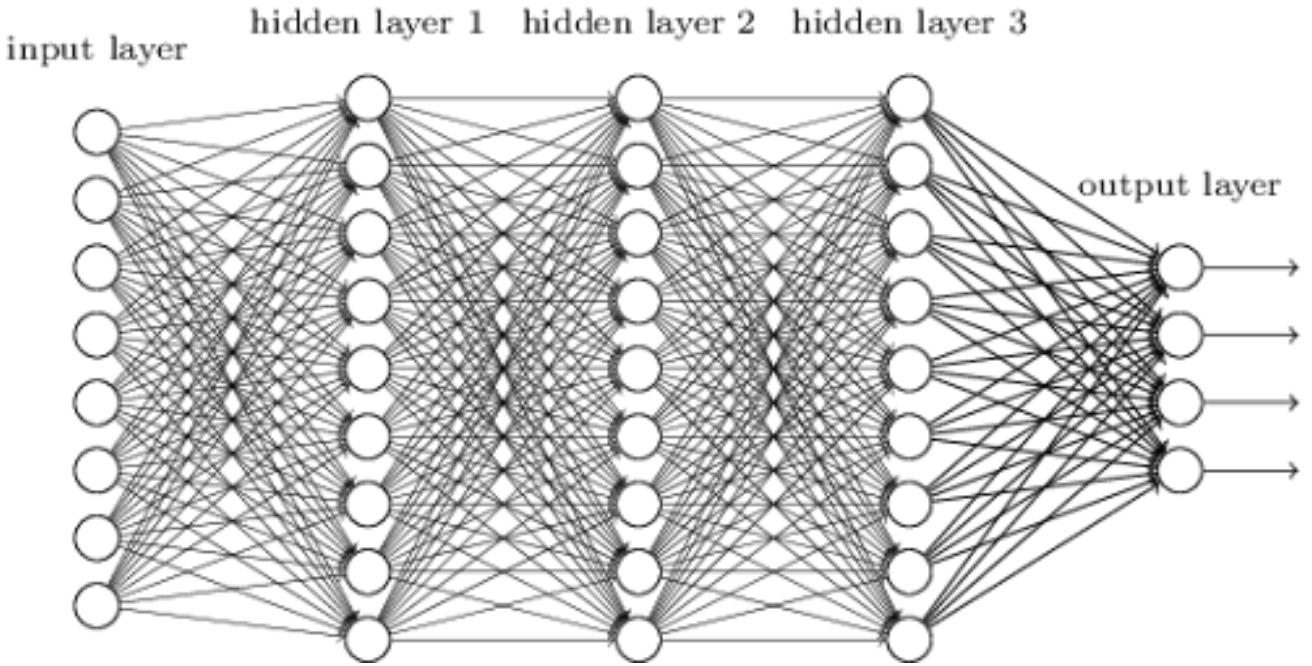
Las funciones conectan las variables entre sí:

- Regresión lineal: una variable como suma ponderada de otras
- Deep Q-learning: valor de una acción en función del estado
- Clustering: función que asigna puntos a grupos
- Distribución conjunta: co-ocurrencia de valores
- Modelo causal: relación causa-efecto entre variables

Complejidad de las Funciones

Las funciones varían desde simples hasta complejas:

- Simple: $Y = 5 \cdot X$
- Compleja: red neuronal profunda con millones de parámetros



Adaptación de los Modelos

El proceso de adaptar la función del modelo se llama:

- Estimación
- Entrenamiento
- Ajuste (fitting)
- Aprendizaje

El Modelo No Define Su Propósito

- La interpretación y uso del modelo depende de la mentalidad del modelador, no del modelo en sí.
- Dos modelos matemáticamente idénticos pueden usarse de formas diferentes.

Ejemplo - Predicción del Rendimiento del Arroz

Un modelo de regresión lineal predice el rendimiento del arroz basándose en:

- Lluvia
- Temperatura
- Uso de fertilizantes

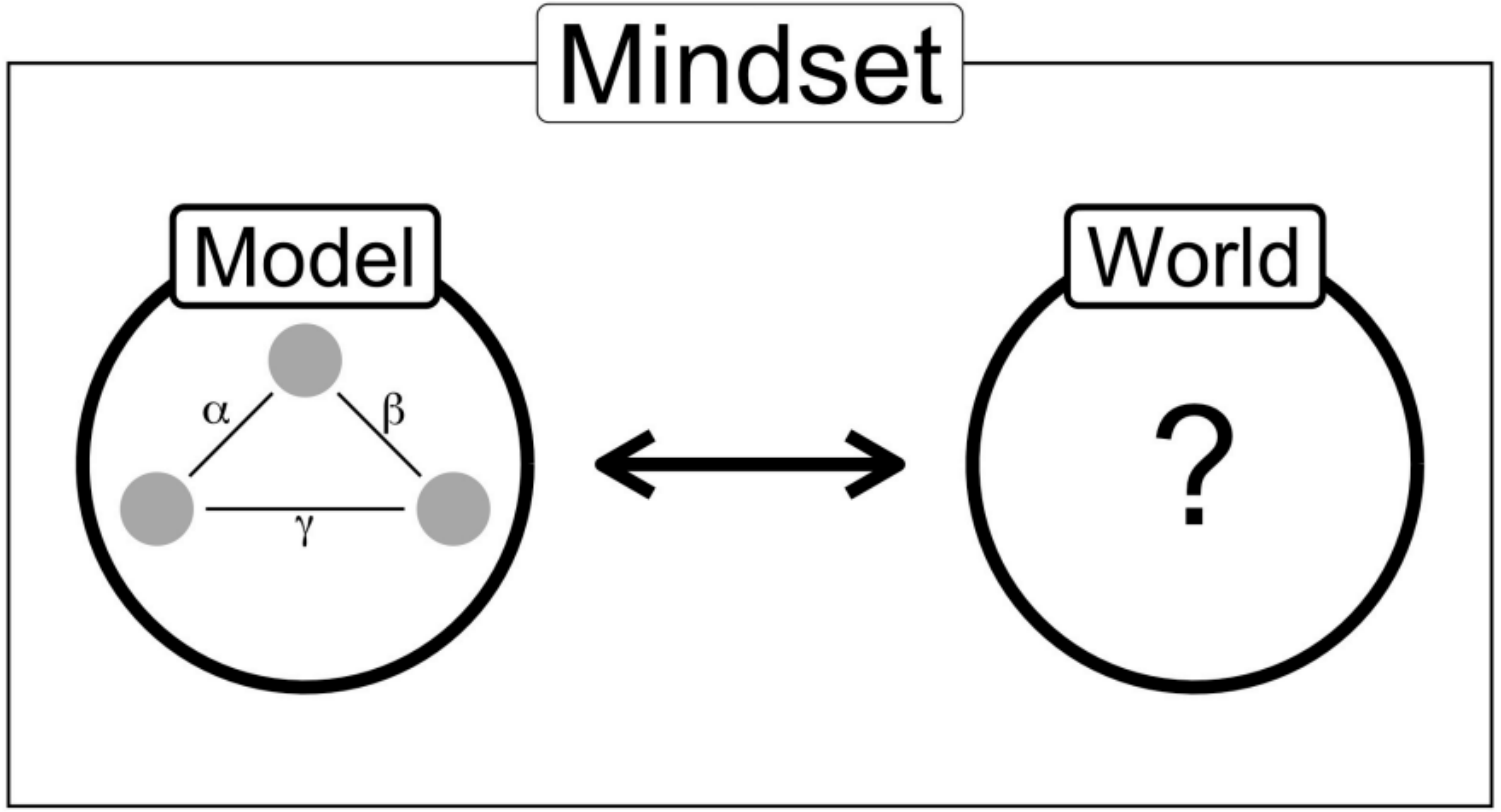


Diferentes Interpretaciones del Mismo Modelo

- ¿El efecto del fertilizante es causal? → Requiere modelo causal
- ¿El modelo predice bien? → Requiere mentalidad de aprendizaje supervisado
- ¿El efecto es significativo? → Requiere mentalidad frecuentista

Marco para Modelar el Mundo

- Una mentalidad de modelado proporciona el marco para modelar el mundo con datos.
- Modelar significa investigar un fenómeno del mundo real indirectamente usando un modelo.



Las Mentalidades Como Lentes

Las mentalidades son como diferentes lentes:

- Todas muestran el mundo, pero con diferente enfoque
- Algunas magnifican lo cercano
- Otras detectan lo lejano
- Algunas están tintadas para ambientes brillantes

Diferencias Entre Mentalidades

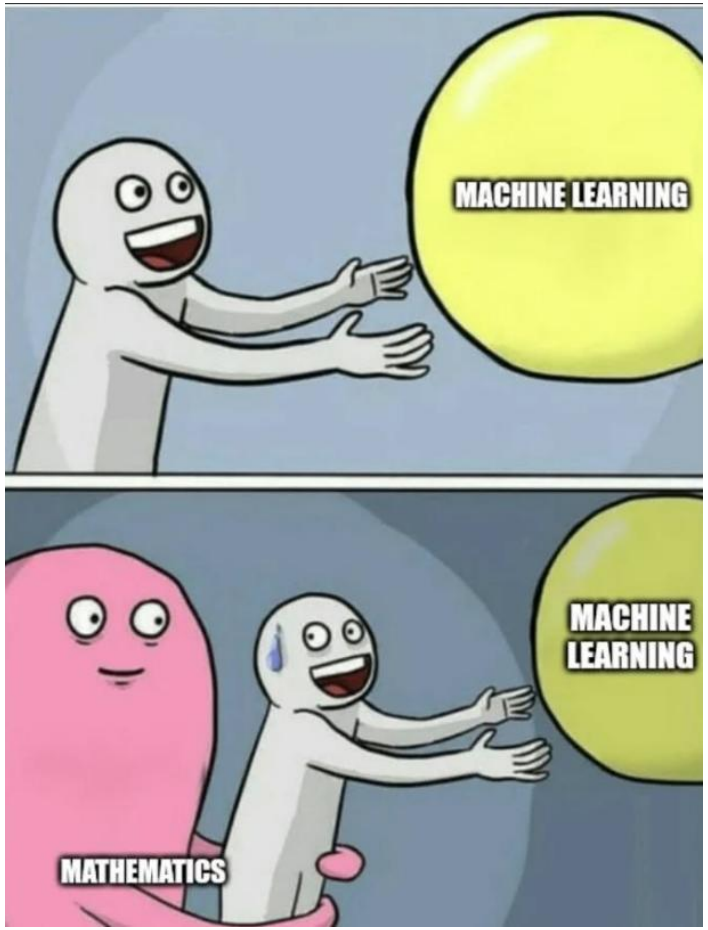
Las mentalidades difieren en:

- Cómo interpretan las probabilidades
- Si las probabilidades son centrales o no
- Qué tareas realizan mejor
- Qué preguntas permiten formular

Limitaciones de las Mentalidades

Cada mentalidad limita las preguntas que pueden hacerse.

Ejemplo: En aprendizaje supervisado puro, las preguntas sobre distribuciones de probabilidad están fuera del alcance.



Mentalidades y Comunidades (Cultura)

Cada mentalidad tiene:

- Un conjunto diferente de modelos permitidos
- Diferentes formas de evaluar qué tan bueno es un modelo
- Posibles solapamientos entre mentalidades

Las mentalidades de modelado:

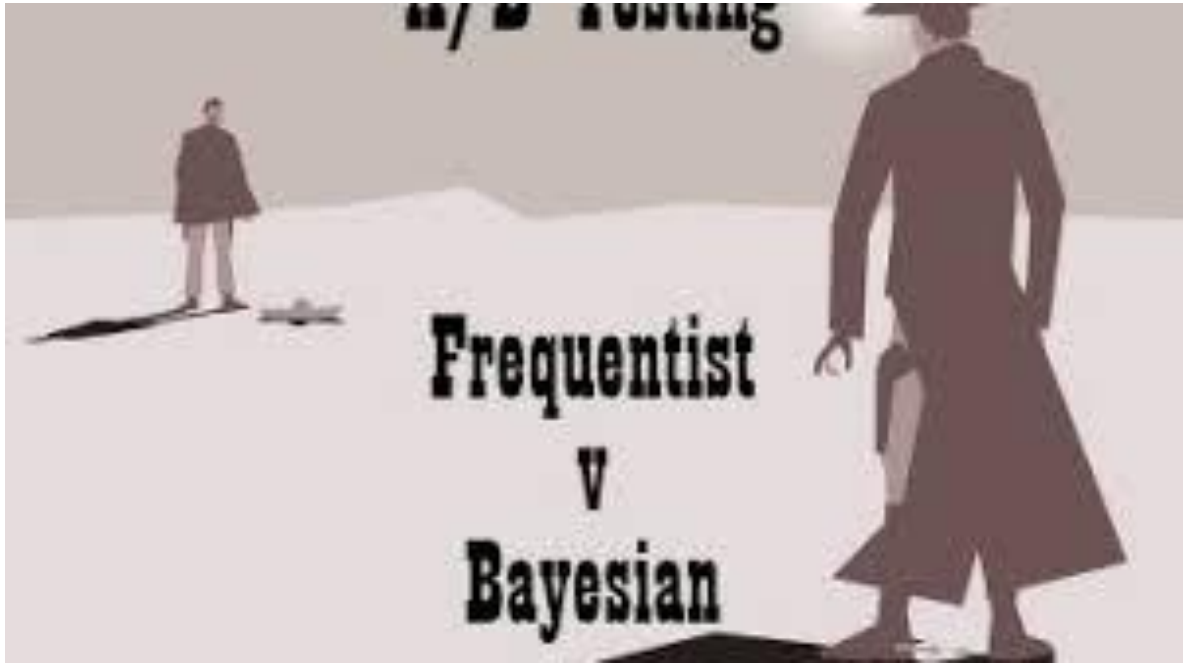
- No son solo teorías
- Dan forma a las comunidades
- Son moldeadas por quienes las aplican



Arquetipos vs. Realidad

Las mentalidades presentadas son arquetipos: formas puras y extremas.

En la realidad, los límites entre mentalidades son mucho más fluidos.



Ejemplos de Fluidez

- Un científico de datos puede usar modelos de ML y también pruebas de hipótesis

- Una comunidad puede aceptar análisis frecuentistas y bayesianos

- Una competencia de ML podría premiar modelos interpretables y causales

Personas Como Arquetipos

- El aprendiz supervisado: "¿Dónde están las etiquetas?"
- El estadístico: siempre quiere pruebas de hipótesis
- El bayesiano: discusiones intensas sobre probabilidad



El Valor de la Mente Abierta

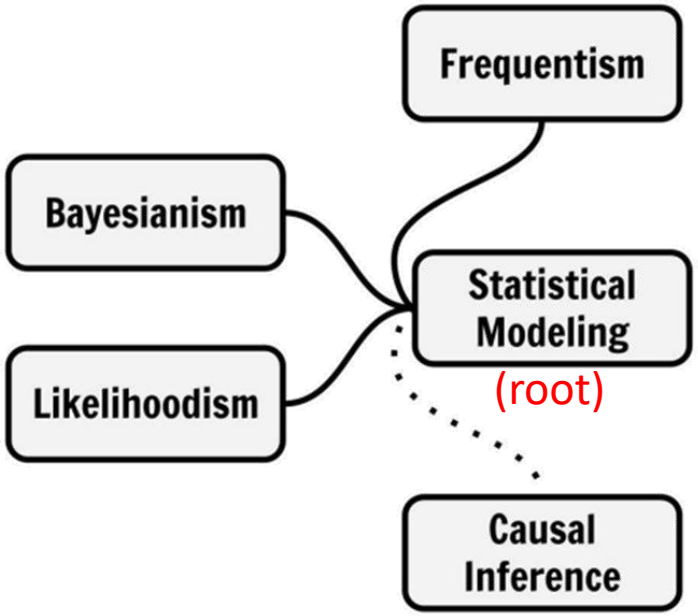
La mayoría de las personas han aprendido más de una mentalidad.

Tener una mente abierta sobre el modelado te convierte en un mejor modelador.



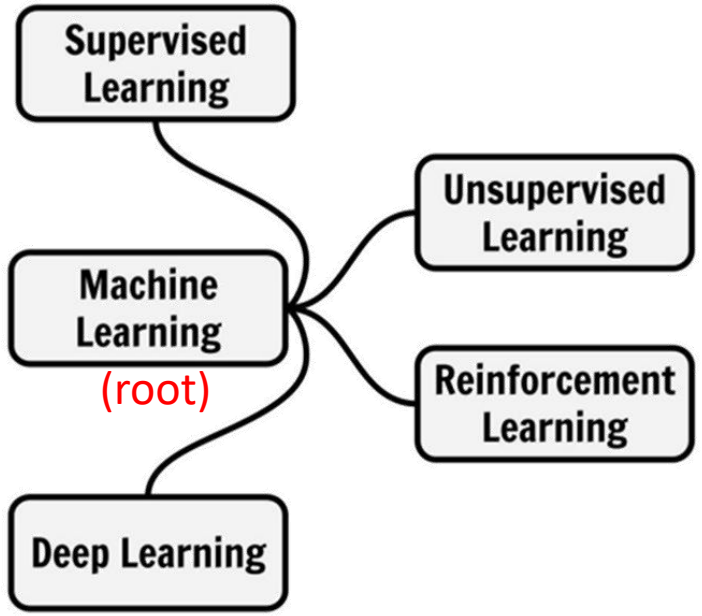
Las mentalidades de modelado

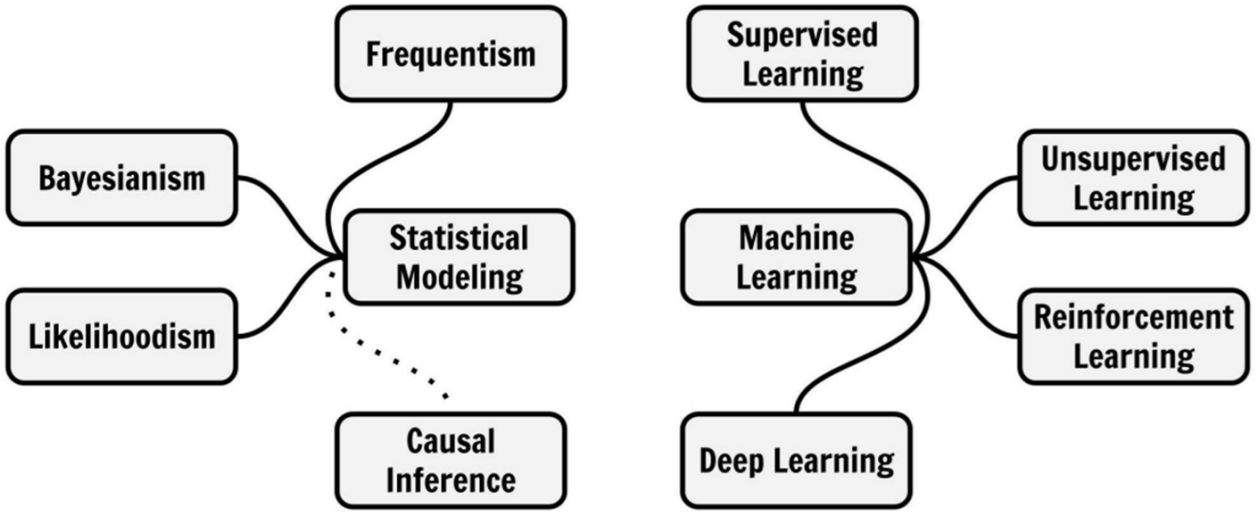
(más comunes)





(Todos manejan datos)





MODELADO ESTADÍSTICO

(Razonar Bajo Incertidumbre)

Premisa del Modelado Estadístico

- **Premisa:** El mundo se aborda mejor a través de la probabilidad.
- **Consecuencia:** Estimar aspectos de estas distribuciones usando modelos estadísticos para razonar bajo incertidumbre.

El Desafío de la Incertidumbre

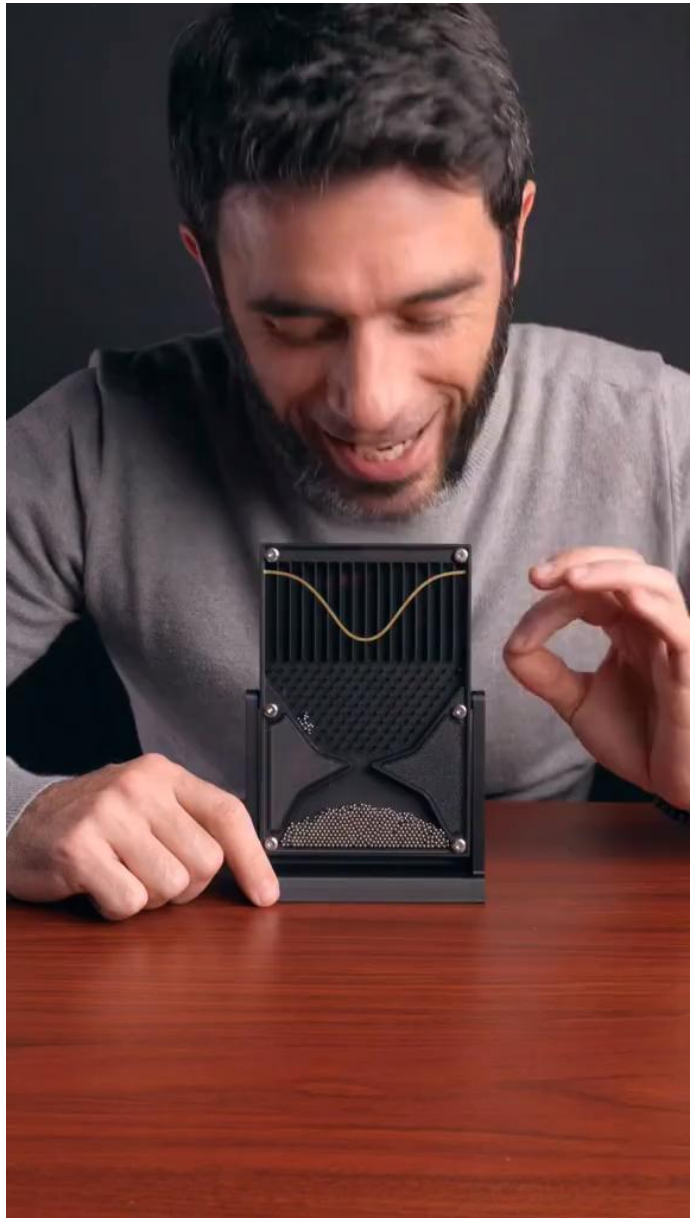
¿Te vuelves más productivo
cuando bebes mucha agua?

El Desafío de la Incertidumbre

- ¿Te vuelves más productivo cuando bebes mucha agua?
- Tu productividad variará naturalmente de un día a otro, independientemente de la hidratación.
- Esta incertidumbre oscurece el efecto del consumo de agua sobre la productividad.

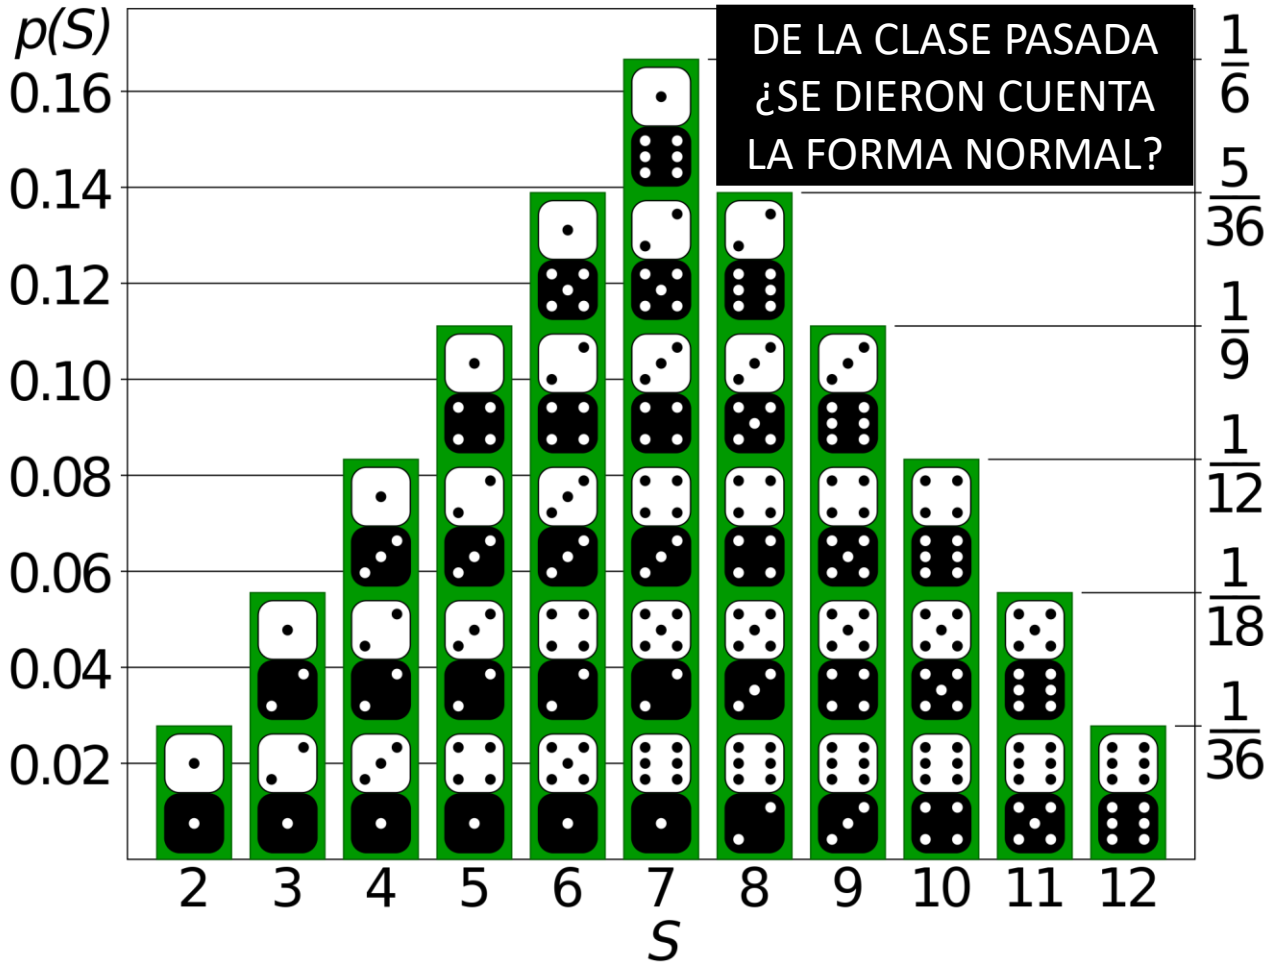
¿Cómo saber si es azar?

¿Existe el Azar?
¿Cómo explican esto?



El Azar tiene propiedades

- **Teorema Central del Límite:** La suma de variables aleatorias independientes converge hacia una distribución normal, sin importar su distribución original. El orden emerge del caos.
- **Ley de los Grandes Números:** A mayor número de repeticiones, la media observada converge al valor esperado teórico. La incertidumbre individual se disuelve en la certeza colectiva.



La Solución Estadística

El modelado estadístico ofrece herramientas matemáticas para manejar la incertidumbre.

La idea fundamental:

- Los datos son generados por un proceso que involucra distribuciones de probabilidad

- Los modelos estadísticos aproximan este proceso

- Los modeladores interpretan los resultados para razonar bajo incertidumbre

Cada "Cosa" Tiene una Distribución

Variables Aleatorias

- Los modeladores estadísticos piensan en variables aleatorias
- Estas variables son objetos matemáticos que codifican la incertidumbre en forma de distribuciones de probabilidad
- En el modelado estadístico, **los datos son realizaciones** (muestreo estocástico/aleatorio) de estas variables

Ejemplos de Variables

- Resultado del lanzamiento de un dado
- Número de patos en un parque
- Si un cliente canceló su contrato el mes pasado
- Número diario de ataques de patos
- El color de una camiseta
- Dolor en una escala del 1 al 10 por mordeduras de pato

¿Qué Son las Distribuciones de Probabilidad?

- Las distribuciones de probabilidad describen cómo se comportan las variables.
- Una distribución es una función que asigna una probabilidad a cada resultado posible de una variable.
- Entrada: valor → Salida: probabilidad

Ejemplos de Distribuciones

- Dado justo: 6 resultados posibles, cada uno con probabilidad 1/6
- Temperatura: la distribución Normal es una opción común
- Conteos: distribución de Poisson
- Proporciones: distribución Binomial
- Tiempos de espera: distribución Gamma

Parámetros de las Distribuciones

Cada distribución tiene parámetros que la modifican:

- Media
- Varianza
- Otros parámetros específicos

Esta propiedad permite ajustar las distribuciones a los datos.

Del Proceso al Modelo

- El modelador traduce el proceso generador de datos en un modelo estadístico.
- Todo tipo de supuestos entran en el modelo.

Supuestos del Modelo

- Elección de variables relevantes
- Cómo se distribuyen las variables
- Si los datos son independientes e idénticamente distribuidos (IID)
- Cómo se relacionan las variables entre sí (efectos lineales, suaves, codificación de variables categóricas)

Ejemplo - Productividad y Agua

Datos: consumo diario de agua y número de tareas completadas

El modelador podría asumir que:

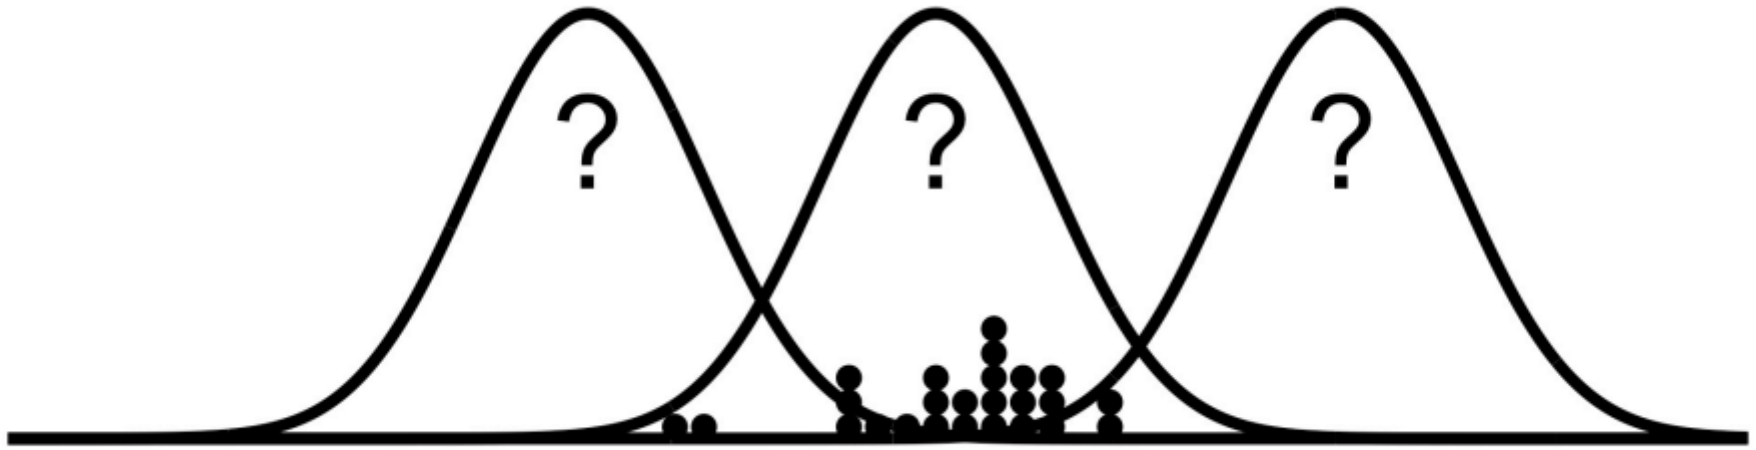
- La productividad sigue una distribución de Poisson
- Dado el consumo de agua y día de la semana
- Existe un efecto adicional por "participante"

Contraste con Machine Learning

- Modelado estadístico: Enfoque en **replicar el proceso** generador de datos
- Machine Learning: Enfoque en **resolver la tarea** (como predicción), más que en replicar el proceso

Ajuste del Modelo (Fitting)

- Parte fija: Todos los supuestos del modelo
- Parte flexible: Los parámetros que se adaptan a los datos
- Los modeladores "ajustan" modelos adaptando los parámetros para que los datos parezcan probables bajo el modelo estadístico.



Estimación de Parámetros

Los parámetros dentro del modelo describen aspectos de la distribución que interesan al modelador:

- Coeficientes que afectan la media condicional
- Correlación entre variables
- La distribución completa

El Problema del Sobreajuste

- La bondad de ajuste se calcula frecuentemente con los mismos datos usados para ajustar el modelo.
- Sobreajuste: Cuanto más flexible es un modelo, más puede copiar la aleatoriedad de los datos.
- Muchas métricas de bondad de ajuste consideran la complejidad del modelo.

Contraste con Aprendizaje Supervisado

Modelado estadístico: Bondad de ajuste con datos de entrenamiento (ajustando por complejidad)

Aprendizaje supervisado: Esquemas de evaluación con datos no vistos para evitar sobreajuste y obtener estimaciones honestas del error de generalización

Usos de los Modelos Estadísticos

Los modelos estadísticos pueden ayudar a:

- Tomar decisiones
- Entender el mundo
- Hacer predicciones

Pero usar el modelo como representación del mundo no es gratuito. El modelador debe considerar:

- La representatividad de los datos
- Supuestos adicionales (filosóficos)

Representatividad de los Datos

Ejemplo: Un estudio muestra que una herramienta de screening de sepsis redujo muertes en un hospital.

Pregunta: ¿Son estos datos representativos de todos los hospitales del país?

Un buen modelador define la población a estudiar y discute si los datos la representan bien.

La Cuestión Filosófica



"Se acepta unánimemente que la estadística depende de algún modo de la probabilidad. Pero, en cuanto a qué es la probabilidad y cómo está conectada con la estadística, rara vez ha habido un desacuerdo tan completo y una ruptura de la comunicación semejante desde la Torre de Babel."

— Leonard Savage, 1972

Sabores del Modelado Estadístico

Diferentes interpretaciones de la probabilidad y la evidencia llevan a diferentes sabores:

- Inferencia frecuentista
- Inferencia bayesiana
- ~~Likelihoodismo~~

Inferencia Frecuentista

- Ve la probabilidad como frecuencias relativas a largo plazo.
- Ejemplo: Si lanzas una moneda infinitas veces, la proporción de caras se acercará a 0.5.

Inferencia Bayesiana

- Basada en una interpretación de la probabilidad como grado de creencia sobre el mundo.
- Permite actualizar creencias con nueva evidencia.

Todos estos sabores del modelado estadístico tienen una visión probabilística del mundo en común.

Fortalezas

✓ Las distribuciones y modelos estadísticos proporcionan un lenguaje para describir el mundo y sus incertidumbres.

✓ El mismo lenguaje se usa para describir y entender algoritmos de machine learning bajo la etiqueta de "aprendizaje estadístico".

✓ El modelado estadístico tiene una extensa base teórica: desde la teoría de medición como base de la probabilidad hasta miles de artículos sobre modelos específicos.

✓ El proceso generador de datos es un modelo mental poderoso que fomenta hacer preguntas sobre los datos.

Fortalezas

✓ Los modelos estadísticos proporcionan los medios para razonar bajo incertidumbre:

- Tomar decisiones
- Entender el mundo
- Evaluar hipótesis
- Hacer predicciones

Limitaciones

✗ Modelar el proceso generador de datos puede ser bastante manual y tedioso, ya que deben hacerse muchos supuestos.

✗ Mentalidades más automatizables, como el aprendizaje supervisado, son más convenientes.

Limitaciones

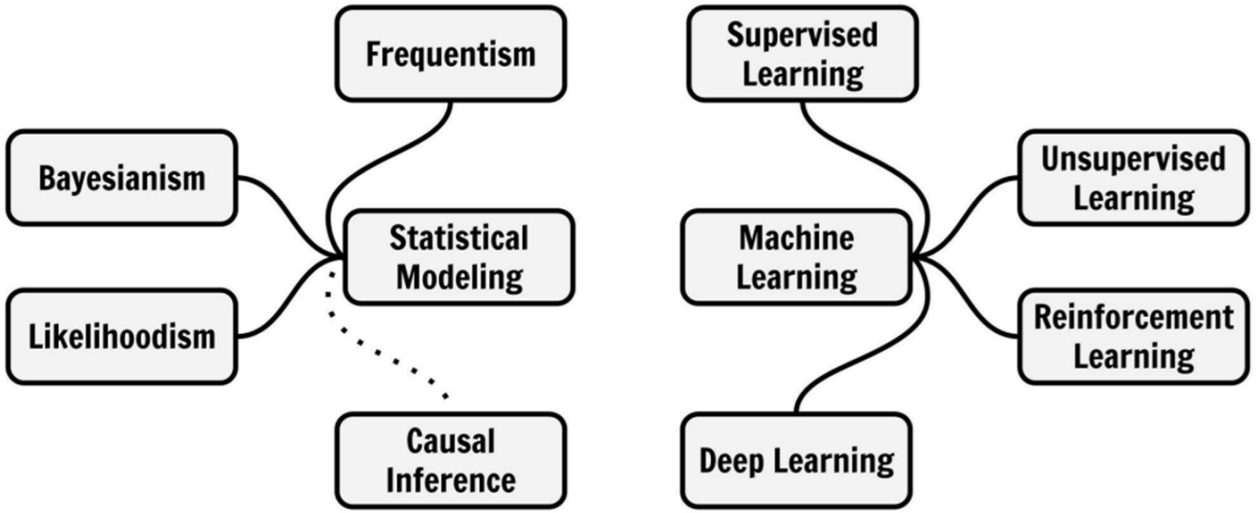
✗ La mentalidad del modelado estadístico tiene dificultades con distribuciones complejas, como datos de imágenes y texto.

✗ Aquí es donde el machine learning, especialmente el deep learning, brillan.

Limitaciones

✗ La bondad de ajuste no garantiza un alto rendimiento predictivo en datos nuevos.

✗ Si el objetivo es hacer predicciones, un enfoque de aprendizaje supervisado es más adecuado.



FRECUENTISMO

(Inferir la “Verdadera” distribución)

Premisa del Frecuentismo

- **Premisa:** El mundo se aborda mejor a través de distribuciones de probabilidad con parámetros fijos pero desconocidos.
- **Consecuencia:** Estimar e interpretar los parámetros usando frecuencias a largo plazo para tomar decisiones bajo incertidumbre.

Ejemplo del Mundo Real

- Beber alcohol está asociado con un riesgo 1.81 veces mayor de diabetes en hombres de mediana edad.
- Los investigadores usaron inferencia frecuentista para llegar a esta conclusión.

Señales de un Frecuentista

Los modeladores que piensan en estos términos probablemente son frecuentistas:

- Niveles de significancia
- Valores p
- Pruebas de hipótesis
- Intervalos de confianza

Dominancia del Frecuentismo

- En muchos campos científicos (medicina, psicología), la inferencia frecuentista es la mentalidad de modelado dominante.
- Los artículos frecuentistas siguen patrones similares, hacen supuestos similares y contienen tablas y figuras similares.

Aplicaciones en la Industria

El frecuentismo tiene un fuerte arraigo en la industria:

- Análisis de pruebas A/B para sitios web
- Cálculo de riesgo de portafolios
- Monitoreo de calidad en líneas de producción

Interpretación Frecuentista de la Probabilidad

La probabilidad se ve como la frecuencia relativa de un evento en ensayos repetidos infinitamente.

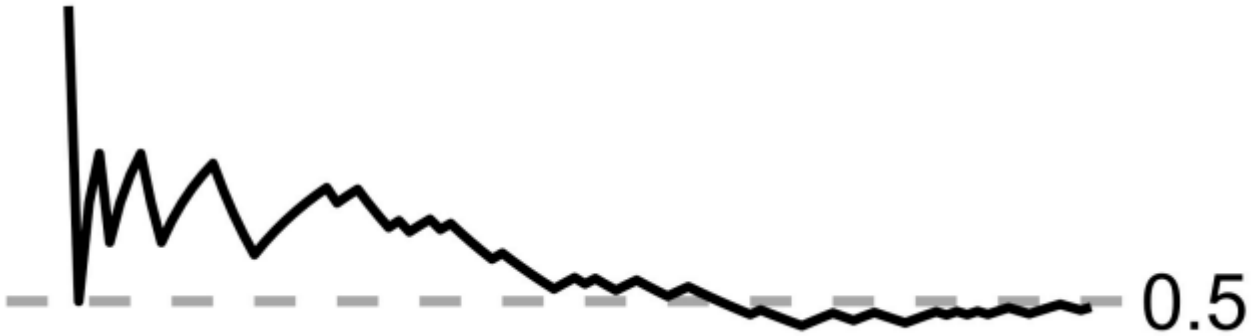
El Problema de la Aleatoriedad

1.81 es mayor que 1, así que parece haber una diferencia entre hombres que beben alcohol y los que no.

Pero: ¿Cómo pueden los investigadores estar seguros de que el 1.81 no es un resultado aleatorio?

La Analogía de la Moneda

- Si lanzas una moneda 100 veces y sale cruz 51 veces, nuestro instinto dice que la moneda es justa.
- Pregunta: ¿Dónde está el umbral? ¿55 cruces? ¿60?
- Ver la probabilidad como frecuencias a largo plazo permite definir un umbral.



Supuesto de Parámetros Fijos

- Los frecuentistas asumen que cada parámetro tiene un valor fijo y verdadero.
- Las observaciones repetidas revelan los valores verdaderos a largo plazo.
- Objetivo del modelado: Estimar (descubrir) el parámetro y cuantificar qué tan cierta es la estimación.

Ejemplo - Estudio de Diabetes

- El estudio reportó un intervalo de confianza del 95% para el coeficiente de alcohol: de 1.14 a 2.92.
- El intervalo no contiene 1, por lo tanto los investigadores concluyeron que el alcohol está significativamente asociado con la diabetes en hombres.

Camino hacia la Inferencia

- Para entender el frecuentismo, trabajamos desde:
- Datos → Modelo estadístico → Estimador → Experimentos imaginarios → Decisión

Paso 1 - Los Datos Son Variables Aleatorias

Ejemplo: Un modelador observa 10 extracciones independientes del peso de manzanas.

Supuesto: El peso sigue una distribución Gaussiana.

Preguntas:

A) ¿Cuál es el peso promedio, incluyendo incertidumbre?

B) ¿La manzana promedio pesa menos de 90 gramos?

Paso 2 - Los Estimadores Son Variables Aleatorias

Para responder las preguntas, el modelador estima la media del peso.

Cálculo: Sumar todos los valores y dividir entre 10.

Resultado: 79 gramos.

Como función de una variable, este estimador de la media es una variable aleatoria en sí misma.

Modelos Más Complejos

Podemos imaginar modelos más complejos para las manzanas:

- Relacionar peso con "rojez"
- Estimar distribución condicional por tipo de manzana y temporada
- Modelar el cuantil 90% del peso

Paso 3 - Interpretación de Frecuencias a Largo Plazo

- 79 es menor que 90 (pregunta B). Pero el estimador viene con incertidumbre.
- Pregunta: Asumiendo que el peso promedio verdadero es 90, ¿no podría una muestra de 10 manzanas pesar 79 gramos en promedio, solo por azar?

Derivación de la Distribución

- Malas noticias: El modelador solo tiene una observación de la media.
- Buenas noticias: El modelador puede derivar la distribución de la estimación de la media a partir de la distribución de los datos.
- Como los pesos siguen una distribución Gaussiana, la media sigue una distribución t.

Paso 4 - Decisiones Basadas en Experimentos Imaginarios

- Para sacar conclusiones sobre la población, el frecuentista elabora cómo se comportaría la estimación de la media si el experimento se repitiera.
- El experimento: Muestrear 10 manzanas, pesarlas, calcular el peso promedio.

Herramientas del Frecuentista

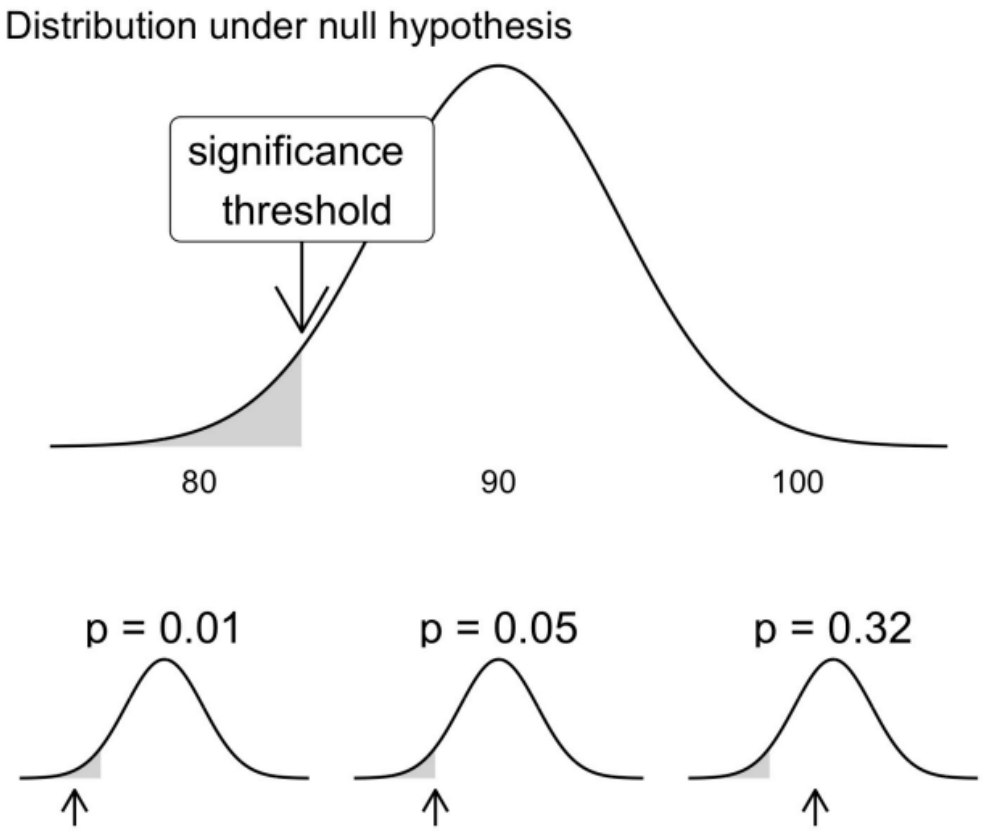
Dos herramientas para hacer declaraciones probabilísticas:

1. Pruebas de hipótesis
2. Intervalos de confianza

Ambas herramientas hacen declaraciones binarias claras, permitiendo decisiones definitivas.

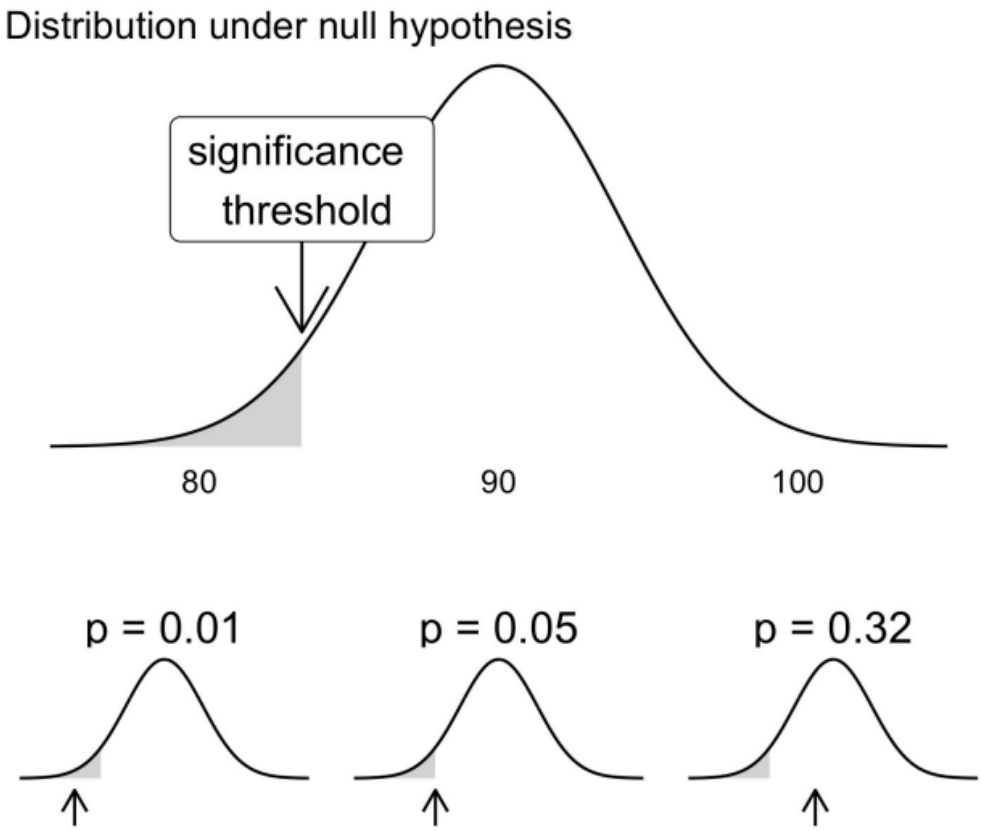
Prueba de Hipótesis

- Una prueba de hipótesis es un método para decidir si los datos apoyan una hipótesis.
- En el caso de las manzanas: ¿El promedio observado de 79 gramos aún apoya la hipótesis de 90 gramos?
- 90 gramos es la hipótesis nula.



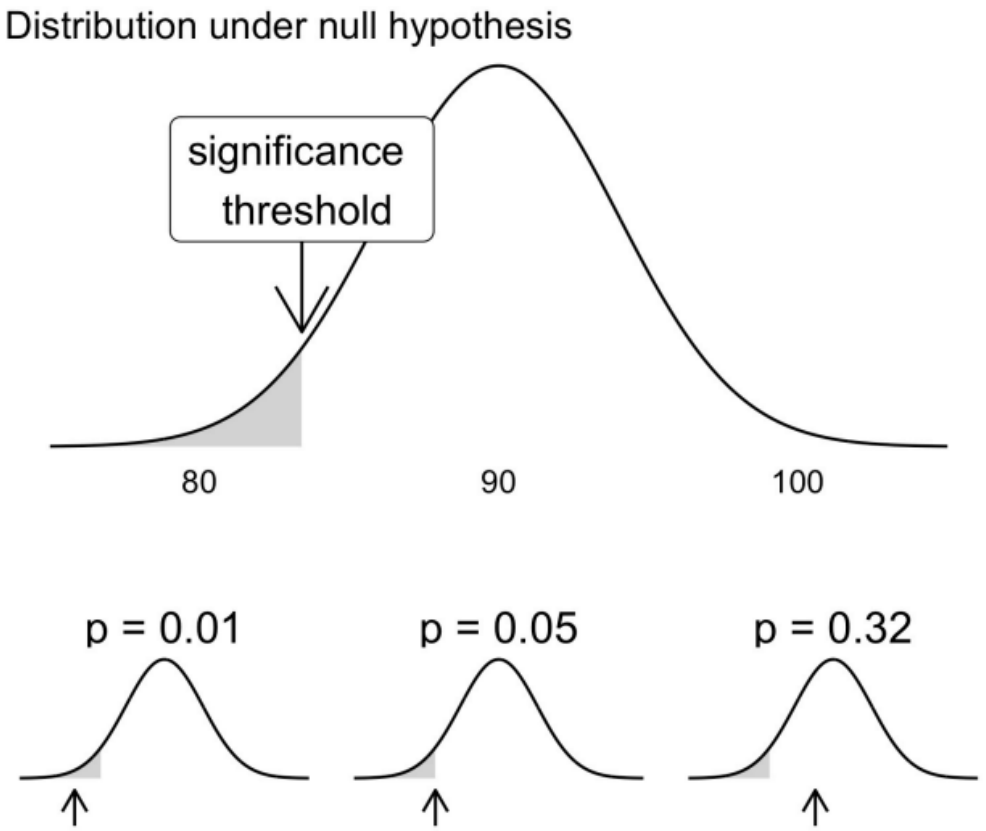
El Valor p

- La prueba t calcula un valor p que indica qué tan probable es un resultado de 79 (o más extremo) si 90 gramos es el peso promedio verdadero.
- Si el valor p está por debajo del nivel de confianza (frecuentemente 5%), se rechaza la hipótesis de 90 gramos.



Tasa de Error

Si la hipótesis nula es realmente verdadera, la prueba rechazaría falsamente la hipótesis en el 5% de los casos (1 de cada 20).



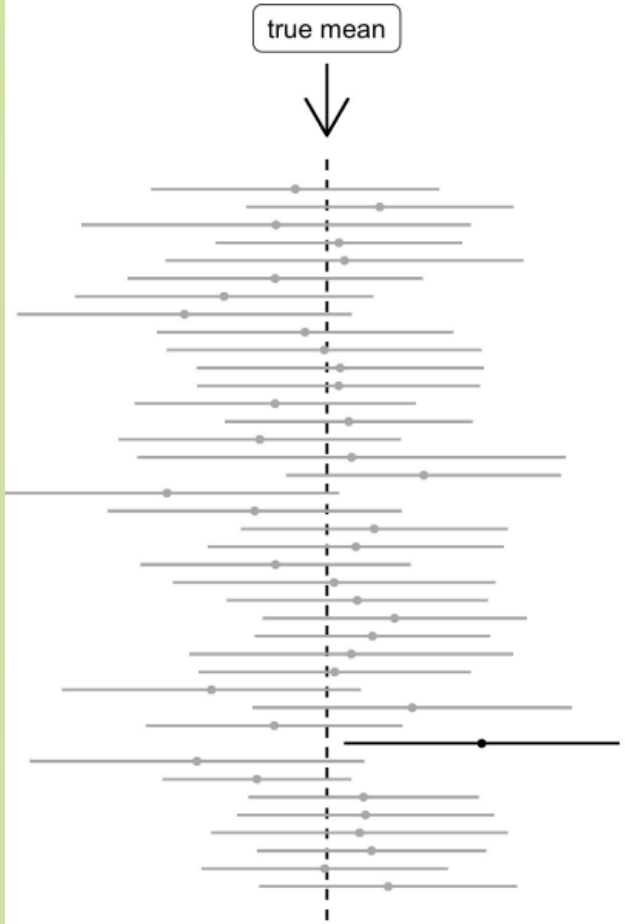
Críticas al NHST

La prueba de significancia de hipótesis nula (NHST) es popular pero criticada por:

- Ser simplista
- Resultar en muchos hallazgos falsos positivos debido al "p-hacking"
- Problemas con pruebas múltiples

“Hackear P”





https://www.youtube.com/watch?v=i60wwZDA1CI&t=85s

Intervalos de Confianza

- Los intervalos de confianza son una alternativa a las pruebas de hipótesis.
- Cuantifican qué tan cierta fue la estimación: cuanto más estrecho el intervalo, más cierta la estimación.

¿Qué Es un Intervalo de Confianza?

- Es la región que probablemente cubre el parámetro verdadero (asumido como fijo pero desconocido).
- ERROR COMÚN: "Hay un 95% de probabilidad de que el parámetro verdadero caiga en este intervalo."

¡INCORRECTO!

Interpretación Correcta

- Interpretación frecuentista del intervalo de confianza del 95%:
- Si el modelador repitiera el experimento muchas veces, el 95% de las veces el intervalo de confianza correspondiente cubriría el parámetro verdadero.
- Una repetición significa: extraer otras 10 manzanas y calcular intervalos de confianza de esa nueva muestra.

Diferencia con Bayesianos

Si el modelador quiere decir "hay un 95% de probabilidad de que el parámetro esté en este intervalo", debe usar intervalos de credibilidad bayesianos.

Fortalezas

✓ La inferencia frecuentista permite tomar decisiones. Esta simplicidad es una razón de su popularidad en publicaciones científicas y decisiones de negocios.

✓ Una vez que entiendes la inferencia frecuentista, puedes entender la sección de análisis de muchos artículos de investigación.

Fortalezas

✓ Los métodos frecuentistas son rápidos de computar, frecuentemente más rápidos que métodos de inferencia bayesiana o machine learning.

✓ Comparado con el bayesianismo, no se requiere información previa sobre los parámetros.

Limitaciones

✗ El frecuentismo incentiva a los modeladores a simplificar excesivamente las preguntas en preguntas de sí-o-no.

✗ El enfoque en valores p fomenta el "p-hacking": la búsqueda de resultados significativos para publicar artículos científicos, lo que lleva a muchos hallazgos falsos.

Limitaciones

✗ La interpretación frecuentista de la probabilidad puede ser incómoda, especialmente para intervalos de confianza. Los intervalos de credibilidad bayesianos parecen tener una interpretación más "natural" de la incertidumbre.

✗ El análisis frecuentista depende no solo de los datos sino también del diseño experimental (viola el principio de verosimilitud).