Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería



1INF02 APRENDIZAJE DE MÁQUINA

Análisis Estadístico y Tratamiento de Datos

Prof. Rodrigo Uribe

Organización de las Clases

(10 min) Preguntas y consultas.

(30 min) Respuesta *Vibe Quest.*

(45 min) Análisis Estadístico de Datos e Imputación de datos.



(10 min) Break

(45 min) Transformación de datos, datos atípicos y aumentación de datos.

(30 min) Ejercicios y/o Dinámica.

(10 min) Preguntas *Vibe Quest.*



Respuestas Vibe Quest

- Explora escenarios donde los métodos de ensamble NO son la mejor opción. ¿Existen tipos de datos, problemas o contextos donde un modelo simple supere consistentemente a los ensambles? Diseña experimentos para identificar estos "puntos de quiebre" y propón explicaciones teóricas.
- ¿Cuántos modelos base necesita realmente un ensamble? Investiga cómo determinar el número óptimo de estimadores considerando múltiples factores: rendimiento, tiempo de cómputo, memoria, y estabilidad. ¿Existe una fórmula universal o depende completamente del contexto?
- En los ensambles existe una tensión entre tener modelos diversos (que cometan errores diferentes) versus modelos precisos individualmente. ¿Cómo medirías y optimizarías esta tensión? ¿Qué estrategias creativas existen para maximizar ambas características?
- Los ensambles clásicos asumen datos estáticos, pero el mundo real es dinámico. ¿Cómo adaptarías Random Forest o AdaBoost para problemas donde los datos cambian constantemente? Propón y evalúa estrategias para "ensambles adaptativos" que evolucionen con el tiempo.

¿Qué es y por qué importa el tratamiento de datos?

¿Por Qué Importa el Tratamiento de Datos?

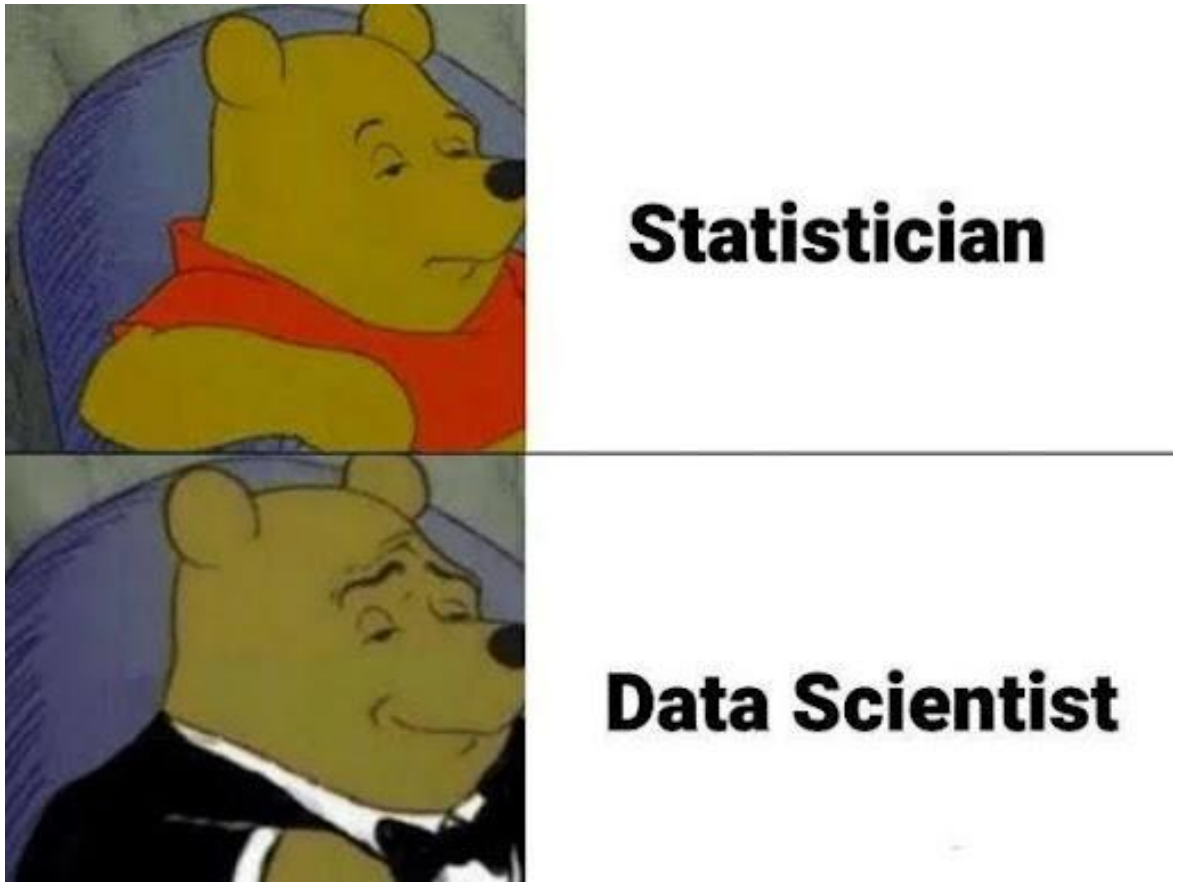
- Cada decisión de preprocesamiento incorpora supuestos estadísticos o prácticos
- Estos supuestos afectan:
  - Validez de la inferencia estadística (valores p, intervalos de confianza)
  - Interpretabilidad de los coeficientes del modelo
  - Generalizabilidad de las predicciones
  - Reproducibilidad de los hallazgos de investigación
- El tratamiento de datos no es "limpieza" — es modelado
- Malas decisiones pueden invalidar análisis correctos

Perspectivas Clásica vs. Moderna

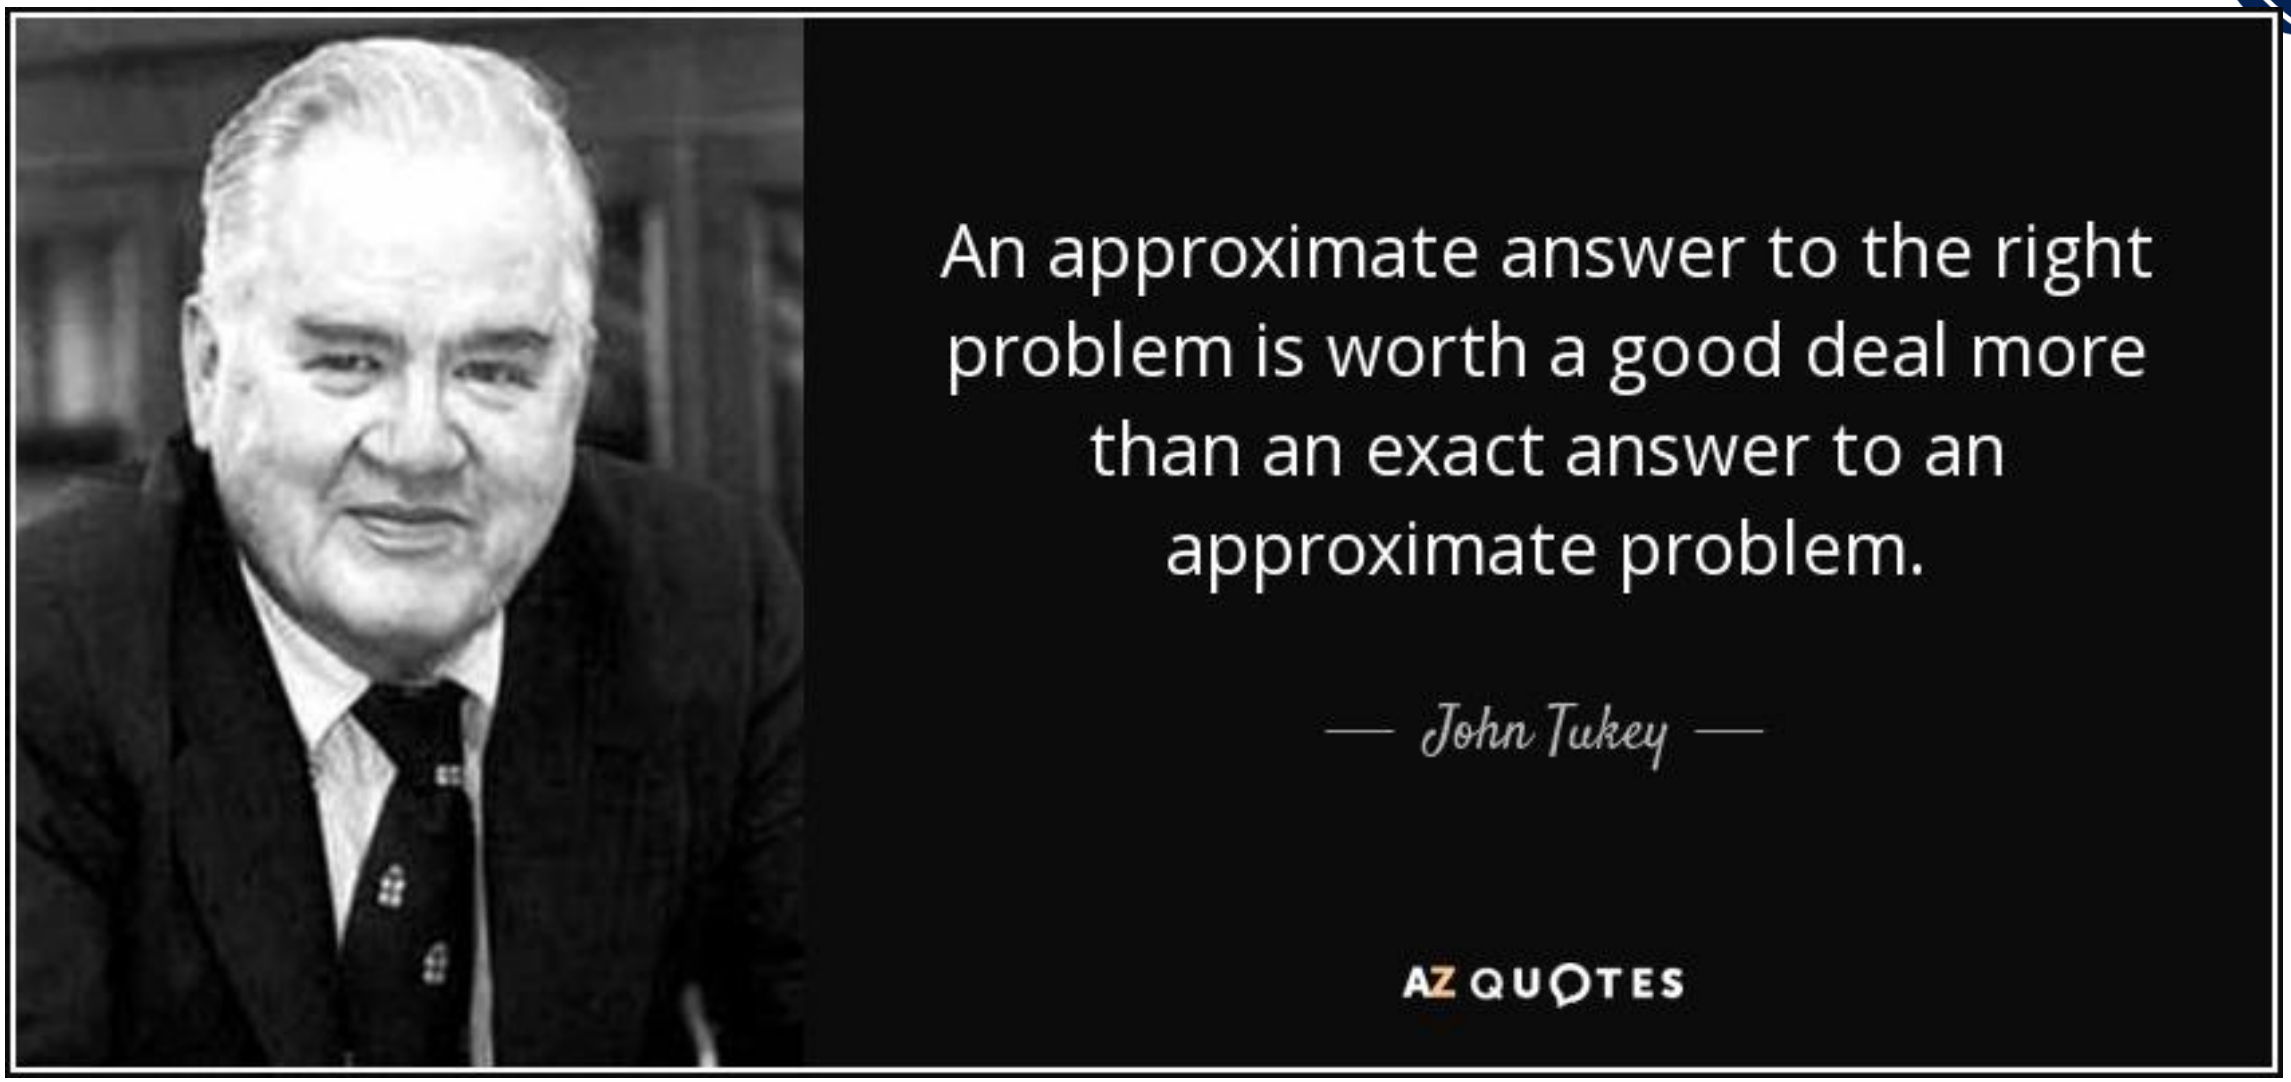
- Enfoques Estadístico:
  - Objetivo: comprender los datos
  - Enfoque en supuestos y diagnósticos
  - Cuantifica apropiadamente la incertidumbre
- Enfoques de Aprendizaje de Maquina:
  - Objetivo: extraer estructura
  - Patrones ≠ significado
  - Puede ignorar consecuencias inferenciales
  - Interpretación posterior

¿Qué mentalidad tiene la ciencia de datos?

Todo esta en la mentalidad...



Profession	Average salary
Data Scientist	$96494
Machine Learning Engineer	$111,600
Data Visualisation Specialist	$76065
Data Engineer	$116,591
Big Data Engineer	$114,800
Data Architect	$115,800
Data Analyst	$73372
Data Engineer	$1,02,864
Business Intelligence Analyst	$67,600
Business Analyst	$72,000
Data Analyst	$62,453
Statistician	$72,100
Analytics Engineer	$111,480



¿Quién es John W. Tukey?

¿Qué es el Análisis Exploratorio de Datos?

- AED: Una filosofía y conjunto de técnicas para entender los datos
- Desarrollado principalmente por John Tukey (1915-2000)
- Principio clave: Dejar que los datos hablen antes de imponer modelos
- Objetivos del AED:
  - Descubrir patrones, relaciones y anomalías
  - Verificar supuestos antes del modelado formal
  - Generar hipótesis (no probarlas)
  - Guiar la selección y especificación del modelo

La Revolución de John Tukey

- "El Futuro del Análisis de Datos" (1962)
  - Desafió el dominio de la estadística confirmatoria
  - Argumentó que el análisis de datos es más amplio que la inferencia estadística
- "Análisis Exploratorio de Datos" (1977)
  - Introdujo diagramas de caja, gráficos de tallo y hoja
  - Enfatizó métodos robustos/resistentes
  - Filosofía: "trabajo de detective" en estadística
- Cita famosa: "Es mejor una respuesta aproximada a la pregunta correcta... que una respuesta exacta a la pregunta equivocada"

Fuente: Tukey, J.W. (1962, 1977)

AED vs. Análisis de Datos Confirmatorio

- **Enfoque Clásico (Confirmatorio):**
  - Problema → Datos → Modelo → Análisis → Conclusiones **(análogo al método científico)**
  - El modelo o hipótesis se especifica antes de ver los datos
  - Enfoque en prueba de hipótesis
- **Enfoque Exploratorio (AED):**
  - Problema → Datos → Análisis → Modelo → Conclusiones
  - El análisis informa la elección del modelo
  - Enfoque en descubrimiento de patrones
- Diferencia clave: ¿Cuándo se especifica el modelo?

¿Servirá la estadística confirmatoria?

Fuente: Manual NIST/SEMATECH de Métodos Estadísticos

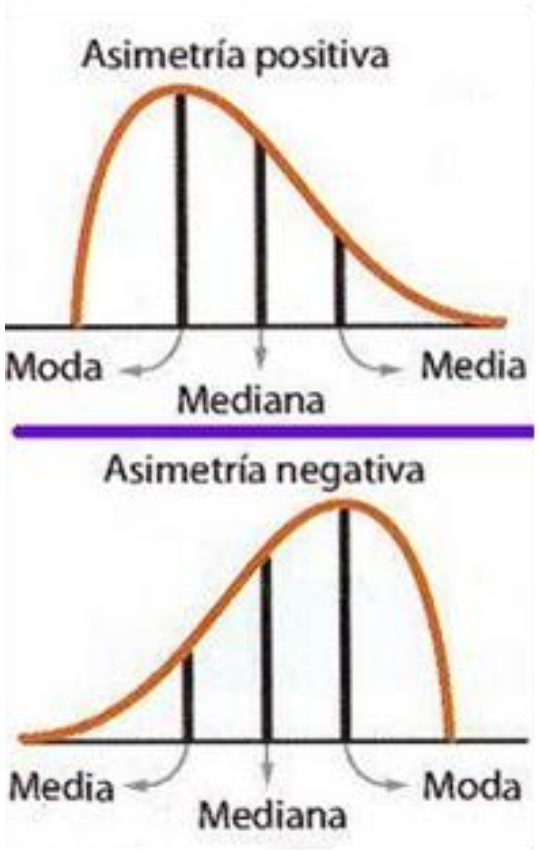
Cuatro Tipos de Análisis Exploratorio

1. **Univariado No Gráfico**
   - Estadísticas resumidas: media, mediana, varianza, asimetría, curtosis
2. **Univariado Gráfico**
   - Histogramas, diagramas de caja, gráficos de tallo y hoja, gráficos Q-Q
3. **Multivariado No Gráfico**
   - Matrices de correlación, tabulaciones cruzadas, estructuras de covarianza
4. **Multivariado Gráfico**
   - Matrices de diagramas de dispersión, coordenadas paralelas, mapas de calor

Fuente: CMU Statistics 309

Medidas de Tendencia Central

- Media (Promedio Aritmético)
  - Suma de valores dividida por el conteo
  - Sensible a valores atípicos
  - Mejor para distribuciones simétricas
- Mediana (Percentil 50)
  - Valor central cuando los datos están ordenados
  - Resistente a valores atípicos
  - Mejor para distribuciones asimétricas
- Moda
  - Valor más frecuente
  - Útil para datos categóricos



¿Para qué sirve una medida de tendencia central?

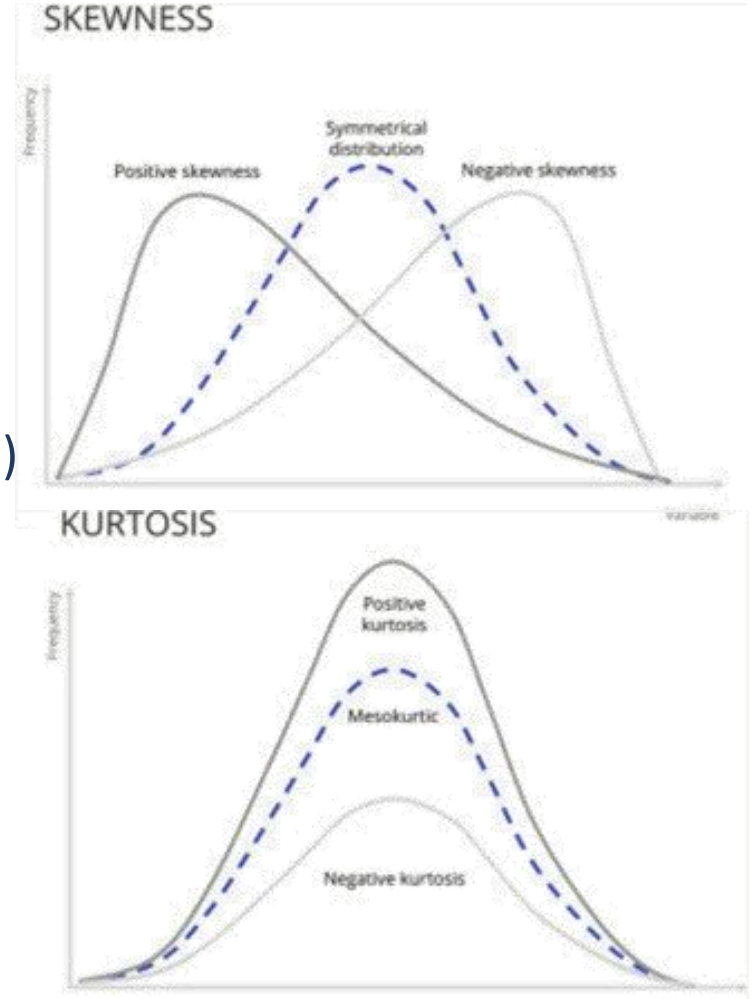
Medidas de Dispersión

- Varianza y Desviación Estándar
  - Varianza: Promedio de desviaciones cuadradas de la media
  - DE: Raíz cuadrada de la varianza (mismas unidades que los datos)
  - Sensible a valores atípicos
- Rango Intercuartílico (RIC)
  - RIC = Q3 - Q1 (50% central de los datos)
  - Resistente a valores atípicos
- Rango
  - Máximo menos mínimo
  - Altamente sensible a valores atípicos

¿Para qué sirve una medida de dispersión?

Medidas de Forma de la Distribución

- Asimetría (Skewness)
  - Mide la asimetría de la distribución
  - Asimetría = 0: Simétrica
  - Asimetría > 0: Sesgada a la derecha (cola derecha larga)
  - Asimetría < 0: Sesgada a la izquierda (cola izquierda larga)
- Curtosis
  - Mide el "peso de las colas" de la distribución
  - Curtosis = 3: Normal (mesocúrtica)
  - Curtosis > 3: Colas pesadas (leptocúrtica)
  - Curtosis < 3: Colas ligeras (platicúrtica)



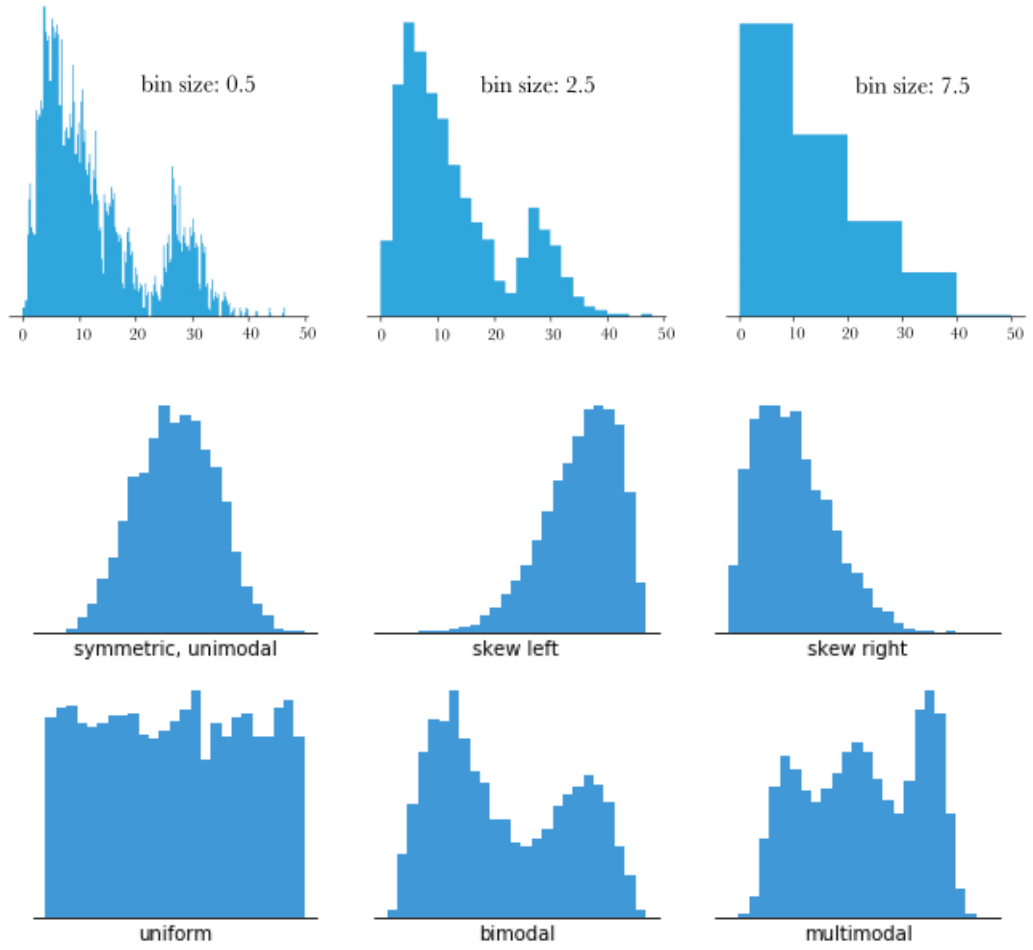
¿Para qué sirve saber la forma de la distribución?

Interpretando la Asimetría en la Práctica

- Distribuciones sesgadas a la derecha (asimetría positiva):
  - Media > Mediana > Moda
  - Común en: ingresos, precios, tiempos de reacción
  - Considerar: transformación logarítmica
- Distribuciones sesgadas a la izquierda (asimetría negativa):
  - Media < Mediana < Moda
  - Común en: edad de muerte, puntajes de exámenes fáciles
  - Considerar: transformación cuadrática o exponencial
- Regla general: |asimetría| > 1 indica sesgo sustancial

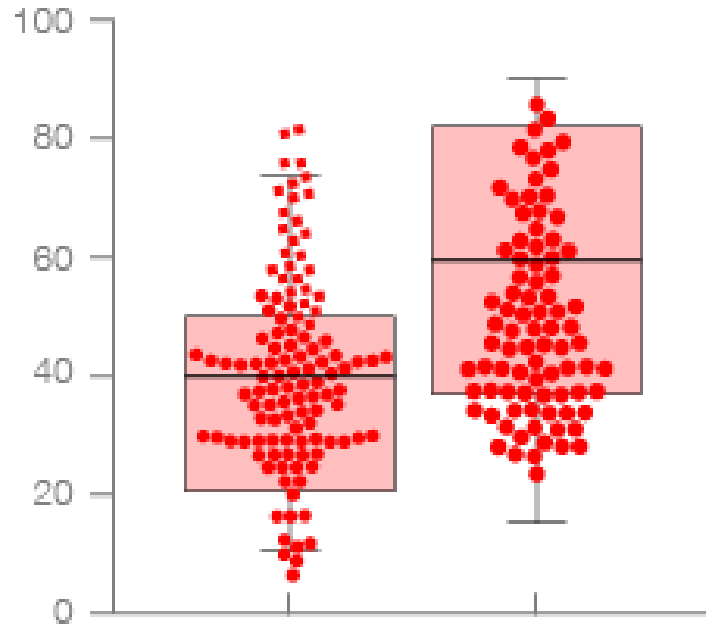
Histogramas: Construcción e Interpretación

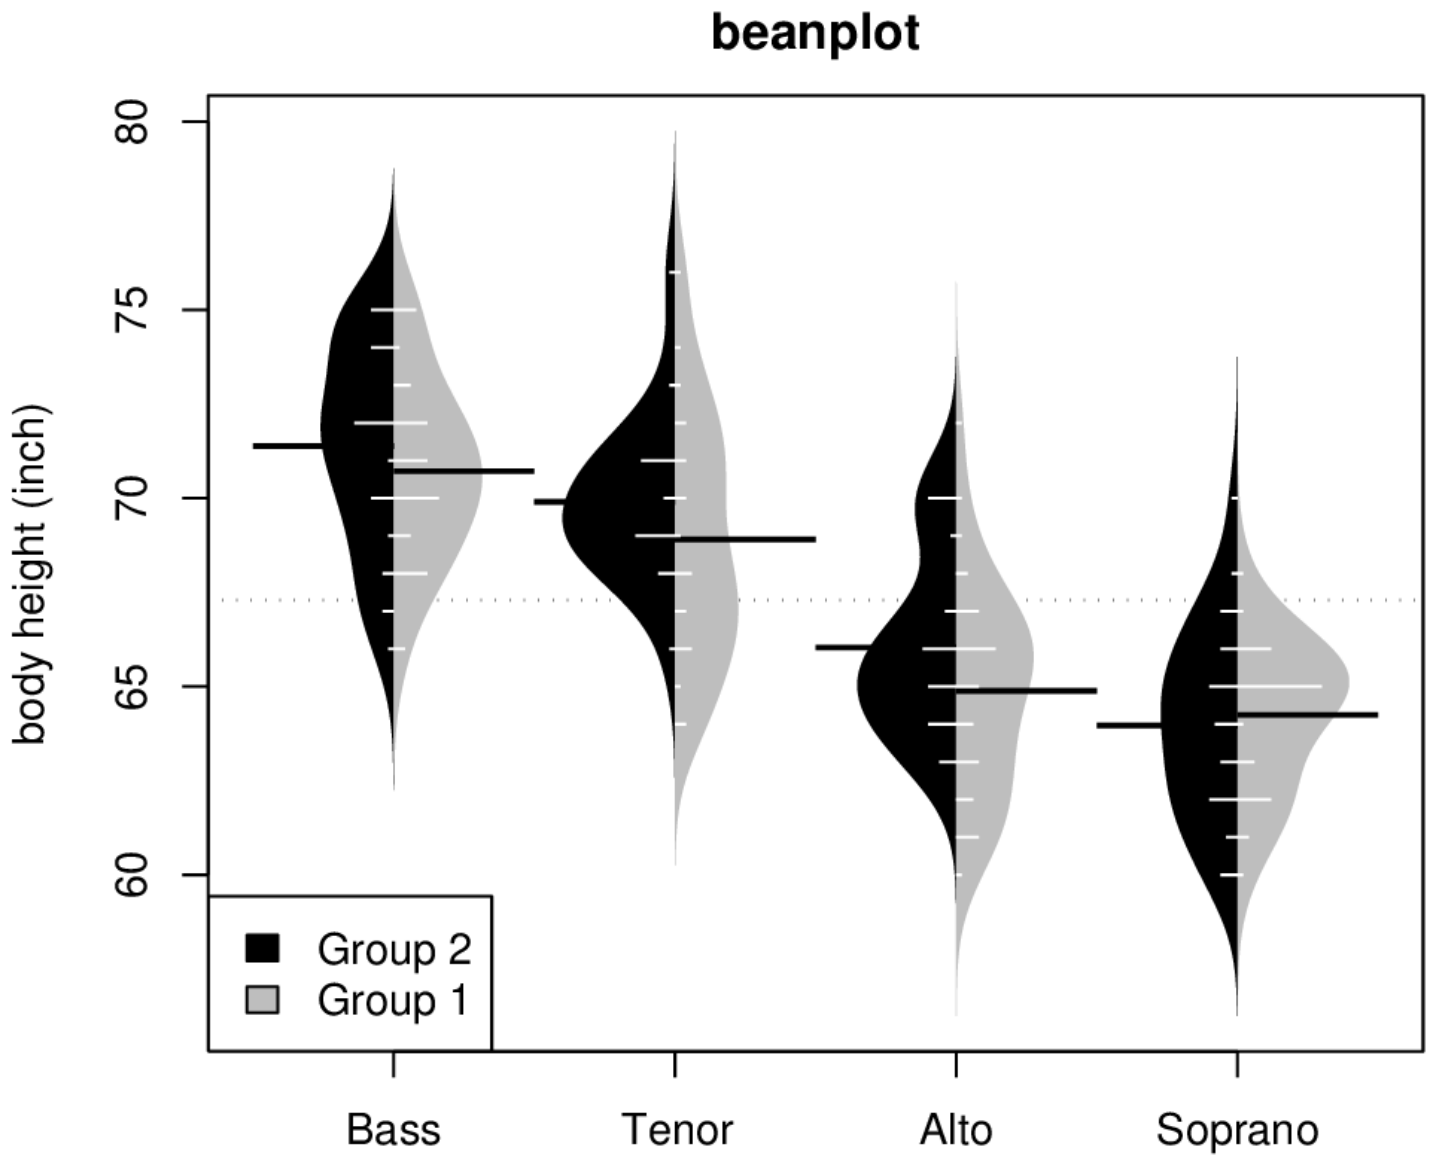
- Propósito: Visualizar la forma de la distribución
- Decisiones de construcción:
  - El número de intervalos afecta la apariencia
  - Muy pocos intervalos: se pierde detalle
  - Demasiados intervalos: muy ruidoso
  - Reglas: Sturges, Scott, Freedman-Diaconis
- Qué buscar:
  - Forma general (simétrica, sesgada, bimodal)
  - Centro y dispersión
  - Valores atípicos y brechas
  - Características inesperadas



Diagramas de Caja: Resumen de Cinco Números de Tukey

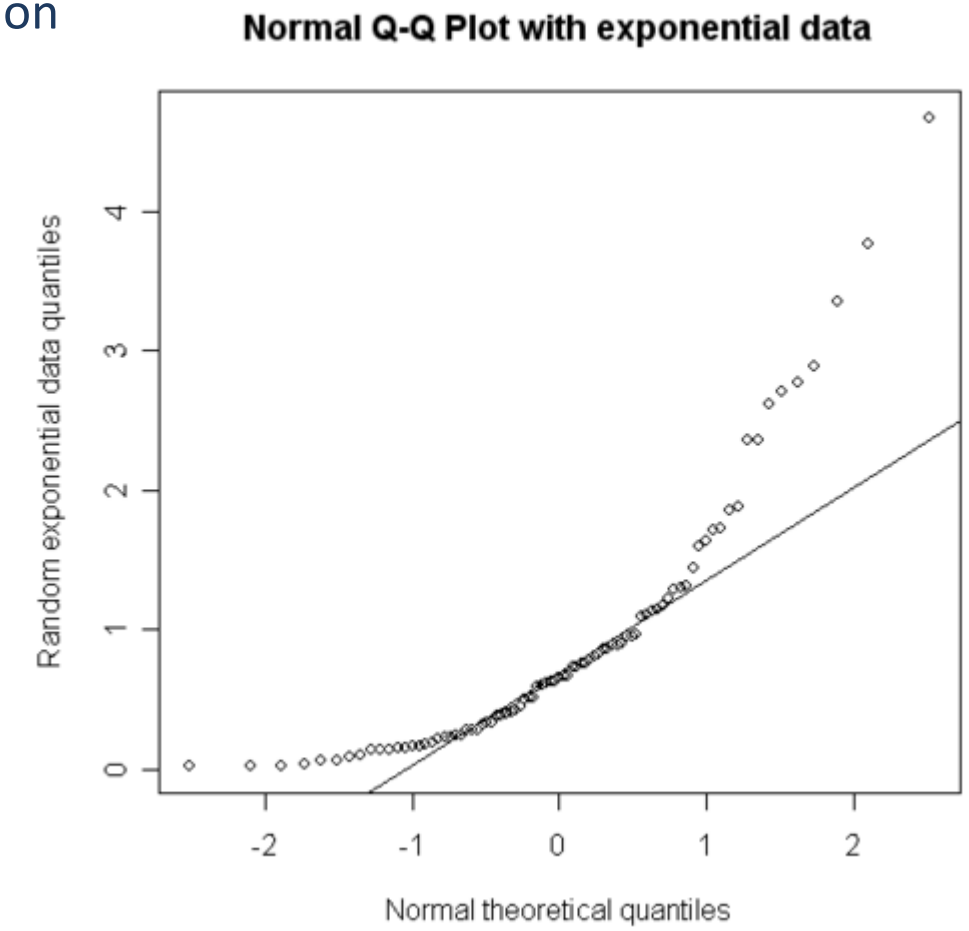
- Componentes de un diagrama de caja:
  - Caja: Q1 (percentil 25) a Q3 (percentil 75)
  - Línea dentro de la caja: Mediana (Q2)
  - Bigotes: Se extienden hasta el valor extremo no atípico
  - Puntos más allá de los bigotes: Posibles valores atípicos
- Cálculo de bigotes (regla de Tukey):
  - Cerca inferior: Q1 - 1.5 × RIC
  - Cerca superior: Q3 + 1.5 × RIC
- Ventajas: Compacto, muestra valores atípicos, fácil comparar grupos




beanplot
body height (inch)
80
75
70
65
60
Group 2
Group 1
Bass
Tenor
Alto
Soprano

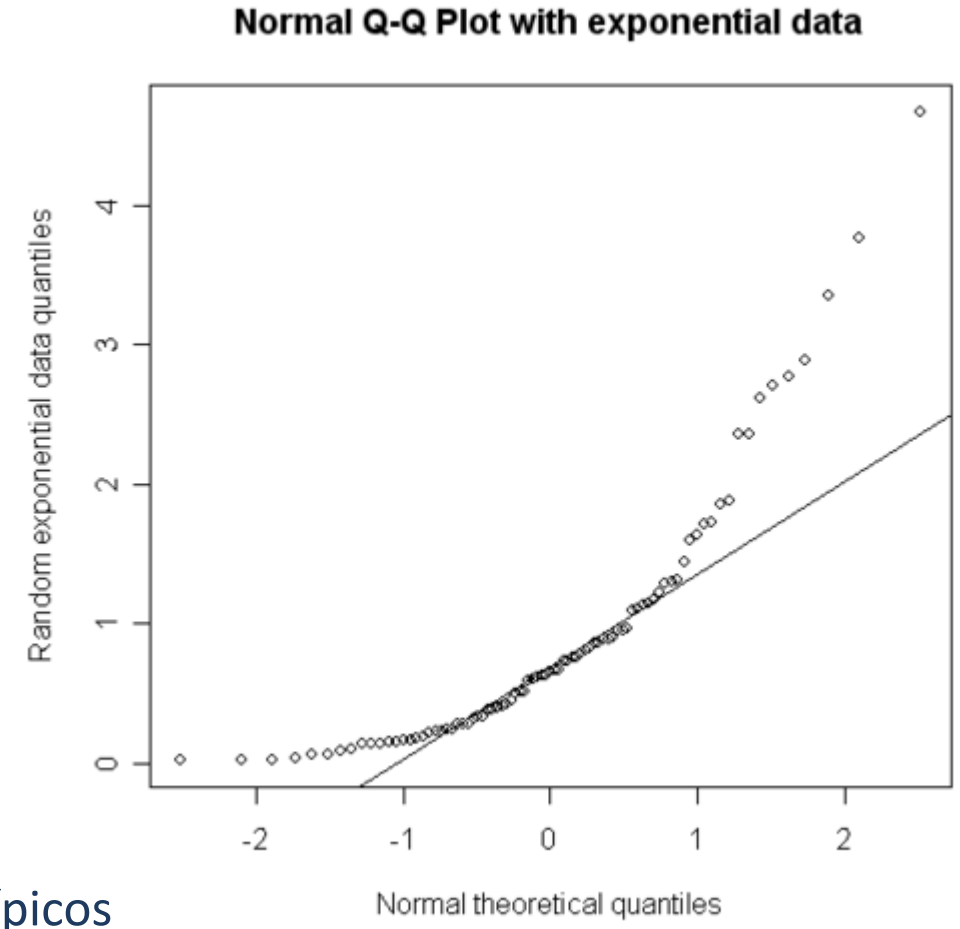
Gráficos Q-Q: Gráficos Cuantil-Cuantil

- Propósito: Comparar distribución muestral con distribución teórica
- Construcción:
  - Eje X: Cuantiles teóricos (ej., de la normal)
  - Eje Y: Cuantiles muestrales (datos ordenados)
  - Si las distribuciones coinciden: Puntos caen en línea diagonal
- Uso más común: Gráfico Q-Q normal
  - Evalúa el supuesto de normalidad
  - Crítico para muchas pruebas estadísticas
  - Importante para diagnósticos de regresión



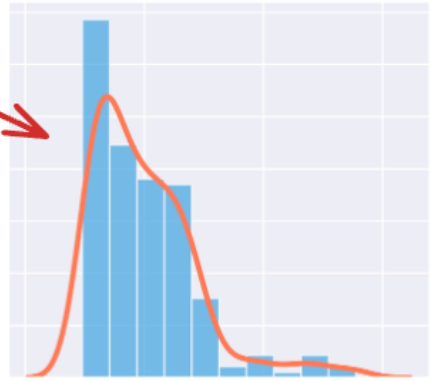
Interpretando Gráficos Q-Q

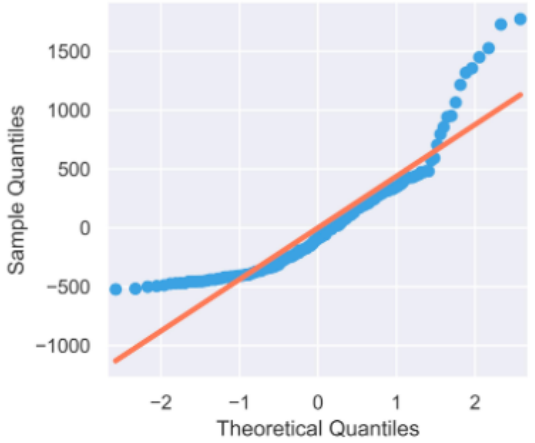
- Puntos sobre la línea:
  - Los datos siguen la distribución de referencia
- Curva en forma de S:
  - Los datos tienen colas más ligeras que la referencia
- Forma de S invertida:
  - Los datos tienen colas más pesadas que la referencia
- Curvado hacia arriba en ambos extremos:
  - Los datos están sesgados a la derecha
- Curvado hacia abajo en ambos extremos:
  - Los datos están sesgados a la izquierda
- Puntos individuales fuera de línea en extremos: Valores atípicos



Gráficos Q-Q: Gráficos Cuantil-Cuantil

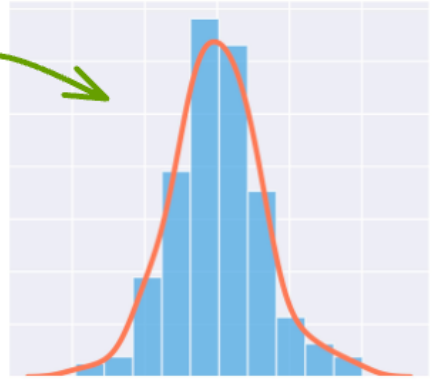
Not normal distribution

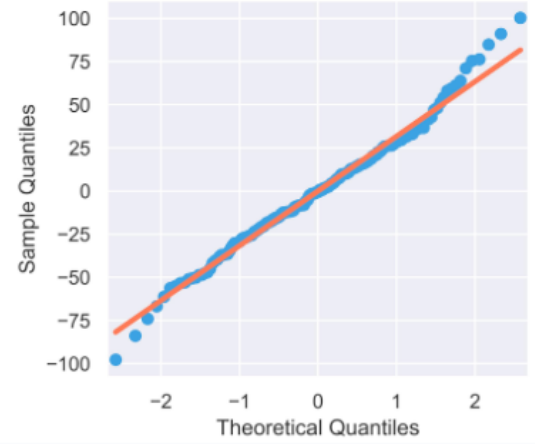




Significant Deviations from reference line

Normal distribution

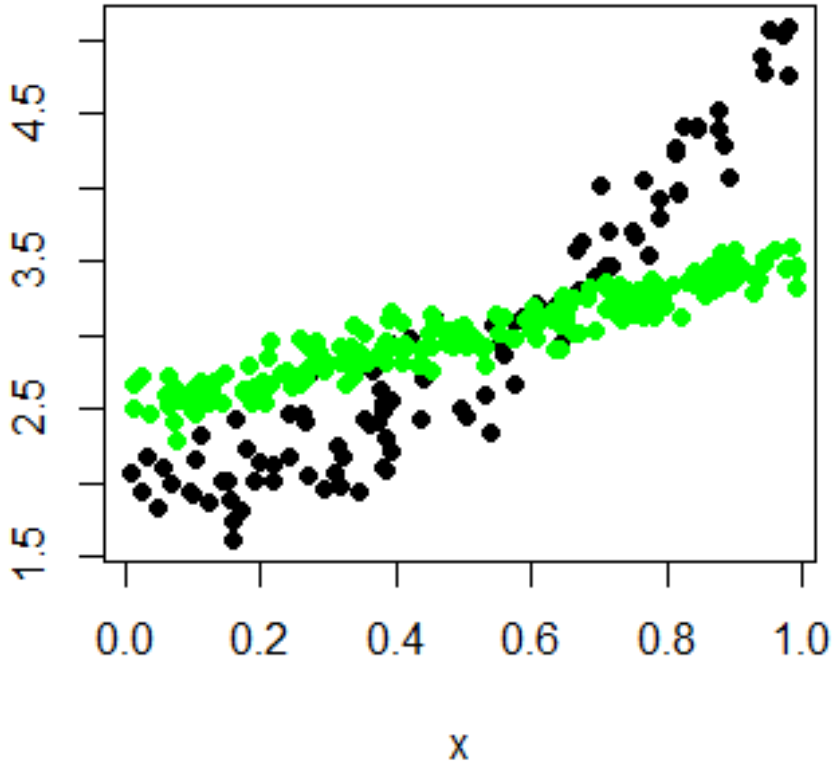




Few deviations from the reference line

Diagramas de Dispersión: Relaciones Bivariadas

- Propósito: Visualizar relación entre dos variables continuas
- Qué examinar:
  - Dirección: Asociación positiva, negativa o nula
  - Forma: Lineal, curva, agrupada
  - Fuerza: Qué tan apretados siguen el patrón los puntos
  - Valores atípicos: Puntos lejos del patrón principal
- Idea clave: Correlación ≠ Causalidad
  - Los diagramas de dispersión muestran solo asociación
  - No pueden determinar causa y efecto

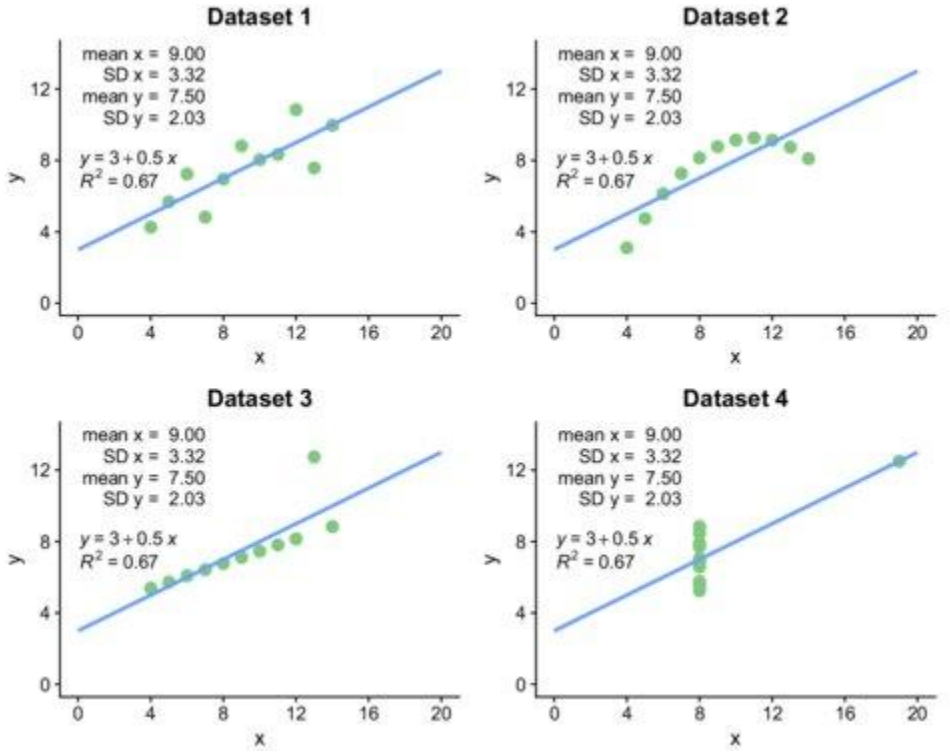


Coeficientes de Correlación

- Correlación de Pearson (r):
  - Mide asociación lineal
  - Rango: -1 a +1
  - r = 0: Sin relación lineal (¡puede haber no lineal!)
  - Sensible a valores atípicos
- Correlación de Spearman (ρ):
  - Mide asociación monótona
  - Basada en rangos, no en valores
  - Más robusta a valores atípicos
- Precaución: Siempre grafique los datos — la correlación puede engañar

El Cuarteto de Anscombe: Por qué Importa la Visualización

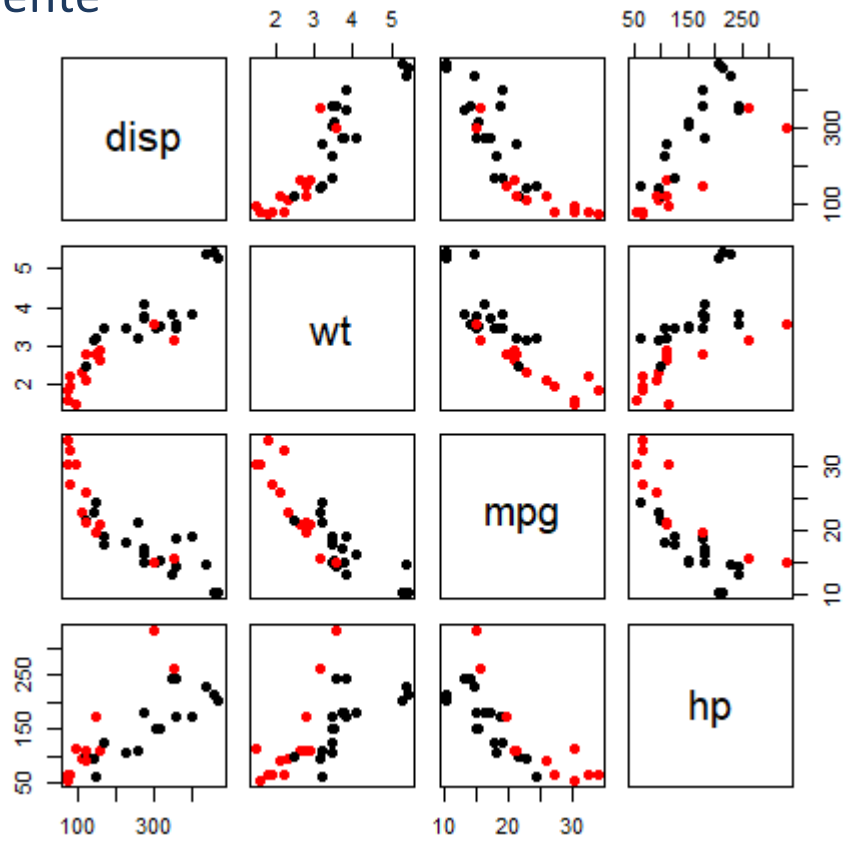
- Cuatro conjuntos de datos con estadísticas resumidas idénticas:
  - Misma media de X e Y
  - Misma varianza de X e Y
  - Misma correlación (r = 0.816)
  - Misma línea de regresión
- ¡Pero patrones completamente diferentes al graficar!
  - Conjunto 1: Relación lineal
  - Conjunto 2: No lineal (cuadrática)
  - Conjunto 3: Lineal con un valor atípico
  - Conjunto 4: Línea vertical con un punto influyente
- Lección: Siempre visualice sus datos



Fuente: Anscombe (1973)

Matrices de Diagramas de Dispersión

- Propósito: Examinar todas las relaciones por pares simultáneamente
- Estructura:
  - Cuadrícula de diagramas de dispersión
  - Cada variable contra todas las demás
  - La diagonal a menudo muestra histogramas o densidades
- Útil para:
  - Identificar qué predictores se relacionan con la respuesta
  - Detectar multicolinealidad entre predictores
  - Encontrar grupos o clusters en los datos
  - Detectar valores atípicos que afectan múltiples variables



¿Cuáles son más utilizadas?

Matrices de Correlación con Mapas de Calor

- Matriz de correlación:
  - Tabla mostrando correlaciones por pares
  - Simétrica: r(X,Y) = r(Y,X)
  - Diagonal = 1 (variable correlacionada consigo misma)
- Visualización de mapa de calor:
  - Codifica por colores la fuerza de correlación
  - Fácil detectar grupos de variables relacionadas
  - Identifica potencial multicolinealidad
- Señales de alerta:
  - Correlaciones > 0.8 entre predictores
  - Puede ser necesario eliminar o combinar variables

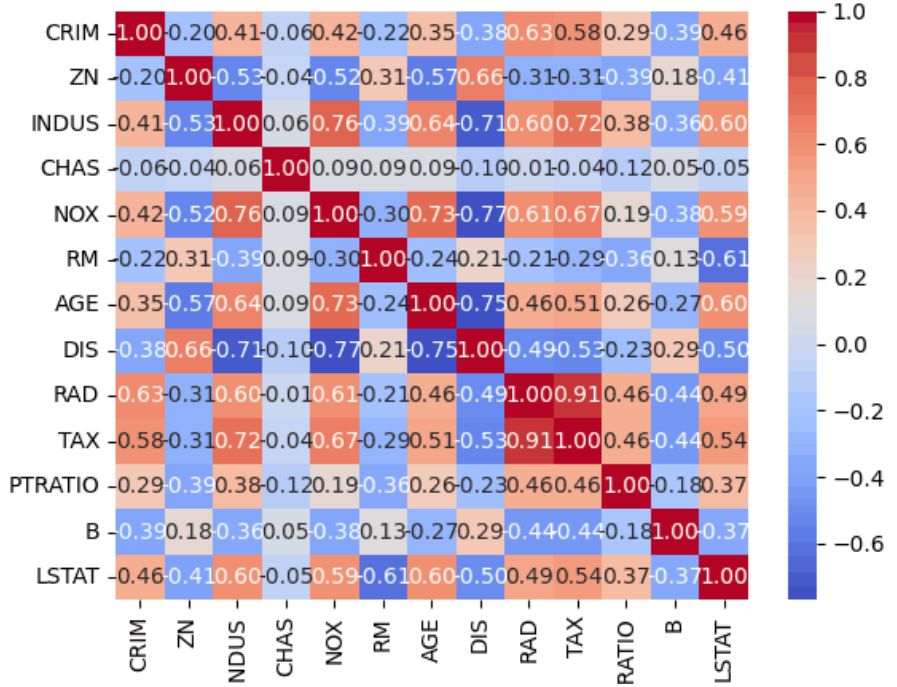
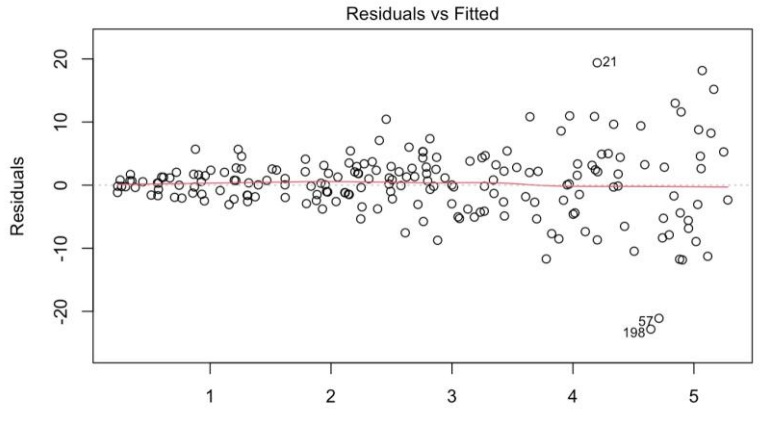
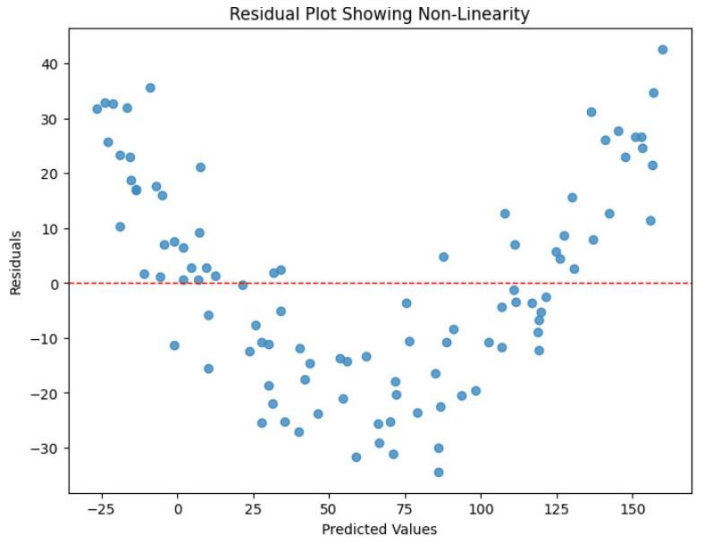


Gráfico de residuos

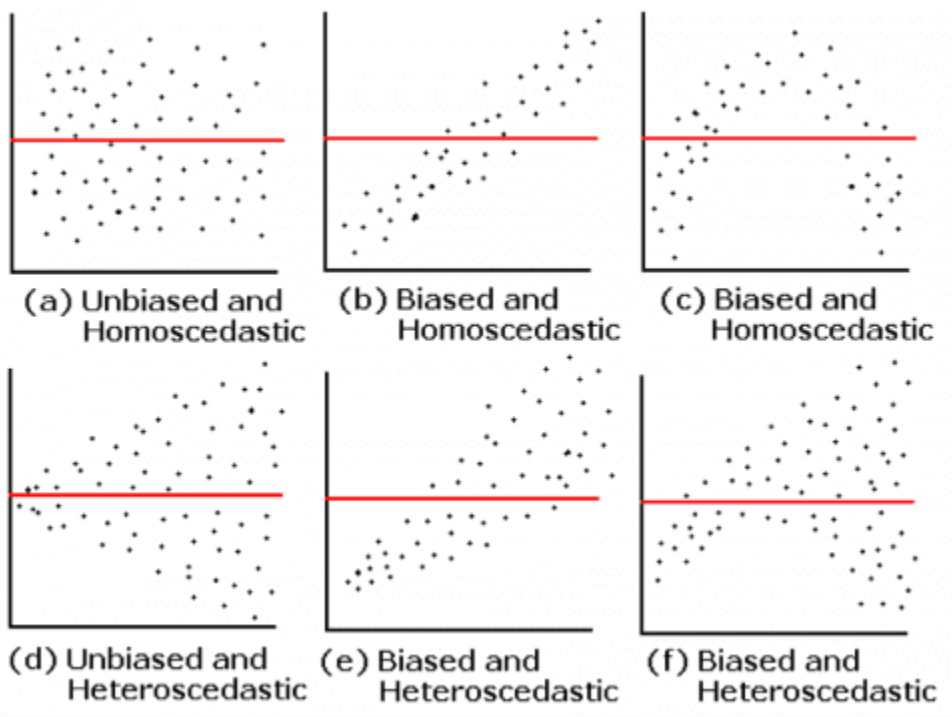
- Residuo: Valor observado menos valor ajustado
  - $e_i = Y_i - \hat{Y}_i$
- ¿Por qué analizar residuos?
  - Los supuestos son sobre errores, no sobre datos crudos
  - Los residuos estiman los verdaderos errores
  - Patrones en residuos indican problemas del modelo
  - "Un R^2 alto no significa que el modelo ajuste bien"
  - Los gráficos de residuos revelan lo que R^2 oculta





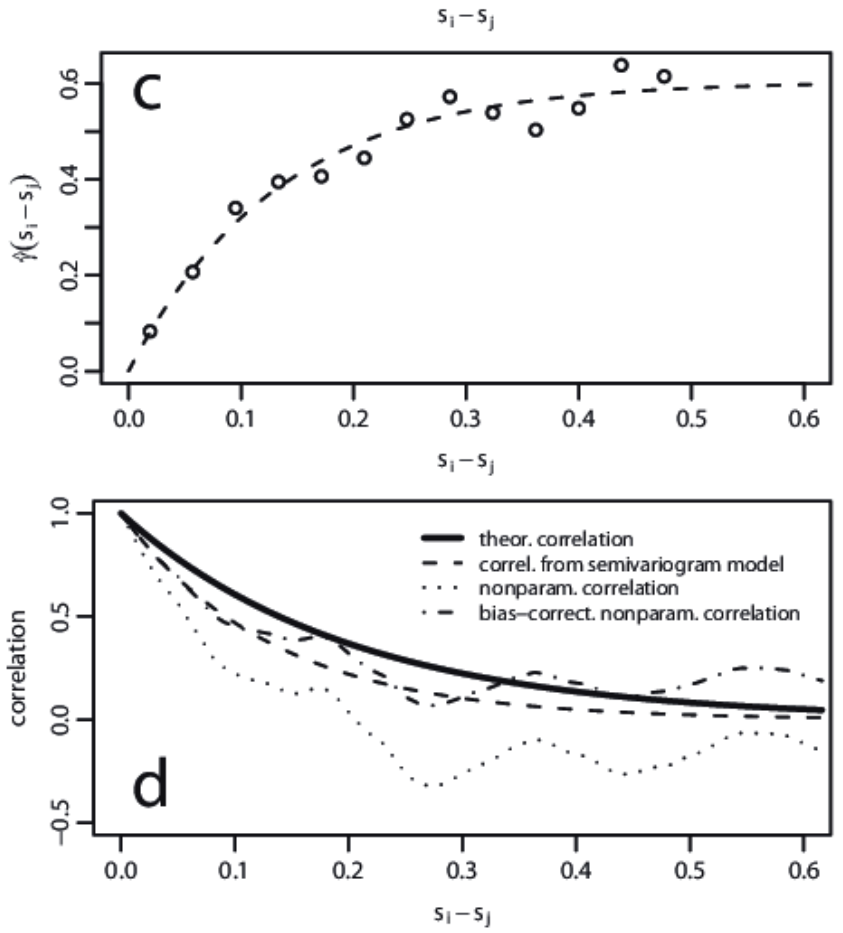
Diagnosticando Heterocedasticidad

- Heterocedasticidad: Varianza del error no constante
- Síntoma: Gráfico de residuos en forma de embudo
  - La dispersión aumenta (o disminuye) con valores ajustados
- Consecuencias:
  - Las estimaciones MCO siguen siendo insesgadas
  - Pero los errores estándar están mal
  - Intervalos de confianza inválidos
  - Pruebas de hipótesis no confiables
- Soluciones:
  - Transformar Y (ej., log)
  - Mínimos cuadrados ponderados
  - Errores estándar robustos



Variograma y Autocorrelación Espacial

- Autocorrelación espacial:
  - Valores cercanos espacialmente tienden a ser más similares que valores distantes.
  - Indica dependencia espacial en datos georreferenciados (ej. precios vivienda, contaminación, rendimientos agrícolas).
  - Puede ser positiva (similitud entre vecinos), negativa o nula.
- Variograma:
  - Herramienta principal para cuantificar la autocorrelación espacial.
  - Mide la semivarianza γ(h) entre pares de puntos separados por distancia h (lag espacial).



Diagnosticando No Linealidad

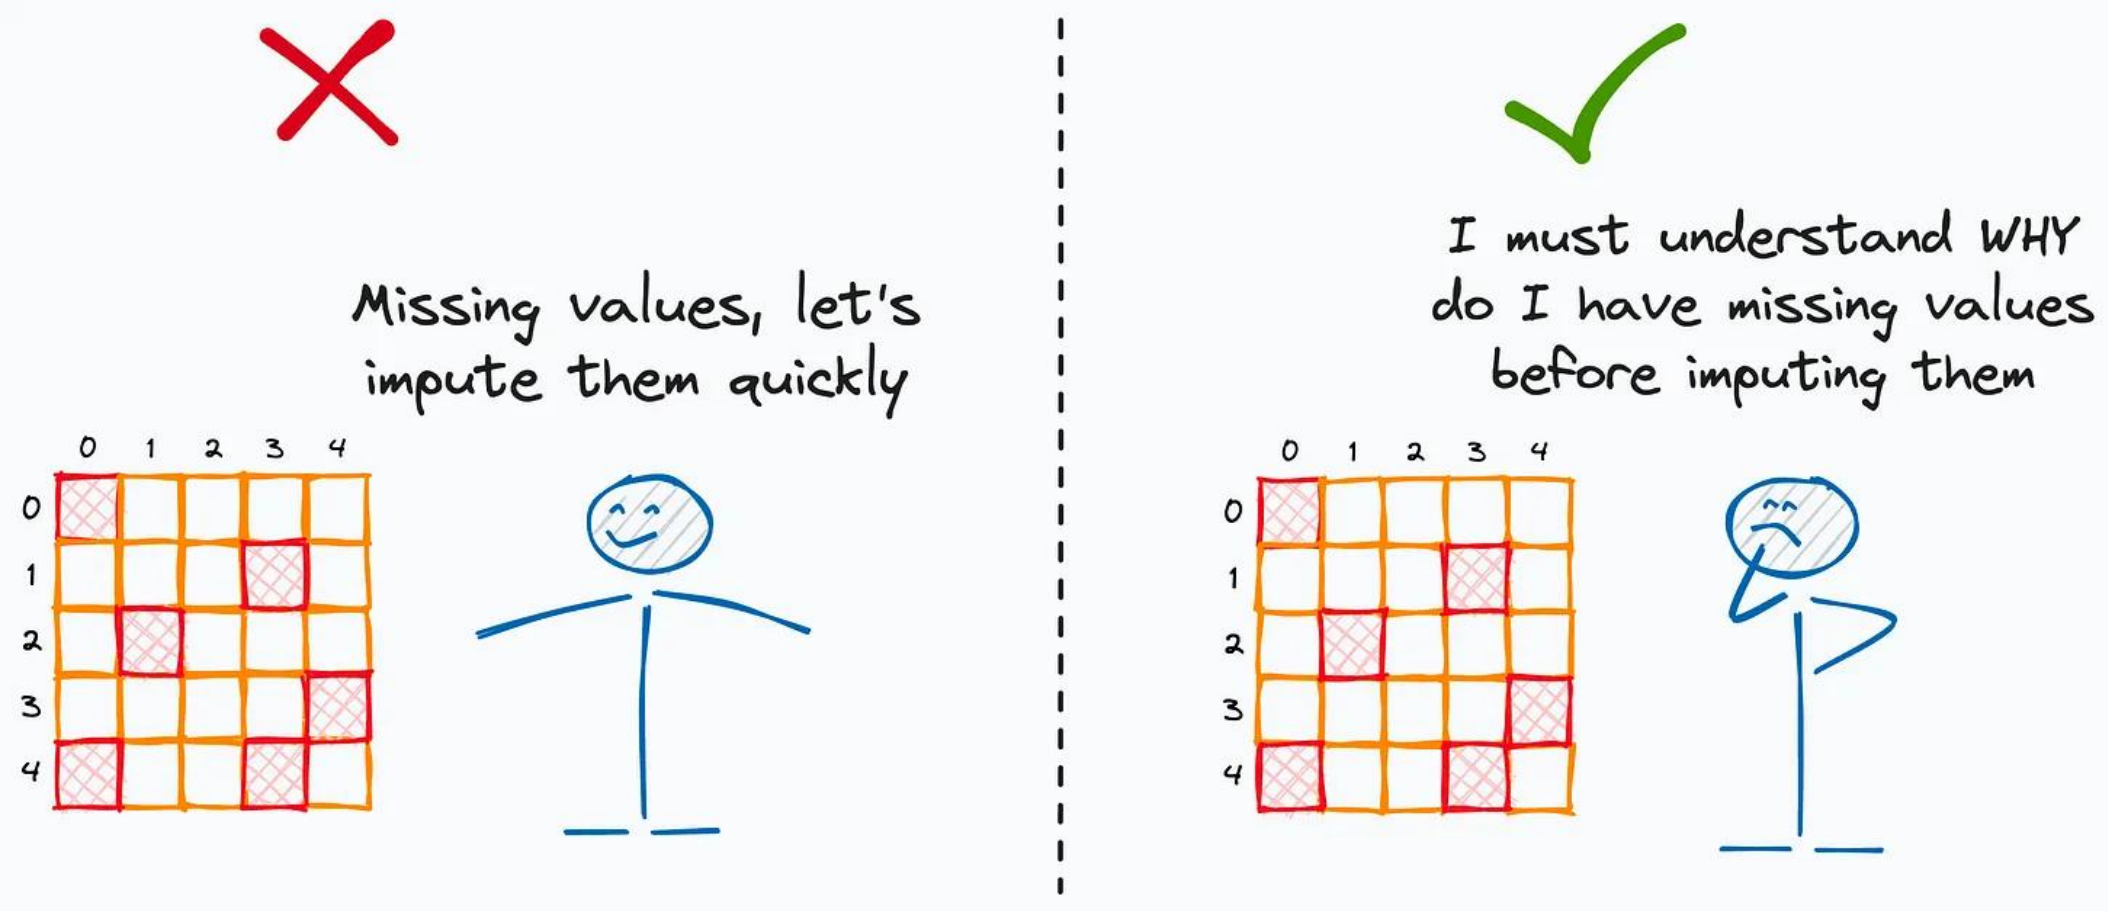
- Síntoma: Patrón curvo en residuos vs. ajustados
- Residuos en forma de U:
  - La relación verdadera es convexa (curva hacia arriba)
  - Puede necesitar término cuadrático o log(X)
- Forma de U invertida:
  - La relación verdadera es cóncava (curva hacia abajo)
  - Puede necesitar término cuadrático o sqrt(X)
- Soluciones:
  - Agregar términos polinomiales
  - Transformar predictores
  - Usar modelos no lineales

AED: Puntos Clave

- El AED no es opcional — **es esencial**
- Siempre visualice **antes** de modelar:
  - Las estadísticas pueden engañar (Cuarteto de Anscombe)
  - Los patrones guían la especificación del modelo
- Documente lo que encuentra:
  - Los hallazgos del AED informan todas las decisiones posteriores
  - La transparencia es esencial para la reproducibilidad

Pero...
¿Qué se puede hacer si faltan datos?
¿Qué casos pueden existir?

El Problema de los Datos Faltantes



El Problema de los Datos Faltantes

- Los datos faltantes son ubicuos en conjuntos de datos reales
- Consecuencias de ignorar datos faltantes:
  - Tamaño de muestra y potencia reducidos
  - Potencial sesgo en las estimaciones
  - Inferencia inválida (EE, valores p incorrectos)
- Idea clave:
  - Cómo manejar datos faltantes depende de
  - POR QUÉ los datos están faltantes
  - Esto es el "mecanismo de datos faltantes"

Marco de Datos Faltantes de Rubin (1976)

- Donald Rubin estableció la taxonomía fundamental
- Tres mecanismos:
  - Missing Completely At Random (MCAR): Faltante Completamente al Azar
  - Missing At Random (MAR): Faltante al Azar
  - Not Missing At Random (MNAR): Faltante No al Azar
- Principio crítico:
  - La validez de CUALQUIER método depende del mecanismo
  - Supuesto incorrecto → resultados sesgados
- El mecanismo usualmente es imposible de conocer con certeza

Fuente: Rubin (1976), U. Wisconsin STAT 992

MCAR: Faltante Completamente al Azar



MCAR: Faltante Completamente al Azar

- Definición:
  - Probabilidad de faltante no relacionada con NINGÚN dato
  - Ni valores observados ni no observados
- Ejemplos:
  - Muestra de laboratorio accidentalmente tirada
  - Falla aleatoria del equipo
  - Ítems seleccionados aleatoriamente para control de calidad
- Implicaciones:
  - El análisis de casos completos es insesgado
  - Pero: Aún se pierde potencia (ineficiente)
- MCAR es el supuesto más restrictivo

Prueba para MCAR

- Prueba MCAR de Little:
  - Prueba formal del supuesto MCAR
  - Compara medias de subgrupos
- Verificaciones informales:
  - Comparar observados vs. faltantes en otras variables
  - Si son diferentes → No es MCAR
- Limitaciones:
  - No puede probar MCAR, solo rechazarlo
  - No rechazar ≠ MCAR es verdadero
  - No puede distinguir MAR de MNAR

Little's MCAR Test

Not significant: p-value = 0.30

Age, Income, Gender, Living arrangements

Chi-square	Degrees of freedom	p-value
3.65	3	0.30

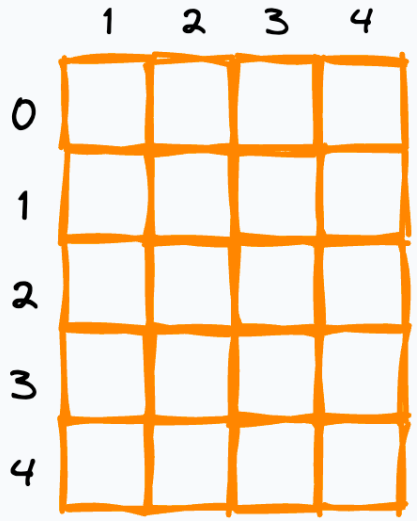
n = 327 cases used in estimation; null hypothesis: missing data is Missing Completely At Random (MCAR);

MAR: Faltante al Azar

Feature with missing values



can be explained using



Observed data

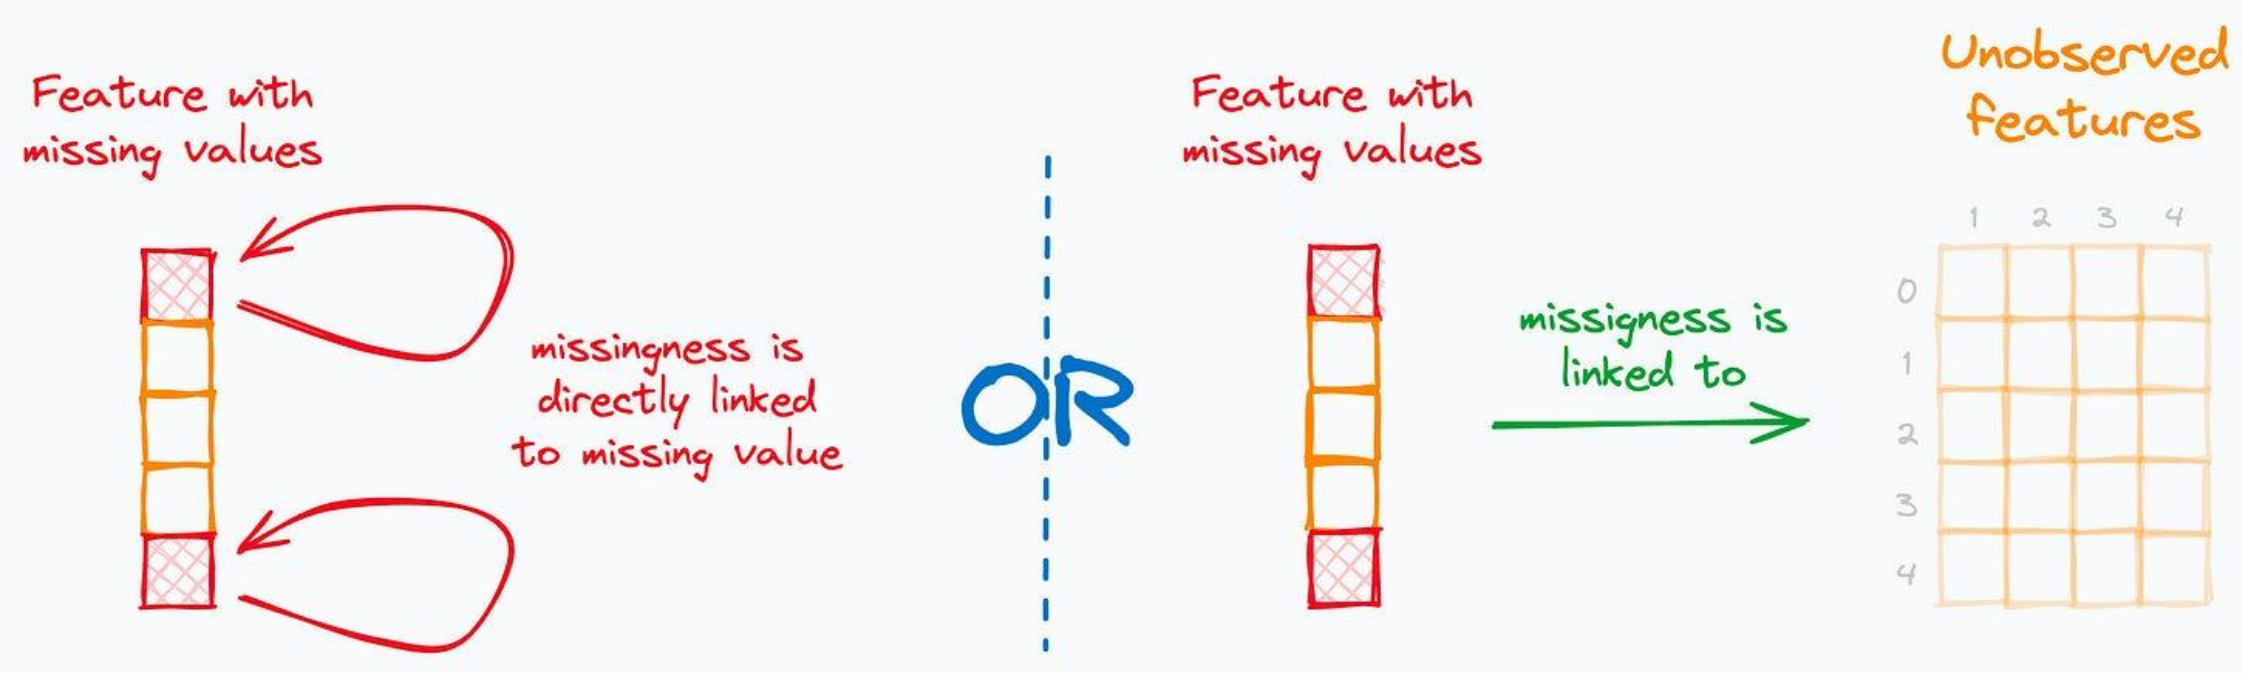
MAR: Faltante al Azar

- Definición:
  - Probabilidad de faltante depende de datos OBSERVADOS
  - Pero NO de los valores faltantes mismos
- Ejemplos:
  - Hombres menos propensos a reportar peso que mujeres
  - Dentro de género, faltante no relacionado con peso real
- Implicaciones:
  - El análisis de casos completos está sesgado
  - La imputación múltiple puede producir estimaciones insesgadas
  - SI el modelo de imputación está correctamente especificado
- MAR es el supuesto de trabajo más común

Ejemplos de MAR en la Práctica

- Encuesta sobre ingresos:
  - Personas de altos ingresos omiten preguntas de ingresos más a menudo
  - Pero: Dados otros predictores (educación, trabajo), faltante es aleatorio
- Seguimiento médico:
  - Pacientes más enfermos más propensos a abandonar
  - Si medimos severidad basal, podemos modelar esto
- Idea clave:
  - MAR permite que el faltante sea predecible
  - por variables que observamos
  - Por eso incluir predictores ayuda

MNAR: Faltante No al Azar



MNAR: Faltante No al Azar

- Definición:
  - Probabilidad de faltante depende del VALOR FALTANTE mismo
- Ejemplos:
  - Personas con ingresos más altos rehúsan reportar ingresos
  - PORQUE su ingreso es alto
  - Pacientes deprimidos abandonan estudio
  - PORQUE se vuelven más deprimidos
- Implicaciones:
  - No hay solución general
  - Debe modelar el mecanismo de faltante explícitamente
  - Requiere supuestos no verificables
  - Análisis de sensibilidad esencial

Comparando Mecanismos de Datos Faltantes

- MCAR:
  - Faltante no relacionado con ningún dato
  - Casos completos OK (excluir faltantes) (pero ineficiente)
- MAR:
  - Faltante relacionado con datos observados
  - Imputación puede funcionar si modelo es correcto
- MNAR:
  - Faltante relacionado con valores faltantes
  - Sin solución general; necesita modelos especiales
- Realidad: Usualmente asumir MAR y hacer análisis de sensibilidad

Análisis de Casos Completos (Eliminación por Lista)

- Método: Usar solo casos con datos completos
- Ventajas:
  - Simple de implementar
  - Insesgado bajo MCAR
  - Sin supuestos sobre datos faltantes
- Desventajas:
  - Puede perder datos sustanciales (y potencia)
  - Sesgado bajo MAR y MNAR
  - Desperdicia información observada
- Cuándo es aceptable: Tasa de faltantes muy baja (<5%), MCAR plausible

Imputación por Media/Mediana

- Método: Reemplazar valores faltantes con la media (o mediana)
- Problemas severos:
  - Subestima la varianza
  - Todos los valores imputados idénticos → pico artificial
  - Distorsiona correlaciones (atenúa hacia cero)
  - Sesga errores estándar hacia abajo
- Advertencia de Van Buuren:
  - "La imputación por media es posiblemente el peor método"
- Casi nunca apropiado para análisis
  - Excepción: Solo trabajo exploratorio rápido

Fuente: van Buuren, Flexible Imputation of Missing Data

Imputación por Regresión Determinística

- Método: Predecir valores faltantes de variables observadas
  - Usar regresión para llenar Y faltante desde X observada
- Mejor que imputación por media:
  - Usa información de otras variables
  - Preserva relaciones de regresión
- Aún problemático:
  - Aún subestima varianza
  - Sobreestima correlaciones
  - Todos los puntos imputados sobre línea de regresión
  - Ignora incertidumbre en valores imputados

Imputación por Regresión Estocástica

- Método: Agregar residuo aleatorio a predicción de regresión
  - $\hat{Y}$ = valor predicho + error aleatorio
- Mejora:
  - Preserva varianza
  - Preserva correlaciones
  - Valores imputados más realistas
- Aún un problema:
  - Trata valores imputados como si fueran reales
  - Errores estándar aún muy pequeños
  - Intervalos de confianza muy estrechos
- Solución: Imputación multiple **(diferentes realizaciones de valores imputados)**

Demostración: Por Qué Falla la Imputación Simple

Estudio de simulación de Van Buuren:

- La cobertura verdadera debería ser 95%
- Cobertura real con diferentes métodos:
  - Casos completos (MCAR): 94% ✓
  - Imputación por media: 79% ✗
  - Imputación por regresión: 36% ✗
  - Regresión estocástica: 91% (cerca)
  - Imputación múltiple: 95% ✓

¡Imputación por regresión: 36% de cobertura!

  - Intervalos de confianza demasiado estrechos

Fuente: van Buuren, FIMD Sección 2.5

Imputación Múltiple: Visión General

- Desarrollada por Donald Rubin (1987)
- Idea clave:
  - Imputar valores faltantes múltiples veces
  - Creando m conjuntos de datos completos
  - Cada uno refleja incertidumbre sobre valores faltantes
- ¿Por qué múltiple?
  - Imputación única ignora incertidumbre de imputación
  - Múltiples imputaciones capturan esta incertidumbre
- m típico: 5-20 imputaciones (a menudo 5-10 suficiente)

Fuente: Rubin (1987), Oxford Missing Data slides

Imputación Múltiple: Tres Fases

- Fase 1: IMPUTACIÓN
  - Crear m conjuntos de datos completos
  - Cada uno con diferentes valores plausibles
  - Debe incorporar aleatoriedad apropiada
- Fase 2: ANÁLISIS
  - Realizar análisis deseado en cada conjunto
  - Obtener m conjuntos de resultados (estimaciones, EE)
- Fase 3: COMBINACIÓN
  - Combinar m resultados usando reglas de Rubin
  - Produce estimaciones finales y EE válidos

Reglas de Combinación de Rubin

- Estimación combinada:
  - $\bar{Q} = (1/m) \Sigma \hat{Q}_i$
  - Promedio de m estimaciones
- Varianza intra-imputación:
  - $\bar{W} = (1/m) \Sigma \text{Var}(\hat{Q}_i)$
  - Promedio de m estimaciones de varianza
- Varianza entre-imputaciones:
  - $B = (1/(m-1)) \Sigma (\hat{Q}_i - \bar{Q})^2$
  - Varianza de estimaciones entre imputaciones
- Varianza total:
  - $T = \bar{W} + (1 + 1/m)B$

Fuente: Rubin (1987), U. Minnesota handout

MICE: Imputación Múltiple por Ecuaciones Encadenadas

- También llamada: Especificación Totalmente Condicional (FCS)
- Idea: Imputar cada variable condicional en las otras
- Algoritmo:

1. Llenar valores iniciales (ej., aleatorio de observados)
2. Para cada variable con datos faltantes:
   - Regresionar sobre todas las otras variables
   - Imputar valores faltantes de este modelo
3. Repetir paso 2 muchas veces (iterar)
4. Guardar conjunto de datos imputado final
5. Repetir todo el proceso m veces

Fuente: van Buuren, algoritmo MICE

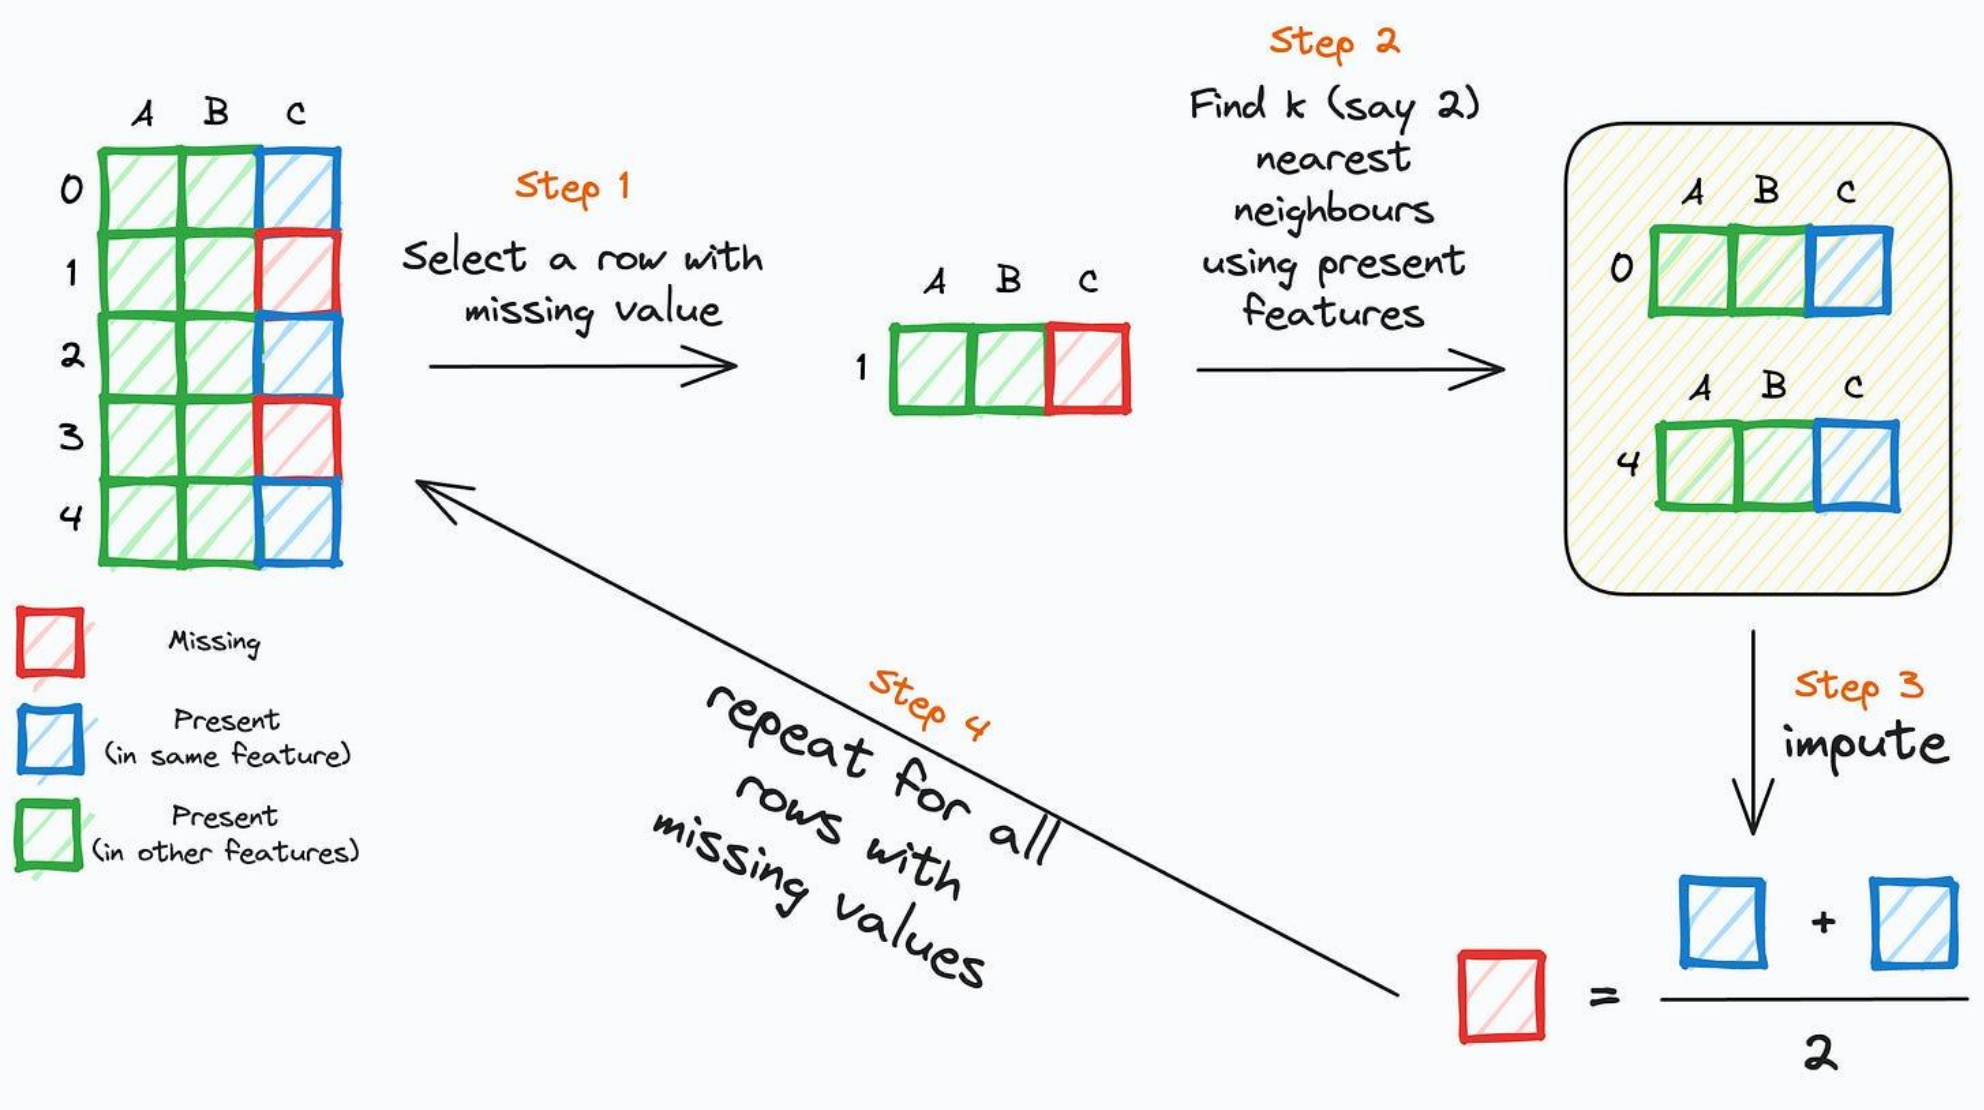
Ventajas de MICE

- Flexibilidad:
  - Puede usar diferentes modelos para diferentes variables
  - Logística para binaria, lineal para continua, etc.
- Puede manejar:
  - Tipos mixtos de variables
  - Patrones complejos de faltantes
  - Patrones de salto en encuestas
- Práctico:
  - Disponible en R (mice), Stata (mi), Python
  - Bien documentado y ampliamente probado

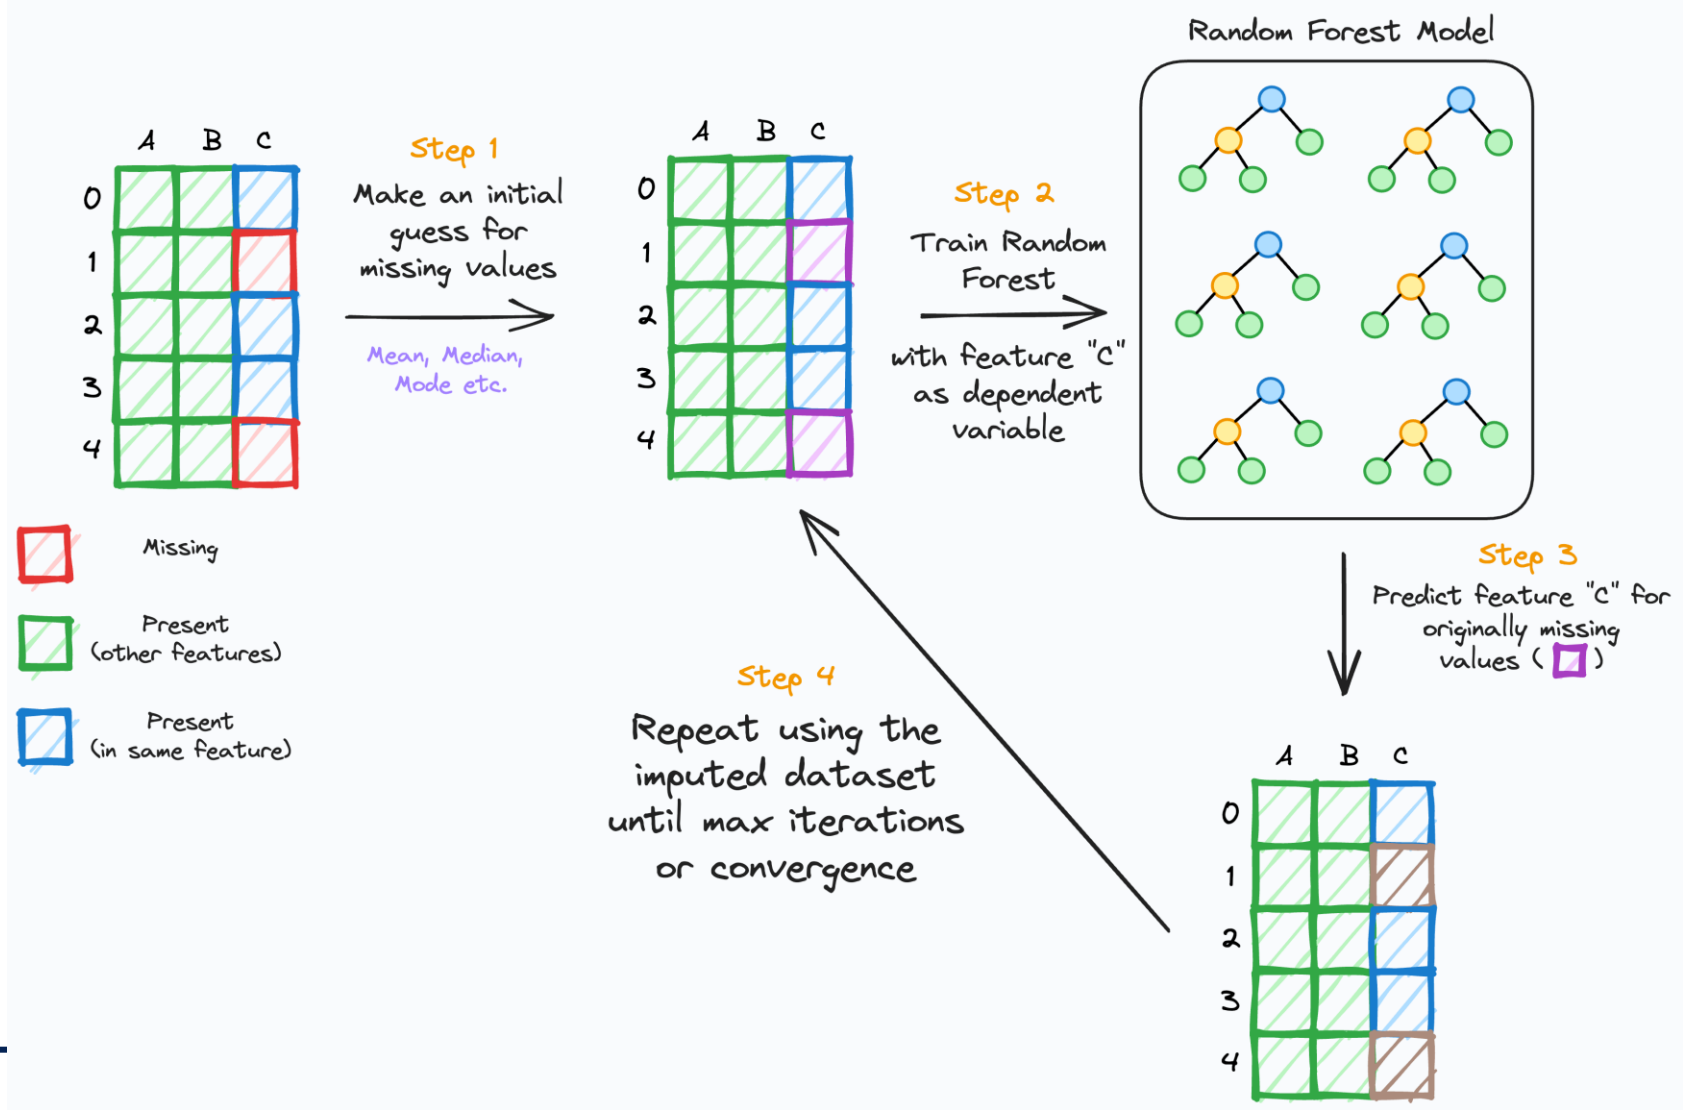
Construyendo un Buen Modelo de Imputación

- Incluir en el modelo de imputación:
  - Todas las variables en el modelo de análisis
  - Variables predictivas del faltante
  - Variables predictivas de los valores faltantes
- Enfoque de "incluir todo" a menudo recomendado:
  - Incluir más en vez de menos predictores
  - Variables extra raramente perjudican
  - Predictores faltantes pueden sesgar resultados
- Precaución: No incluir variables derivadas del objetivo

Imputación usando ML (KNN)



Imputación usando ML (Miss Forest)



Imputación ML vs. Imputación Estadística

- Métodos ML (KNN, Random Forest, Redes Neuronales):
  - Pueden dar mejores predicciones puntuales
  - Pero: A menudo ignoran incertidumbre
  - Errores estándar pueden estar mal
- Métodos Estadísticos (IM, MICE):
  - Diseñados para inferencia válida
  - Cuantifican apropiadamente la incertidumbre
  - Pueden tener predicciones puntuales menos precisas
- La elección depende del objetivo:
  - Precisión predictiva → ML puede estar OK
  - Inferencia estadística → Usar IM

Fuente: Estudio benchmark Frontiers (2021)

Datos Faltantes: Puntos Clave

- El mecanismo importa:
  - MCAR, MAR, MNAR tienen implicaciones diferentes
- Los métodos simples usualmente están mal:
  - Imputación por media casi nunca es apropiada
  - Casos completos sesgado bajo MAR
- La imputación múltiple es el estándar de oro:
  - Considera apropiadamente la incertidumbre
  - Da errores estándar válidos
- Siempre reportar:
  - Cantidad de datos faltantes
  - Método usado y supuestos hechos

(10 min) Break



¿Por Qué Transformar Datos?

¿Por Qué Transformar Datos?

Tres motivaciones estadísticas principales:

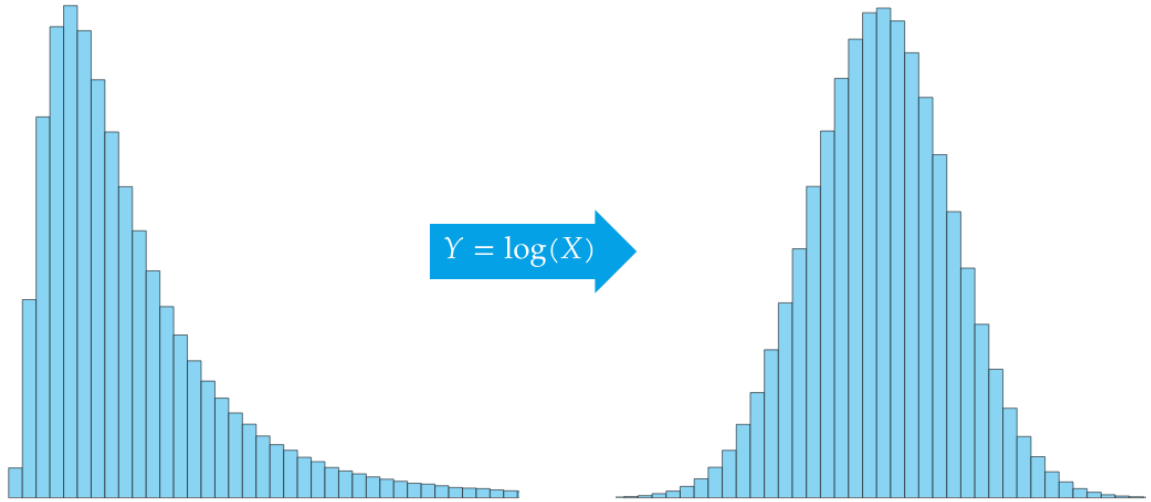
1. Lograr Linealidad
    - Muchas relaciones son inherentemente no lineales
    - Las transformaciones pueden linealizarlas
2. Estabilizar Varianza (Homocedasticidad)
    - La heterocedasticidad invalida la inferencia
    - Las transformaciones pueden igualar la varianza
3. Lograr Normalidad
    - Importante para inferencia con muestras pequeñas
    - Importa para intervalos de predicción

La Filosofía de las Transformaciones

- Las transformaciones no son "trampa"
  - Cambian la escala de medición
  - La escala transformada puede ser más natural
- Ejemplo: Ingresos
  - Dólares crudos: altamente sesgados
  - Log(ingresos): más simétrico
  - Cambios porcentuales a menudo más significativos que absolutos
- Principio clave:
  - Elegir transformaciones con significado sustantivo
  - No solo para "arreglar" problemas estadísticos

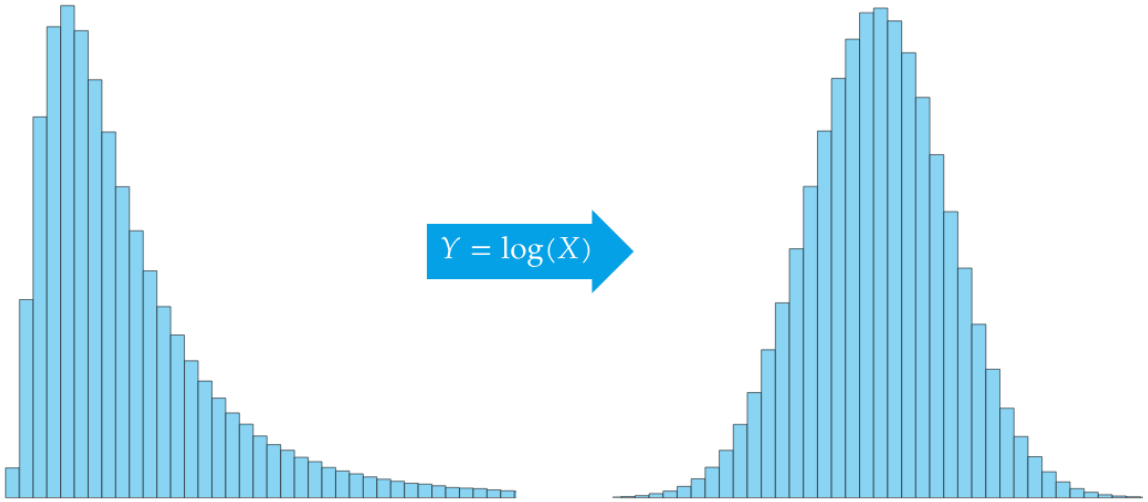
Transformación Logarítmica

- Fórmula: $Y' = \ln(Y)$ o $Y' = \log_{10}(Y)$
- Cuándo usar:
  - Datos sesgados a la derecha
  - Relaciones multiplicativas
  - Efectos de porcentaje constante
  - Varianza aumenta con el nivel
- Requisito: Todos los valores deben ser positivos
  - Para ceros: usar log(Y + 1) u otros ajustes
- Común en: economía, biología, finanzas



Propiedades de la Transformación Logarítmica

- Comprime valores grandes, expande valores pequeños
- Convierte multiplicativo a aditivo:
  - log(A × B) = log(A) + log(B)
  - Útil para procesos de crecimiento
- Convierte exponencial a lineal:
  - Si Y = ae^(bX), entonces ln(Y) = ln(a) + bX
- Interpretación porcentual:
  - Diferencias en logs ≈ diferencias porcentuales
  - ln(110) - ln(100) ≈ 0.10 ≈ 10%



Transformación de Raíz Cuadrada

- Fórmula: $Y' = \sqrt{Y}$
- Cuándo usar:
  - Datos de conteo (distribución Poisson)
  - Sesgo leve a la derecha
  - Varianza proporcional a la media
- Ventajas sobre log:
  - Compresión menos agresiva
  - Maneja ceros naturalmente ($\sqrt{0} = 0$)
- Común en: datos de conteo, estabilización de varianza

Transformación Recíproca

- Fórmula: Y' = 1/Y
- Cuándo usar:
  - Tasas y razones
  - Sesgo severo a la derecha
  - Relaciones hiperbólicas
- Precauciones:
  - Invierte el orden (grande se vuelve pequeño)
  - No puede manejar ceros
  - La interpretación puede ser contraintuitiva
- Ejemplo: Velocidad (km/hr) → Tiempo por km (min/km)

Transformaciones de Potencia

- Forma general: Y' = Y^λ
- Casos especiales:
  - λ = 2: Cuadrado (datos sesgados a la izquierda)
  - λ = 1: Sin transformación
  - λ = 0.5: Raíz cuadrada
  - λ = 0: Logaritmo (por convención)
  - λ = -0.5: Raíz cuadrada recíproca
  - λ = -1: Recíproco
- La "escalera" de potencias:
  - Bajar (λ más pequeño) para sesgo derecho
  - Subir (λ más grande) para sesgo izquierdo

Transformación de Box-Cox

- Método sistemático para encontrar la transformación óptima
- Fórmula:

$$\begin{cases} \frac{x^{\lambda}-1}{\lambda} & \text{if} \quad \lambda \neq 0 \\ log(x) & \text{if} \quad \lambda = 0 \end{cases},$$

- El "-1" y división por λ aseguran continuidad en λ=0
- Encontrando λ óptimo:
  - Estimación de máxima verosimilitud
  - Gráfico de verosimilitud de perfil
  - Elegir λ donde la verosimilitud es máxima

λ	Transformed Data
-2	y^{-2}
-1	y^{-1}
-0.5	$1/\sqrt{y}$
0	ln(y)
0.5	$\sqrt{y}$
1	y
2	y^2

Fuente: Box & Cox (1964), Revisión LSE

Box-Cox en la Práctica

- Pasos:
  - 1. Calcular log-verosimilitud para rango de valores λ
  - 2. Graficar verosimilitud vs. λ
  - 3. Encontrar el máximo
  - 4. Verificar si valor simple (0, 0.5, 1) está en IC
- Consejo práctico:
  - Si IC incluye 1: No transformar
  - Si IC incluye 0.5: Usar raíz cuadrada
  - Si IC incluye 0: Usar log
  - Preferir valores interpretables sobre λ "óptimo"

Transformando la Variable Respuesta (Y)

- Efectos de transformar Y:
- Sobre linealidad:
  - Cambia la forma funcional
  - Puede linealizar relaciones multiplicativas
- Sobre varianza:
  - Herramienta principal para estabilización de varianza
  - Aborda heterocedasticidad
- Sobre distribución:
  - Puede hacer los errores más normales
- Precaución: Cambia la interpretación del modelo

Transformando Variables Predictoras (X)

- Efectos de transformar X:
- Sobre linealidad:
  - Cambia la forma de la relación
  - Puede linealizar relaciones curvas
- Sobre varianza:
  - NO arregla heterocedasticidad
- Sobre interpretación:
  - Cambia las unidades del coeficiente
- Ventaja:
  - Las predicciones quedan en unidades originales de Y
  - No se necesita retro-transformación

Fuente: Penn State STAT 501

Decidiendo Qué Transformar

- Si los residuos muestran forma de embudo (heterocedasticidad):
  - Transformar Y
- Si los residuos muestran curvatura:
  - Primero intentar transformar X
  - Si sigue curvo, transformar Y
- Si hay ambos problemas:
  - Transformar Y primero (aborda ambos parcialmente)
  - Luego verificar si aún se necesita transformación de X

Fuente: UC Irvine STAT 110

Retro-Transformación de Predicciones

- Cuando Y está log-transformada, las predicciones están en escala log
- Retro-transformación ingenua:
  - $\hat{Y}$ = exp(ln(Y) predicho)
  - ¡Esto da la mediana, no la media!
- Retro-transformación correcta para la media:
  - $E[Y] = \exp(\mu + \sigma^2/2)$
  - Necesita considerar la varianza residual
- Alternativa: Estimador de suavizado de Duan
  - Más robusto, no asume normalidad

Centrado de Variables

- Centrado: X* = X - media(X)
- Efectos:
  - El intercepto se convierte en E[Y] cuando X está en su media
  - La pendiente no cambia
  - Reduce multicolinealidad con términos de interacción
- Cuándo centrar:
  - Cuando cero no es significativo para X
  - Cuando se incluyen términos polinomiales o de interacción
  - Cuando importa la interpretación del intercepto

Estandarización (Puntuaciones Z)

- Estandarización: Z = (X - media) / DE
- Efectos:
  - La media se convierte en 0, la DE en 1
  - Los coeficientes se convierten en "coeficientes estandarizados"
  - Comparables entre diferentes escalas
- Interpretación:
  - Un aumento de 1 DE en X se asocia con
  - un cambio de β_1 unidades (o DE) en Y
- Esencial para:
  - Regresión regularizada (LASSO, Ridge)
  - Comparar tamaños de efecto

Transformaciones: Puntos Clave

- Las transformaciones cambian la interpretación
  - Siempre sepa qué significan sus coeficientes
- Elija transformaciones con significado
  - Prefiera interpretable sobre "óptimo"
- Transforme Y para problemas de varianza
  - Transforme X para problemas de curvatura
- Estandarice para comparación
  - Esencial para regularización
- Documente todas las transformaciones
  - Crítico para reproducibilidad

¿Qué es un Valor Atípico?

¿Qué es un Valor Atípico?

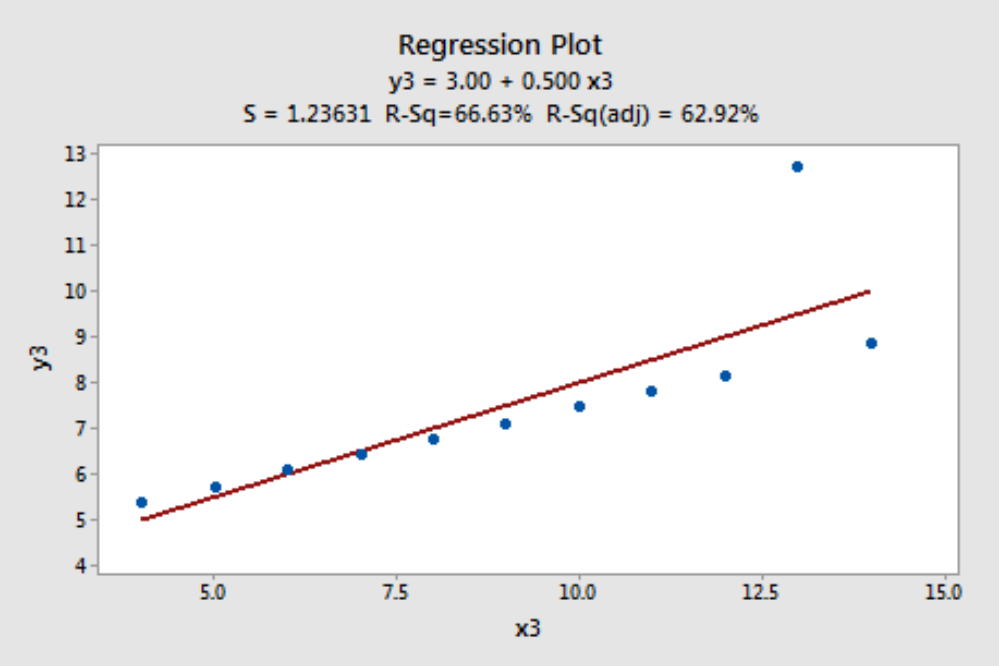
- Definición:
  - Una observación que está fuera del patrón general
- Idea clave:
  - "Inusual" depende del modelo asumido
  - Lo que es atípico bajo un modelo puede no serlo bajo otro
- Los valores atípicos pueden ser:
  - Errores de datos (errores tipográficos, fallas de medición)
  - Valores extremos legítimos
  - De una población diferente
  - ¡Las observaciones más interesantes!

Por Qué Importan los Valores Atípicos para Regresión

- Efectos en la estimación:
  - Pueden cambiar dramáticamente los coeficientes de regresión
  - Pueden inflar o desinflar R^2
- Efectos en la inferencia:
  - Pueden distorsionar errores estándar
  - Pueden crear significancia falsa u ocultar efectos reales
  - Minimiza errores al cuadrado
  - Elevar al cuadrado da peso extra a residuos grandes
  - Un valor atípico puede dominar el ajuste

Puntos de Alto Apalancamiento

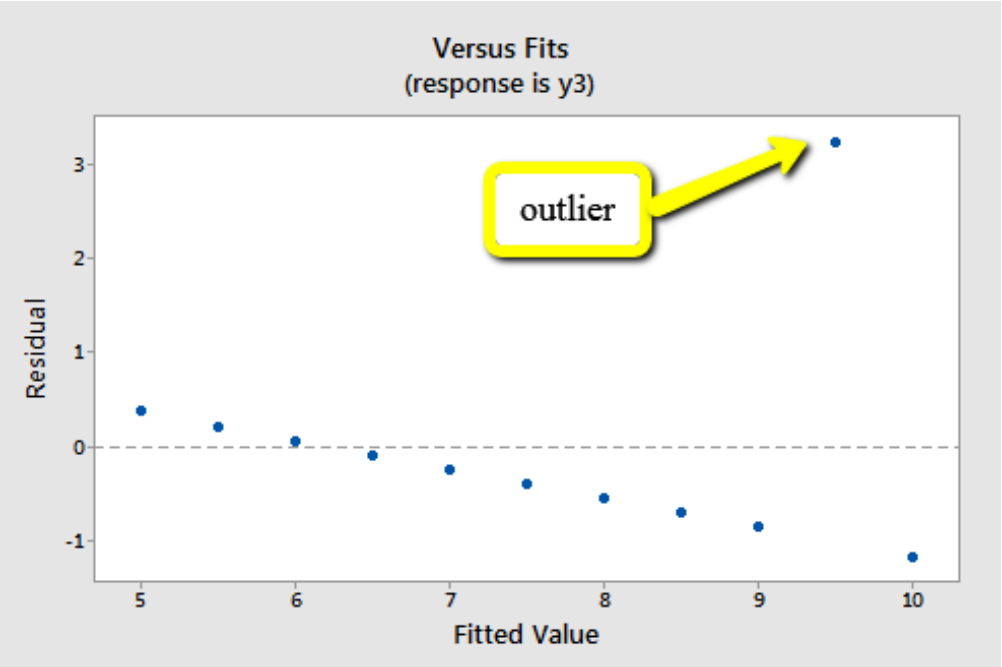
- Definición: Extremo en el espacio de predictores (X)
- Apalancamiento (h_{ii}):
  - Elemento diagonal de matriz hat $H = X(X^TX)^{-1}X^T$
  - Mide distancia del centro del espacio X
- Propiedades:
  - Rango: $1/n \leq h_{ii} \leq 1$
  - Apalancamiento promedio = $(p+1)/n$
- Regla general:
  - Alto apalancamiento si $h_{ii} > 2(p+1)/n$
  - o $h_{ii} > 3(p+1)/n$ para corte conservador



Fuente: Penn State STAT 462

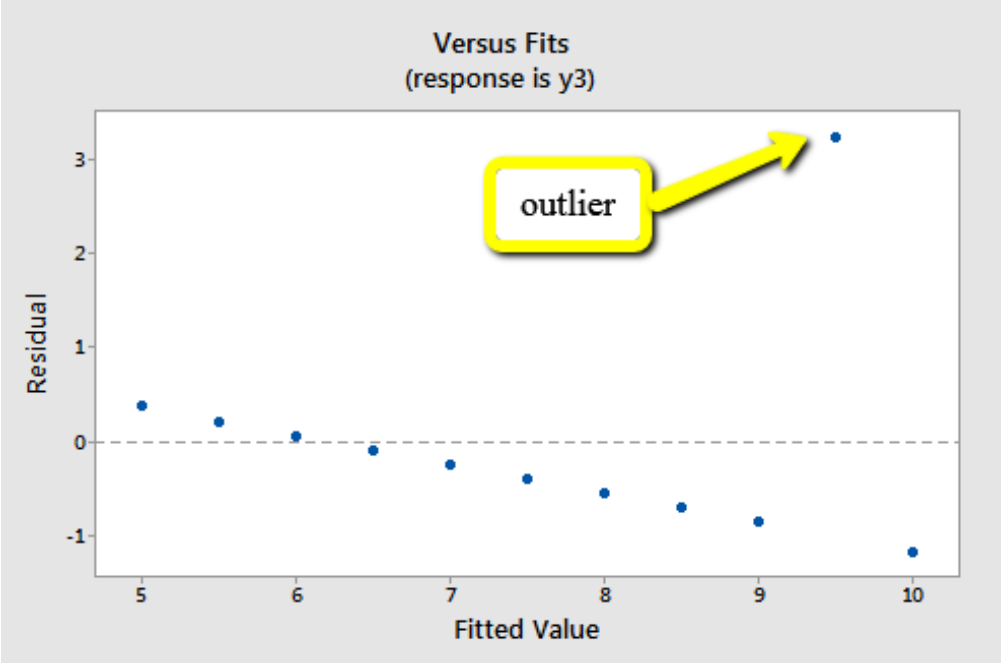
Implicaciones del Alto Apalancamiento

- Los puntos de alto apalancamiento tienen potencial de influir
  - Pero pueden o no hacerlo realmente
- Si el punto de alto apalancamiento está sobre la línea:
  - Residuo pequeño
  - Puede realmente estabilizar el ajuste
- Si el punto de alto apalancamiento está fuera de la línea:
  - Residuo grande
  - Influirá fuertemente en el ajuste
- Clave: El apalancamiento solo no dice si es un problema



Valores Atípicos en la Dirección Y

- Definición: Residuo grande (lejos de la línea ajustada)
- Tipos de residuos:
  - Residuo crudo: $e_i = Y_i - \hat{Y}_i$
  - Residuo estandarizado: $e_i / (\hat{\sigma}\sqrt{(1-h_{ii})})$
  - Residuo estudentizado: Usa $\hat{\sigma}$ de dejar-uno-fuera
- Regla general:
  - Potencial atípico si |residuo estandarrizado| > 2
  - Probable atípico si |residuo estandarrizado | > 3
- Nota: Puede ser atípico sin ser influyente



Puntos Influyentes

- Definición: Realmente cambia el ajuste cuando se elimina
- Influencia = Apalancamiento × Atipiedad
  - Alto apalancamiento + residuo grande = influyente
- Una observación es influyente si eliminarla:
  - Cambia sustancialmente las estimaciones de coeficientes
  - Cambia sustancialmente los valores ajustados
  - Cambia sustancialmente las predicciones
- Influyente ≠ Incorrecto
  - Puede ser el punto de datos más importante
  - Puede revelar inadecuación del modelo

Métodos de Detección Univariada

- Método de puntuación Z:
  - $|z| = |x - \mu|/\sigma > 3$
  - Problema: Asume normalidad; atípicos inflan σ
- Puntuación Z modificada:
  - Usa mediana y DAM (Desviación Absoluta de la Mediana)
  - DAM = mediana($|x_i$ - mediana(x)|)
  - Más robusta a los propios valores atípicos
- Regla del diagrama de caja de Tukey:
  - Atípico si bajo Q1-1.5×RIC o sobre Q3+1.5×RIC
  - Libre de distribución pero asume simetría

Fuente: U. Pittsburgh revisión de valores atípicos

El Problema del Enmascaramiento

- Definición: Múltiples atípicos se ocultan entre sí
- Cómo sucede:
  - Los atípicos jalan el ajuste hacia ellos
  - Esto reduce sus residuos
  - Ya no parecen atípicos
- Ejemplo:
  - Dos atípicos en direcciones opuestas
  - Pueden cancelar el efecto del otro
  - Ninguno parece influyente individualmente
- Problema: Los diagnósticos estándar pueden no detectarlos

Fuente: U. Pittsburgh revisión de valores atípicos

El Problema del Anegamiento

- Definición: Los atípicos hacen que puntos buenos parezcan malos
- Cómo sucede:
  - Los atípicos distorsionan el modelo ajustado
  - Los puntos regulares ahora lejos del ajuste (incorrecto)
  - Parecen ser atípicos
- Consecuencia:
  - Puede marcar buenas observaciones como atípicas
  - Puede eliminar observaciones incorrectas
  - Empeora el problema
- Ambos problemas surgen de estimación no robusta

Soluciones al Enmascaramiento y Anegamiento

- 1. Métodos robustos:
  - Usar estimadores resistentes a valores atípicos
  - M-estimadores, LTS, LMS
- 2. Eliminación secuencial:
  - Eliminar un atípico a la vez
  - Recalcular diagnósticos después de cada uno
- 3. Búsqueda hacia adelante:
  - Comenzar con subconjunto limpio
  - Gradualmente agregar observaciones
  - Observar saltos repentinos en diagnósticos
- 4. Usar múltiples criterios juntos

Paso 1: Investigar el Valor Atípico

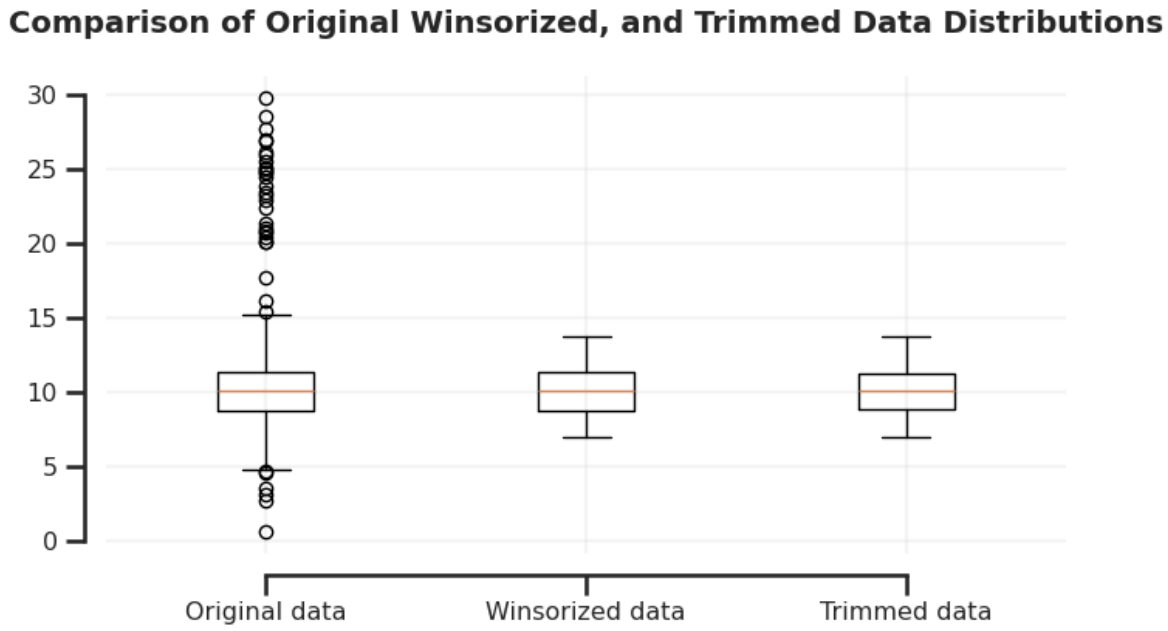
- ¡Antes de cualquier tratamiento, investigue!
- ¿Es un error de datos?
  - Error tipográfico, error de codificación, falla de medición
  - Si es así: Corregir si es posible, eliminar si no
- ¿Es un valor legítimo?
  - Observación inusual pero real
  - Puede ser de una subpoblación diferente
- ¿Es la observación más interesante?
  - A veces los atípicos son la historia
  - No descartar automáticamente

Opción 1: Mantener la Observación

- Cuándo mantener:
  - Valor extremo legítimo
  - Refleja variabilidad real en la población
- Cómo proceder:
  - Reportar análisis de sensibilidad
  - Mostrar resultados con y sin el atípico
  - Dejar que los lectores juzguen la importancia
- Precaución:
  - Las inferencias pueden estar distorsionadas
  - Ser transparente sobre la influencia

Opción 2: Winsorización (capeado)

- Método: Limitar valores extremos en percentiles
  - Valores bajo P_1 se establecen en P_1
  - Valores sobre P_{99} se establecen en P_{99}
- Niveles comunes:
  - 1%/99% (leve)
  - 5%/95% (moderado)
- Ventajas:
  - Reduce influencia sin eliminar
  - Preserva tamaño de muestra
- Desventaja:
  - La elección del percentil es arbitraria



Opción 3: Regresión Robusta

- Usar estimadores diseñados para resistir valores atípicos
- M-estimadores:
  - Minimizan función de pérdida menos sensible
  - Huber: Híbrido de cuadrado y absoluto
  - Tukey bisquare: Pondera completamente abajo atípicos
- Otros métodos robustos:
  - Desviaciones Absolutas Mínimas (LAD/L1)
  - Mínimos Cuadrados Recortados (LTS)
  - Regresión cuantílica (regresión mediana)
- Compensación: Menos eficiente si datos son realmente normales

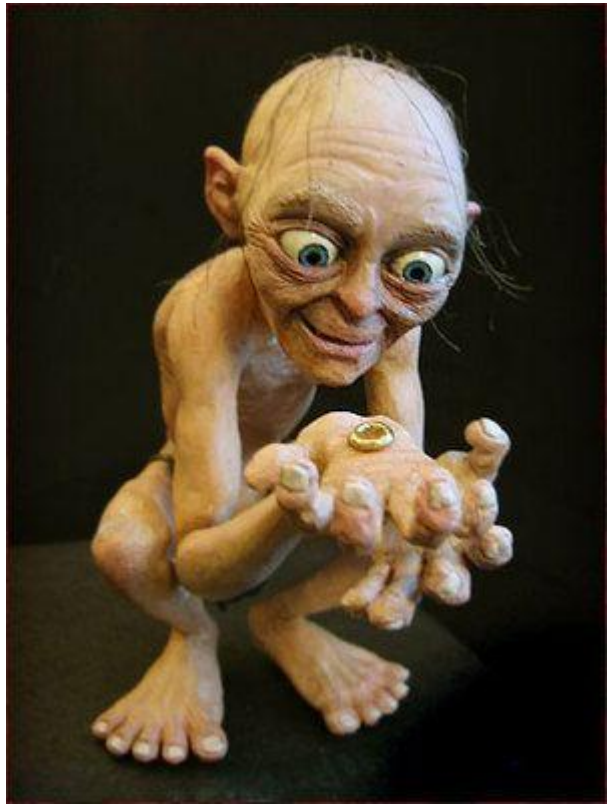
Fuente: Penn State STAT 501, UCLA OARC

Opción 4: Transformar los Datos

- Si los atípicos surgen de asimetría:
  - Log, sqrt, o Box-Cox pueden ayudar
  - Valores extremos se vuelven menos extremos
- Ejemplo:
  - Ingreso: $1M es extremo en dólares
  - log($1M) = 13.8 vs. log($50K) = 10.8
  - Menos extremo en escala log
- Precaución:
  - Cambia la interpretación
  - El atípico puede seguir siendo atípico después de transformar

La Regla de Oro del Tratamiento de Atípicos

- NUNCA elimine valores atípicos solo para:
  - Mejorar R^2
  - Lograr significancia estadística
  - Hacer que los resultados "se vean mejor"
- SIEMPRE:
  - Investigar la causa antes de cualquier acción
  - Documentar cada decisión y justificación
  - Reportar análisis de sensibilidad
  - Ser transparente en publicaciones
- El valor atípico podría estar diciéndole algo importante



Valores Atípicos: Puntos Clave

- No todos los atípicos son influyentes
  - Necesita tanto apalancamiento como residuo grande
- No todos los puntos influyentes son errores
  - Pueden ser legítimos e importantes
- Use múltiples diagnósticos:
  - Cook's D, DFFITS, DFBETAS juntos
- Investigue antes del tratamiento:
  - ¿Error? Corregir o eliminar
  - ¿Legítimo? Reportar análisis de sensibilidad
- Considere métodos robustos como alternativa a eliminación



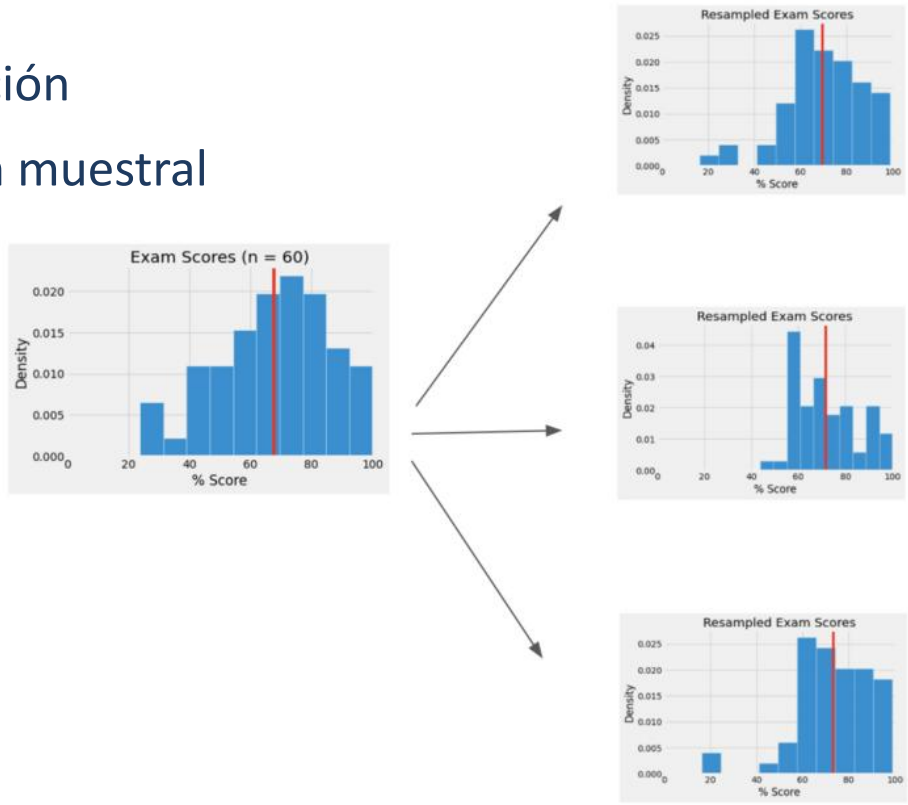
¿Qué es el Aumento de Datos?
(data augmentation)

¿Qué es el Aumento de Datos?

- Crear puntos de datos adicionales a partir de datos existentes
- Dos propósitos principales:
  - 1. Inferencia estadística (bootstrap)
  - 2. Entrenar modelos de aprendizaje automático
- Pregunta clave: ¿El aumento crea información?
  - NO: No puede crear información que no existía
  - SÍ: Puede aprovechar invarianzas y estructura
- Perspectiva estadística: Reducción de varianza

El Bootstrap: La Visión de Efron (1979)

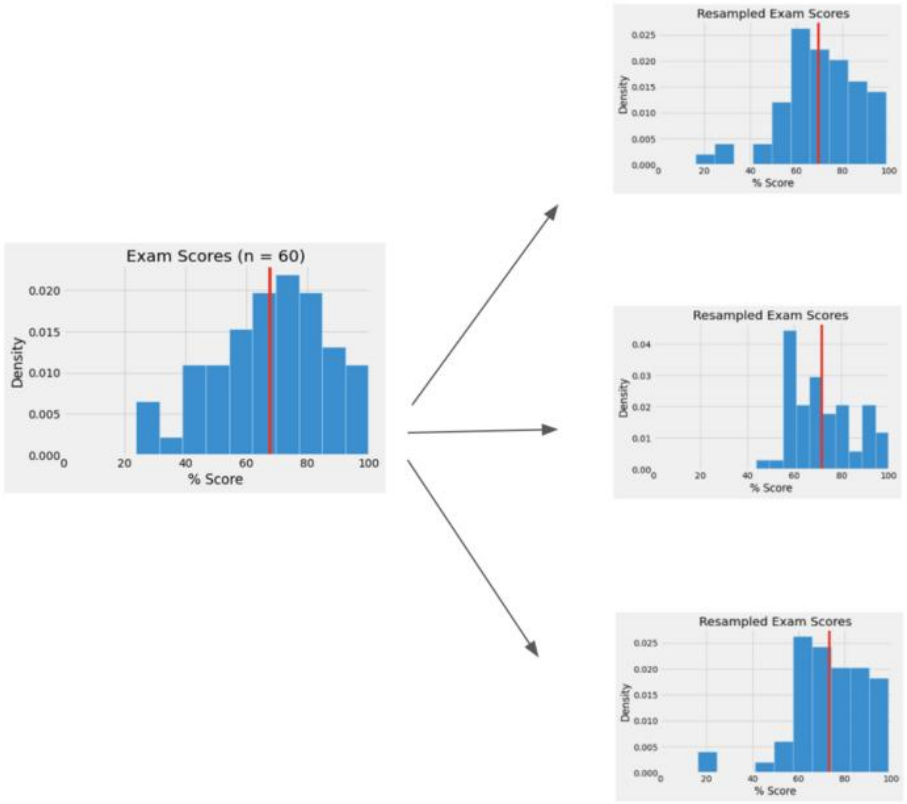
- Idea clave:
  - La muestra es nuestra mejor estimación de la población
  - Remuestrear de la muestra para estimar distribución muestral
- Filosofía:
  - "Levantarse por los propios cordones" (bootstraps)
  - Sin supuestos sobre la distribución poblacional
- Revolucionario porque:
  - Funciona para estadísticas complejas
  - No necesita fórmulas analíticas
  - Intensivo computacionalmente (ahora trivial)



Fuente: Efron (1979), Duke STA 325

El Algoritmo Bootstrap

- Dados datos X_1, X_2, ..., X_n
- 1. Extraer muestra bootstrap:
  - Muestrear n observaciones CON reemplazo
  - Algunas observaciones repetidas, algunas faltantes
- 2. Calcular estadística θ* en muestra bootstrap
- 3. Repetir pasos 1-2 B veces (B = 1000-10000)
- 4. Usar distribución de valores θ* para inferencia:
  - Error estándar: DE de estimaciones bootstrap
  - Intervalo de confianza: Percentiles de la distribución



Errores Estándar Bootstrap

- Error estándar de $\hat{\theta}$:
  - EE = DE de ($\hat{\theta}^*_1$, $\hat{\theta}^*_2$, ..., $\hat{\theta}^*_B$)
- Por qué funciona:
  - Distribución bootstrap imita distribución muestral
  - Dispersión de estimaciones $\hat{\theta}^*$ ≈ dispersión de $\hat{\theta}$ entre muestras
- Ventajas:
  - No se necesita fórmula
  - Funciona para estadísticas complejas
  - Medianas, razones, correlaciones, etc.
- B = 200-500 a menudo suficiente para EE

Intervalos de Confianza Bootstrap

- Método de percentiles (más simple):
  - IC 95%: [percentil 2.5, percentil 97.5] de θ*
- Método BCa (corregido por sesgo y acelerado):
  - Ajusta por sesgo y asimetría
  - Generalmente preferido por precisión
- Método básico/pivotal:
  - Usa distribución θ - θ*
- Para intervalos de confianza: B = 1000+ recomendado
  - Necesita percentiles de cola precisos

Fuente: CMU ADA Capítulo 6

Cuándo Falla el Bootstrap

- El bootstrap puede fallar para:
- Cuantiles extremos (máximo, mínimo):
  - Máximo muestral raramente igual al poblacional
  - Bootstrap no puede exceder máximo muestral
- Distribuciones de colas pesadas:
  - Poblaciones con varianza infinita
  - Varianza bootstrap no converge
- Muestras pequeñas con eventos raros:
  - El evento puede no aparecer en muestras bootstrap
- Parámetros en la frontera:
  - Varianza = 0, correlación = 1, etc.

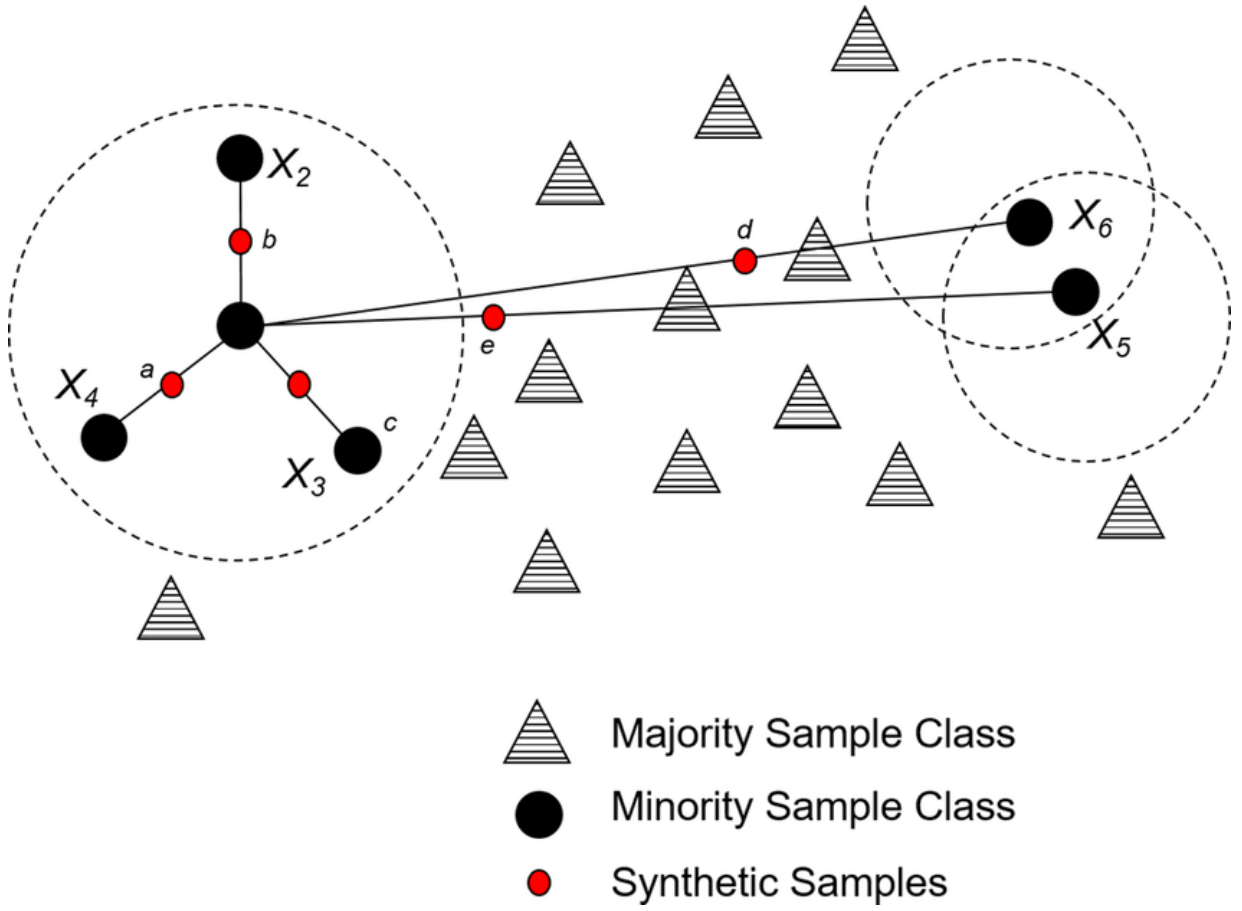
Fuente: CMU Shalizi Capítulo 6

El Problema del Desbalance de Clases

- Problema: Frecuencias de clases desiguales en clasificación
  - Ejemplo: 99% no-fraude, 1% fraude
- Por qué importa:
  - El clasificador puede ignorar la clase minoritaria
  - ¡99% de precisión prediciendo todo negativo!
- Soluciones:
  - Submuestrear clase mayoritaria
  - Sobremuestrear clase minoritaria
  - Generar ejemplos sintéticos de minoritaria (SMOTE)
  - Usar diferentes métricas de evaluación (F1, AUC)

Algoritmo SMOTE

- Técnica de Sobremuestreo de Minoría Sintética
- Algoritmo:
  - 1. Para cada observación de clase minoritaria:
  - 2. Encontrar k vecinos más cercanos (en clase minoritaria)
  - 3. Seleccionar aleatoriamente un vecino
  - 4. Crear punto sintético:
  - x_nuevo = x + λ × (x_vecino - x)
  - donde λ es aleatorio en [0, 1]
- Resultado: Puntos sintéticos en segmentos de línea conectando puntos reales



Fuente: Chawla et al. (2002), JAIR

Problemas Estadísticos con SMOTE

- Supuesto de linealidad:
  - Asume que el espacio entre puntos es válido
  - Puede crear observaciones no plausibles
- Altas dimensiones:
  - Maldición de la dimensionalidad
  - "Vecinos" pueden no ser significativos
- Solapamiento de clases:
  - Puede generar puntos en región equivocada
  - Aumenta ruido, no señal
- Inferencia:
  - Errores estándar sin sentido con datos sintéticos

Advertencia Crítica: SMOTE en Altas Dimensiones

- Hallazgo de investigación NIH/PMC:
- "SMOTE sin selección de variables NO debería usarse
- en configuraciones de alta dimensionalidad"
- Problemas observados:
  - Sesga fuertemente hacia clase minoritaria
  - A menudo peor que simple submuestreo (boostrap)
  - Falsa sensación de rendimiento mejorado
- Recomendación:
  - Usar con precaución, solo en bajas dimensiones
  - Siempre validar apropiadamente

Fuente: Estudio PMC/NIH sobre SMOTE

¿Cómo afecta el error del modelo?

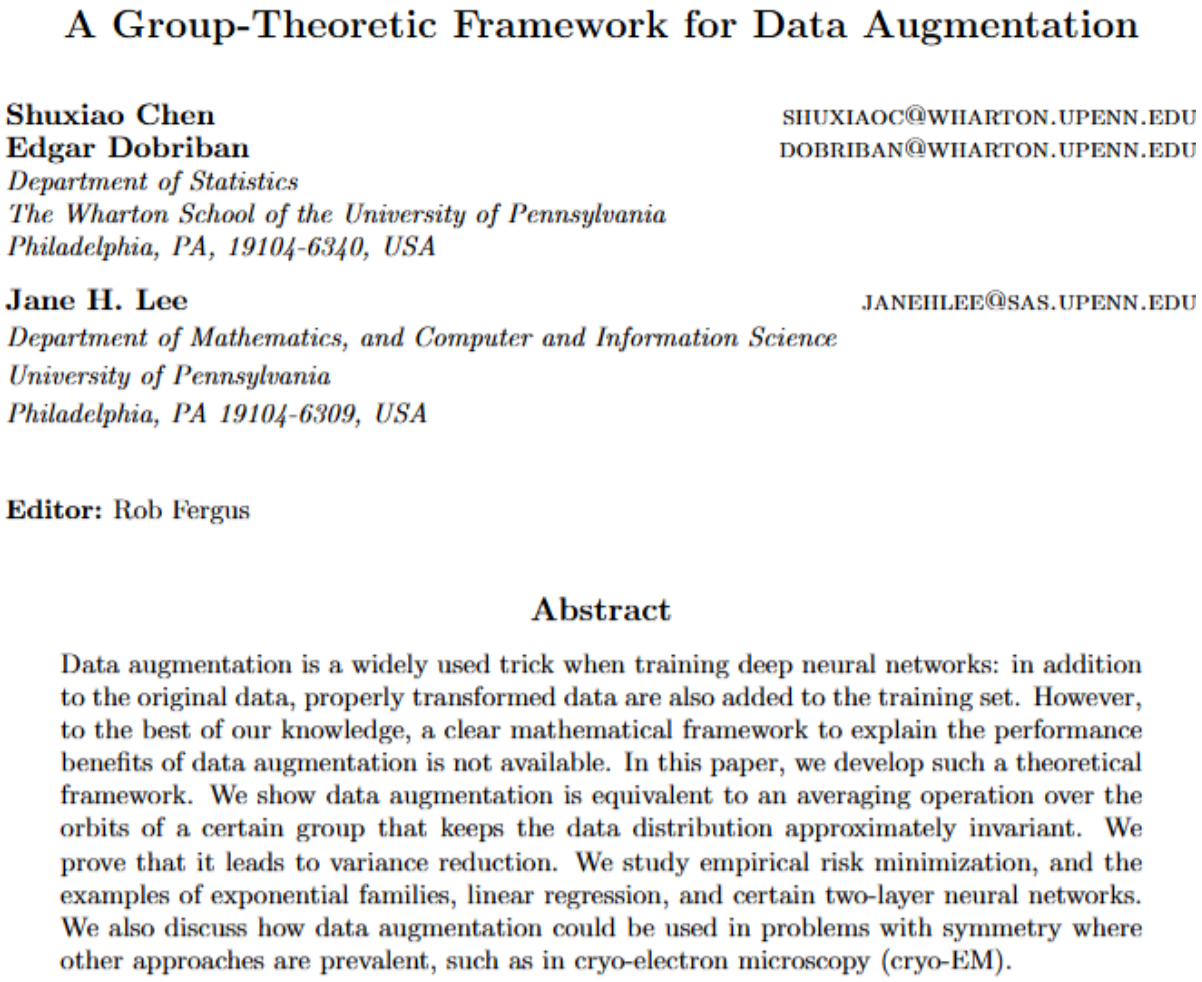
Compensación Sesgo-Varianza

- Descomposición del Error Cuadrático Medio:
  - ECM = Varianza + Sesgo² + Error Irreducible
- Efecto del aumento de datos:
  - Reduce varianza: Más datos → estimaciones más estables
  - Puede introducir sesgo: Si datos sintéticos no coinciden con distribución real
- El efecto neto depende de:
  - Qué tan bien el aumento coincide con la realidad
  - Tamaño de muestra original
  - Complejidad del modelo

Fuente: MIT 15.097

Fundamento Teórico: Teoría de Kernel (2020)

- Dao et al., JMLR 2020:
- Teorema clave:
  - Aumento = Optimizar objetivo "promediado sobre órbita"
  - Sobre grupo de transformaciones de aumento
- Implicación:
  - Mismo sesgo que estimador original
  - Covarianza reducida
  - Conexión con teorema de Rao-Blackwell
- Idea clave: El aumento aprovecha invarianzas
  - No crea información de la nada



A Group-Theoretic Framework for Data Augmentation

Shuxiao Chen SHUXIAOC@WHARTON.UPENN.EDU
Edgar Dobriban DOBRIBAN@WHARTON.UPENN.EDU
Department of Statistics
The Wharton School of the University of Pennsylvania
Philadelphia, PA, 19104-6340, USA

Jane H. Lee JANEHLEE@SAS.UPENN.EDU
Department of Mathematics, and Computer and Information Science
University of Pennsylvania
Philadelphia, PA 19104-6309, USA

Editor: Rob Fergus

Abstract

Data augmentation is a widely used trick when training deep neural networks: in addition to the original data, properly transformed data are also added to the training set. However, to the best of our knowledge, a clear mathematical framework to explain the performance benefits of data augmentation is not available. In this paper, we develop such a theoretical framework. We show data augmentation is equivalent to an averaging operation over the orbits of a certain group that keeps the data distribution approximately invariant. We prove that it leads to variance reduction. We study empirical risk minimization, and the examples of exponential families, linear regression, and certain two-layer neural networks. We also discuss how data augmentation could be used in problems with symmetry where other approaches are prevalent, such as in cryo-electron microscopy (cryo-EM).

Fuente: Dao et al., JMLR 2020

Problema Crítico: Fuga de Datos

- Fuga de datos: Información del conjunto de prueba "se filtra" al entrenamiento
- Con aumento:
  - Si aumenta antes de dividir entrenamiento/prueba
  - Versiones aumentadas de puntos de prueba en entrenamiento
  - Estimaciones de rendimiento demasiado optimistas
- Hallazgo reciente (2025):
  - ~8% de inflación en puntaje F1 por fuga
- Procedimiento correcto:
  - Dividir primero, luego aumentar solo datos de entrenamiento
  - Aumentar dentro del ciclo de validación cruzada

Fuente: arXiv 2025 estudio de sesgo por aumento

Aumento de Datos: Puntos Clave

- Bootstrap para inferencia:
  - Herramienta poderosa y de propósito general
  - Saber cuándo falla (extremos, colas pesadas)
- SMOTE con precaución:
  - Puede ayudar con desbalance de clases
  - Problemático en altas dimensiones
  - Invalida errores estándar
- Siempre:
  - Validar apropiadamente (sin fuga de datos)
  - Entender qué invarianzas está asumiendo

¿Cuál sería su flujo de trabajo para tratar datos?

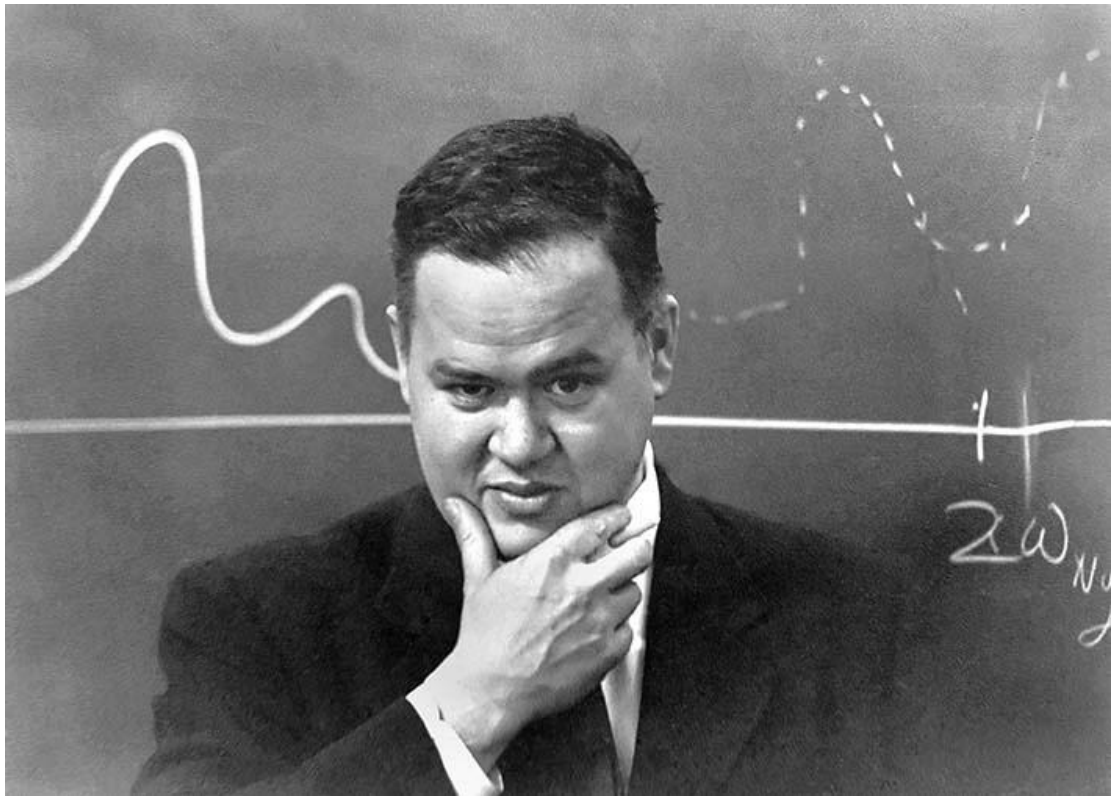
Flujo de Trabajo Recomendado

1. AED primero: Entender antes de modelar
2. Evaluar faltantes: Determinar mecanismo
3. Transformar si es necesario: Documentar interpretación
4. Identificar valores atípicos: Investigar causas
5. Análisis de sensibilidad: Reportar robustez
6. Documentar todo: La reproducibilidad importa

Principios Clave

1. Cada decisión de preprocesamiento es una decisión de modelado
2. Los supuestos importan para la validez inferencial
3. La transparencia y documentación son esenciales
4. Los métodos simples a menudo funcionan bien
    - No use métodos complejos sin justificación
5. El contexto y conocimiento del dominio guían decisiones
    - La estadística proporciona herramientas, no respuestas
6. El análisis de sensibilidad debería ser rutinario

Siempre Recordar



"La combinación de algunos datos y un deseo ardiente de una respuesta no asegura que una respuesta razonable pueda extraerse de un cuerpo dado de datos."

— John W. Tukey

Problema: Aplicación SMOTE

Se considera un conjunto de datos bidimensional simplificado con una clase minoritaria que contiene solo dos muestras. El objetivo es generar una muestra sintética nueva utilizando SMOTE con un parámetro de vecinos más cercanos $k = 1$. Se procede paso a paso, con cálculos explícitos.

Conjunto de Datos Inicial

Suponga que la clase minoritaria consta de las siguientes muestras en un espacio de características bidimensional (x_1, x_2):

- Muestra $\mathbf{x}_i = (1, 1)$
- Muestra $\mathbf{x}_j = (3, 3)$

Solución

- Seleccione una muestra de la clase minoritaria para generar una sintética. Elegimos $\mathbf{x}_i = (1, 1)$como la muestra base.
- Calcule la distancia euclidiana entre $\mathbf{x}_i$y las otras muestras en la clase minoritaria para encontrar el vecino más cercano ($k = 1$).

Distancia a $\mathbf{x}_j = (3, 3)$:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(3-1)^2 + (3-1)^2} = \sqrt{4+4} = \sqrt{8} = 2\sqrt{2} \approx 2.828$$

- Dado que solo hay una otra muestra, el vecino más cercano $\mathbf{x}_{nn}$es $(3, 3)$.

Solución

- La fórmula de SMOTE para una nueva muestra sintética $\mathbf{x}_{new}$es:
  - $\mathbf{x}_{new} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_{nn} - \mathbf{x}_i)$

  donde λ es un valor aleatorio uniformemente distribuido en el intervalo [0, 1].
- Asuma $\lambda = 0.5$(un valor fijo para este ejercicio; en la práctica, se genera aleatoriamente).
- Calcule la diferencia vectorial: $\mathbf{x}_{nn} - \mathbf{x}_i = (3, -13 - 1) = (2, 2)$
- Multiplique por λ: $0.5 \cdot (2, 2) = (1, 1)$
- Sume a la muestra base: $\mathbf{x}_{new} = (1, 1) + (1, 1) = (2, 2)$
- Conjunto de datos de la clase minoritaria después de agregar la muestra sintética:
- Originales: $(1, 1)$,$(3, 3)$
- Sintética: $(2, 2)$

Preguntas Vibe Quest

- El Análisis Exploratorio de Datos (EDA) enfatiza “dejar que los datos hablen”, mientras que los pipelines modernos automatizados (AutoML, feature engineering automático) reducen o eliminan esta etapa. ¿En qué escenarios la automatización puede ser activamente peligrosa? Diseña un experimento donde omitir el EDA lleve a un modelo con buen performance pero conclusiones profundamente erróneas.
- La imputación múltiple es el “estándar de oro”, pero introduce datos que nunca fueron observados. ¿En qué contextos imputar puede ser conceptualmente peor que perder potencia estadística? Diseña un criterio claro para decidir cuándo no imputar, incluso bajo MAR plausible.
- Los valores atípicos pueden destruir modelos… o ser lo más interesante del dataset. ¿Cómo distinguir entre “ruido” y “señal rara” sin usar información externa? Plantea un protocolo de decisión que minimice arbitrariedad.
- El aumento de datos no crea información nueva, pero sí cambia el error del modelo. ¿Puede el data augmentation generar una falsa sensación de certeza científica? Analiza el trade-off sesgo–varianza desde una perspectiva inferencial, no predictiva.
- Cada decisión de preprocesamiento es una decisión de modelado. ¿Cuál es la decisión “invisible” más peligrosa en el tratamiento de datos? Propón un estándar mínimo de documentación que debería exigirse en papers y proyectos industriales.