Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería

1INF02 APRENDIZAJE DE MÁQUINA

Modelos de Clustering y Declustering

Prof. Rodrigo Uribe

Organización de las Clases

(10 min) Preguntas y consultas.

(30 min) Respuesta *Vibe Quest.*

(45 min) Revisión de examen 1 y desagrupamiento de datos.



(10 min) Break

(55 min) Clusters y visión probabilística de clusters.

(20 min) Ejercicio de clustering.

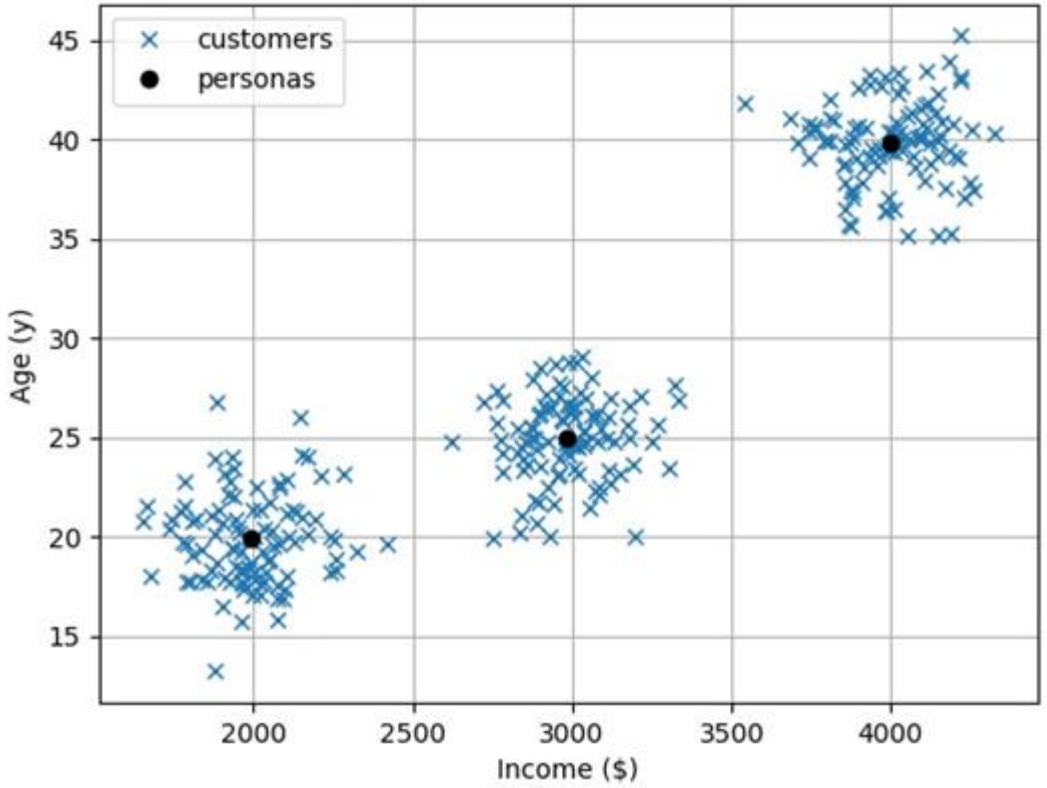
(10 min) Preguntas *Vibe Quest.*

Respuestas Vibe Quest

- El Análisis Exploratorio de Datos (EDA) enfatiza “dejar que los datos hablen”, mientras que los pipelines modernos automatizados (AutoML, feature engineering automático) reducen o eliminan esta etapa. ¿En qué escenarios la automatización puede ser activamente peligrosa? Diseña un experimento donde omitir el EDA lleve a un modelo con buen performance pero conclusiones profundamente erróneas.
- La imputación múltiple es el “estándar de oro”, pero introduce datos que nunca fueron observados. ¿En qué contextos imputar puede ser conceptualmente peor que perder potencia estadística? Diseña un criterio claro para decidir cuándo no imputar, incluso bajo MAR plausible.
- Los valores atípicos pueden destruir modelos… o ser lo más interesante del dataset. ¿Cómo distinguir entre “ruido” y “señal rara” sin usar información externa? Plantea un protocolo de decisión que minimice arbitrariedad.
- El aumento de datos no crea información nueva, pero sí cambia el error del modelo. ¿Puede el data augmentation generar una falsa sensación de certeza científica? Analiza el trade-off sesgo–varianza desde una perspectiva inferencial, no predictiva.
- Cada decisión de preprocesamiento es una decisión de modelado. ¿Cuál es la decisión “invisible” más peligrosa en el tratamiento de datos? Propón un estándar mínimo de documentación que debería exigirse en papers y proyectos industriales.

Revisión Examen 1

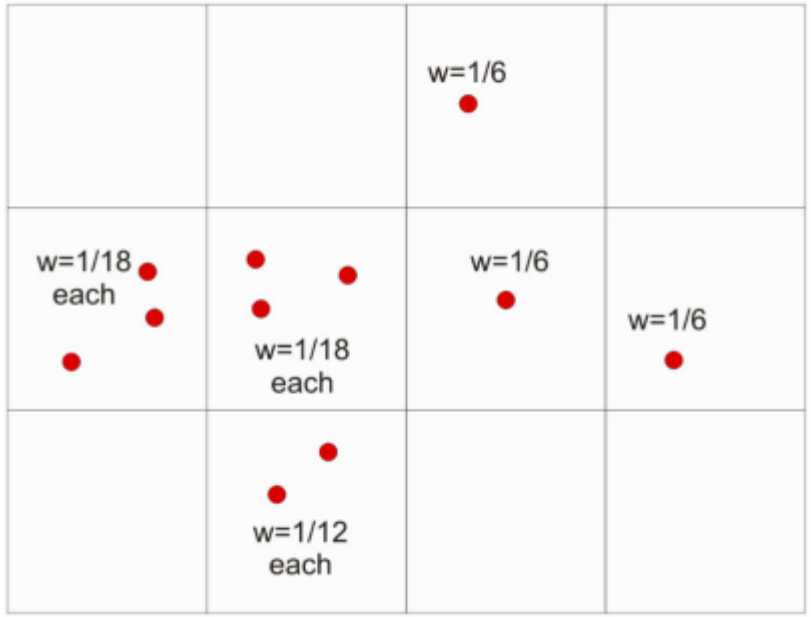
¿Cómo entendemos este patrón de datos?



(hay 2 respuestas)

Respuesta 1: Patrón de datos producto del proceso de recolección de datos

- Los datos rara vez se recolectan por su representatividad estadística
- Las áreas que se explotan primero necesitan más perforaciones
- Motivación para confirmar áreas de alta ley
- Recordar Bayes y la importancia de la distribución a priori



Estadísticas Representativas

- Relato del Dr. George Gallup



https://www.gallup.com/corporate/178136/george-gallup.aspx

- Los datos son de incuestionable importancia para nosotros
- El desafío es modelar la vasta región no muestreada entre los datos

- Esta clase no trata sobre datos sesgados o errores de medición
- Esta clase se refiere a la representatividad de los datos

Desagrupamiento (declustering)

Ubicación Espacial de los Datos

- Los datos rara vez se recolectan para ser estadísticamente representativos:
  - Las áreas de interés (mejores) se delinean más completamente
  - Las muestras se toman preferencialmente
- Estas prácticas de recolección de datos no tienen que cambiarse; conducen a la mejor economía y al mayor número de datos en las porciones más importantes del área de estudio
- Sin embargo, es necesario ajustar los histogramas y estadísticas resumen para que sean representativas de todo el volumen de interés

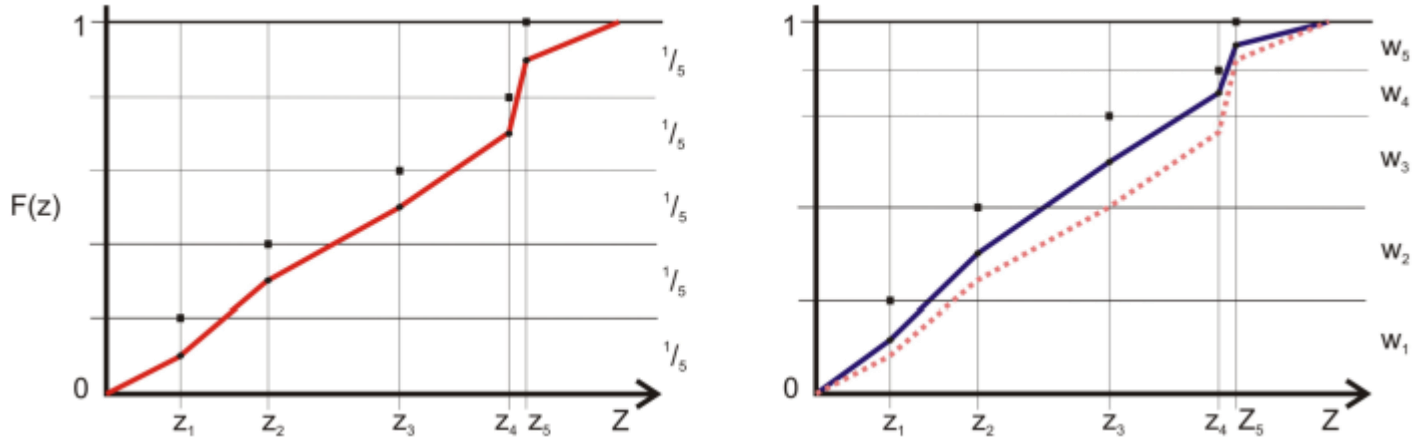
- Las técnicas de **desagrupamiento** asignan a cada dato un peso basado en la cercanía a los datos circundantes
  - wi, i=1,...n
  - El histograma y el histograma acumulado usan wi en lugar de 1/n
- La **corrección de sesgo** usa una variable secundaria o tendencia para establecer histogramas o proporciones representativas

Estadísticas Representativas

- Hay necesidad de proporciones e histogramas representativos:
  - Verificación de modelos
  - Evaluación global de recursos
  - Como entrada para la simulación
- Asignar pesos diferenciales a los datos basados en la proximidad a otros datos
- Ejemplo con cinco datos con pesos iguales (izquierda) y ponderados (derecha)

$$\bar{z} = \frac{\sum_{i=1}^{n} w_i z_i}{\sum_{i=1}^{n} w_i}$$

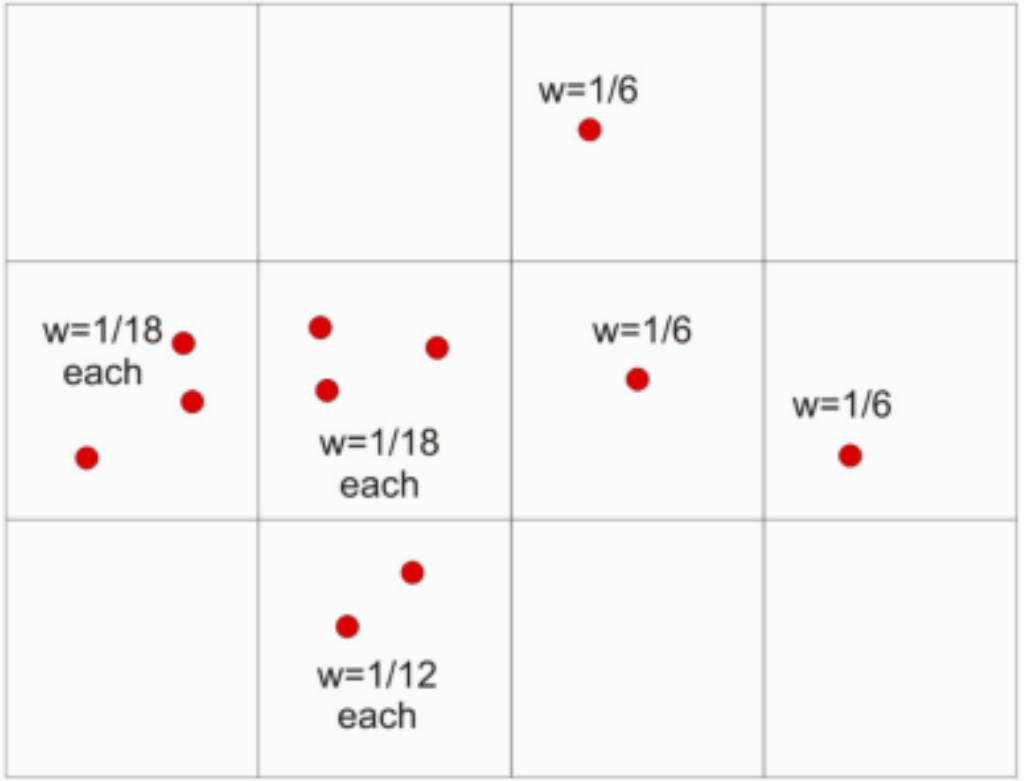
$$s = \sqrt{\frac{\sum_{i=1}^{n} w_i (z_i - \bar{z})^2}{\sum_{i=1}^{n} w_i}}$$



Desagrupamiento por Celdas

- Técnica venerable que generalmente funciona

1. Superponer celdas de igual tamaño
2. Contar el número de celdas ocupadas
3. Dar a cada celda ocupada el mismo peso
4. Los datos en una celda reciben el mismo peso



Algunos Detalles de Implementación

- Mover el origen de forma aleatoria o sistemática para eliminar la sensibilidad a ese parámetro
- El promedio de pesos positivos que suman uno también son positivos y suman uno
- Los datos no pueden caer en los límites de las celdas debido a la precisión, pero se moverán aleatoriamente si es necesario

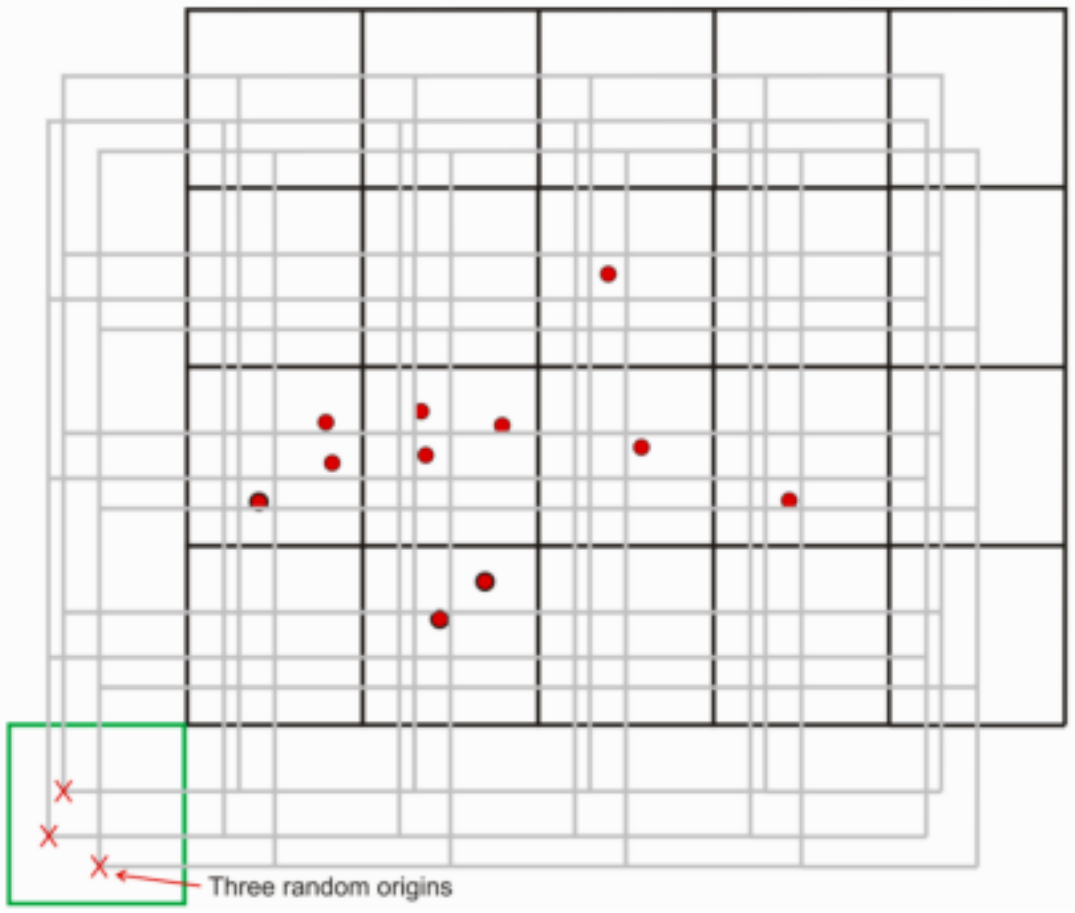
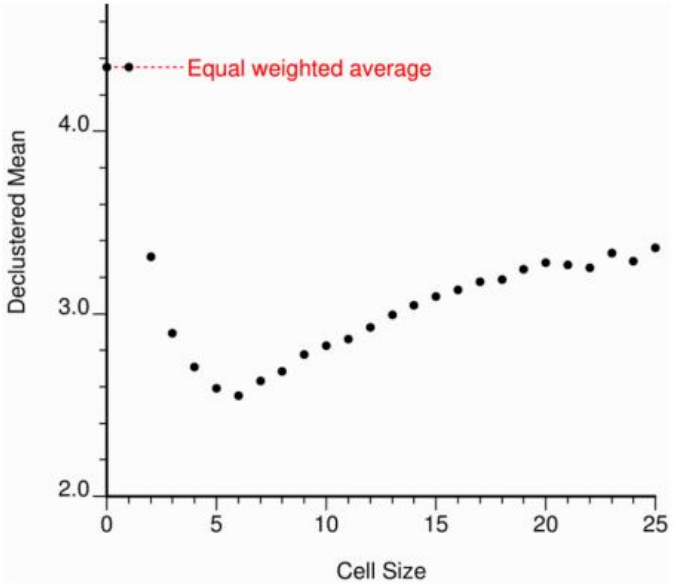
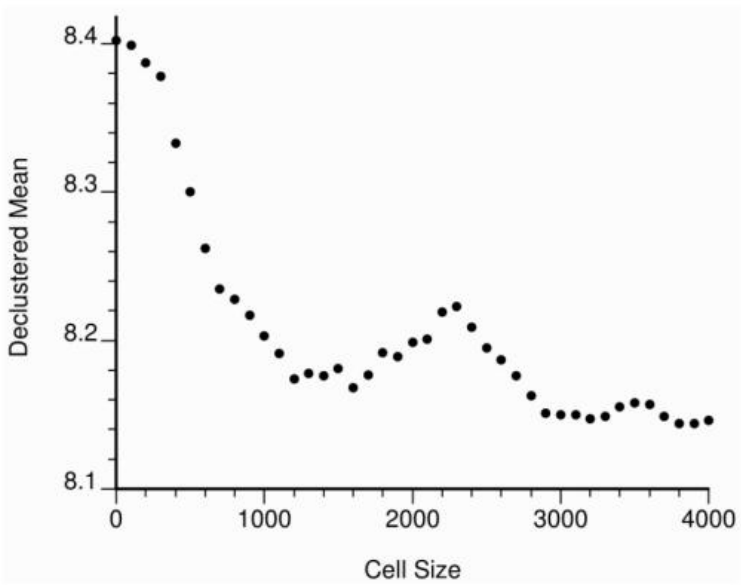


Gráfico Diagnóstico del Desagrupamiento

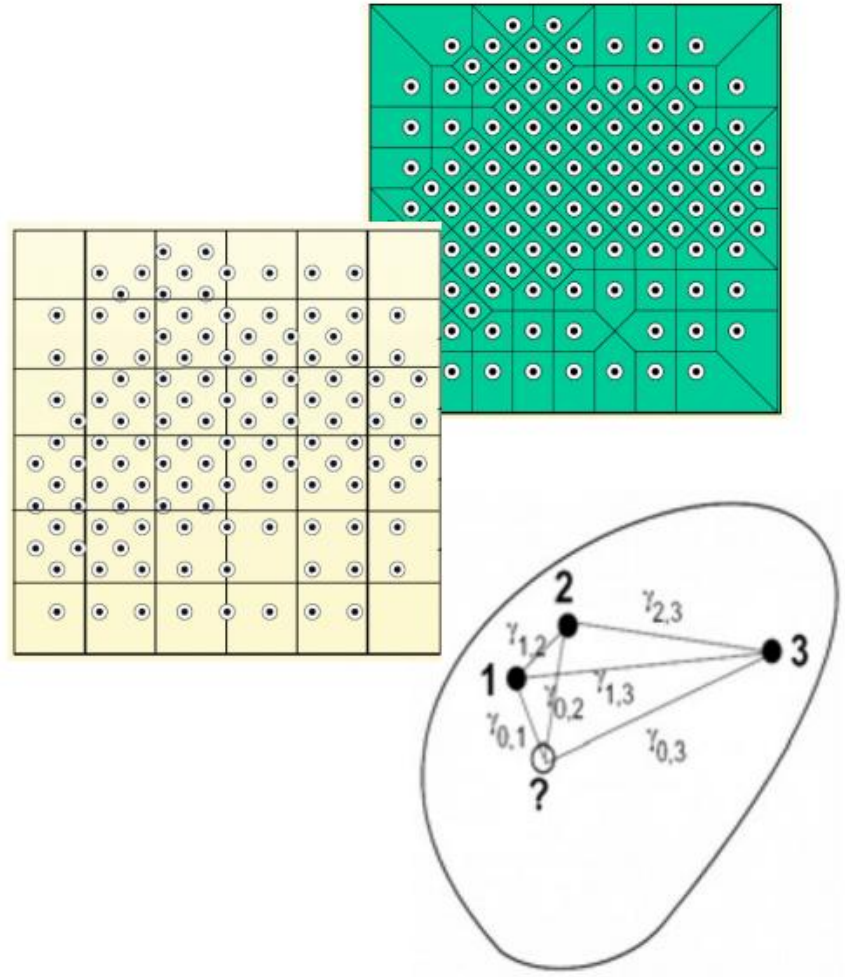
- Graficar la media desagrupada versus el tamaño de celda es muy común
- No hay teoría para tomar el mínimo (o máximo)
- A menudo el primer mínimo o máximo estable es razonable
- Respalda la elección final de un tamaño de celda





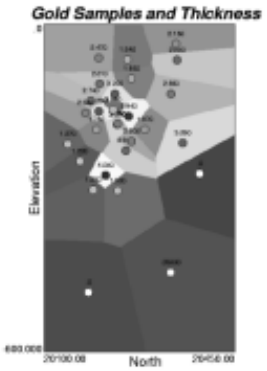
Problemas de Utilizar Celdas

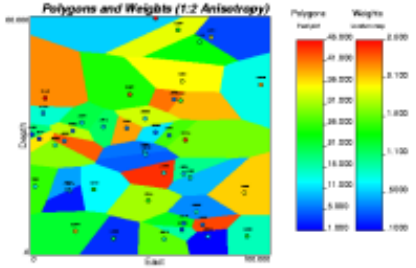
- El desagrupamiento es sensible a complejidades como los límites
- El método poligonal o de vecino más cercano ha surgido como útil
- La acumulación de pesos de estimación también ha surgido como útil
- Muchos detalles prácticos de implementación - no es tan fácil como debería ser



Desagrupamiento Poligonal

- También llamado 'área de influencia'
- A los datos se les asigna un peso proporcional a las áreas, estandarizado por el área total
- Se logra creando una grilla muy fina y contando el número de nodos más cercanos a cada dato
- Funciona bien cuando los bordes/límites del área de interés están bien definidos
- Cuando no están bien definidos, el peso dado a los datos del borde es problemático

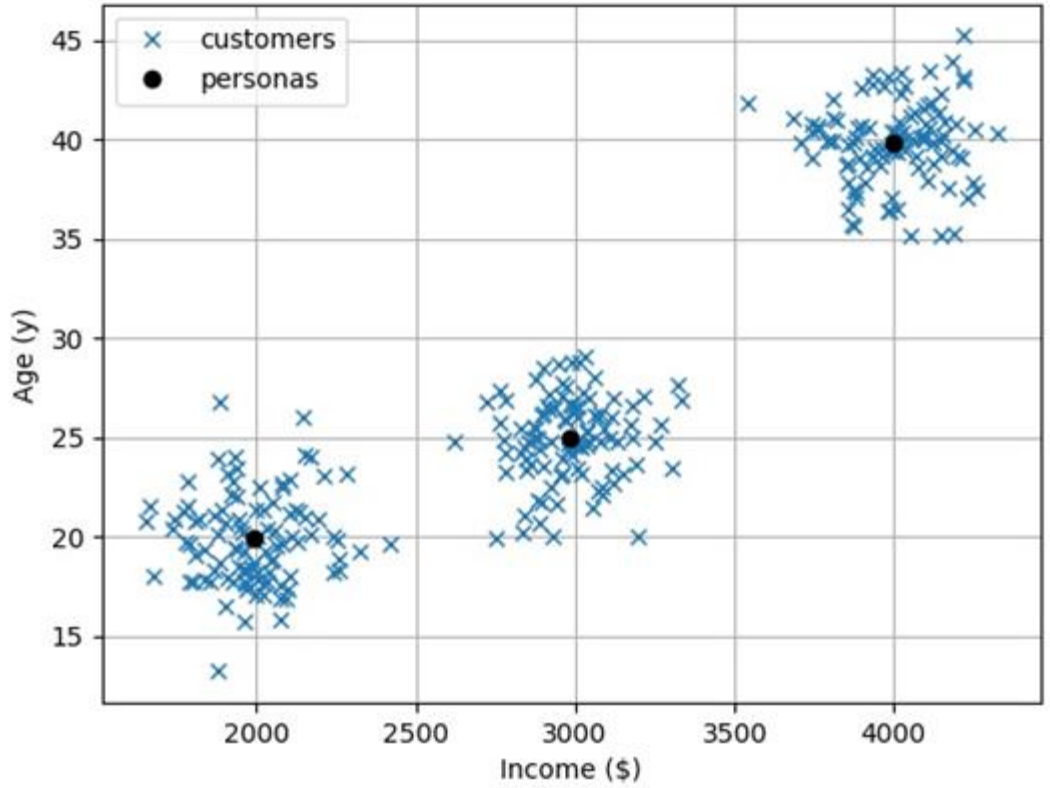




(10 min) Break



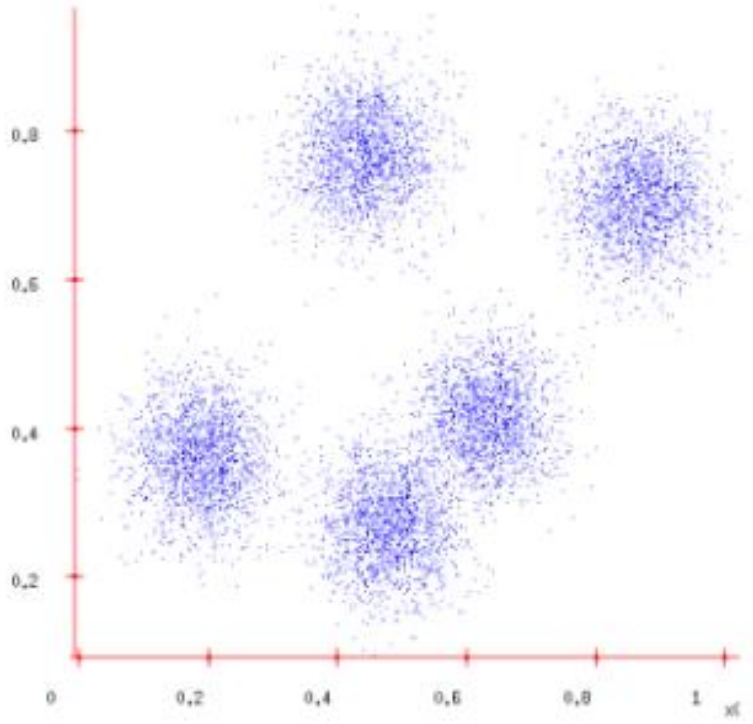
¿Cómo entendemos este patrón de datos?



(hay 2 respuestas)

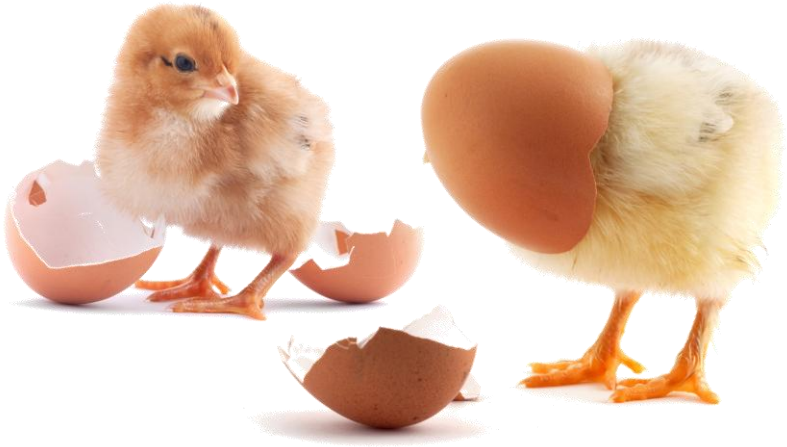
Respuesta 2: Patrón de datos producto del proceso generador natural de datos

- A veces los datos forman **clusters**, donde las muestras dentro de un cluster son similares entre sí, y las muestras en diferentes clusters son disímiles.
- Tal distribución es multimodal, ya que tiene múltiples modas, o regiones de alta masa de probabilidad.
- Agrupar puntos de datos en clusters, sin etiquetas observadas, se llama agrupamiento. Es una técnica de aprendizaje no supervisado.
- Ej: agrupar artículos de aprendizaje automático por tema (aprendizaje profundo, modelos Bayesianos, etc.)
    - Pero los temas nunca se observan (no supervisado).



Intuición de K-means

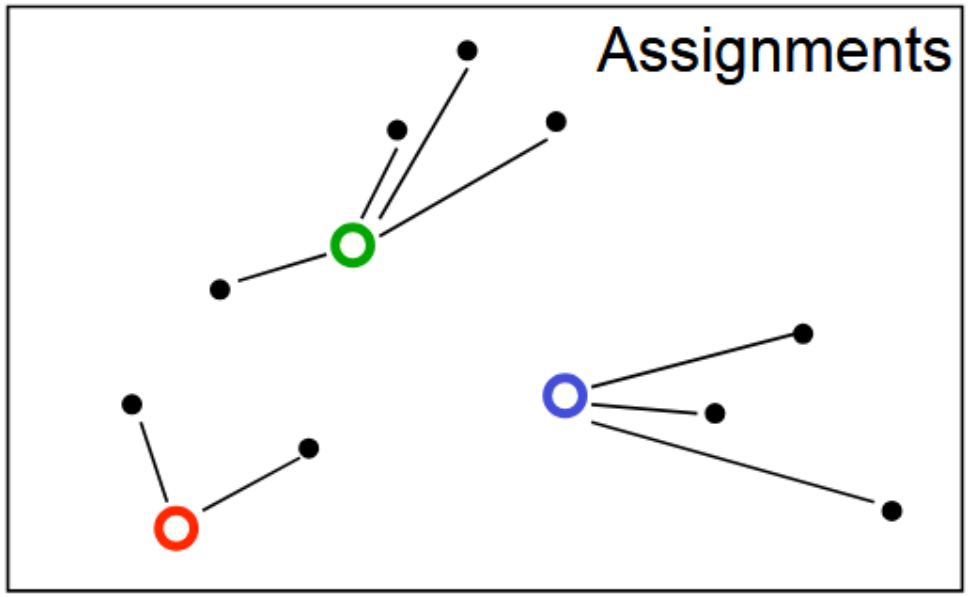
- K-means asume que hay k clusters, y cada punto está cerca del centro de su cluster, o media (la media de los puntos en el cluster).
  - Si conociéramos la asignación de clusters, podríamos calcular fácilmente los centros.
  - Si conociéramos los centros, podríamos calcular fácilmente la asignación de clusters.
  - ¡Problema del huevo y la gallina!

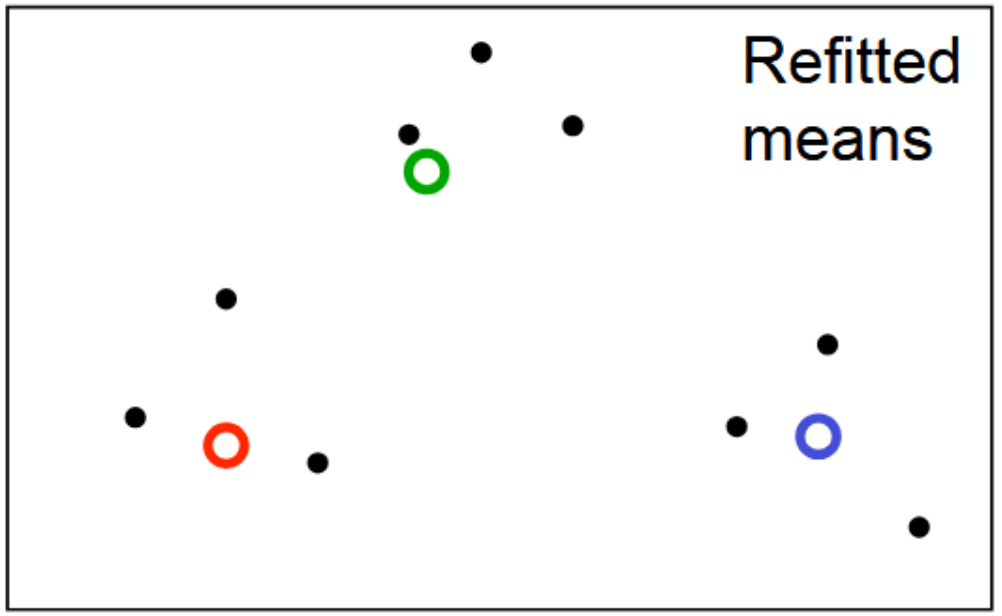


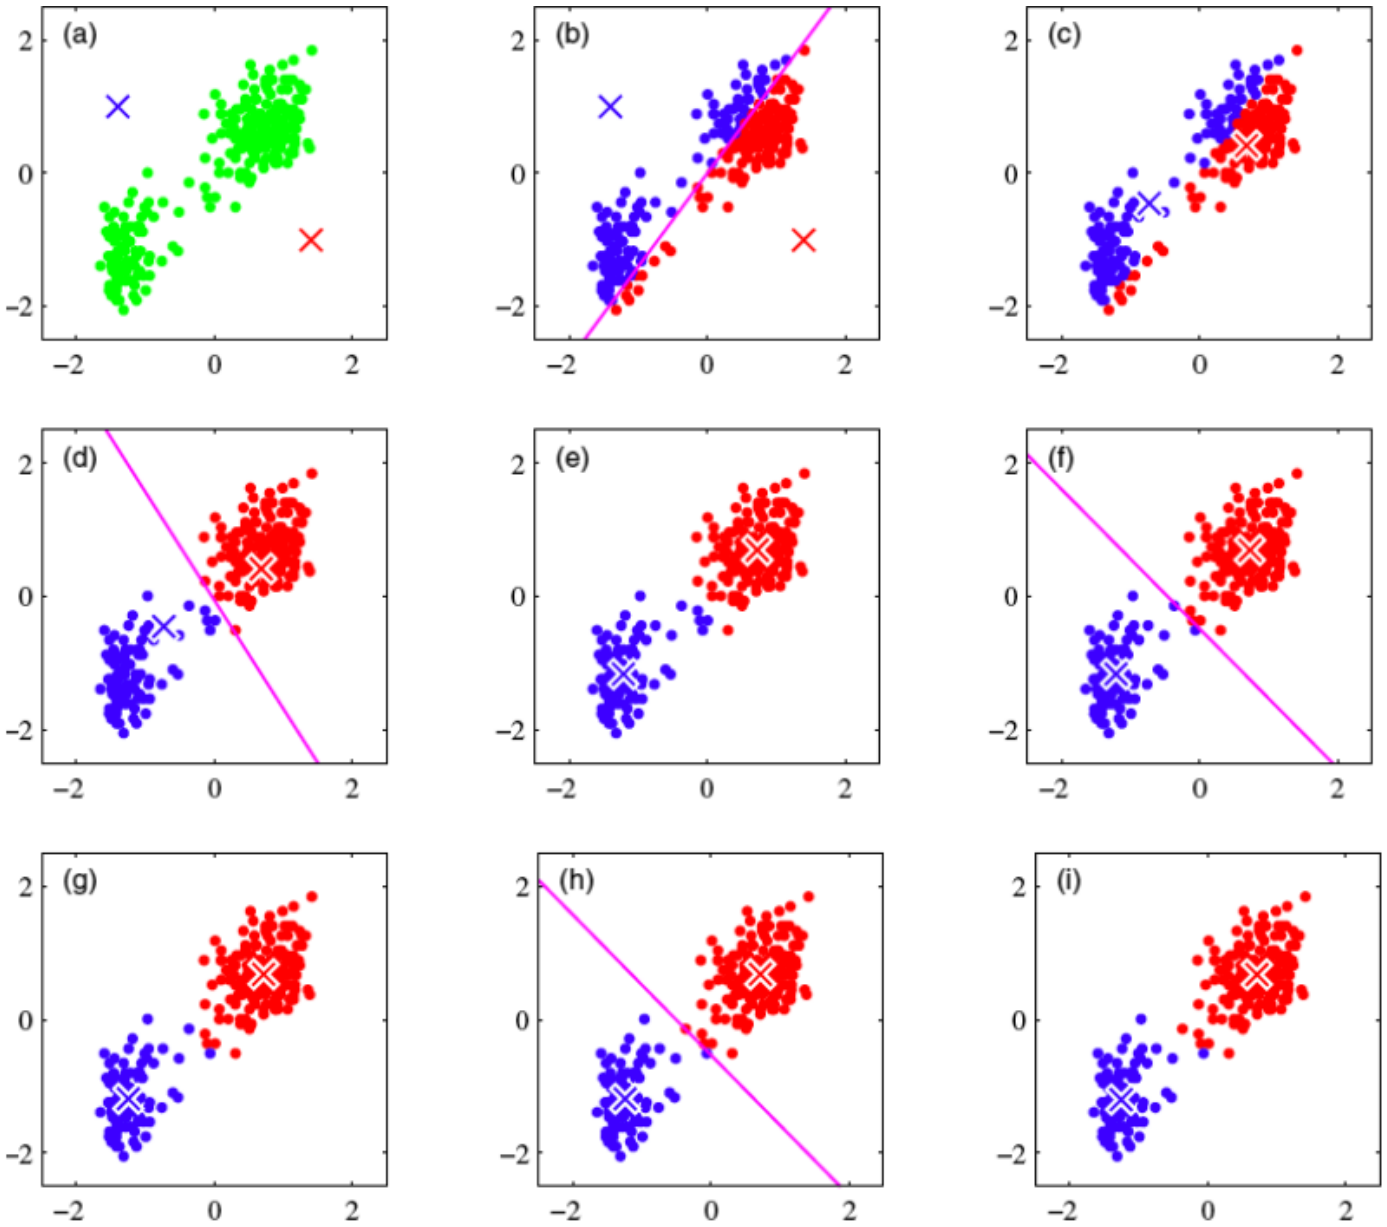
- Heurística muy simple (y útil) - ¡empezar aleatoriamente y alternar entre los dos!

K-means

- Inicialización: inicializar centros de cluster aleatoriamente
- El algoritmo alterna iterativamente entre dos pasos:
  - Paso de asignación: Asignar cada punto de datos al cluster más cercano
  - Paso de reajuste: Mover cada centro de cluster al centro de gravedad de los datos asignados a él







https://syskall.com/kmeans.js/

¿Cómo escribiríamos la optimización?



Objetivo de K-means

- ¿Qué se está optimizando realmente?

K-means Objective:
Find cluster centers $\mathbf{m}$ and assignments $\mathbf{r}$ to minimize the sum of squared distances of data points $\{\mathbf{x}^{(n)}\}$ to their assigned cluster centers

$$\min_{\{\mathbf{m}\},\{\mathbf{r}\}} J(\{\mathbf{m}\},\{\mathbf{r}\}) = \min_{\{\mathbf{m}\},\{\mathbf{r}\}} \sum_{n=1}^{N}\sum_{k=1}^{K} r_k^{(n)} ||\mathbf{m}_k - \mathbf{x}^{(n)}||^2$$

$$\text{s.t.} \sum_k r_k^{(n)} = 1, \forall n, \quad \text{where} \quad r_k^{(n)} \in \{0,1\}, \forall k, n$$

where $r_k^{(n)} = 1$ means that $\mathbf{x}^{(n)}$ is assigned to cluster k (with center $\mathbf{m}_k$)

- Encontrar el óptimo exacto es NP-difícil. ¿Cuántos parámetros minimizamos?
- K-means puede verse como descenso de coordenadas por bloques sobre este objetivo
  - Paso de asignación = minimizar respecto a $\{r_k^{(n)}\}$
  - Paso de reajuste = minimizar respecto a $\{m_k\}$

¿Cómo optimizar?: Minimización Alternante

- Problema de optimización:

$$\min_{\{\mathbf{m}_k\},\{\mathbf{r}^{(n)}\}} \sum_{n=1}^{N}\sum_{k=1}^{K} r_k^{(n)} ||\mathbf{m}_k - \mathbf{x}^{(n)}||^2$$

- Si fijamos los centros $\{m_k\}$, podemos encontrar fácilmente las asignaciones óptimas $\{r^{(n)}\}$ para cada muestra n

$$\min_{\mathbf{r}^{(n)}} \sum_{k=1}^{K} r_k^{(n)} ||\mathbf{m}_k - \mathbf{x}^{(n)}||^2$$

  - Asignar cada punto al cluster con el centro más cercano

$$r_k^{(n)} = \begin{cases} 1 & \text{if } k = \arg\min_j \|\mathbf{x}^{(n)} - \mathbf{m}_j\|^2 \\ 0 & \text{otherwise} \end{cases}$$

  - Ej: si $x^{(n)}$ está asignado al cluster k, (One-hot encoding)

$$\mathbf{r}^{(n)} = \underbrace{[0, 0, ..., 1, ..., 0]^\top}_{\text{Only } \hat{k}\text{-th entry is 1}}$$

Minimización Alternante

- De igual forma, si fijamos las asignaciones $\{r^{(n)}\}$, podemos encontrar fácilmente los centros óptimos $\{m_k\}$

$$0 = \frac{\partial}{\partial \mathbf{m}_l} \sum_{n=1}^{N} \sum_{k=1}^{K} r_k^{(n)} ||\mathbf{m}_k - \mathbf{x}^{(n)}||^2$$

$$= 2 \sum_{n=1}^{N} r_l^{(n)} (\mathbf{m}_l - \mathbf{x}^{(n)}) \quad \Longrightarrow \quad \mathbf{m}_l = \frac{\sum_n r_l^{(n)} \mathbf{x}^{(n)}}{\sum_n r_l^{(n)}}$$

- K-Means simplemente alterna entre minimizar respecto a las asignaciones y los centros. Esto es una instancia de minimización alternante, o descenso de coordenadas por bloques.

El Algoritmo K-means

- Inicialización: Establecer K centros de cluster $m_1,...,m_k$ con valores aleatorios
- Repetir hasta convergencia (hasta que las asignaciones no cambien):
  - Asignación: Optimizar J respecto a {r}: Cada punto $x^{(n)}$ se asigna al centro más cercano

$$\hat{k}^{(n)} = \arg\min_k ||\mathbf{m}_k - \mathbf{x}^{(n)}||^2$$

y Responsabilidades (codificación 1-hot o 1-de-K)

$$r_k^{(n)} = \mathbb{I}[\hat{k}^{(n)} = k] \quad \text{for} \quad k = 1, .., K$$

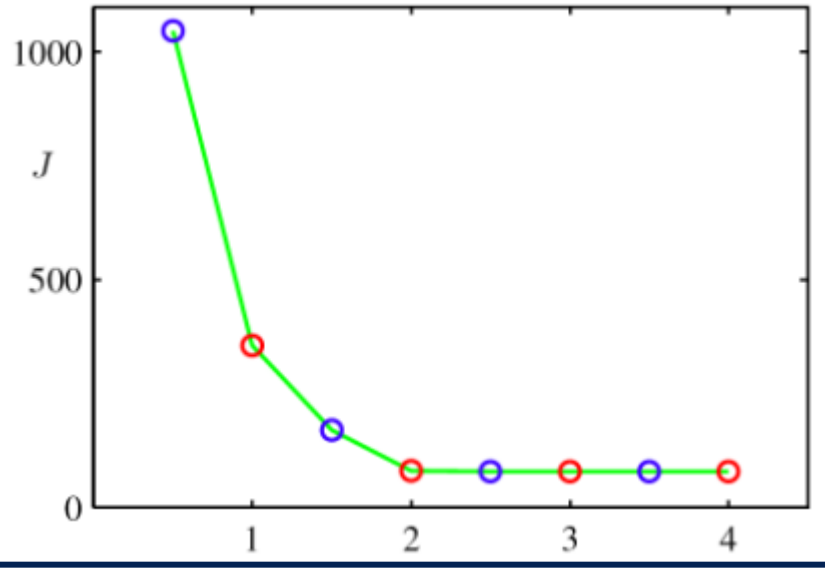
  - Reajuste: Optimizar J respecto a {m}: Cada centro se establece como la media de los datos asignados

$$\mathbf{m}_k = \frac{\sum_n r_k^{(n)} \mathbf{x}^{(n)}}{\sum_n r_k^{(n)}}.$$

Por qué K-means Converge

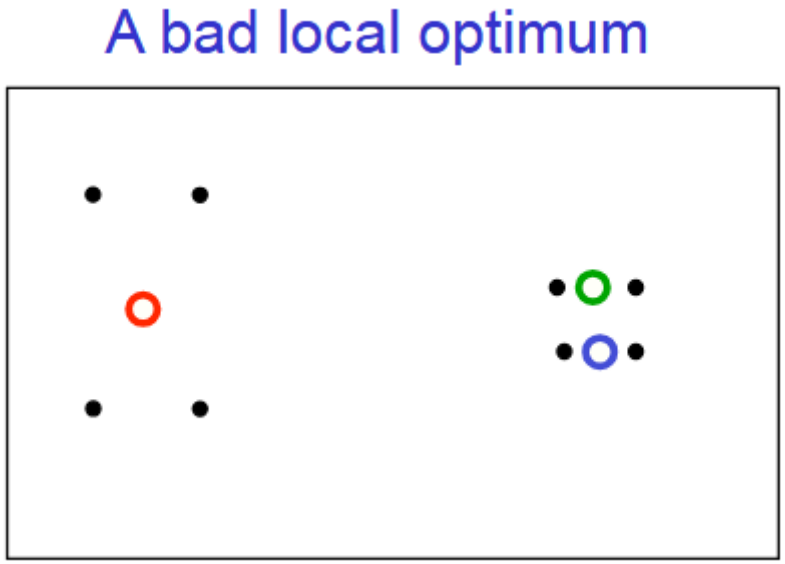
- El algoritmo K-means reduce el costo en cada iteración.
  - Cada vez que se cambia una asignación, la suma de distancias cuadradas J de los puntos de datos a sus centros de cluster asignados se reduce.
  - Cada vez que se mueve un centro de cluster, J se reduce.
- Prueba de convergencia: Si las asignaciones no cambian en el paso de asignación, hemos convergido (al menos a un mínimo local).
- Esto siempre ocurrirá después de un número finito de iteraciones, ya que el número de posibles asignaciones de clusters es finito.

Función de costo de K-means después de cada paso de asignación (azul) y reajuste (rojo). El algoritmo convergió después del tercer paso de reajuste.

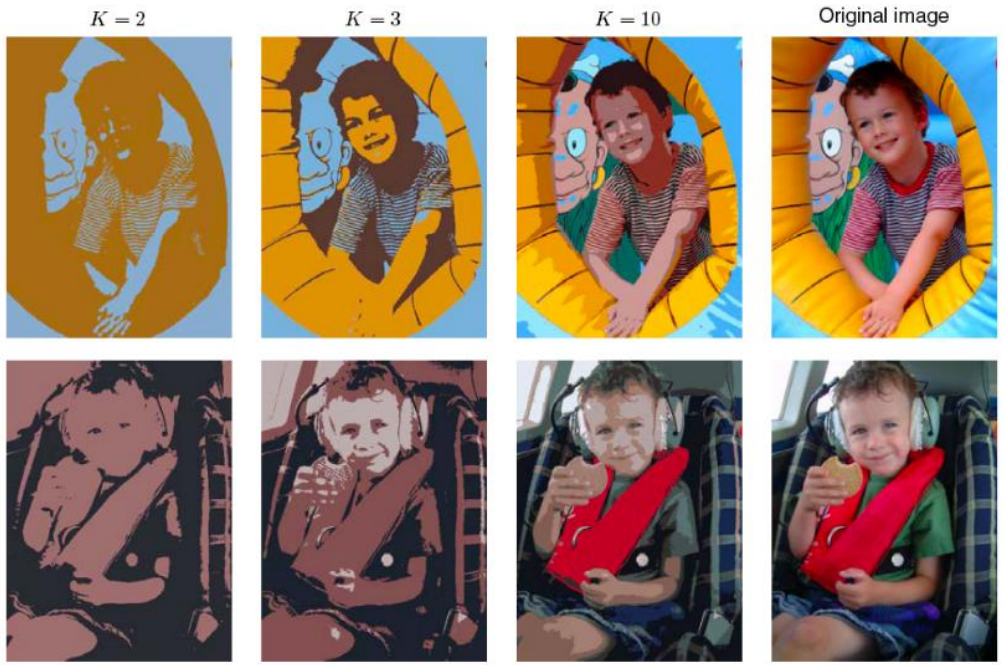


Mínimos Locales

- El objetivo J es no convexo (por lo que el descenso de coordenadas en J no garantiza convergencia al mínimo global)
- No hay nada que impida que K-means quede atrapado en mínimos locales.
- Podríamos probar muchos puntos de inicio aleatorios.

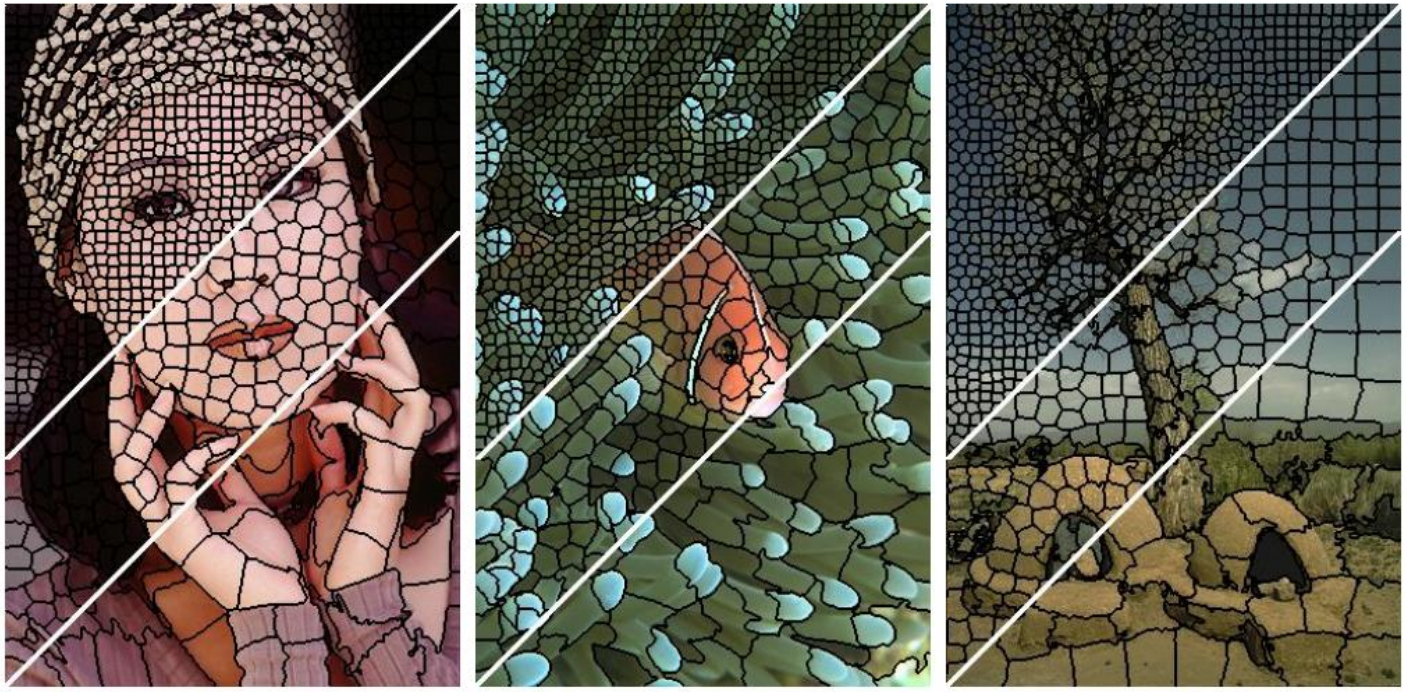


K-means para Cuantización Vectorial



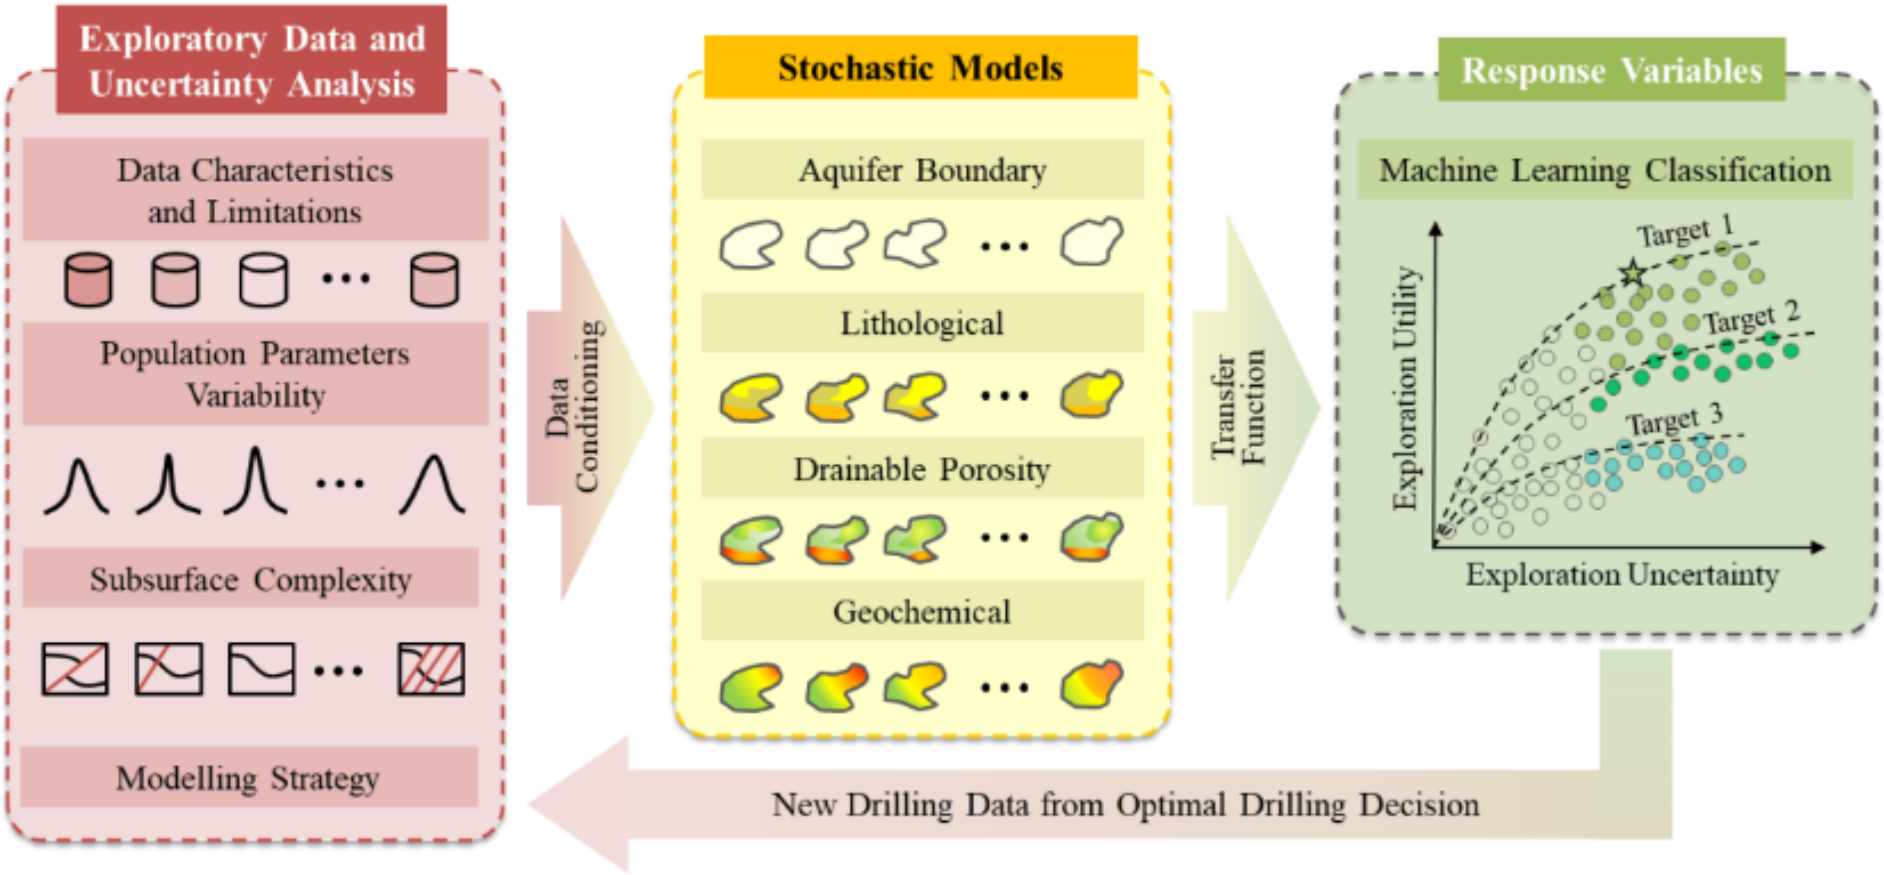
- Figuras de Bishop: Compresión de imagen con K=2, K=3, K=10 y original
- Dada una imagen, construir un 'conjunto de datos' de píxeles representados por sus intensidades de píxel RGB
- Ejecutar K-means, reemplazar cada píxel por su centro de cluster

K-means para Segmentación de Imágenes

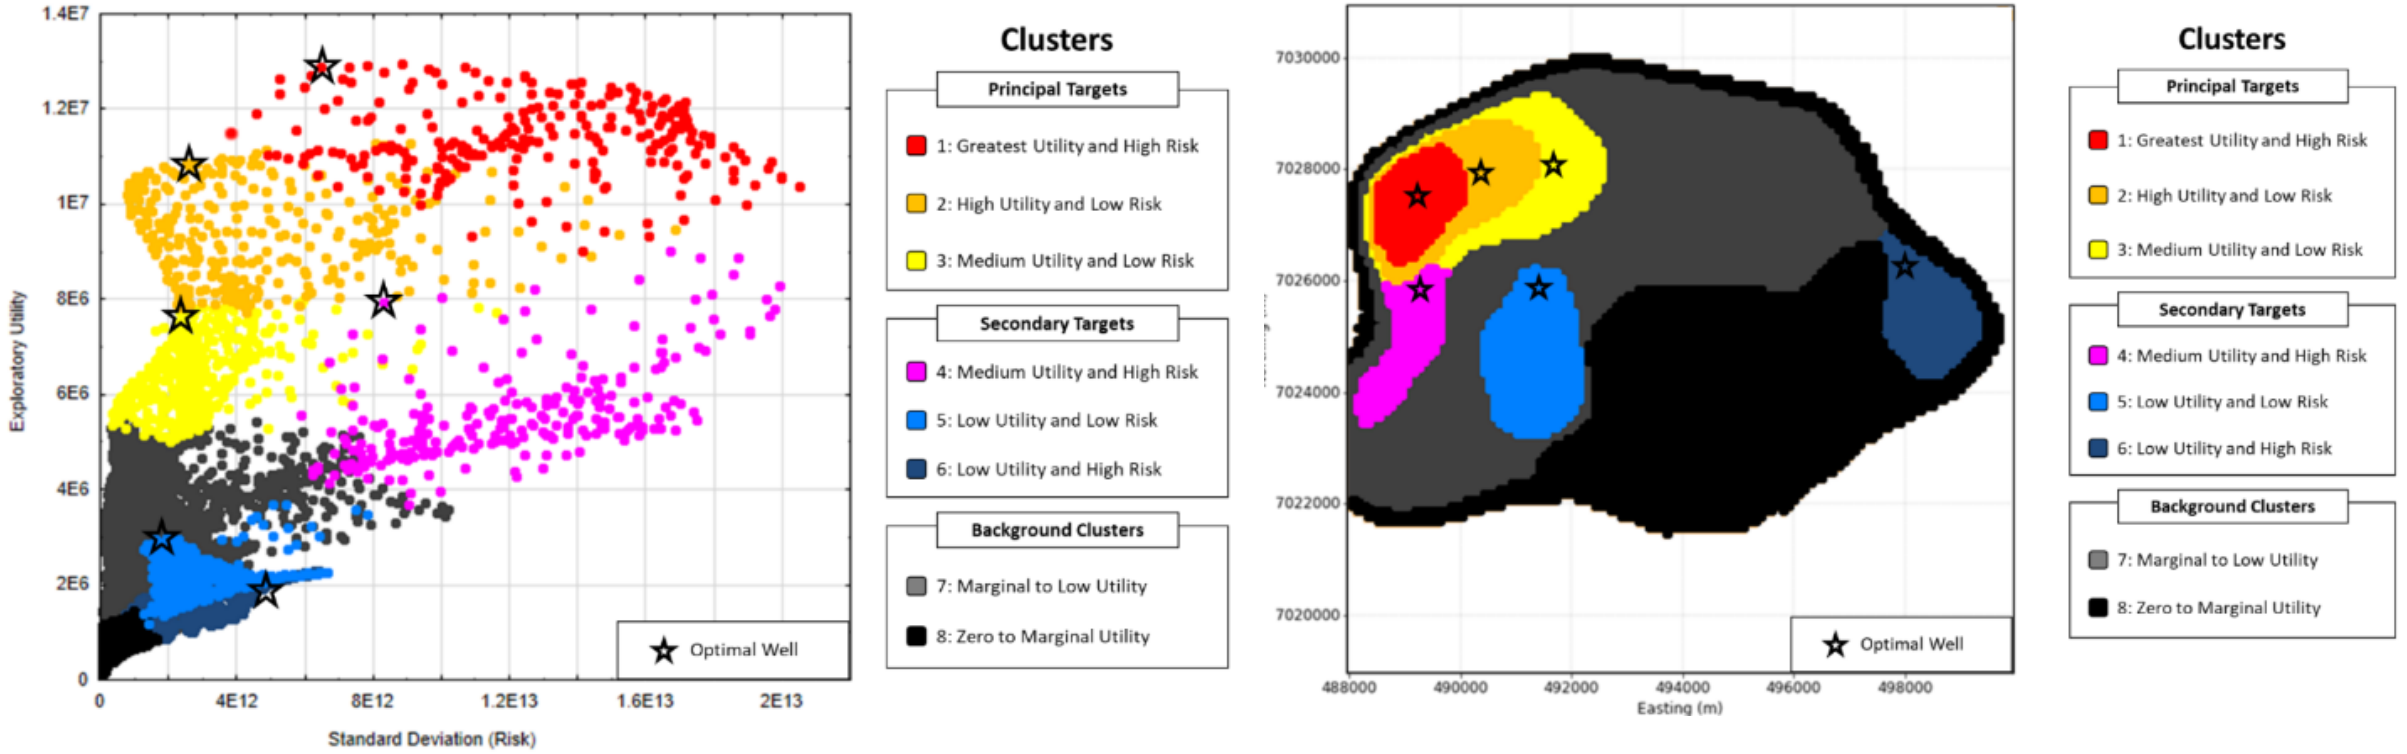


- [Figuras: Tres ejemplos de segmentación de imágenes con superpíxeles]
- Dada una imagen, construir un 'conjunto de datos' de píxeles, representados por sus intensidades de píxel RGB y ubicaciones en la cuadrícula
- Ejecutar K-means (con algunas modificaciones) para obtener superpíxeles

Ejemplo estadístico usando K-mean



Ejemplo estadístico usando K-mean





¿Problemas de utilizar K-means?



K-means Suave (Soft K-means)

- En lugar de hacer asignaciones duras de puntos de datos a clusters, podemos hacer asignaciones suaves. Un cluster puede tener una “responsabilidad” de 0.7 para un punto y otro puede tener una “responsabilidad” de 0.3.
  - Permite que un cluster use más información sobre los datos en el paso de reajuste.
  - ¿Cómo decidimos las asignaciones suaves?

Algoritmo de K-means Suave

- Inicialización: Establecer K medias $\{m_k\}$ con valores aleatorios
- Repetir hasta convergencia (medida por cuánto cambia J):
  - Asignación: Cada punto n recibe un 'grado de asignación' suave a cada media de cluster k, basado en responsabilidades

$$r_k^{(n)} = \frac{\exp[-\beta \|\mathbf{m}_k - \mathbf{x}^{(n)}\|^2]}{\sum_j \exp[-\beta \|\mathbf{m}_j - \mathbf{x}^{(n)}\|^2]}$$

$$\Longrightarrow \mathbf{r}^{(n)} = \text{softmax}(-\beta\{\|\mathbf{m}_k - \mathbf{x}^{(n)}\|^2\}_{k=1}^{K})$$

  - Reajuste: Los parámetros del modelo, las medias, se ajustan para coincidir con las medias muestrales de los puntos de los que son responsables:

$$\mathbf{m}_k = \frac{\sum_n r_k^{(n)} \mathbf{x}^{(n)}}{\sum_n r_k^{(n)}}$$



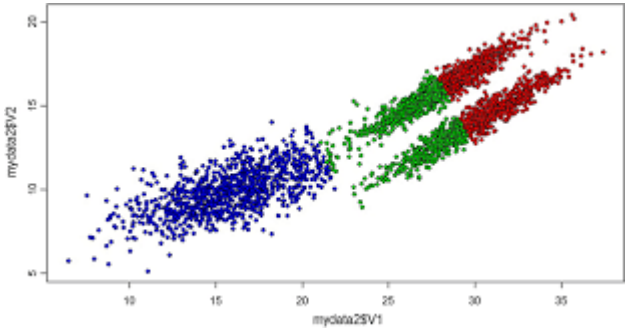
Preguntas sobre K-means Suave

- Algunos problemas pendientes:
  - ¿Cómo establecer β?
  - ¿Clusters con peso y ancho desiguales?
- Estos no son sencillos de abordar con K-means. En su lugar, a continuación reformularemos el agrupamiento usando un modelo generativo.

- Cuando $\beta \to \infty$, ¡K-means suave se convierte en K-means! (Ejercicio)

Una Vista Generativa del Agrupamiento

- ¿Qué pasa si los datos no se ven como esferas?
  - clusters elongados
  - datos discretos



- Resto de esta clase: formular el agrupamiento como un modelo probabilístico
  - especificar supuestos sobre cómo las observaciones se relacionan con las variables latentes
  - usar un algoritmo llamado E-M para maximizar (aproximadamente) la verosimilitud (distribuciones) de las observaciones
- Esto nos permite generalizar el agrupamiento a centros no esféricos o a modelos de observación no gaussianos.



Repaso de Modelos Generativos

- Clasificadores generativos (utilizando Bayes):

$$p(\mathbf{x}, t) = p(\mathbf{x} \mid t)\, p(t)$$

  - Ajustamos p(t) y p(x | t) usando datos etiquetados.
- Si t nunca se observa, la llamamos variable latente, o variable oculta, y generalmente la denotamos con z.
  - Las cosas que podemos observar (es decir, x) se llaman observables.
- Marginalizando z, obtenemos una densidad sobre los observables:

$$p(\mathbf{x}) = \sum_z p(\mathbf{x}, z) = \sum_z p(\mathbf{x} \mid z)\, p(z)$$

- Esto se llama un modelo de variables latentes.
- Si p(z) es una distribución categórica, esto es un modelo de mezcla, y diferentes valores de z corresponden a diferentes componentes.

Modelo de Mezcla Gaussiana (GMM)

El modelo de mezcla más común: modelo de mezcla gaussiana (GMM)

- Un GMM representa una distribución como

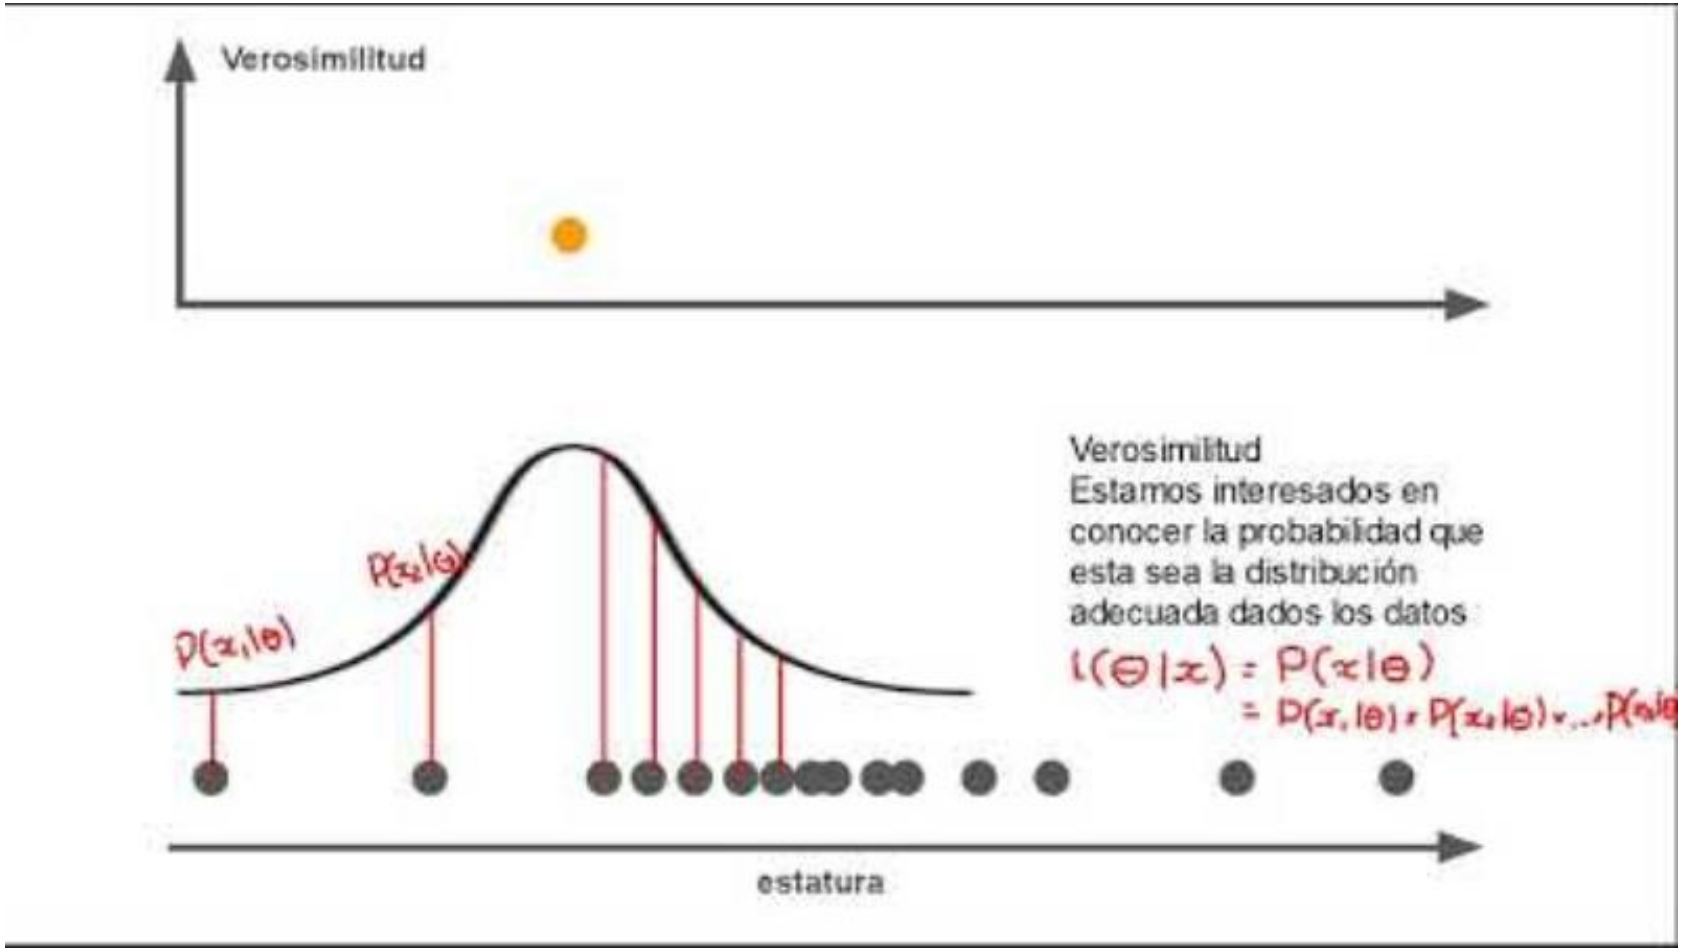
$$p(\mathbf{x}) = \sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

- con π_k los coeficientes de mezcla, donde:

$$\sum_{k=1}^{K} \pi_k = 1 \quad \text{and} \quad \pi_k \geq 0 \quad \forall k$$

- Esto define una densidad sobre x, así que podemos ajustar los parámetros usando máxima verosimilitud. Intentamos coincidir con la densidad de datos de x lo más posible.
  - Este es un problema de optimización complejo (y no es el enfoque de esta clase).
- Los GMMs son aproximadores universales de distribuciones.

Máxima Verosimilitud



https://www.youtube.com/watch?v=PzJQ4SE7iv4

Modelo de Mezcla Gaussiana (GMM) - Proceso Generativo

- También podemos escribir el modelo como un proceso generativo:

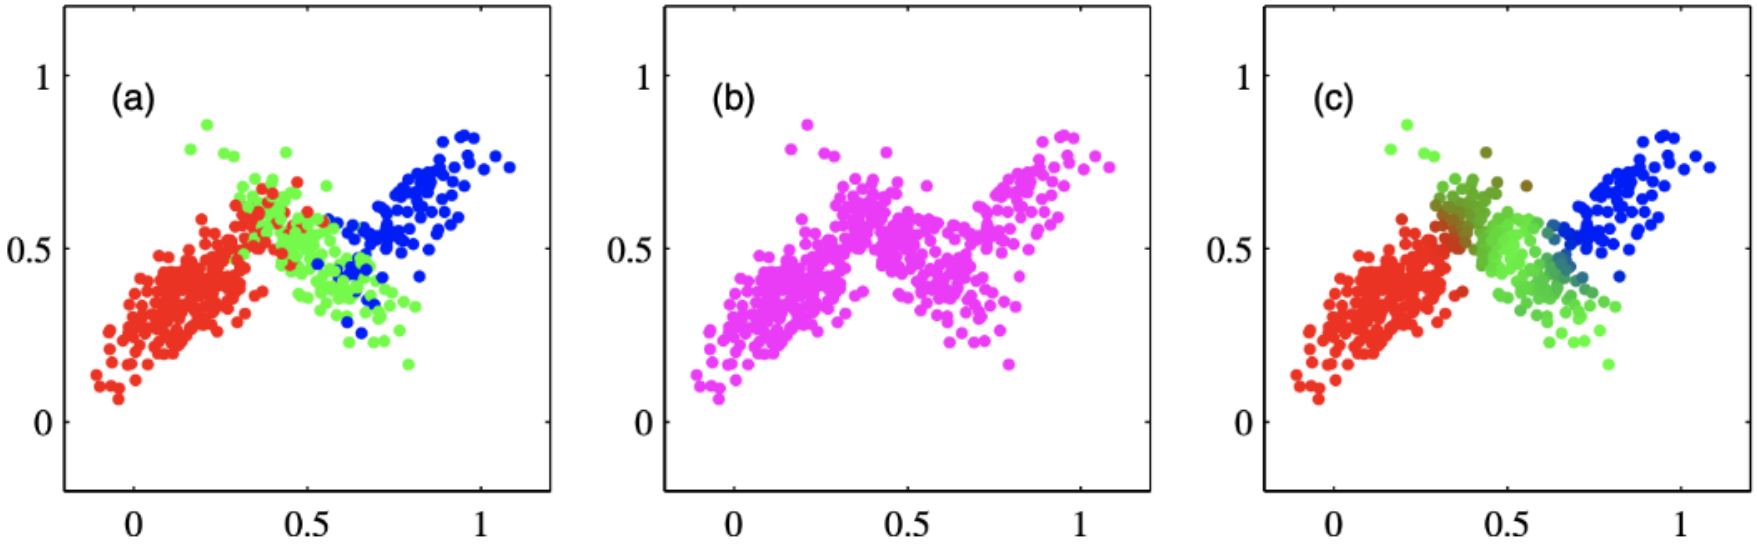
$$\text{For } i = 1, \ldots, N\text{:}$$

$$z^{(i)} \sim \text{Categorical}(\boldsymbol{\pi})$$

$$\mathbf{x}^{(i)} \mid z^{(i)} \sim \mathcal{N}(\boldsymbol{\mu}_{z^{(i)}}, \boldsymbol{\Sigma}_{z^{(i)}})$$

El Modelo Generativo

- 500 puntos extraídos de una mezcla de 3 Gaussianas.



a) Samples from $p(\mathbf{x} \mid z)$ b) Samples from the marginal $p(\mathbf{x})$ c) Responsibilities $p(z \mid \mathbf{x})$

Máxima Verosimilitud con Variables Latentes

- ¿Cómo elegir los parámetros $\{\pi_k, \mu_k, \Sigma_k\}_{k=1}^{K}$?
- Principio de máxima verosimilitud: elegir parámetros para maximizar la verosimilitud de los datos observados
- No observamos las asignaciones de cluster z, solo vemos los datos x
- Dados los datos $D = \{x^{(n)}\}_{n=1}^{N}$, elegir parámetros para maximizar:

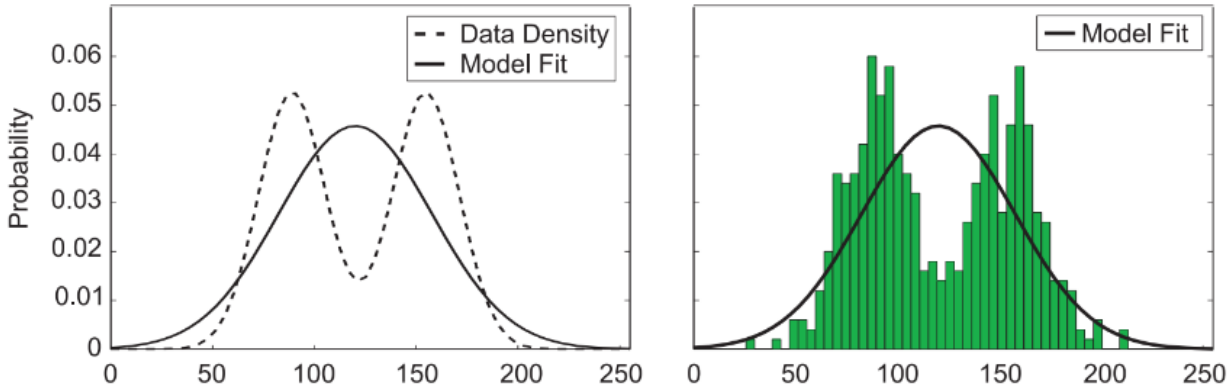
$$\log p(\mathcal{D}) = \sum_{n=1}^{N} \log p(\mathbf{x}^{(n)})$$

- Podemos encontrar p(x) marginalizando z:

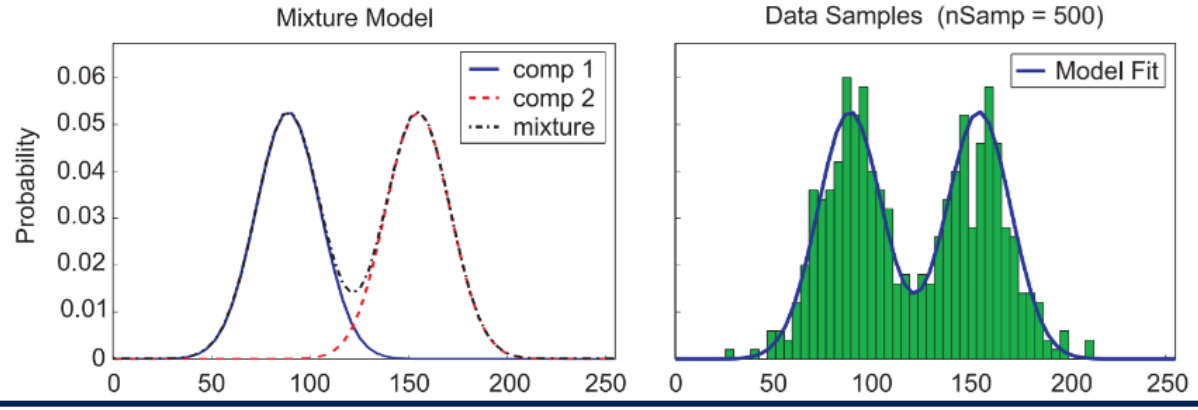
$$p(\mathbf{x}) = \sum_{k=1}^{K} p(z = k, \mathbf{x}) = \sum_{k=1}^{K} p(z = k) p(\mathbf{x}|z = k)$$

Visualización de una Mezcla de Gaussianas - Gaussianas 1D

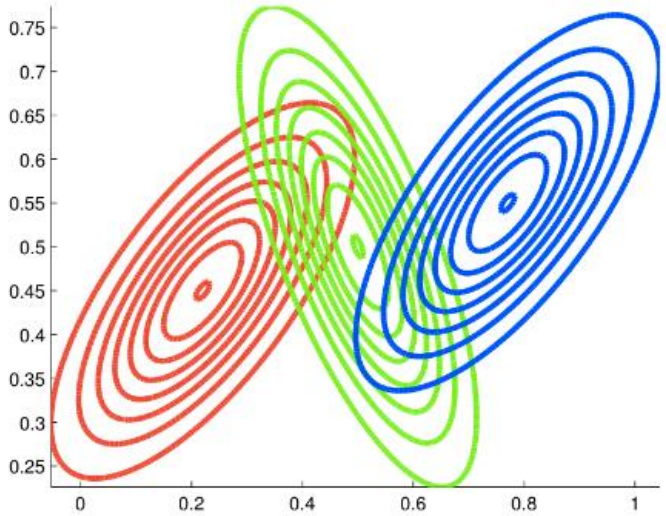
- Si ajustas una Gaussiana a los datos:

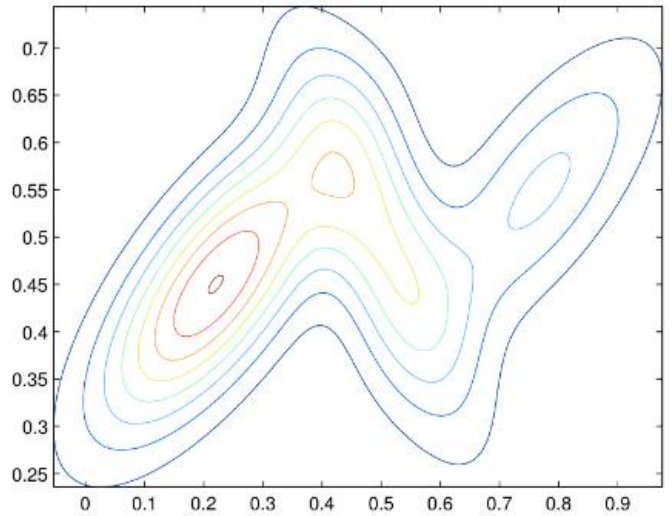


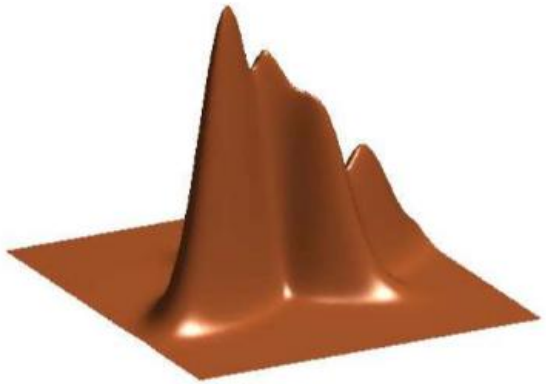
- Ahora, estamos intentando ajustar un GMM (con K=2 en este ejemplo):



Visualización de una Mezcla de Gaussianas - Gaussianas 2D









Expectación-Maximización (E-M)



Ajuste de GMMs: Máxima Verosimilitud

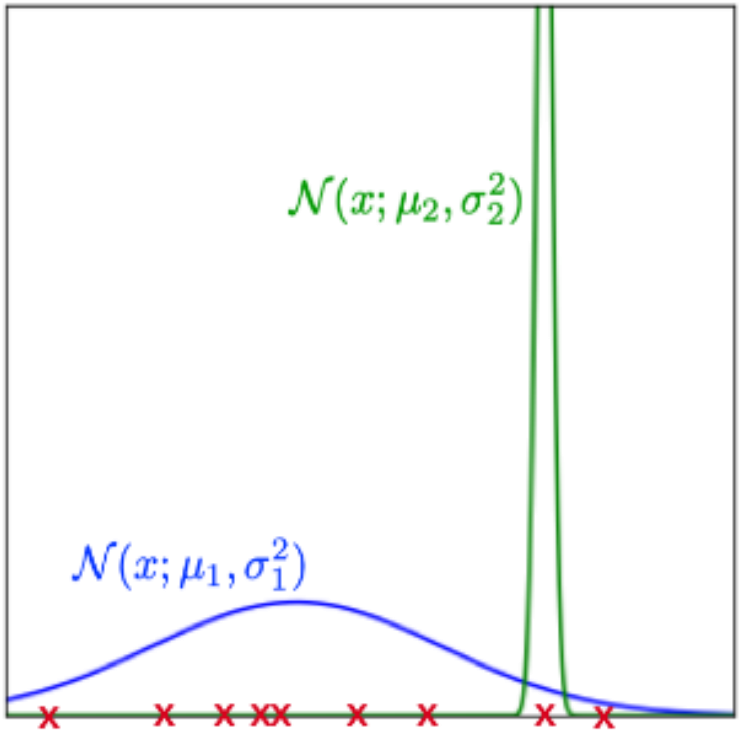
- Notación abreviada: sea $\theta = \{\pi_k, \mu_k, \Sigma_k\}$ el conjunto completo de parámetros del modelo. Sea $X = \{x^{(i)}\}$ y $Z = \{z^{(i)}\}$.
- Objetivo de máxima verosimilitud:

$$\log p(\mathbf{X}; \boldsymbol{\theta}) = \sum_{i=1}^{N} \log \left(\sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x}^{(i)}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right)$$

- En general, no hay solución en forma cerrada
- No identificable: la solución es invariante a permutaciones
- Desafíos para optimizar esto con descenso de gradiente:
  - No convexo (debido a simetría de permutación)
  - Necesidad de imponer restricción de no negatividad en π_k y restricción PSD en Σ_k
  - Las derivadas respecto a Σ_k son costosas/complicadas.
- ¡Necesitamos un enfoque diferente!

Ajuste de GMMs: Máxima Verosimilitud -

- Advertencia: no queremos el máximo global. Se puede lograr una verosimilitud de entrenamiento arbitrariamente alta colocando una componente gaussiana de varianza pequeña sobre un ejemplo de entrenamiento.
- Esto se conoce como una singularidad.





Modelos de Variables Latentes: Inferencia

- Si conociéramos los parámetros $\theta = \{\pi_k, \mu_k, \Sigma_k\}$, podríamos inferir a qué componente probablemente pertenece un punto $x^{(i)}$ infiriendo su variable latente $z^{(i)}$.
- Esto es simplemente inferencia posterior, que hacemos usando la Regla de Bayes:

$$\Pr(z^{(i)} = k \,|\, \mathbf{x}^{(i)}) = \frac{\Pr(z = k)\, p(\mathbf{x} \,|\, z = k)}{\sum_\ell \Pr(z = \ell)\, p(\mathbf{x} \,|\, z = \ell)}$$

- Igual que Naïve Bayes, GDA, etc. en tiempo de prueba.

Modelos de Variables Latentes: Aprendizaje

- Si de alguna manera conociéramos las variables latentes para cada punto, podríamos simplemente maximizar la log-verosimilitud conjunta.

$$\log p(\mathbf{X}, \mathbf{Z}; \boldsymbol{\theta}) = \sum_{i=1}^{N} \log p(\mathbf{x}^{(i)}, z^{(i)}; \boldsymbol{\theta})$$
$$= \sum_{i=1}^{N} \log p(z^{(i)}) + \log p(\mathbf{x}^{(i)} \mid z^{(i)}).$$



Modelos de Variables Latentes

- Pero no conocemos las $z^{(i)}$, así que necesitamos marginalizarlas. Ahora la log-verosimilitud es más incómoda.

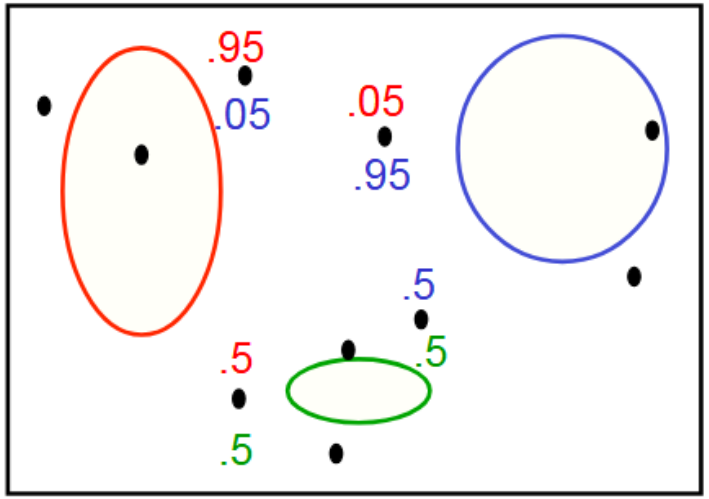
$$\log p(\mathbf{X}; \boldsymbol{\theta}) = \sum_{i=1}^{N} \log p(\mathbf{x}^{(i)} \mid \boldsymbol{\theta})$$

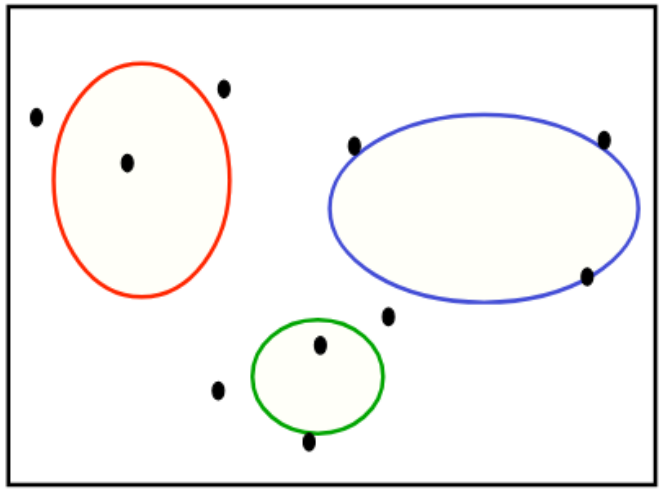
$$= \sum_{i=1}^{N} \log \sum_{z^{(i)}=1}^{K} p(\mathbf{x}^{(i)} \mid z^{(i)}; \{\boldsymbol{\mu}_k\}, \{\boldsymbol{\Sigma}_k\})\, p(z^{(i)} \mid \boldsymbol{\pi})$$

- Problema: el logaritmo está fuera de la suma, así que las cosas no se simplifican.
- ¡Tenemos un problema del huevo y la gallina, igual que con K-Means!
  - Dado θ, inferir las $z^{(i)}$ es fácil.
  - Dadas las $z^{(i)}$, aprender θ (con máxima verosimilitud) es fácil.
  - Hacer ambos simultáneamente es difícil.
- ¿Puedes adivinar el algoritmo?

Intuitivamente, ¿Cómo Ajustar una Mezcla de Gaussianas?

- Usamos el algoritmo de Expectación-Maximización, que alterna entre dos pasos:
- 1. Paso de Expectación (E-step): Calcular la probabilidad posterior sobre z dado nuestro modelo actual - es decir, cuánto creemos que cada Gaussiana genera cada punto.
- 2. Paso de Maximización (M-step): Asumiendo que los datos realmente se generaron así, cambiar los parámetros de cada Gaussiana para maximizar la probabilidad de que genere los datos de los que es actualmente responsable.





Resumen de EM para GMM

1. E-step:

- Asignar la responsabilidad $r_k^{(i)}$ de la componente k para el punto i usando la probabilidad posterior:

$$r_k^{(i)} = \Pr(z^{(i)} = k \mid \mathbf{x}^{(i)}; \boldsymbol{\theta})$$

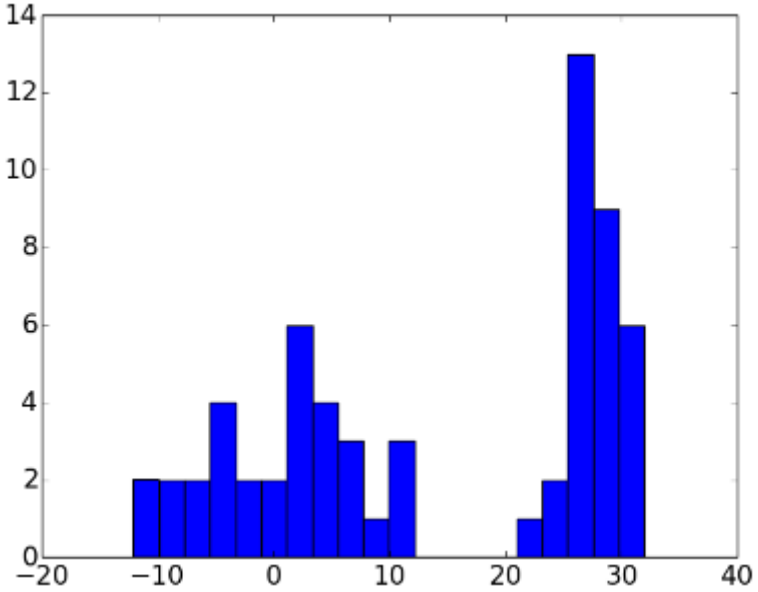
2. M-step:

- Aplicar las actualizaciones de máxima verosimilitud, donde cada componente se ajusta con un conjunto de datos ponderado. Los pesos son proporcionales a las responsabilidades.

$$\begin{aligned}
\pi_k &= \frac{1}{N} \sum_{i=1}^{N} r_k^{(i)} \\
\boldsymbol{\mu}_k &= \frac{\sum_{i=1}^{N} r_k^{(i)} \cdot \mathbf{x}^{(i)}}{\sum_{i=1}^{N} r_k^{(i)}} \\
\boldsymbol{\Sigma}_k &= \frac{1}{\sum_{i=1}^{N} r_k^{(i)}} \sum_{i=1}^{N} r_k^{(i)} (\mathbf{x}^{(i)} - \boldsymbol{\mu}_k)(\mathbf{x}^{(i)} - \boldsymbol{\mu}_k)^\top
\end{aligned}$$

Ejemplo

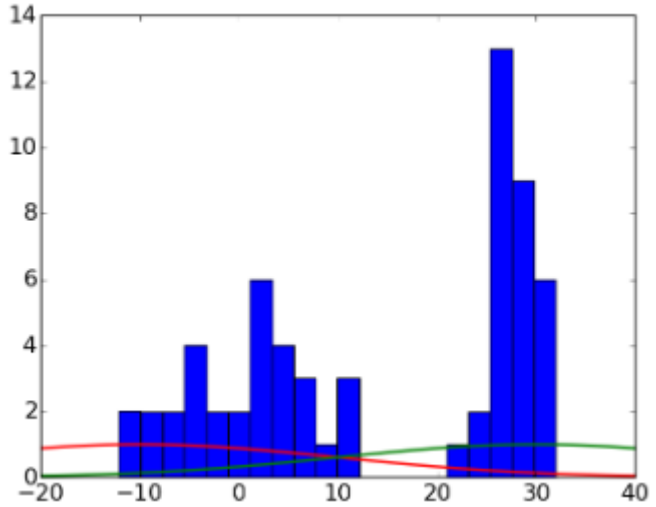
- Supongamos que registramos un montón de temperaturas en marzo para Toronto y Miami, pero olvidamos registrar cuál era cuál, y están todas mezcladas.



- Intentemos separarlas usando una mezcla de Gaussianas y E-M.

Ejemplo - Inicialización

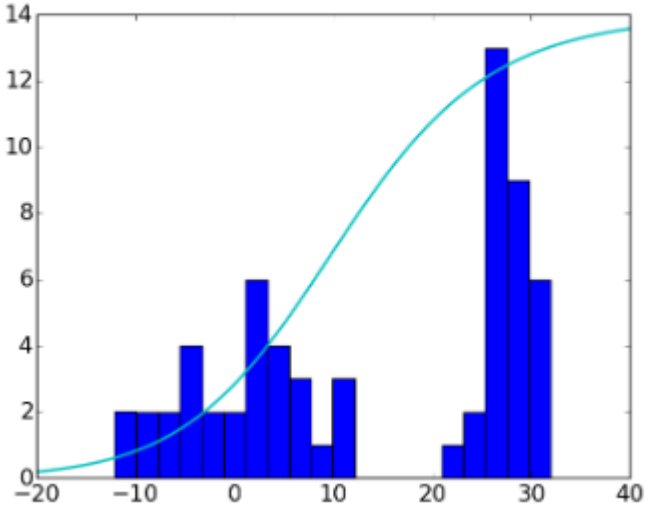
- Inicialización aleatoria



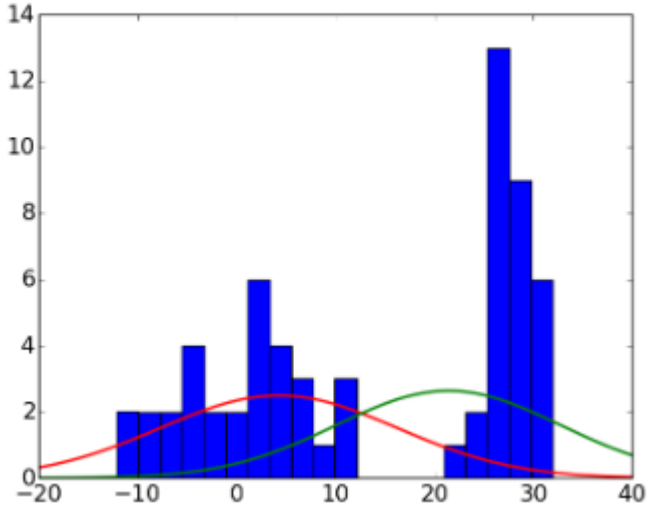
Ejemplo - Paso 1

- Paso 1:

E-step



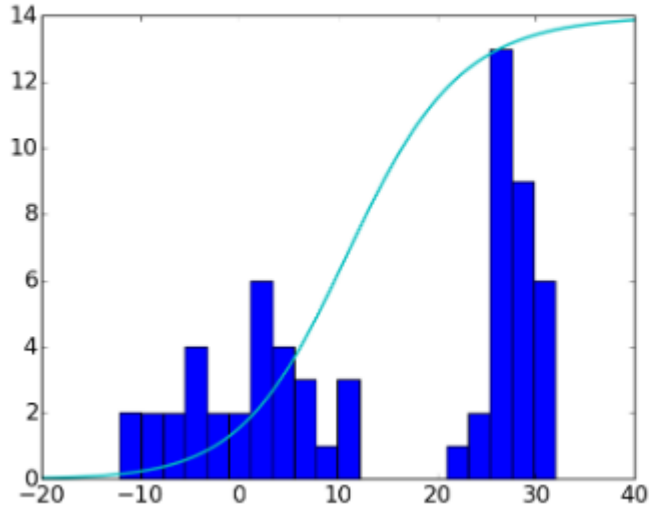
M-step



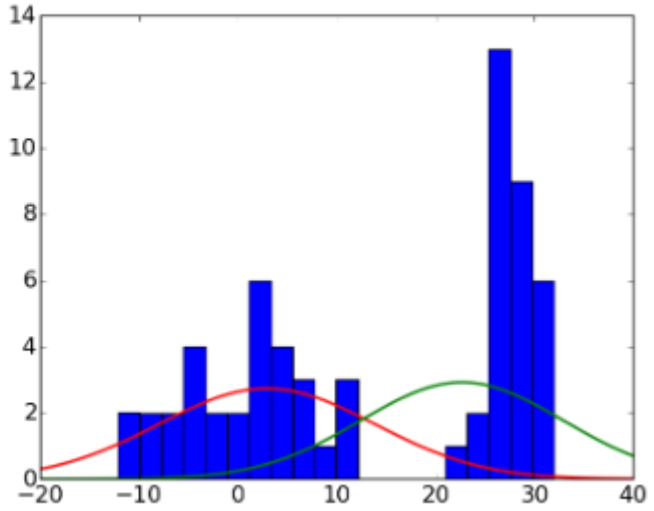
Ejemplo - Paso 2

- Paso 2:

E-step

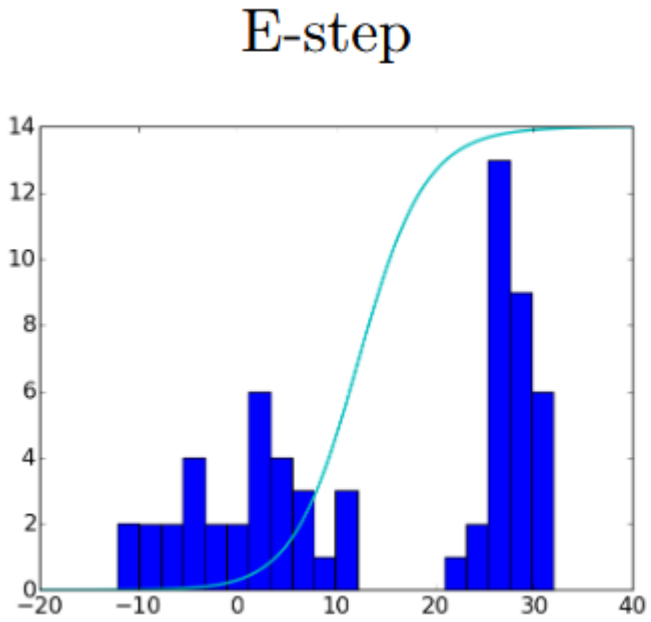


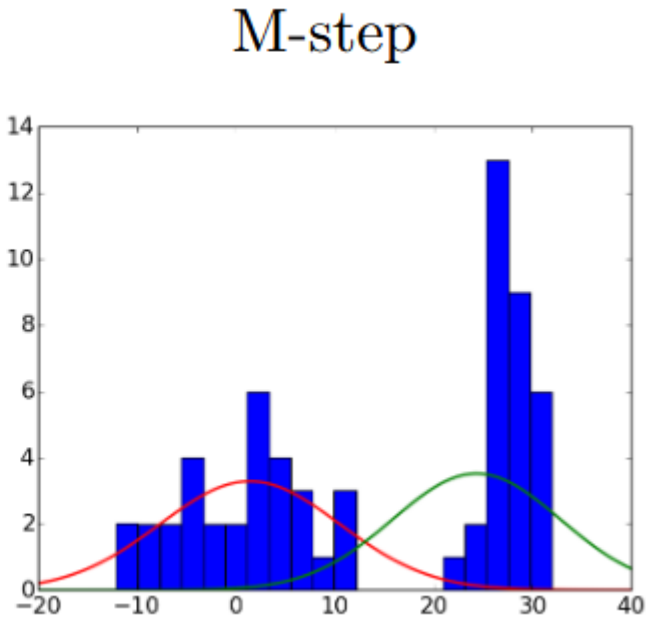
M-step



Ejemplo - Paso 3

- Paso 3:

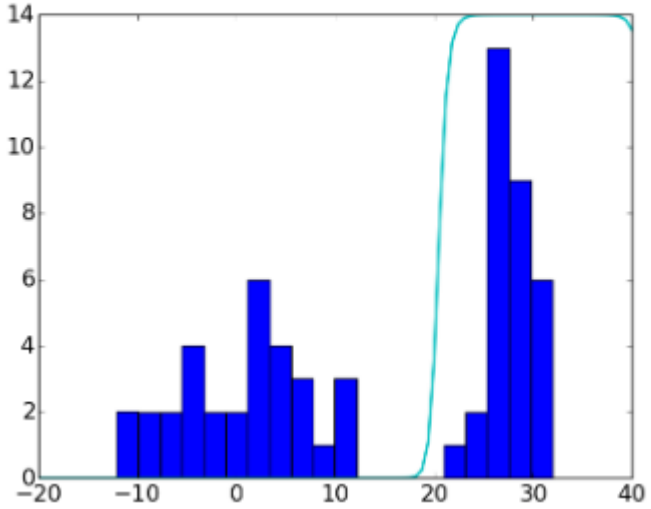




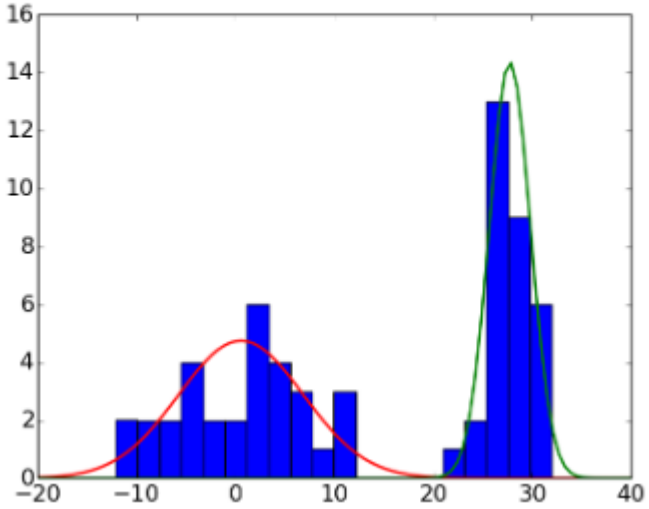
Ejemplo - Paso 10

- Paso 10:

E-step

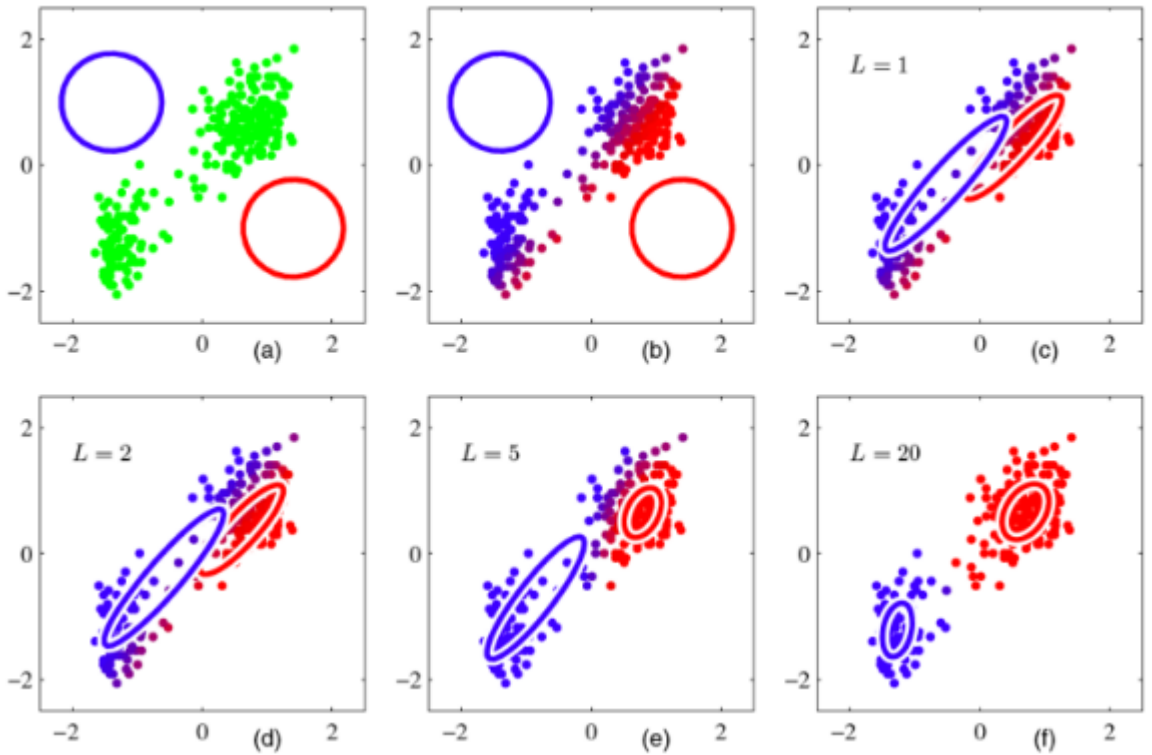


M-step



Expectación-Maximización

- EM para Gaussianas Multivariadas:



- Se puede ajustar un modelo de mezcla de Bernoullis.

Relación con K-Means

- El Algoritmo K-Means:
  1. **Paso de asignación**: Asignar cada punto al cluster más cercano
  2. **Paso de reajuste**: Mover cada centro de cluster al promedio de los datos asignados
- El Algoritmo EM:
  1. **E-step**: Calcular la probabilidad posterior sobre z dado nuestro modelo actual
  2. **M-step**: Maximizar la probabilidad de que generaría los datos de los que es actualmente responsable.
- ¿Puedes encontrar las similitudes entre el algoritmo K-Means suave y el algoritmo EM con covarianza compartida $(1/\beta)I$?
- Ambos dependen de métodos de optimización alternante y pueden sufrir de malos óptimos locales.

Recapitulación del GMM

- Una vista probabilística del agrupamiento - Cada cluster corresponde a una Gaussiana diferente.
- Modelo usando variables latentes.
- Enfoque general, puede reemplazar Gaussiana con otras distribuciones (continuas o discretas)
- Más generalmente, los modelos de mezcla son modelos muy poderosos, es decir, aproximadores universales de distribuciones
- La optimización se realiza usando el algoritmo EM.

Problema: Soft K-Means

Considere un conjunto de datos unidimensional con $N = 3$puntos:

- $x^{(1)} = 1$
- $x^{(2)} = 3$
- $x^{(3)} = 5$
- Se utilizan $K = 2$clústeres y $\beta = 0.5$(un valor moderado para una asignación suave; valores mayores de βaproximan el comportamiento de k-means duro).

Realizar una iteración de optimización considerando los centroides inicializados en:

- $m_1 = 2$ (clúster 1)
- $m_2 = 4$ (clúster 2)

$$r_k^{(n)} = \frac{\exp\left(-\beta \|\mathbf{m}_k - \mathbf{x}^{(n)}\|^2\right)}{\sum_{j=1}^{K} \exp\left(-\beta \|\mathbf{m}_j - \mathbf{x}^{(n)}\|^2\right)} \qquad \mathbf{m}_k = \frac{\sum_{n=1}^{N} r_k^{(n)} \mathbf{x}^{(n)}}{\sum_{n=1}^{N} r_k^{(n)}}$$

Problema: Soft K-Means

Para $x^{(1)} = 1$:

- Distancia a m_1 :$(2-1)^2 = 1 \rightarrow -\beta \cdot 1 = -0.5 \rightarrow \exp(-0.5) \approx 0.6065$
- Distancia a m_2 :$(4-1)^2 = 9 \rightarrow -\beta \cdot 9 = -4.5 \rightarrow \exp(-4.5) \approx 0.0111$
- Denominador: $0.6065 + 0.0111 = 0.6176$
- $r_1^{(1)} = 0.6065/0.6176 \approx 0.9820$
- $r_2^{(1)} = 0.0111/0.6176 \approx 0.0180$

Problema: Soft K-Means

Para $x^{(2)} = 3$:

- Distancia a m_1 :$(2-3)^2 = 1 \rightarrow -\beta \cdot 1 = -0.5 \rightarrow \exp(-0.5) \approx 0.6065$
- Distancia a m_2 :$(4-3)^2 = 1 \rightarrow -\beta \cdot 1 = -0.5 \rightarrow \exp(-0.5) \approx 0.6065$
- Denominador: $0.6065 + 0.6065 = 1.2130$
- $r_1^{(2)} = 0.6065/1.2130 \approx 0.5000$
- $r_2^{(2)} = 0.6065/1.2130 \approx 0.5000$

Problema: Soft K-Means

Para $x^{(3)} = 5$:

- Distancia a m_1 :$(2-5)^2 = 9 \rightarrow -\beta \cdot 9 = -4.5 \rightarrow \exp(-4.5) \approx 0.0111$
- Distancia a m_2 :$(4-5)^2 = 1 \rightarrow -\beta \cdot 1 = -0.5 \rightarrow \exp(-0.5) \approx 0.6065$
- Denominador: $0.0111 + 0.6065 = 0.6176$
- $r_1^{(3)} = 0.0111/0.6176 \approx 0.0180$
- $r_2^{(3)} = 0.6065/0.6176 \approx 0.9820$

Problema: Soft K-Means

Para m_1:

- Numerador: $r_1^{(1)} \cdot 1 + r_1^{(2)} \cdot 3 + r_1^{(3)} \cdot 5 = 0.9820 \cdot 1 + 0.5000 \cdot 3 + 0.0180 \cdot 5 \approx 0.9820 + 1.5000 + 0.0900 = 2.5720$
- Denominador: $r_1^{(1)} + r_1^{(2)} + r_1^{(3)} \approx 0.9820 + 0.5000 + 0.0180 = 1.5000$
- $m_1^{nuevo} = 2.5720/1.5000 \approx 1.7147$

Para m_2:

- Numerador: $r_2^{(1)} \cdot 1 + r_2^{(2)} \cdot 3 + r_2^{(3)} \cdot 5 = 0.0180 \cdot 1 + 0.5000 \cdot 3 + 0.9820 \cdot 5 \approx 0.0180 + 1.5000 + 4.9100 = 6.4280$
- Denominador: $r_2^{(1)} + r_2^{(2)} + r_2^{(3)} \approx 0.0180 + 0.5000 + 0.9820 = 1.5000$
- $m_2^{nuevo} = 6.4280/1.5000 \approx 4.2853$

Problema: Soft K-Means

- Para m_1:
- Numerador: $r_1^{(1)} \cdot 1 + r_1^{(2)} \cdot 3 + r_1^{(3)} \cdot 5 = 0.9820 \cdot 1 + 0.5000 \cdot 3 + 0.0180 \cdot 5 \approx 0.9820 + 1.5000 + 0.0900 = 2.5720$
- Denominador: $r_1^{(1)} + r_1^{(2)} + r_1^{(3)} \approx 0.9820 + 0.5000 + 0.0180 = 1.5000$
- $m_1^{nuevo} = 2.5720/1.5000 \approx 1.7147$

Preguntas Vibe Quest

- Compara desagrupamiento por celdas y desagrupamiento poligonal utilizando el mismo conjunto de datos, visualizando cómo cambian los pesos individuales y las estadísticas globales al modificar la geometría del dominio y la densidad de muestreo.
- Explora soft K-means variando el parámetro β y visualiza cómo cambian las responsabilidades, los centroides y la suavidad de las fronteras entre clusters, mostrando la transición continua entre asignaciones suaves y asignaciones duras.
- Ajusta un modelo de mezcla gaussiana (GMM) con diferentes valores de K y distintos tipos de covarianza, y visualiza simultáneamente las densidades aprendidas, las responsabilidades posteriores y la log-verosimilitud para analizar cómo el modelo representa la estructura probabilística de los datos.
- Compara K-means, soft K-means y GMM sobre el mismo conjunto de datos, visualizando simultáneamente asignaciones, densidades y fronteras de decisión para evidenciar las diferencias entre una visión geométrica y una visión probabilística del clustering.