PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ
FACULTAD DE CIENCIAS E INGENIERÍA

APRENDIZAJE DE MÁQUINA (1INF02-1081)

Examen 1
(Ciclo de verano 2026)

Indicaciones generales:

- Duración: 3 horas.
- Materiales o equipos a utilizar: Con apuntes de clase y calculadora no programable.
- No está permitido el uso de ningún material o equipo electrónico adicional al indicado.
- **La presentación, la ortografía y la gramática influirán en la calificación.**

Puntaje total: 20 puntos

---

1. Considere un problema de regresión lineal sin intercepto donde el espacio de hipótesis está restringido a solo dos opciones:

$$H = \{h(x) = wx \mid w \in \{-1, +1\}\}$$

Utilizando el Error Cuadrático Medio (MSE) como la función de costo a minimizar, considere el siguiente conjunto de entrenamiento compuesto por n=6 muestras:

i	1	2	3	4	5	6
x_i	−2	−1	1	1	2	2
y_i	0.4	−0.3	0.2	−0.4	0.1	−0.5

Adicionalmente se realizan 5 submuestras *bootstrap* (muestreo con reemplazo) y se calcula el MSE para cada hipótesis. Los resultados son:

Bootstrap	MSE(w = −1)	MSE(w = +1)
B_1	2.49	3.75
B_2	1.49	2.82
B_3	2.29	1.83
B_4	2.44	3.78
B_5	1.89	3.42

a) Calcule el MSE para cada hipótesis (w = −1 y w = +1) usando el conjunto de datos original y determine cuál hipótesis w* se consideraría óptima. Luego, usando la tabla de *bootstraps*, determine qué hipótesis $\hat{w}_k$ se selecciona para cada muestra *bootstrap* k = 1, ..., 5. **(2 puntos)**

b) Construya un modelo ensamblado usando el método del embolsado (*bagging*) ¿Pertenece la hipótesis ensamblada $h_{ens}(x) = w_{ens}x$ al espacio de hipótesis original H? Justifique matemáticamente. **(2 puntos)**

c) Para un punto de prueba x_{test} = 2 con valor real y_{test} = 0.1, calcule la predicción y el error absoluto tanto del modelo único (parte a) como del ensamble (parte b). ¿Cuál es mejor? Explique conceptualmente por qué el ensamble puede generar hipótesis fuera del espacio H y en qué situaciones esto resulta ventajoso. **(1 puntos)**

2. Considere una Máquina de Soporte Vectorial (SVM) lineal definida por la función de decisión $f(x) = w^T x + b$, con un vector de pesos: w = (1, 1) y un sesgo (bias) b = −2. Se dispone de los siguientes puntos de entrenamiento:

Punto	x = (x_1, x_2)	y (etiqueta)
A	(3, 1)	+1
B	(1.5, 1)	+1
C	(1, 0)	+1

a) Para cada punto (A, B, C), calcule: el margen funcional m ($y.f(x)$) y la variable de holgura ξ (max(0,1 - m)). Clasifique cada punto según su posición respecto al margen: (i) correctamente clasificado fuera del margen, (ii) correctamente clasificado dentro del margen, o (iii) incorrectamente clasificado. **(1 punto)**

b) Calcule la norma ||w|| y el ancho del margen geométrico (2/||w||). Considere la formulación de SVM con margen suave: min (½||w||² + C·Σξᵢ), donde C controla la penalización de errores. Si C disminuye significativamente, ¿qué efecto tendría sobre la tolerancia a violaciones del margen? Justifique usando los datos. **(2 puntos)**

3. Se propone utilizar un *kernel* polinomial de grado d=2 ($K(x,z) = (x^T z + 1)^2$). Este *kernel* corresponde implícitamente a una transformación no lineal al espacio de características, definida como ($\varphi(x) = (1, \sqrt{2} \cdot x_1, \sqrt{2} \cdot x_2, x_1^2, x_2^2, \sqrt{2} \cdot x_1 x_2)$). Dados los vectores: x = (1, 2) y z = (2, 0), realice lo siguiente:

a) Calcule el valor de K(x, z) utilizando directamente la función del *kernel*. **(1 punto)**

b) Calcule los vectores transformados φ(x) y φ(z) en el espacio de características. Compruebe que el producto escalar $\varphi(x)^T\varphi(z)$ = K(x, z) es igual al resultado obtenido en el inciso anterior. **(2 puntos)**

c) Explique brevemente por qué, en términos de complejidad algorítmica y dimensionalidad (especialmente si d o la dimensión de entrada fueran mayores), es preferible utilizar el *kernel* K(x, z) en lugar del producto escalar en el espacio transformado. **(1 puntos)**

4. Considere un modelo de regresión lineal simple sin intercepto ($\hat{y} = wx$). Para entrenar el modelo, se utiliza la función de pérdida del Error Cuadrático Medio (MSE) para un único ejemplo de entrenamiento (x, y) = (2, 6). Dados un peso inicial w_0 = 1 y una tasa de aprendizaje α = 0.25, realice lo siguiente:

   a) Derive la expresión del gradiente ∂L/∂w y evalúelo en w_0 = 1. Aplique una iteración de descenso de gradiente para obtener w_1. Determine el valor óptimo w* (el que minimiza la pérdida) y verifique si w_1 se acerca o se aleja del óptimo. **(2 puntos)**

   b) Finalmente, calcule qué valor tendría w_1 si se usara α = 2 y explique qué problema presenta esta tasa de aprendizaje en términos de convergencia. **(2 puntos)**

5. Considere un clasificador binario basado en el modelo de regresión logística ($\hat{y} = \frac{1}{1 + e^{-(wx + b)}}$). Para entrenar el modelo, se utiliza la función de pérdida de la Entropía Cruzada Binaria para un único ejemplo de entrenamiento (x, y) = (2, 1). Dados un peso inicial w_0 = 0.5 y b = -1, realice lo siguiente:

   a) Calcule el valor de la predicción ŷ, y la pérdida L. Determine el signo del gradiente ∂L/∂w ((ŷ − y)·x) e interprete su significado: ¿debe aumentar o disminuir w para reducir la pérdida? **(2 puntos)**

   b) La frontera de decisión ocurre donde ŷ = 0.5. Con los parámetros actuales ¿en qué valor de x se encuentra la frontera? Si después del entrenamiento w aumenta a 1.0 (manteniendo b = −1), ¿cómo se desplaza la frontera? ¿Este cambio mejora la clasificación del punto de entrenamiento? **(2 puntos)**

Profesor del curso: Rodrigo Uribe

San Miguel, 03 de febrero de 2026