Solucionario – Examen 1
(Ciclo de verano 2026)

Profesor: Rodrigo Uribe

San Miguel, 03 de febrero de 2026

Pregunta 1

a) MSE en el conjunto original (2 puntos)

Conjunto de datos: $x = [-2, -1, 1, 1, 2, 2]$, $y = [0{,}4, -0{,}3, 0{,}2, -0{,}4, 0{,}1, -0{,}5]$

Para $w = -1$: $\sum(y_i + x_i)^2 = (-1{,}6)^2 + (-1{,}3)^2 + (1{,}2)^2 + (0{,}6)^2 + (2{,}1)^2 + (1{,}5)^2 = 12{,}71$
$\text{MSE}(w = -1) = 12{,}71/6 \approx 2{,}1183$

Para $w = +1$: $\sum(y_i - x_i)^2 = (2{,}4)^2 + (0{,}7)^2 + (-0{,}8)^2 + (-1{,}4)^2 + (-1{,}9)^2 + (-2{,}5)^2 = 18{,}71$
$\text{MSE}(w = +1) = 18{,}71/6 \approx 3{,}1183$

La hipótesis óptima es $w^* = -1$ (menor MSE).

Selección por bootstrap (menor MSE): B_1: -1 (2.49 <3.75) B_2: -1 (1.49 <2.82) B_3: $+1$ (1.83 <2.29) B_4: -1 (2.44 <3.78) B_5: -1 (1.89 <3.42)

b) Modelo ensamblado por bagging (2 puntos)

$w_{\text{ens}} = \frac{1}{5}(-1 - 1 + 1 - 1 - 1) = \frac{-3}{5} = -0{,}6$

$h_{\text{ens}}(x) = -0{,}6\,x$

Esta hipótesis **no pertenece** al espacio $H = \{wx \mid w \in \{-1, +1\}\}$, ya que $-0{,}6 \notin \{-1, +1\}$. Matemáticamente, el promedio de hipótesis de H genera una combinación convexa cuyo resultado se encuentra en el convex hull de $\{-1, +1\}$, que es el intervalo $[-1, 1]$, pero H solo contiene los extremos discretos.

c) Predicción y error absoluto para $x_{\text{test}} = 2$, $y_{\text{test}} = 0{,}1$ (1 punto)

Modelo único ($w^* = -1$): $\hat{y} = -2$, error absoluto $= |0{,}1 - (-2)| = 2{,}1$ Ensamble ($w_{\text{ens}} = -0{,}6$): $\hat{y} = -1{,}2$, error absoluto $= |0{,}1 - (-1{,}2)| = 1{,}3$

El ensamble es mejor.

Conceptualmente, el bagging genera hipótesis fuera de H porque produce combinaciones convexas de hipótesis base. Esto es ventajoso cuando la función objetivo real no coincide exactamente con ninguna hipótesis de H, o cuando existe ruido en los datos: reduce la varianza, mejora la generalización y permite aproximaciones más precisas mediante pesos intermedios.

Pregunta 2

a) Margen funcional y clasificación (1 punto)

$f(x) = x_1 + x_2 - 2$

- Punto A (3,1): $f = 2$, $m = 1 \cdot 2 = 2 \geq 1$, $\xi = 0 \rightarrow$ (i) correctamente clasificado fuera del margen - Punto B (1.5,1): $f = 0{,}5$, $m = 0{,}5$, $\xi = 0{,}5 \rightarrow$ (ii) correctamente clasificado dentro del margen - Punto C (1,0): $f = -1$, $m = -1$, $\xi = 2 \rightarrow$ (iii) incorrectamente clasificado

b) Norma, margen y efecto de C (2 puntos)

$\|w\| = \sqrt{1^2 + 1^2} = \sqrt{2}$ Ancho del margen geométrico: $2/\sqrt{2} = \sqrt{2} \approx 1{,}414$

En la formulación soft-margin, si C disminuye significativamente, el término de penalización $C \sum \xi_i$ pierde importancia relativa frente a $\frac{1}{2}\|w\|^2$. Esto incrementa la tolerancia a violaciones del margen (puntos con $\xi_i > 0$). En los datos, el punto C está mal clasificado ($\xi = 2$) y B dentro del margen ($\xi = 0{,}5$). Un C pequeño permitiría mantener o aumentar estas violaciones para lograr un margen más amplio y menor norma de w.

Pregunta 3

a) Kernel directo (1 punto)

$K(x, z) = (x^T z + 1)^2 = (1 \cdot 2 + 2 \cdot 0 + 1)^2 = (2 + 1)^2 = 9$

b) Espacio transformado (2 puntos)

$\varphi(x) = (1, \sqrt{2}, 2\sqrt{2}, 1, 4, 2\sqrt{2})$ $\varphi(z) = (1, 2\sqrt{2}, 0, 4, 0, 0)$

$\varphi(x)^T \varphi(z) = 1 \cdot 1 + \sqrt{2} \cdot 2\sqrt{2} + 2\sqrt{2} \cdot 0 + 1 \cdot 4 + 4 \cdot 0 + 2\sqrt{2} \cdot 0 = 1 + 4 + 4 = 9$

Coincide con $K(x, z)$.

c) Ventaja del kernel trick (1 punto)

El cálculo directo de $K(x, z)$ tiene complejidad $O(d)$ (dimensión de entrada). Construir y multiplicar los vectores $\varphi(x)$ y $\varphi(z)$ requiere $O(d^2)$ operaciones y memoria (dimensión del espacio transformado es $\binom{d+2}{2}$). Para grados mayores o d alto, la explosión dimensional hace inviable el cálculo explícito, mientras que el kernel trick evita esta transformación y trabaja implícitamente en el espacio de alta dimensión.

Pregunta 4

a) Gradiente e iteración con $\alpha = 0{,}25$ (2 puntos)

$L(w) = (6 - 2w)^2$ $\partial L/\partial w = -4(6 - 2w) = 8w - 24$

En $w_0 = 1$: $\partial L/\partial w = 8 - 24 = -16$

$w_1 = 1 - 0{,}25 \cdot (-16) = 1 + 4 = 5$

Óptimo: $w^* = 3$ (ya que $2w^* = 6$). $w_1 = 5$ se aleja del óptimo en esta iteración (sobrepasa el mínimo).

b) Con $\alpha = 2$ (2 puntos)

$w_1 = 1 - 2 \cdot (-16) = 1 + 32 = 33$

Una tasa de aprendizaje tan alta provoca pasos excesivos, haciendo que el algoritmo diverja o oscile sin converger hacia el mínimo.

Pregunta 5

a) Predicción, pérdida y gradiente (2 puntos)

$z = 0{,}5 \cdot 2 - 1 = 0$ $\hat{y} = 1/(1 + e^0) = 0{,}5$ $L = -\log(0{,}5) = \log 2 \approx 0{,}693$

$\partial L/\partial w = (\hat{y} - y)x = (0{,}5 - 1) \cdot 2 = -1 < 0$

Signo negativo: para reducir la pérdida se debe aumentar w (el gradiente apunta hacia valores mayores de w).

b) Frontera de decisión (2 puntos)

Frontera: $wx + b = 0 \implies x = -b/w$ Actual ($w = 0{,}5$, $b = -1$): $x = 2$ (el punto de entrenamiento está exactamente en la frontera).

Con $w = 1{,}0$ (b fijo): $x = 1$ La frontera se desplaza a la izquierda (de $x = 2$ a $x = 1$).

Ahora $z = 1 \cdot 2 - 1 = 1 > 0$, $\hat{y} \approx 0{,}731 > 0{,}5$, lo que mejora la clasificación del punto $(2, 1)$ (probabilidad más cercana a 1).

Profesor del curso: Rodrigo Uribe

San Miguel, 03 de febrero de 2026