

Problema 1: Clasificador Naive Bayes para Spam

Un clasificador Naive Bayes distingue correos entre Spam (S) y No-Spam (N). Del historial, sabemos que el 30% de los correos son Spam. Se han estimado las siguientes probabilidades de que una palabra aparezca dado cada clase:

$$P(\text{"oferta"}|S) = 0.7,\ P(\text{"oferta"}|N) = 0.1$$

$$P(\text{"reunión"}|S) = 0.2,\ P(\text{"reunión"}|N) = 0.8$$

Un nuevo correo contiene las dos palabras "oferta" y "reunión". Asumiendo independencia condicional (supuesto Naive Bayes):

Se pide:

a) Calcule P(oferta ∩ reunión | S) y P(oferta ∩ reunión | N) usando el supuesto de independencia condicional.

b) Aplique el Teorema de Bayes para calcular P(S | oferta, reunión) y P(N | oferta, reunión). ¿Se clasificaría como Spam o No-Spam?

c) Si el correo también contiene "factura" con P(factura|S)=0.4 y P(factura|N)=0.3, ¿cómo cambian las posteriores? ¿Cambia la decisión?

Solución (a)

Supuesto Naive Bayes: $P(w_1 \cap w_2 \mid C) = P(w_1|C) \cdot P(w_2|C)$

Para Spam:

$$P(\text{oferta} \cap \text{reunión} \mid S) = P(\text{oferta}|S) \cdot P(\text{reunión}|S) = 0.7 \times 0.2 = 0.14$$

Para No-Spam:

$$P(\text{oferta} \cap \text{reunión} \mid N) = P(\text{oferta}|N) \cdot P(\text{reunión}|N) = 0.1 \times 0.8 = 0.08$$

$$P(\text{datos} \mid S) = 0.14 \qquad P(\text{datos} \mid N) = 0.08$$

La verosimilitud es mayor para Spam ($0.14 > 0.08$), pero esto no basta — necesitamos las posteriores para decidir.

Solución (b)

Evidencia total P(datos):

$$P(D) = P(D|S)\cdot P(S) + P(D|N)\cdot P(N) = 0.14\times 0.3 + 0.08\times 0.7 = 0.042 + 0.056 = 0.098$$

Posterior Spam:

$$P(S|D) = P(D|S)\cdot P(S) / P(D) = 0.042 / 0.098 = 3/7 \approx 0.4286$$

Posterior No-Spam:

$$P(N|D) = P(D|N)\cdot P(N) / P(D) = 0.056 / 0.098 = 4/7 \approx 0.5714$$

$$P(S|\text{datos}) \approx 0.429 \quad < \quad P(N|\text{datos}) \approx 0.571$$

Se clasifica como No-Spam. "oferta" favorece Spam, pero "reunión" favorece fuertemente No-Spam, y el prior (70% no-spam) inclina la balanza.

Solución (c)

Nuevas verosimilitudes (3 palabras):

$$P(D'|S) = 0.7 \times 0.2 \times 0.4 = 0.056$$

$$P(D'|N) = 0.1 \times 0.8 \times 0.3 = 0.024$$

Nueva evidencia:

$$P(D') = 0.056 \times 0.3 + 0.024 \times 0.7 = 0.0168 + 0.0168 = 0.0336$$

Nuevas posteriores:

$$P(S|D') = 0.0168 / 0.0336 = 0.5$$

$$P(N|D') = 0.0168 / 0.0336 = 0.5$$

$$P(S|\text{datos}') = P(N|\text{datos}') = 0.50 \rightarrow \text{Empate exacto}$$

"factura" sube P(S) de 0.43 a 0.50. La decisión ahora es ambigua — se necesitaría un criterio de desempate o más evidencia.



Problema 2: Embeddings Bayesianos

En un sistema de análisis de sentimiento, cada reseña se clasifica como Positiva (P) o Negativa (N). Se tienen embeddings base en $\mathbb{R}^3$:

$$E_P = (4, 1, 0) \quad | \quad E_N = (0, 1, 4)$$

La distribución a priori es: P(P) = 0.6, P(N) = 0.4. Se observa el adjetivo "increíble" (I) con P(I|P) = 0.7 y P(I|N) = 0.15.

Se pide:

a) Calcule P(I) usando Probabilidad Total, luego aplique Bayes para obtener P(P|I) y P(N|I).

b) Genere el embedding contextual: E_ctx = P(P|I)·E_P + P(N|I)·E_N. Interprete geométricamente.

c) Si además se observa "no" (O) con P(O|P)=0.1 y P(O|N)=0.6, recalcule las posteriores y el nuevo E_ctx. ¿Cómo se invierte la representación?

Solución (a)

Probabilidad marginal P(I):

$$P(I) = P(I|P)\cdot P(P) + P(I|N)\cdot P(N) = 0.7\times 0.6 + 0.15\times 0.4 = 0.42 + 0.06 = 0.48$$

Posterior Positivo:

$$P(P|I) = P(I|P)\cdot P(P) / P(I) = 0.42 / 0.48 = 7/8 = 0.875$$

Posterior Negativo:

$$P(N|I) = P(I|N)\cdot P(N) / P(I) = 0.06 / 0.48 = 1/8 = 0.125$$

$$P(P|I) = 0.875 \qquad P(N|I) = 0.125$$

"increíble" desplaza fuertemente la probabilidad hacia Positivo: de un prior 0.60 a una posterior 0.875.

Solución (b)

$E_ctx = P(P|I)\cdot E_P + P(N|I)\cdot E_N$

$$E_ctx = 0.875\cdot(4, 1, 0) + 0.125\cdot(0, 1, 4)$$

$$= (3.5, 0.875, 0) + (0, 0.125, 0.5)$$

$$= (3.5, 1.0, 0.5)$$

Distancias a los embeddings base:

$$||E_ctx - E_P|| = ||(-0.5, 0, 0.5)|| = \sqrt{0.5} \approx 0.707$$

$$||E_ctx - E_N|| = ||(3.5, 0, -3.5)|| = \sqrt{24.5} \approx 4.95$$

E_ctx está muy cerca de E_P (0.71) y lejos de E_N (4.95). "increíble" empuja la representación hacia el polo positivo.

Solución (c)

Verosimilitudes conjuntas (Naive Bayes):

$$P(I,O|P) = 0.7 \times 0.1 = 0.07 \qquad P(I,O|N) = 0.15 \times 0.6 = 0.09$$

Evidencia y posteriores:

$$P(I,O) = 0.07 \times 0.6 + 0.09 \times 0.4 = 0.042 + 0.036 = 0.078$$

$$P(P|I,O) = 0.042/0.078 = 7/13 \approx 0.538$$

$$P(N|I,O) = 0.036/0.078 = 6/13 \approx 0.462$$

Nuevo embedding:

$$E_ctx' = 0.538 \cdot (4,1,0) + 0.462 \cdot (0,1,4) = (2.15, 1.0, 1.85)$$

Sin "no": E = (3.5, 1.0, 0.5) → Con "no": E = (2.15, 1.0, 1.85)

"no" reduce P(P) de 0.875 a 0.538 y desplaza el embedding hacia E_N. La 3ra componente sube de 0.5 a 1.85.



Problema 3: Diagnóstico Bayesiano

Un sistema de ML clasifica pacientes como Enfermo (E) o Sano (S). Prevalencia P(E) = 0.02 (2%). Se aplican dos tests independientes:

Test 1: Sensibilidad P(+|E)=0.95, Especificidad P(−|S)=0.90, P(+|S)=0.10

Test 2: Sensibilidad P(+|E)=0.90, Especificidad P(−|S)=0.95, P(+|S)=0.05

Un paciente da Positivo en el Test 1.

Se pide:

a) Calcule P(E|T1+) aplicando Bayes. ¿Cuál es la probabilidad de estar realmente enfermo después de un positivo?

b) Usando P(E|T1+) como nuevo prior, el paciente da Positivo en Test 2. Calcule P(E|T1+,T2+) secuencialmente. Compare con (a).

c) Si da Positivo en Test 1 pero Negativo en Test 2, calcule P(E|T1+,T2−). ¿El Test 2 negativo "cancela" al Test 1 positivo?

Solución (a)

Datos: $P(E)=0.02$, $P(S)=0.98$, $P(+_1|E)=0.95$, $P(+_1|S)=0.10$

Evidencia P(T1+):

$$P(+_1) = P(+_1|E)\cdot P(E) + P(+_1|S)\cdot P(S) = 0.95\times 0.02 + 0.10\times 0.98 = 0.019 + 0.098 = 0.117$$

Posterior:

$$P(E|+_1) = P(+_1|E)\cdot P(E) / P(+_1) = 0.019 / 0.117 \approx 0.1624$$

$P(E|T1+) \approx 0.162$ (16.2%) ← subió de 2% a 16.2%

¡Paradoja del test! Aun con 95% sensibilidad y 90% especificidad, un positivo solo da 16% de probabilidad real porque la enfermedad es rara (2%).

Solución (b)

Nuevo prior: $P(E)=0.1624$, $P(S)=0.8376$. Test 2: $P(+_2|E)=0.90$, $P(+_2|S)=0.05$

Nueva evidencia P(T2+):

$$P(+_2) = 0.90\times0.1624 + 0.05\times0.8376 = 0.14616 + 0.04188 = 0.18804$$

Posterior actualizada:

$$P(E|+_1,+_2) = P(+_2|E)\cdot P(E|+_1) / P(+_2) = 0.14616 / 0.18804 \approx 0.7773$$

$$P(E) = 2\% \rightarrow \text{tras T1+: } 16.2\% \rightarrow \text{tras T2+: } 77.7\%$$

Cada test positivo multiplica la evidencia. El segundo test llevó la probabilidad de 16% a 78%, demostrando la actualización secuencial bayesiana.

Solución (c)

Prior tras T1+: P(E) = 0.1624, P(S) = 0.8376

Ahora T2 es negativo: $P(-_2|E) = 1-0.90 = 0.10$, $P(-_2|S) = 0.95$

Evidencia P(T2−):

$$P(-_2) = 0.10\times0.1624 + 0.95\times0.8376 = 0.01624 + 0.79572 = 0.81196$$

Posterior:

$$P(E|+_1,-_2) = 0.01624 / 0.81196 \approx 0.0200$$

$$P(E|T1+, T2-) \approx 0.020 \ (2.0\%) \leftarrow \text{¡Regresa al prior original!}$$

El T2 negativo prácticamente cancela al T1 positivo, regresando a ~2%. Los tests tienen "fuerzas" opuestas similares que se neutralizan.



Problema 4: De K-Means a GMM

Considere N=4 datos unidimensionales x = {1, 3, 7, 9} y un GMM con K=2, covarianzas iguales $\sigma^2=\sigma_c^2$, pesos iguales $\pi_1=\pi_2=0.5$. Medias actuales: $\mu_1=2$, $\mu_2=8$.

Responsabilidades con temperatura T:

$$r_{ik}(T) = \frac{\exp\left(-\frac{d_{ik}^2}{2\,T\,\sigma_c^2}\right)}{\sum_{j=1}^{K}\exp\left(-\frac{d_{ij}^2}{2\,T\,\sigma_c^2}\right)}$$

donde

$$d_{ik} = |x_i - \mu_k|.$$

Se pide:

a) Con $\sigma_c^2=4$ y T=1 (GMM estándar), calcule las responsabilidades. Use $d_{11}^2=1$, $d_{12}^2=49$, $d_{21}^2=1$, $d_{22}^2=25$, $d_{31}^2=25$, $d_{32}^2=1$, $d_{41}^2=49$, $d_{42}^2=1$.

b) Calcule las responsabilidades con T→0 (Hard EM / K-Means). Muestre que se obtiene asignación binaria 0/1.

c) Calcule las nuevas medias μ_k para ambos casos (T=1 y T→0). ¿Cuánto difieren? ¿Cuándo la diferencia sería grande?

Solución (a)

$r_{ik} = \exp(-d_{ik}^2/8) / [\exp(-d_{i1}^2/8) + \exp(-d_{i2}^2/8)]$ $(2T\sigma^2=8)$

x_1=1:

$\exp(-1/8)=0.8825$, $\exp(-49/8)=0.0022$ → $r_{11}=0.9975$, $r_{12}=0.0025$

x_2=3:

$\exp(-1/8)=0.8825$, $\exp(-25/8)=0.0439$ → $r_{21}=0.9526$, $r_{22}=0.0474$

x_3=7:

$\exp(-25/8)=0.0439$, $\exp(-1/8)=0.8825$ → $r_{31}=0.0474$, $r_{32}=0.9526$

x_4=9:

$\exp(-49/8)=0.0022$, $\exp(-1/8)=0.8825$ → $r_{41}=0.0025$, $r_{42}=0.9975$

Con T=1, las responsabilidades son suaves: x_2 y x_3 tienen ~5% de pertenencia al clúster opuesto.

Solución (b)

Cuando T→0:

$\exp(-d_{ik}^2/(2T\sigma^2))$ domina exponencialmente para el k con menor d_{ik}. La responsabilidad converge a:

$$r_{ik}(T\to 0) = 1 \text{ si } k = \text{argmin_j } d_{ij}^2, \quad 0 \text{ en caso contrario}$$

Asignaciones duras:

$x_1=1$: $d_{11}=1 < d_{12}=7 \to r_{11}=1, r_{12}=0$ (clúster 1)

$x_2=3$: $d_{21}=1 < d_{22}=5 \to r_{21}=1, r_{22}=0$ (clúster 1)

$x_3=7$: $d_{31}=5 > d_{32}=1 \to r_{31}=0, r_{32}=1$ (clúster 2)

$x_4=9$: $d_{41}=7 > d_{42}=1 \to r_{41}=0, r_{42}=1$ (clúster 2)

T→0 convierte GMM en K-Means: cada punto se asigna 100% al centroide más cercano. K-Means es el caso límite de EM.

Solución (c)

T=1 (GMM soft):

$\mu_1 = (0.9975\times1 + 0.9526\times3 + 0.0474\times7 + 0.0025\times9) / 2.0 = 4.2096/2.0 = 2.105$

$\mu_2 = (0.0025\times1 + 0.0474\times3 + 0.9526\times7 + 0.9975\times9) / 2.0 = 15.7904/2.0 = 7.895$

T→0 (K-Means hard):

$\mu_1 = (1\times1 + 1\times3) / 2 = 2.0$

$\mu_2 = (1\times7 + 1\times9) / 2 = 8.0$

GMM: μ_1=2.105, μ_2=7.895 K-Means: μ_1=2.0, μ_2=8.0

Difieren por ~0.1. El GMM "jala" medias hacia el centro porque x_2, x_3 comparten responsabilidad. La diferencia crece con más puntos frontera o clústeres solapados.



Problema 5: GMM 2D con Covarianza Completa

Un GMM con K=2 en $\mathbb{R}^2$ tiene un componente diagonal y otro con covarianza completa:

Comp. A: $\pi_A=0.5$, $\mu_A=(0,0)$, $\Sigma_A=[[4,0],[0,1]]$ (diagonal)

Comp. B: $\pi_B=0.5$, $\mu_B=(5,5)$, $\Sigma_B=[[2,1.5],[1.5,2]]$ (correlación positiva)

Se pide:

a) Calcule los autovalores y autovectores de Σ_B. ¿En qué dirección está orientada la elipse? ¿Cuál es el ángulo de rotación?

b) Calcule $\det(\Sigma_A)$ y $\det(\Sigma_B)$. ¿Cuál componente ocupa más "volumen" en 2D?

c) ¿Cuántos parámetros libres tiene un GMM con K componentes en d dimensiones con covarianza completa? Calcule para K=3, d=10.

Solución (a)

$\Sigma B = [[2, 1.5], [1.5, 2]]$. Ecuación característica:

$$\det(\Sigma B - \lambda I) = (2-\lambda)^2 - 1.5^2 = \lambda^2 - 4\lambda + 1.75 = 0$$

$$\lambda = (4 \pm \sqrt{9}) / 2 = (4 \pm 3) / 2 \quad \rightarrow \quad \lambda_1 = 3.5 \quad \lambda_2 = 0.5$$

Autovector para $\lambda_1=3.5$:

$(\Sigma B - 3.5I)v = 0 \rightarrow v_1 = (1,1)/\sqrt{2}$

Para $\lambda_2=0.5$: $v_2 = (1,-1)/\sqrt{2}$

El eje mayor apunta en dirección (1,1), es decir a 45° del eje x. Relación de aspecto $\sqrt{(3.5/0.5)} = \sqrt{7} \approx 2.65$.

La correlación $\rho = 1.5/\sqrt{(2\times2)} = 0.75$ rota la elipse hacia la diagonal.

Solución (b)

Determinantes:

$$\det(\Sigma A) = 4\times1 - 0^2 = 4$$

$$\det(\Sigma B) = 2\times2 - 1.5^2 = 4 - 2.25 = 1.75$$

$$\det(\Sigma A) = 4.00 \quad \det(\Sigma B) = 1.75$$

Como det(ΣA) > det(ΣB), el componente A ocupa más área en el plano 2D.

Interpretación:

ΣA tiene varianza 4 en x pero solo 1 en y → elipse horizontal ancha.

ΣB tiene varianzas 2 en ambas dimensiones pero la correlación "comprime" el volumen total.

det(Σ) mide la incertidumbre generalizada. Correlación alta reduce det(Σ) porque saber x_1 da información sobre x_2.

Solución (c)

Parámetros por componente con covarianza completa:

Medias: d parámetros | Covarianza simétrica: d(d+1)/2 | Total: d + d(d+1)/2

Más (K−1) pesos de mezcla.

Total GMM: $p = K \cdot [d + d(d+1)/2] + (K-1)$

Para K=3, d=10:

Covarianza completa: $p = 3 \times [10 + 55] + 2 = 197$

Covarianza diagonal: $p = 3 \times [10 + 10] + 2 = 62$

Completa: 197 parámetros Diagonal: 62 parámetros (3.2× más)

Con d grande, covarianza completa crece $O(d^2)$. Se usa diagonal o "tied" cuando N es pequeño relativo a $d^2 \cdot K$.



Problema 6: GMM para Detección de Anomalías

Un GMM con K=2 fue entrenado sobre datos "normales" de sensores industriales en $\mathbb{R}^1$:

Comp. 1: $\pi_1=0.6$, $\mu_1=5$, $\sigma_1=2$ | Comp. 2: $\pi_2=0.4$, $\mu_2=20$, $\sigma_2=3$

Se usa umbral de densidad τ: si $p(x) < \tau$, el punto es anomalía. Se propone $\tau = 0.01$. Lecturas: x_A=5, x_B=15, x_C=25.

Se pide:

a) Calcule p(x) para los tres puntos. Clasifique según $\tau=0.01$. Datos: N(5|5,2)=0.1995, N(5|20,3)=0.0001, N(15|5,2)=0.0000, N(15|20,3)=0.0648, N(25|5,2)=0.0000, N(25|20,3)=0.0648.

b) ¿Qué percentil corresponde a $\tau=0.01$? Si generamos M=10000 muestras, ¿cuántas serían falsas alarmas?

c) Compare GMM con una sola gaussiana N(μ_global, σ_global). ¿Cuándo falla la gaussiana única?

Solución (a)

$p(x) = 0.6 \cdot N(x|5,2) + 0.4 \cdot N(x|20,3)$

$x_A = 5$ (centro del comp. 1):

$p(5) = 0.6 \times 0.1995 + 0.4 \times 0.0001 = 0.1197$

$p(5) = 0.1197 > 0.01 \rightarrow$ NORMAL ✓

$x_B = 15$ (entre los dos componentes):

$p(15) = 0.6 \times 0.0000 + 0.4 \times 0.0648 = 0.0259$

$p(15) = 0.0259 > 0.01 \rightarrow$ NORMAL ✓

$x_C = 25$ (cola derecha del comp. 2):

$p(25) = 0.6 \times 0.0000 + 0.4 \times 0.0648 = 0.0259$

$p(25) = 0.0259 > 0.01 \rightarrow$ NORMAL ✓

Los tres son normales. x_A tiene densidad más alta (centro de un modo). x_B y x_C tienen densidades iguales por razones distintas.

Solución (a) cont. — ¿Dónde estarían las anomalías?

Puntos que SÍ serían anomalías ($p(x) < 0.01$):

$x = -5$: $p(-5) \approx 0.000 \rightarrow$ ANOMALÍA ✗

$x = 30$: $p(30) = 0.4 \times 0.0036 = 0.0014 < 0.01 \rightarrow$ ANOMALÍA ✗

$p(x) < \tau \leftrightarrow$ x está lejos de TODOS los modos simultáneamente

La clave del GMM: un punto solo es anómalo si está lejos de TODOS los componentes. El valle entre modas puede tener densidad baja pero aún superar τ.

Solución (b)

El umbral $\tau = 0.01$ define una región donde $p(x) \geq \tau$. Puntos fuera son anomalías. Si los datos son normales, los puntos con $p(x) < \tau$ son falsas alarmas.

Tasa de falsa alarma (FPR):

FPR = $P(p(x) < \tau)$ donde $x \sim$ GMM. Las regiones anómalas son aproximadamente $x < -2$ y $x > 28$.

La fracción en esas colas es pequeña: estimación ≈ 1-3% del total.

De M=10000 muestras, esperaríamos ~100-300 falsas alarmas.

En la práctica, τ se calibra con un dataset de validación para controlar la FPR deseada.

Solución (c)

Gaussiana única para estos datos:

Si ajustamos una sola N(μ,σ): μ_global ≈ 11, σ_global ≈ 9 (muy grande para cubrir ambos modos).

Problema — el valle es "normal":

La gaussiana asigna alta densidad a x=11 (su media), pero ahí casi NO hay datos reales.

Problema — las colas son "anchas":

σ=9 es tan grande que puntos lejanos como x=30 o x=−10 tendrían densidad razonable.

El GMM modela la estructura multimodal: alta densidad SOLO donde hay datos reales

La gaussiana única "rellena" los valles y alarga las colas, perdiendo poder de detección.

Problema 7: Autoencoder Lineal con Cuello de Botella 1D

i	1	2	3
$\mathbf{x_i}$	(2, 1, 0)	(4, 2, 0)	(6, 3, 0)

Un autoencoder lineal mapea entradas $x \in \mathbb{R}^3$ a un espacio latente $z \in \mathbb{R}^1$ y luego las reconstruye. El encoder es $z = w^T x$ ($w \in \mathbb{R}^3$) y el decoder es $\hat{x} = z \cdot d$ ($d \in \mathbb{R}^3$). Datos de entrenamiento:

Se pide:

a) Sea $w = (1,0,0)$ y $d = (1,0,0)$. Calcule z_i y $\hat{x}_i$ para cada punto, luego la pérdida de reconstrucción $L = (1/N) \Sigma ||x_i - \hat{x}_i||^2$. ¿Qué componente de los datos se pierde?

b) Ahora sea $w = (2,1,0)/\sqrt{5}$ y $d = (2,1,0)/\sqrt{5}$. Repita el cálculo. Compare con (a). ¿Por qué este par es mejor? Relaciónelo con la dirección de máxima varianza (PCA).

c) Explique conceptualmente: ¿por qué un autoencoder lineal con cuello de botella 1D aprende el mismo subespacio que la primera componente principal de PCA?

Solución (a)

Cálculo de z y $\hat{x}$:

$z_1 = w^T x_1 = 2 \rightarrow \hat{x}_1 = 2 \cdot (1,0,0) = (2,0,0)$

$z_2 = 4 \rightarrow \hat{x}_2 = (4,0,0)$ $z_3 = 6 \rightarrow \hat{x}_3 = (6,0,0)$

Errores:

$||x_1 - \hat{x}_1||^2 = 1$ $||x_2 - \hat{x}_2||^2 = 4$ $||x_3 - \hat{x}_3||^2 = 9$

$$L = (1/3)(1 + 4 + 9) = 14/3 \approx 4.67$$

Se pierde completamente la segunda componente (eje y). El encoder solo captura el eje x.

Solución (b)

Cálculo de z ($z_i = (2x_{i1} + x_{i2})/\sqrt{5}$):

$z_1 = (4+1)/\sqrt{5} = \sqrt{5} \approx 2.236$ $z_2 = (8+2)/\sqrt{5} = 2\sqrt{5} \approx 4.472$ $z_3 = (12+3)/\sqrt{5} = 3\sqrt{5} \approx 6.708$

Reconstrucciones $\hat{x}_i = z_i \cdot d$:

$\hat{x}_1 = \sqrt{5}\cdot(2,1,0)/\sqrt{5} = (2,1,0) = x_1 \rightarrow$ error = 0

$\hat{x}_2 = 2\sqrt{5}\cdot(2,1,0)/\sqrt{5} = (4,2,0) = x_2 \rightarrow$ error = 0

$\hat{x}_3 = 3\sqrt{5}\cdot(2,1,0)/\sqrt{5} = (6,3,0) = x_3 \rightarrow$ error = 0

$L = (1/3)(0 + 0 + 0) = 0 \leftarrow$ ¡Reconstrucción perfecta!

Los datos viven en la dirección (2,1,0). Este encoder captura toda la varianza = dirección de PCA.

Solución (c)

Un autoencoder lineal minimiza el error de reconstrucción $L = (1/N) \Sigma||x_i - \hat{x}_i||^2$. Para un cuello de botella 1D, la solución óptima es proyectar sobre la dirección que maximiza la varianza retenida y minimiza el error.

Esto es exactamente lo que hace PCA: la primera componente principal es la dirección de máxima varianza. Matemáticamente, minimizar $||x - \hat{x}||^2$ con una proyección lineal de rango 1 es equivalente a maximizar la varianza proyectada.

Problema 8: Divergencia KL en un VAE unidimensional

Imagen	μ	σ	Interpretación
A	0.0	1.0	Coincidencia perfecta con el prior
B	3.0	0.05	Pico agudo, descentrado
C	0.0	4.0	Centrada pero muy dispersa

En un VAE, cada entrada x se codifica en $q(z|x) = N(\mu, \sigma^2)$. La regularización penaliza la desviación del prior $p(z) = N(0,1)$:

$$DKL = 0.5\ (\mu^2 + \sigma^2 - \ln(\sigma^2) - 1)$$

Se pide:

a) Calcule DKL para cada imagen (A, B, C). Para la imagen B, descomponga DKL en las contribuciones del término μ^2, σ^2, y $-\ln(\sigma^2)$. ¿Cuál domina?

b) Si $L = Lrecon + \beta \cdot DKL$, ¿qué pasa con $\beta=0.01$ (muy pequeño) y con $\beta=100$ (muy grande)? Relate con el "colapso posterior" y β-VAE.

c) Demuestre analíticamente que $f(\sigma) = \sigma^2 - \ln(\sigma^2) - 1$ tiene mínimo global en $\sigma=1$ con $f(1)=0$. (Derive respecto a σ^2, iguale a cero, verifique segunda derivada.)

Solución (a)

Imagen A (μ=0, σ=1):

$DKL = 0.5(0^2 + 1^2 - \ln(1^2) - 1) = 0.5(0 + 1 - 0 - 1) = 0$

Imagen B (μ=3, σ=0.05) — Descomposición:

Término μ^2: 9.0 | Término σ^2: 0.0025 | Término $-\ln(\sigma^2)$: 5.99
Suma = 9 + 0.0025 + 5.99 − 1 = 13.99 → DKL = 0.5 × 13.99 ≈ 7.00

Domina $\mu^2 = 9$ (media lejos del origen), seguido de $-\ln(\sigma^2) \approx 5.99$ (varianza casi cero).

Imagen C (μ=0, σ=4):

$DKL = 0.5(0 + 16 - \ln(16) - 1) = 0.5(16 - 2.77 - 1) = 0.5(12.23) \approx 6.12$

Solución (b)

β = 0.01 (muy pequeño):

La DKL casi no influye → el encoder puede memorizar cada entrada como un punto δ en el latente (σ→0, μ arbitrario). Reconstrucción excelente, pero espacio latente caótico e inútil para generación. Se comporta como un autoencoder clásico.

β = 100 (muy grande):

La DKL domina → todas las distribuciones colapsan hacia N(0,1). El encoder ignora la entrada (μ≈0, σ≈1 para todo x). Esto es el colapso posterior: el decoder debe generar desde un z no informativo, produciendo salidas borrosas promediadas.

β-VAE: Se ajusta β para controlar el trade-off. β>1 fuerza representaciones más disentangled pero peor reconstrucción. β<1 prioriza fidelidad sobre estructura.

Solución (c)

Sea $u = \sigma^2$ y $f(u) = u - \ln(u) - 1$ para $u > 0$

Primera derivada: $f'(u) = 1 - 1/u$

Punto crítico: $f'(u)=0 \rightarrow u=1 \rightarrow \sigma=1$

Segunda derivada: $f''(u) = 1/u^2 \rightarrow f''(1) = 1 > 0$ ✓

$f(1) = 1 - \ln(1) - 1 = 0$ ✓ Mínimo global en $\sigma = 1$

σ^2 crece con σ, y $-\ln(\sigma^2)$ crece cuando σ decrece. Se equilibran en $\sigma = 1$.

Problema 9: Interpolación y Reparametrización en un VAE

Imagen	μ	σ
Dígito "3"	(−2.0, 1.0)	(0.3, 0.3)
Dígito "7"	(2.0, −1.0)	(0.4, 0.2)

Un VAE con espacio latente 2D ha sido entrenado sobre dígitos manuscritos. Dos imágenes se codifican en las siguientes distribuciones latentes:

Se pide:

a) Para interpolar entre "3" y "7": $z_t = (1-t)\mu_3 + t\mu_7$. Calcule z_t para t = 0, 0.25, 0.5, 0.75 y 1.0. Calcule $||\mu_3 - \mu_7||$.

b) Calcule DKL para el "3" y el "7" usando: $DKL = 0.5\ \Sigma(\mu_i^2 + \sigma_i^2 - \ln(\sigma_i^2) - 1)$. ¿Cuál está más regularizado? Pista: $\ln(0.09)\approx-2.41$, $\ln(0.16)\approx-1.83$, $\ln(0.04)\approx-3.22$

Solución (a)

$z_t = (1-t)(-2, 1) + t(2, -1)$
$t = 0.00$: $z = (-2.0, 1.0)$
$t = 0.25$: $z = (-1.0, 0.5)$
$t = 0.50$: $z = (0.0, 0.0)$
$t = 0.75$: $z = (1.0, -0.5)$
$t = 1.00$: $z = (2.0, -1.0)$

Distancia euclidiana:

$||\mu_3 - \mu_7|| = ||(-4, 2)|| = \sqrt{(16 + 4)} = \sqrt{20} = 2\sqrt{5} \approx 4.47$

Solución (b)

Dígito "3" (μ=(−2,1), σ=(0.3,0.3)):

Dim 1: 4 + 0.09 + 2.41 − 1 = 5.50
Dim 2: 1 + 0.09 + 2.41 − 1 = 2.50 → DKL = 0.5(5.50+2.50) = 4.00

Dígito "7" (μ=(2,−1), σ=(0.4,0.2)):

Dim 1: 4 + 0.16 + 1.83 − 1 = 4.99
Dim 2: 1 + 0.04 + 3.22 − 1 = 3.26 → DKL = 0.5(4.99+3.26) = 4.125

$$DKL("3") = 4.00 \quad < \quad DKL("7") = 4.125$$

El "3" está más regularizado. Un espacio regularizado (DKL baja) produce interpolaciones más suaves porque las distribuciones se solapan más.