Solución al Examen 2
Aprendizaje de Máquina (1INF02-1081)
Ciclo de verano 2026

Preparado para referencia académica

San Miguel, marzo de 2026

Indicaciones generales

Se presentan las soluciones completas y detalladas a las cinco preguntas del examen. Aunque el enunciado indica resolver solo cuatro preguntas, se incluyen todas para mayor utilidad académica. Las respuestas siguen estrictamente las fórmulas y datos proporcionados en el examen. Se utilizan aproximaciones numéricas solo donde se indica en el enunciado (por ejemplo, $\ln(0{,}01) \approx -4{,}60$ y $\ln(1{,}44) \approx 0{,}36$).

1. Pregunta 1: Modelo de Mezcla de Gaussianas (GMM)

a) Cantidad efectiva de puntos y pesos de mezcla

La cantidad efectiva de puntos asignados a cada clúster se calcula como:

$$N_1 = \sum_{i=1}^{4} r_{i1} = 0{,}9 + 0{,}8 + 0{,}1 + 0{,}2 = 2{,}0$$

$$N_2 = \sum_{i=1}^{4} r_{i2} = 0{,}1 + 0{,}2 + 0{,}9 + 0{,}8 = 2{,}0$$

Los nuevos pesos de mezcla en el Paso M son:

$$\pi_1 = \frac{N_1}{N} = \frac{2}{4} = 0{,}5, \quad \pi_2 = \frac{N_2}{N} = 0{,}5$$

b) Nueva media del primer componente

$$\mu_1 = \frac{1}{N_1} \sum_{i=1}^{4} r_{i1} \cdot x_i = \frac{1}{2} \left(0{,}9 \cdot 1 + 0{,}8 \cdot 2 + 0{,}1 \cdot 8 + 0{,}2 \cdot 9\right)$$

$$= \frac{1}{2}(0{,}9 + 1{,}6 + 0{,}8 + 1{,}8) = \frac{5{,}1}{2} = 2{,}55$$

c) Comparación con K-Means

En el GMM las responsabilidades r_{ik} representan una asignación suave (valores entre 0 y 1), mientras que K-Means utiliza una asignación dura (0 o 1). La ventaja del GMM es que permite que puntos cercanos a la frontera pertenezcan parcialmente a varios clústeres, lo que es más adecuado para datos con solapamiento. En la tabla, por ejemplo, el cliente con $x = 2$ tiene $r_{i1} = 0{,}8$ (no 1.0), reflejando incertidumbre; K-Means forzaría una asignación exclusiva, lo que podría distorsionar los parámetros en clústeres solapados.

2. Pregunta 2: Autoencoder Variacional (VAE)

a) Matriz de covarianza

Dado que las dimensiones son independientes:

$$\Sigma = \begin{pmatrix} 0{,}1^2 & 0 \\ 0 & 1{,}2^2 \end{pmatrix} = \begin{pmatrix} 0{,}01 & 0 \\ 0 & 1{,}44 \end{pmatrix}$$

b) Divergencia KL (cálculo componente a componente)

La fórmula es:

$$D_{KL} = 0{,}5 \sum_{i=1}^{2} \left(\mu_i^2 + \sigma_i^2 - \ln(\sigma_i^2) - 1\right)$$

Dimensión 1 ($\mu_1 = 0{,}5$, $\sigma_1 = 0{,}1$):

$$0{,}5^2 + 0{,}01 - (-4{,}60) - 1 = 0{,}25 + 0{,}01 + 4{,}60 - 1 = 3{,}86$$

Dimensión 2 ($\mu_2 = -0{,}1$, $\sigma_2 = 1{,}2$):

$$(-0{,}1)^2 + 1{,}44 - 0{,}36 - 1 = 0{,}01 + 1{,}44 - 0{,}36 - 1 = 0{,}09$$

$$D_{KL} = 0{,}5 \times (3{,}86 + 0{,}09) = 0{,}5 \times 3{,}95 = 1{,}975$$

c) Pérdida total

$$L = \text{MSE} + D_{KL} = 1{,}5 + 1{,}975 = 3{,}475$$

d) Análisis conceptual del valor de σ

La primera dimensión ($\sigma_1 = 0{,}1$) recibe un castigo mucho mayor porque el término $-\ln(\sigma_i^2)$ crece rápidamente cuando $\sigma_i \to 0$. Cuando el modelo intenta colapsar la varianza a cero, el término logarítmico hace que $D_{KL} \to +\infty$, impidiendo que la distribución latente se vuelva determinista y forzando al encoder a mantener una varianza mínima adecuada.

3. Pregunta 3: Embeddings contextuales con Teorema de Bayes

a) Probabilidad marginal y posteriores

$$P(H) = P(H \mid F)P(F) + P(H \mid V)P(V) = 0{,}1 \times 0{,}4 + 0{,}8 \times 0{,}6 = 0{,}04 + 0{,}48 = 0{,}52$$

$$P(F \mid H) = \frac{P(H \mid F)P(F)}{P(H)} = \frac{0{,}04}{0{,}52} = \frac{1}{13} \approx 0{,}0769$$

$$P(V \mid H) = \frac{0{,}48}{0{,}52} = \frac{12}{13} \approx 0{,}9231$$

b) Embedding contextual

$$E_{\text{context}} = P(F \mid H) \cdot E_F + P(V \mid H) \cdot E_V = \frac{1}{13}(5,0) + \frac{12}{13}(0,5) = \left(\frac{5}{13}, \frac{60}{13}\right) \approx (0{,}3846, 4{,}6154)$$

c) Ventaja del enfoque bayesiano

Los embeddings estáticos (como Word2Vec) asignan un único vector promedio a la palabra, sin distinguir sus sentidos. El enfoque bayesiano resuelve esta limitación calculando las probabilidades posteriores $P(\text{sentido} \mid \text{contexto})$ y ponderando los embeddings base según el contexto observado (aquí «hoja» favorece fuertemente el sentido vegetal). Así, el embedding resultante es dinámico y específico para la oración.

4. Pregunta 4: Análisis de Componentes Principales (PCA)

a) Matriz de covarianza empírica (solo sobre X_{train})

El vector de medias es $\mu = (0, 0)$. La matriz de covarianza es:

$$\Sigma = \frac{1}{4} \sum_{i=1}^{4} x_i x_i^T = \begin{pmatrix} 2{,}5 & 2{,}5 \\ 2{,}5 & 2{,}5 \end{pmatrix}$$

b) Primer autovalor, autovector y proyección

Los autovalores son $\lambda_1 = 5$ y $\lambda_2 = 0$. El autovector normalizado asociado a λ_1 es:

$$u_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

La proyección escalar del punto de prueba $x_{\text{test}} = (4, -4)$ es:

$$z = x_{\text{test}}^T u_1 = 4 \cdot \frac{1}{\sqrt{2}} + (-4) \cdot \frac{1}{\sqrt{2}} = 0$$

c) Data Leakage

Incluir x_{test} en el cálculo de Σ invalidaría la evaluación porque el preprocesamiento (covarianza) utilizaría información del conjunto de prueba. Esto constituye Data Leakage: el modelo recibe indirectamente conocimiento del test durante el entrenamiento/preprocesamiento, produciendo una estimación optimista y no representativa del rendimiento en datos verdaderamente nuevos.

5. Pregunta 5: Red Neuronal y Backpropagation

a) Forward pass

$$z_1 = w_1 x + b_1 = 0 \cdot 2 + 0 = 0$$
$$h = \sigma(z_1) = \frac{1}{1+e^0} = 0{,}5$$
$$y = w_2 h + b_2 = 4 \cdot 0{,}5 - 1 = 1$$
$$J = \frac{1}{2}(y-t)^2 = \frac{1}{2}(1-2)^2 = 0{,}5$$

b) Gradiente $\partial J/\partial w_1$

Aplicando la regla de la cadena:

$$\frac{\partial J}{\partial w_1} = (y-t) \cdot \frac{\partial y}{\partial h} \cdot \frac{\partial h}{\partial z_1} \cdot \frac{\partial z_1}{\partial w_1}$$

$$= (-1) \cdot 4 \cdot [0{,}5(1-0{,}5)] \cdot 2 = (-1) \cdot 4 \cdot 0{,}25 \cdot 2 = -2$$

El signo negativo indica que, para reducir el error (descenso por gradiente), debe aumentarse w_1.