Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería

1INF02 APRENDIZAJE DE MÁQUINA

Mentalidad de Modelado (Parte 2)

Prof. Rodrigo Uribe

Revisión de grupos

CONFIRMADOS	
POR CONFIRMAR	

GRUPO 1: 48.9
DIAZ MENDIETA, Kevin Martin
RODRIGUEZ TORRES, Marco Antonio Junior
CHÁVEZ POZO, Jared Dalmiro

GRUPO 2: Condolin
HOLGUIN HUARI, Rodrigo Alejandro
BACA CHAVEZ, Benny Segundo
MULATILLO GOMEZ, Ariana Camila

GRUPO 3: Palantir
CORDOVA RIVERO, Katherine Daniela
BRAVO BRAVO, Ashley Estefania
AGURTO TUMIALAN, Rodrigo Willians

GRUPO 4: GLTeam
SALAZAR CANTO, Yomira Rossana
ALCANTARA TORRES, Alessandro Javier

GRUPO 6: Machine learning
POMA CANCHARI, Gianfranco Moises
CHUMBIMUNI BUSTAMANTE, Sergio Alonso
MEDINA VIVANCO, MATHIAS ALDAIR

GRUPO 7: XX
GUERRA HEREDIA, Ariel Antonio
CANCHARI COA, VLADYMIR ANDRES
URBINA GARRO, GIOVANNA MILENA

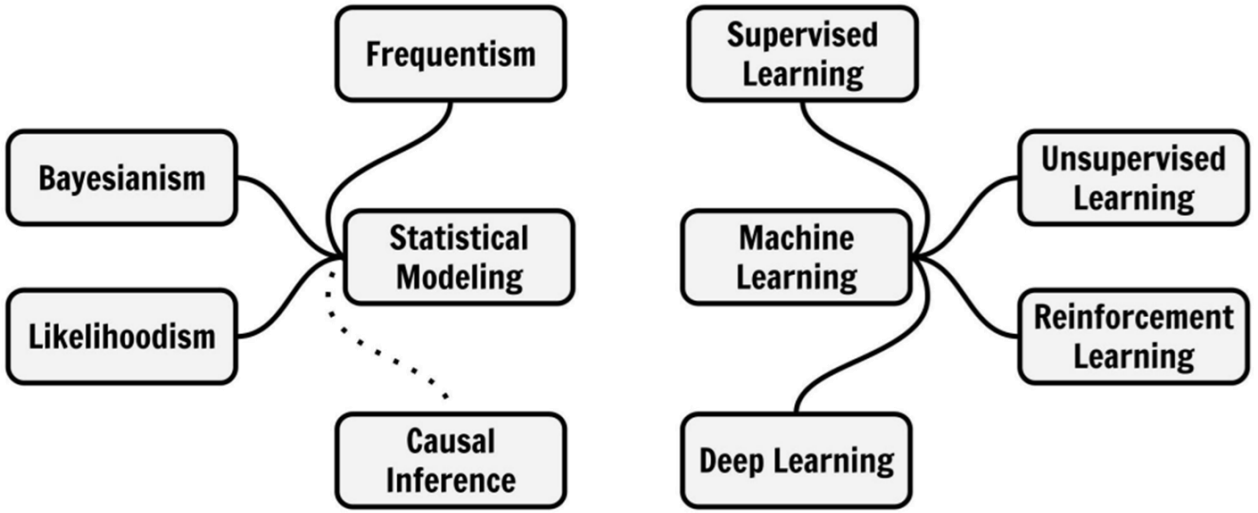
GRUPO 8: Ay Vamos
VASQUEZ MORALES, Carlos Camilo
TORRES FLORES, Gustavo Alberto
VELAZCO CHANCAFE. Luis Enrique

GRUPO 9: Solo Team
HUARIPATA TRUJILLO, Axel Edu
DEL CARPIO GOMEZ, JOSE EDUARDO

GRUPO 11: Los guardianes
CALDERON BARRIAL, Cristian Smith
IZARRA LIMACHE, Luis Mario
CHANG RAMIREZ, Rodrigo Bryan

GRUPO 12: NombreDeEjemplo
HURTADO CLAROD, LHÍA ANTONELLA
ALVAREZ CORREA, NELSON ANDRE
SIVINCHA BAILÓN, JOSUÉ MANUEL

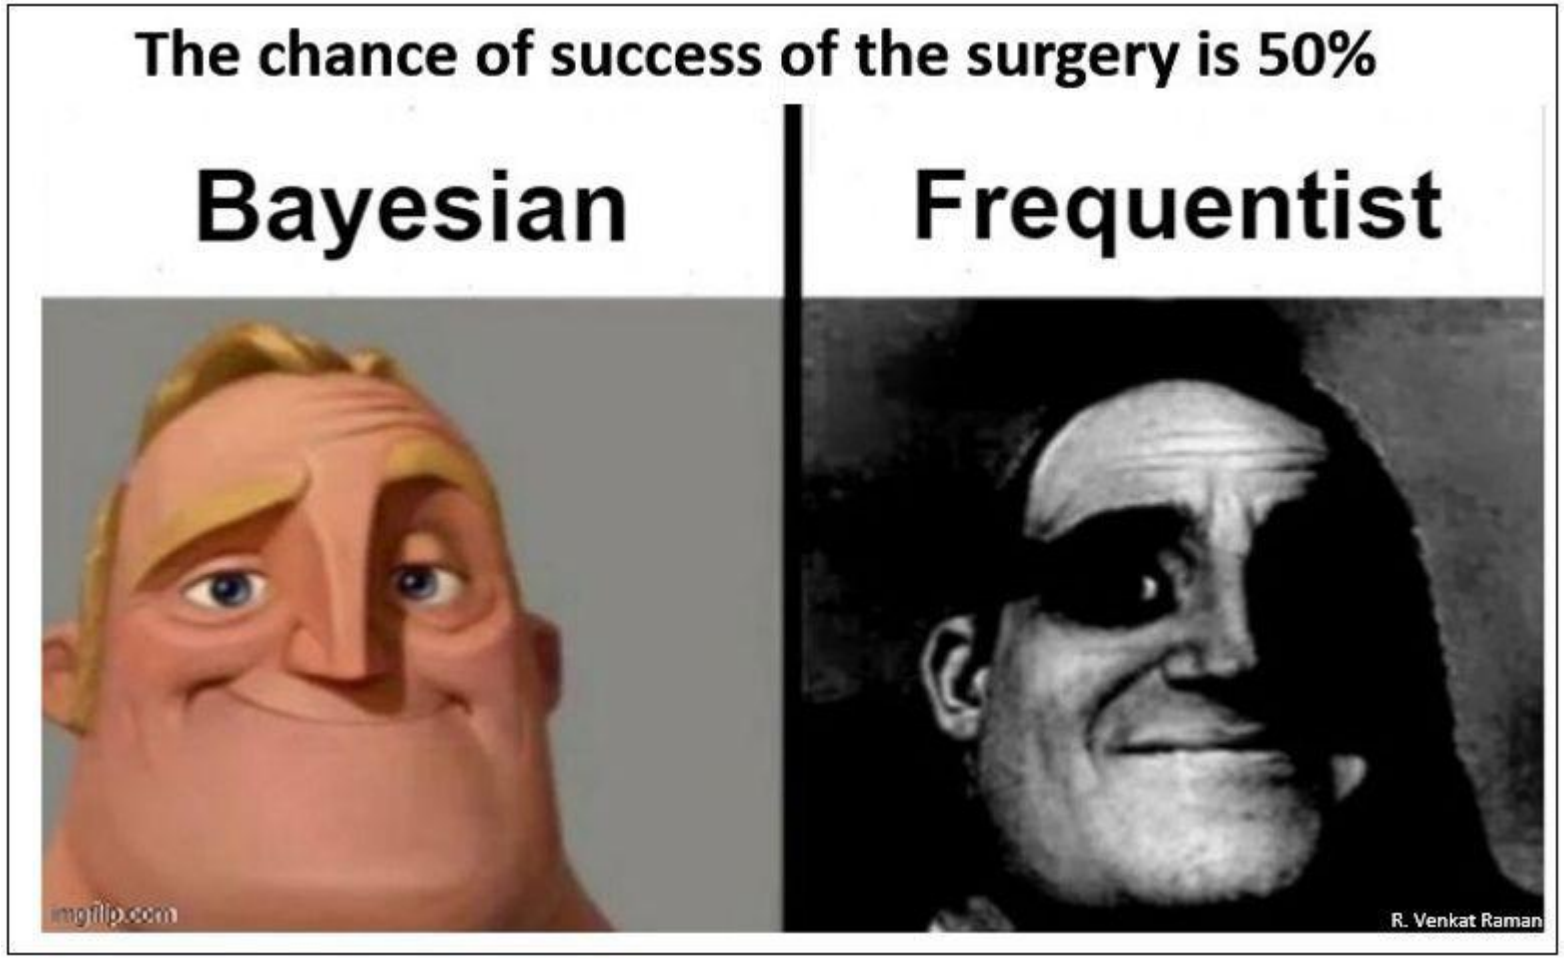
GRUPO 13: VibeForce
ORIHUELA MONTERO, JOHNNY FABRICIO
SANCHEZ PASTOR, RODRIGO ALONSO
LA TORRE VALLE, CARLOS DANIEL



BAYESIANISMO

(Actualiza la distribución en base a evidencia)

¿Cuál es el problema principal con la estadística frecuentista?

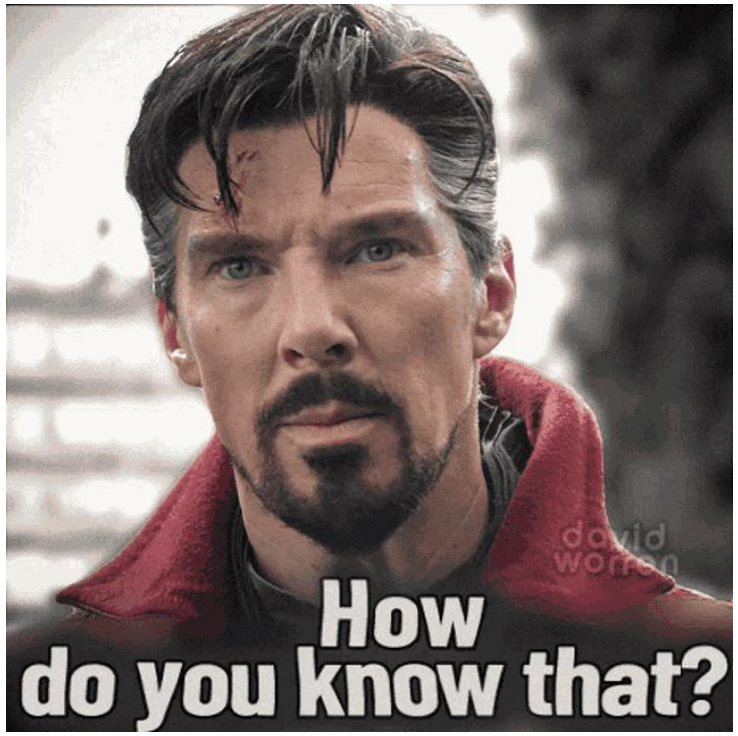


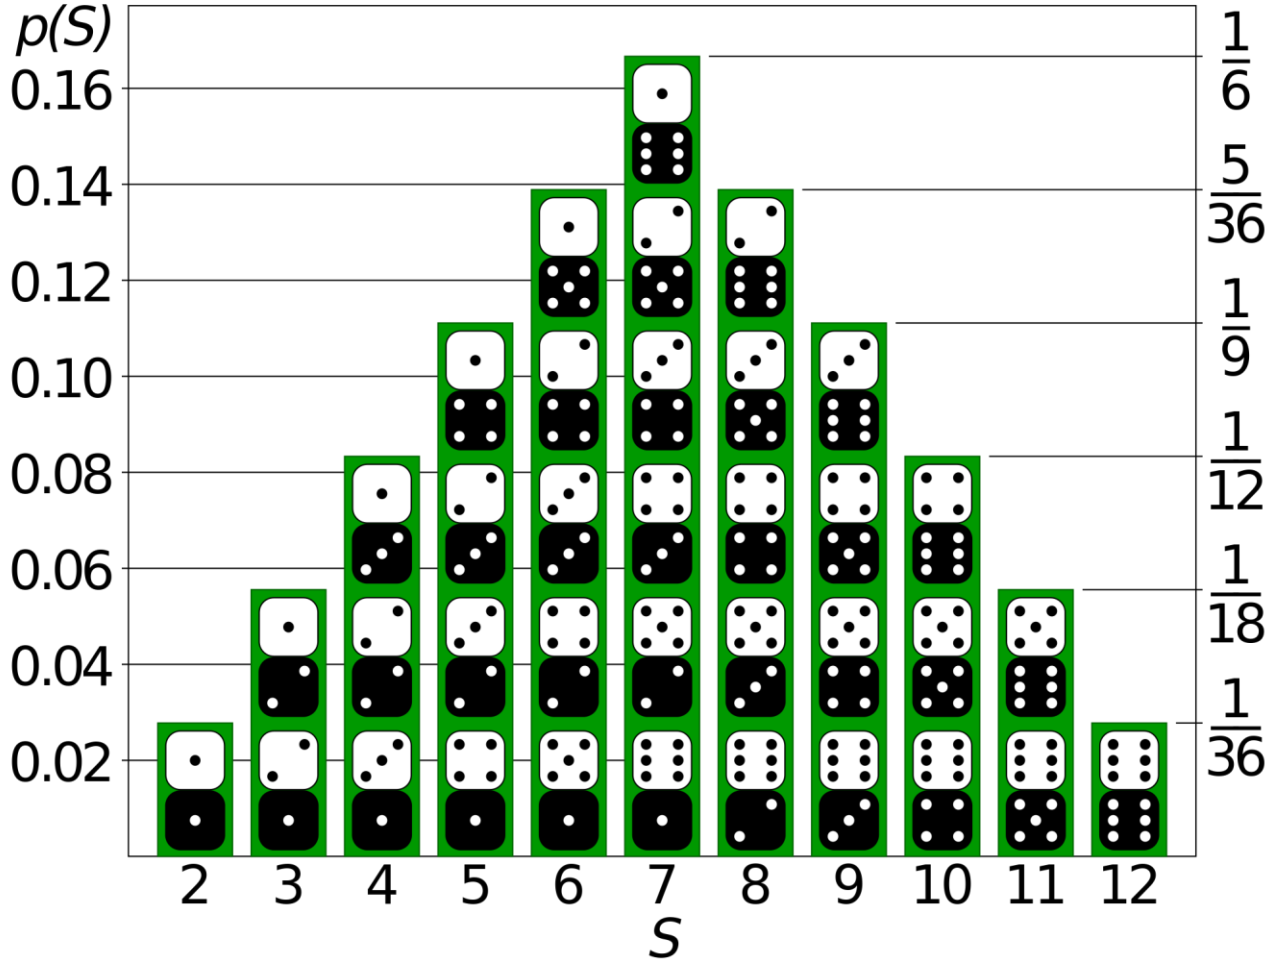
¿Qué era una distribución probabilística?

Premisa del Bayesianismo

- **Premisa:** El mundo se aborda mejor a través de distribuciones de probabilidad con parámetros probabilísticos (pueden cambiar).
- **Consecuencia:** Actualizar las distribuciones de parámetros a priori usando datos para obtener la distribución posterior y sacar conclusiones.

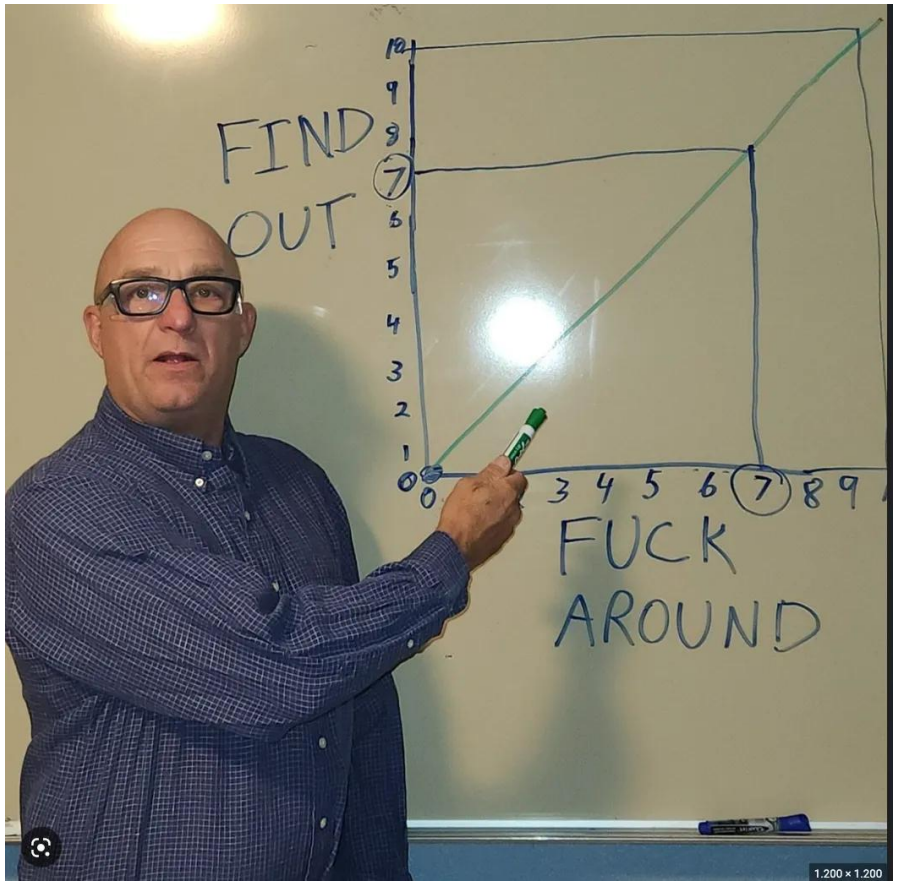
El caso del dado (pensamiento bayesiano)





Esencia del pensamiento Bayesiano

- Experimentar (probar cosas) genera información que actualiza nuestras creencias.
- La incertidumbre inicial no es ignorancia, es un punto de partida.
- Cada experimento transforma esa incertidumbre en conocimiento más preciso.



Implicaciones de la Premisa

- Las distribuciones probabilísticas de parámetros son variables (no fijos, sino inciertos)
- Por lo tanto, el objetivo es estimar la distribución asociada a nuestros datos: P(parámetros | datos)
- Problema: P(parámetros | datos) no es directamente observable (esta es la respuesta que quisiéramos)

Implicaciones de la Premisa

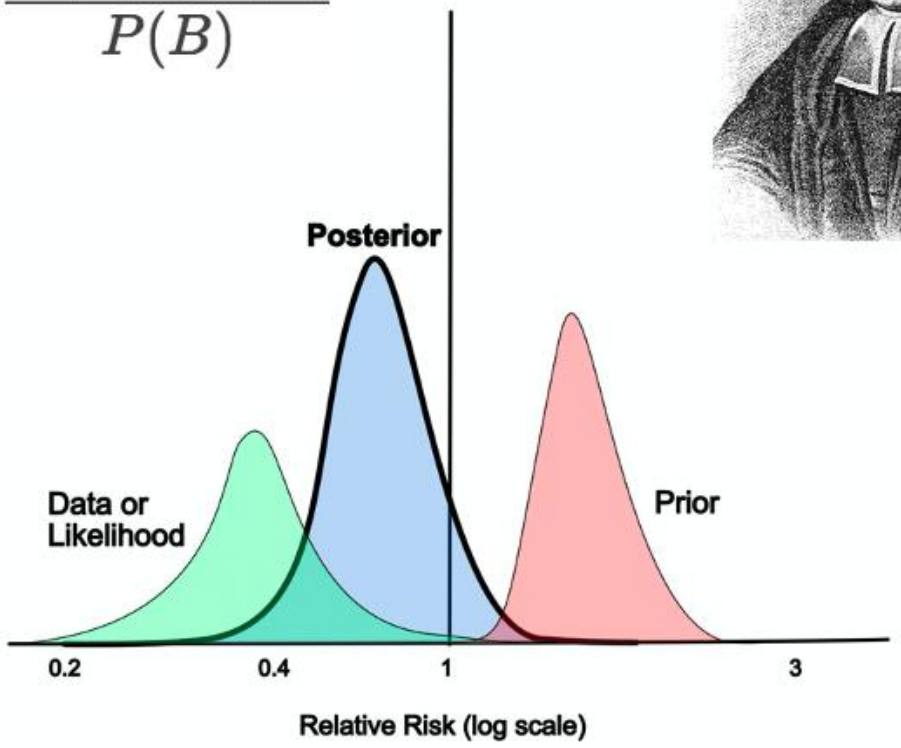
- Un "truco" matemático ayuda: el teorema de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$



- El teorema invierte la condición a P(datos | parámetros), que es la función de verosimilitud

- El teorema también involucra P(parámetros), la distribución a priori



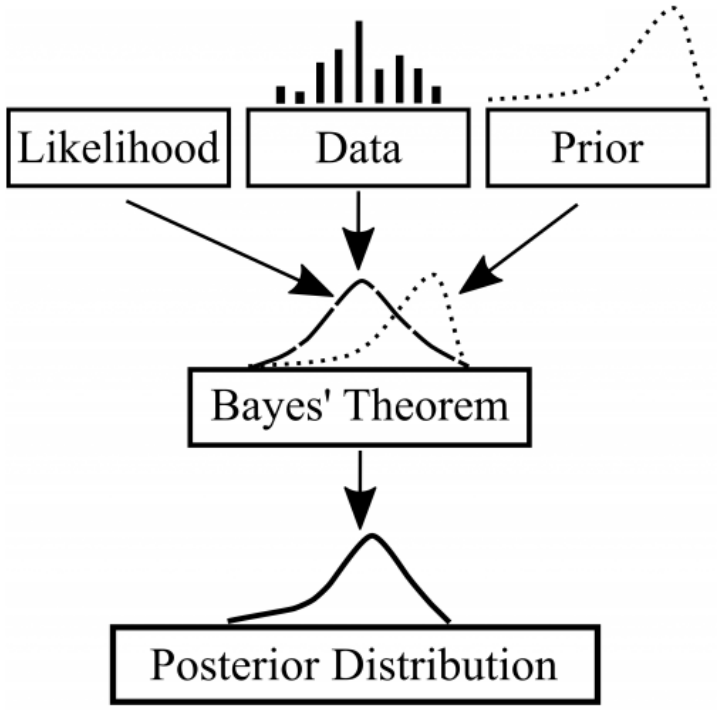
Componentes del Teorema

- Prior: Distribución de probabilidad del parámetro antes de considerar datos
- Verosimilitud: Qué tan probables son los datos dado los parámetros
- Evidencia: Factor de normalización
- Posterior: Creencia actualizada sobre los parámetros

Ejemplo del dado

¿Cómo aplicarían Bayes para ver si un dado esta cargado?

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$



Ejemplo del dado

Hipótesis:

- **H_justo:** Cada cara tiene probabilidad 1/6 ≈ 0.167
- **H_cargado:** El 6 tiene probabilidad 1/2, las demás caras tienen probabilidad 1/10 cada una

Prior inicial (incertidumbre total):

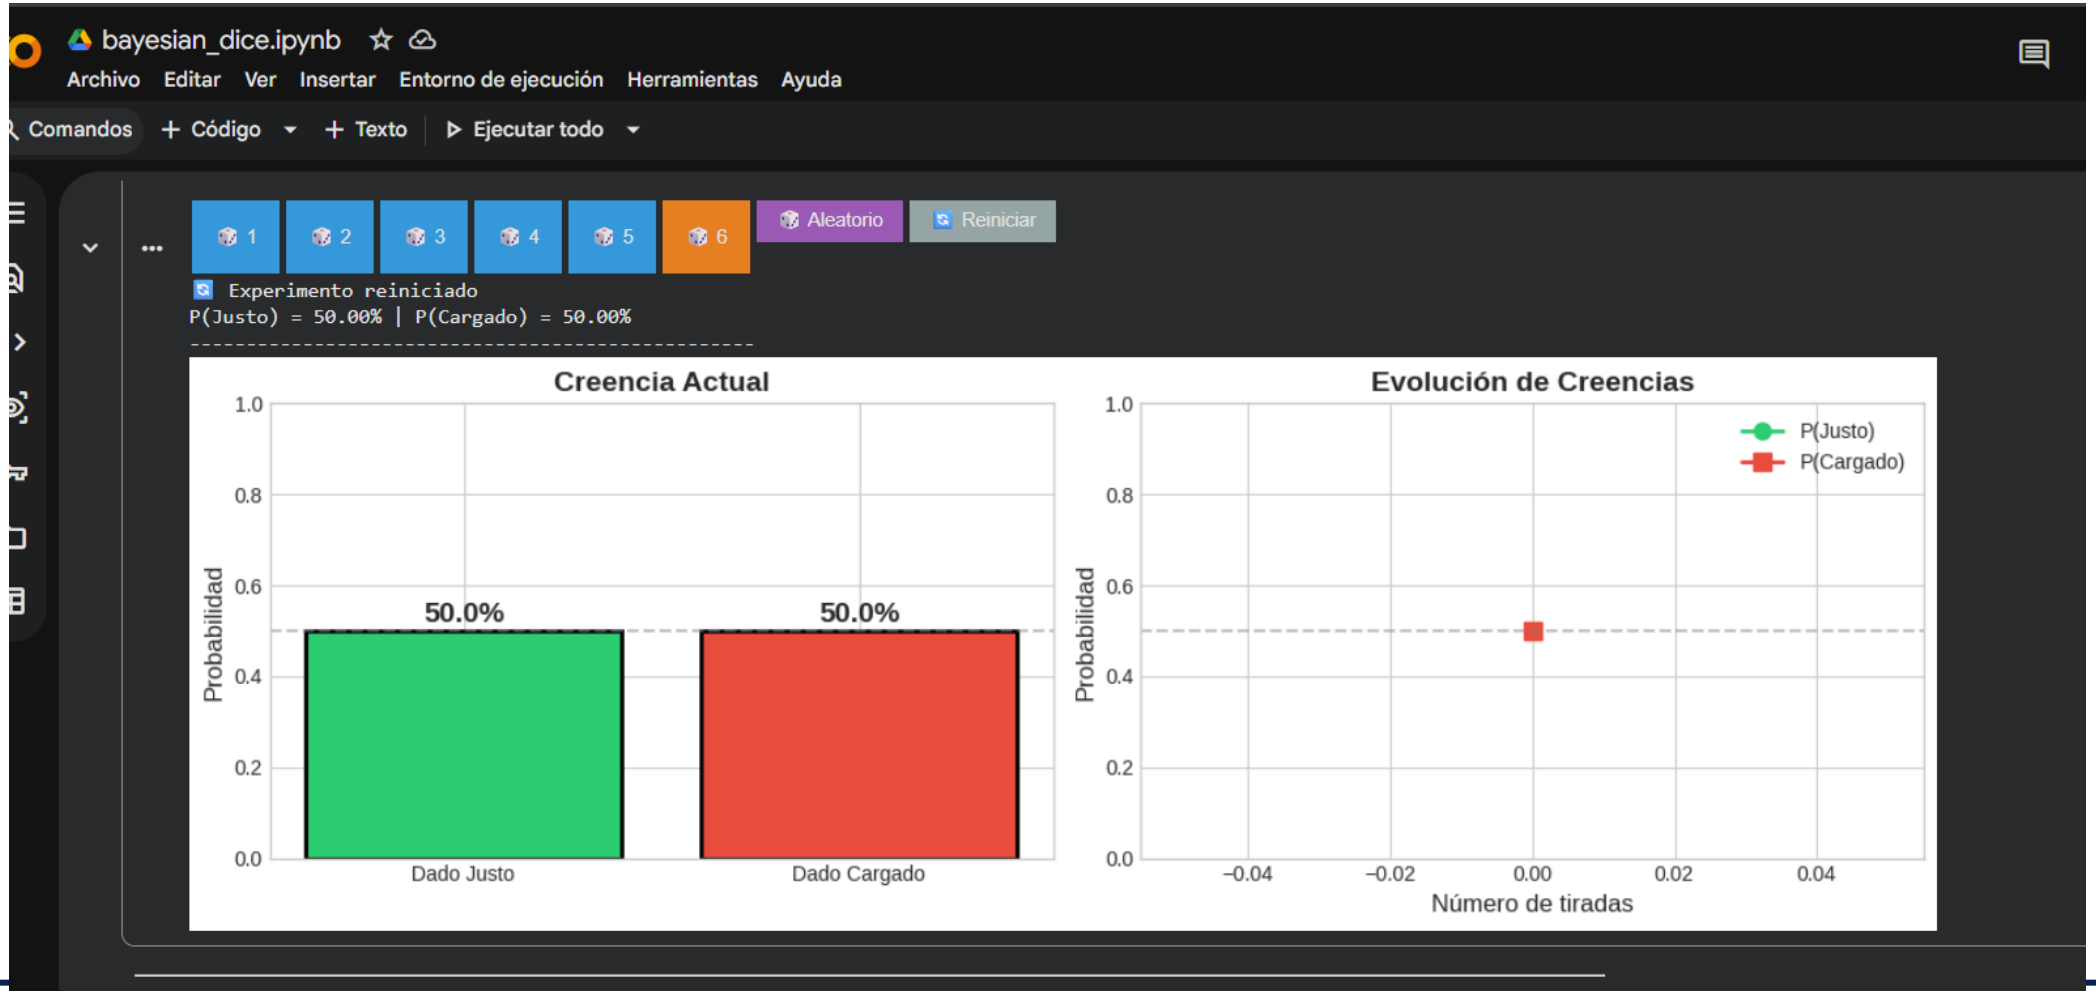
- P(H_justo) = 0.50
- P(H_cargado) = 0.50

$$P(H|dato) = \frac{P(dato|H) \cdot P(H)}{P(dato)}$$

Donde:

$$P(dato) = P(dato|H_{justo}) \cdot P(H_{justo}) + P(dato|H_{cargado}) \cdot P(H_{cargado})$$

Ejemplo del dado (demo)



Implicaciones de la Premisa

- Por eso los bayesianos deben especificar una distribución de parámetros antes de observar datos

- Estimación del modelo = actualización de prior a posterior

- El teorema también involucra P(X) llamada la evidencia, que usualmente es difícil de estimar

- Esto hace que los modelos bayesianos sean más intensivos computacionalmente

Necesidad del Prior

Los bayesianos asumen que los parámetros tienen una distribución de probabilidad a priori.

Los priors son:

- Una consecuencia de decir que los parámetros son variables aleatorias
- Un requisito técnico para trabajar con el teorema de Bayes

Primera Consideración - Espacio de Parámetros

- El espacio de parámetros es el conjunto o rango de valores que los parámetros pueden tomar.
- Ejemplo: Si el parámetro solo puede ser positivo, el prior debe tener probabilidad cero para valores negativos (ej: distribución Gamma).

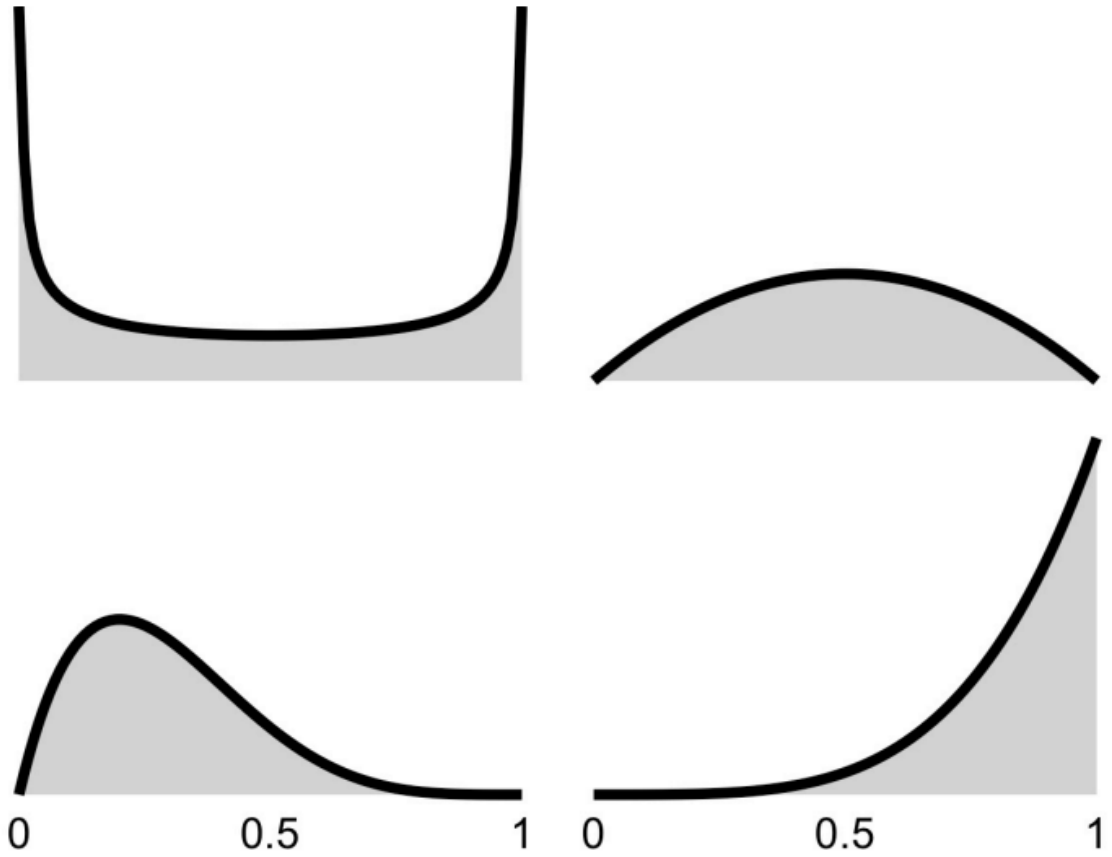
Codificar Conocimiento de Dominio

Ejemplo: Si los datos siguen una distribución Binomial (número de cruces en lanzamientos de moneda), la distribución Beta es un posible prior para el parámetro de probabilidad de éxito.

La distribución Beta tiene parámetros que permiten incorporar conocimiento adicional.

Ejemplos de *Priors* Beta

- Prior simétrico alrededor de 0.5 (para monedas justas)
- Prior centrado en 0.25
- Prior que da mayor probabilidad a 0 y 1



Crítica a los Priors

Los críticos del bayesianismo critican que la elección de un prior es subjetiva.

Los bayesianos también pueden sentirse molestos al tener que elegir priors, especialmente si el modelo tiene muchos parámetros.

Los Priors Como Solución

Aunque los priors pueden verse como un problema, también pueden ser una solución:

- Regularizan el modelo (especialmente si hay pocos datos)
- Codifican conocimiento de dominio y resultados experimentales previos
- Permiten un manejo natural de errores de medición y datos faltantes (muestreo selectivo)

Efecto de Más Datos

Especialmente con muchos datos, modelos de diferentes mentalidades estadísticas resultarán en conclusiones similares.

Cuantos más datos, más cierta se vuelve la verosimilitud y el impacto del prior desaparece.

Objetivo Bayesiano

El objetivo de los modeladores bayesianos es estimar las distribuciones posteriores de los parámetros.

Una vez que tienen los posteriores, pueden:

- Interpretarlos
- Hacer predicciones
- Sacar conclusiones sobre el mundo

El Problema de la Evidencia

En el caso ideal, el posterior puede escribirse como fórmula explícita.

Pero: Para la mayoría de los modelos bayesianos, es imposible obtener una forma cerrada del posterior.

El problema es el término de evidencia: usualmente es difícil de computar.

¿Cómo multiplicamos distribuciones?

¿Qué es un muestreo estadístico?

La Solución - Muestreo

En lugar de computar el posterior, los bayesianos muestrean de él.

MCMC (Markov Chain Monte Carlo): Genera muestras de la distribución posterior.

Intuición: MCMC produce caminatas aleatorias a través del posterior, "visitando" regiones con mayor posterior más frecuentemente.

Consideraciones Prácticas

- La mayoría del software bayesiano ejecuta MCMC automáticamente
- Puede ser lento comparado con procedimientos frecuentistas de máxima verosimilitud
- Alternativa más rápida: Inferencia variacional (heurística)

Contenido del Posterior

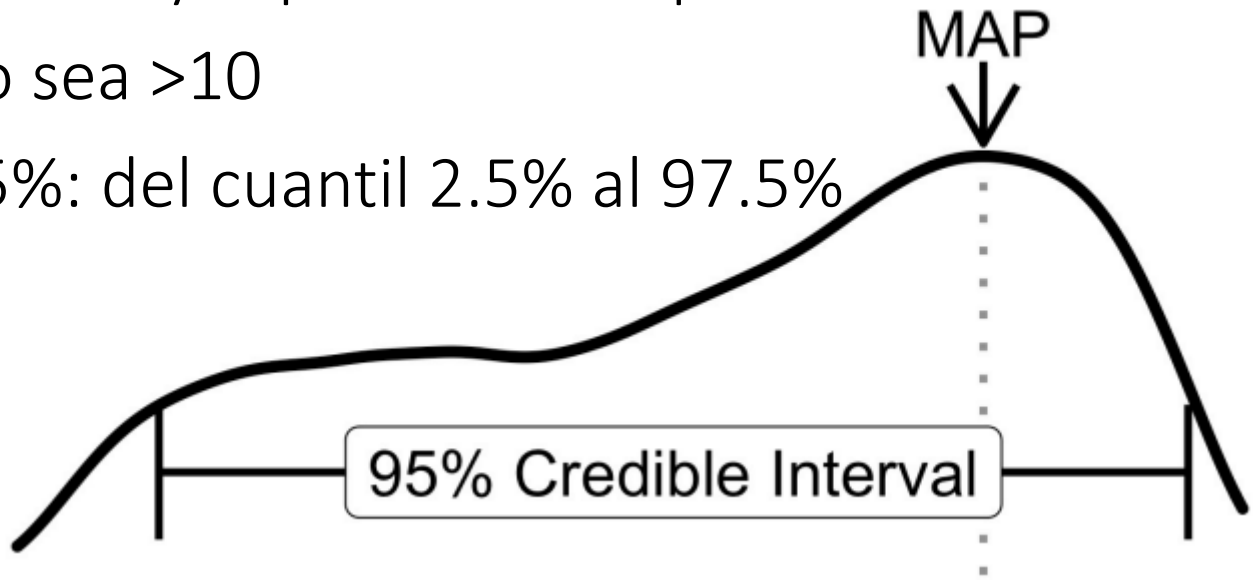
Las distribuciones posteriores contienen todo lo que los modelos aprendieron de los datos.

Visualizar los posteriores proporciona acceso a esa información completa.

Resumir el Posterior

Aunque algunos argumentan no resumir el posterior, muchos modeladores lo hacen para simplificar resultados:

- MAP: Valor del parámetro con la mayor probabilidad posterior
- Probabilidad: que el parámetro sea >10
- Intervalo de credibilidad del 95%: del cuantil 2.5% al 97.5%



Modelado del Proceso Generador

Como en otras mentalidades de modelado estadístico, los bayesianos construyen modelos para aproximar el proceso generador de datos.

Aprender de los datos significa actualizar parámetros del modelo.

Contraste con Frecuentistas

Frecuentistas: Asumen parámetros desconocidos pero fijos; incertidumbre es función de los estimadores; conclusiones se derivan de cómo se espera que los estimadores se comporten en repeticiones.

Bayesianos: Parámetros son variables aleatorias con distribuciones que se actualizan con datos.

Predicción Bayesiana

Si los parámetros son variables aleatorias, las predicciones también lo son.

Proceso de predicción:

1. Muestrear parámetros de los posteriores
2. Hacer predicciones con el modelo
3. Repetir múltiples veces
4. Obtener una distribución de la predicción

Propagación de Incertidumbre

La incertidumbre de los parámetros se propaga a la incertidumbre de las predicciones.

Aunque puede parecer inconveniente, es mucho más honesto e informativo que una estimación puntual.

La incertidumbre es una parte natural del modelado bayesiano.

Fortalezas

✓ Los modelos bayesianos pueden aprovechar información previa, como conocimiento de dominio.

✓ La inferencia bayesiana proporciona un lenguaje expresivo para construir modelos que propagan incertidumbre naturalmente.

✓ Cuando los practicantes malinterpretan los intervalos de confianza frecuentistas, frecuentemente es porque los interpretan como intervalos de credibilidad.

✓ La inferencia bayesiana desacopla inferencia (estimar posterior) y toma de decisiones (sacar conclusiones del posterior).

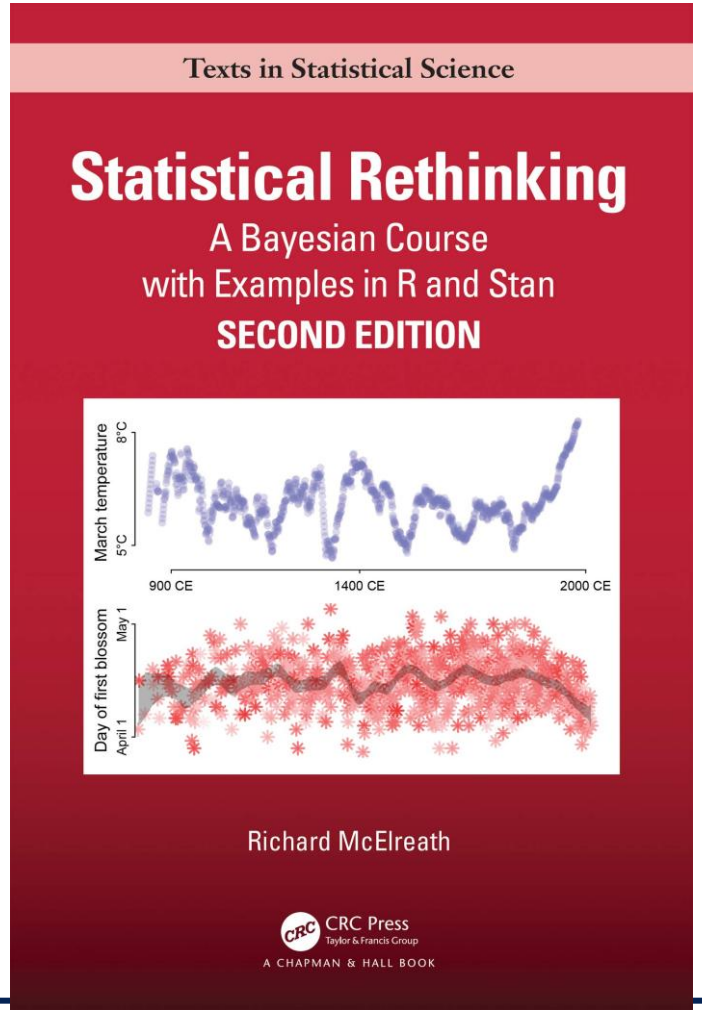
Limitaciones

✗ Elegir un prior puede ser difícil y criticado como subjetivo.

✗ Los métodos bayesianos son matemáticamente demandantes y computacionalmente costosos.

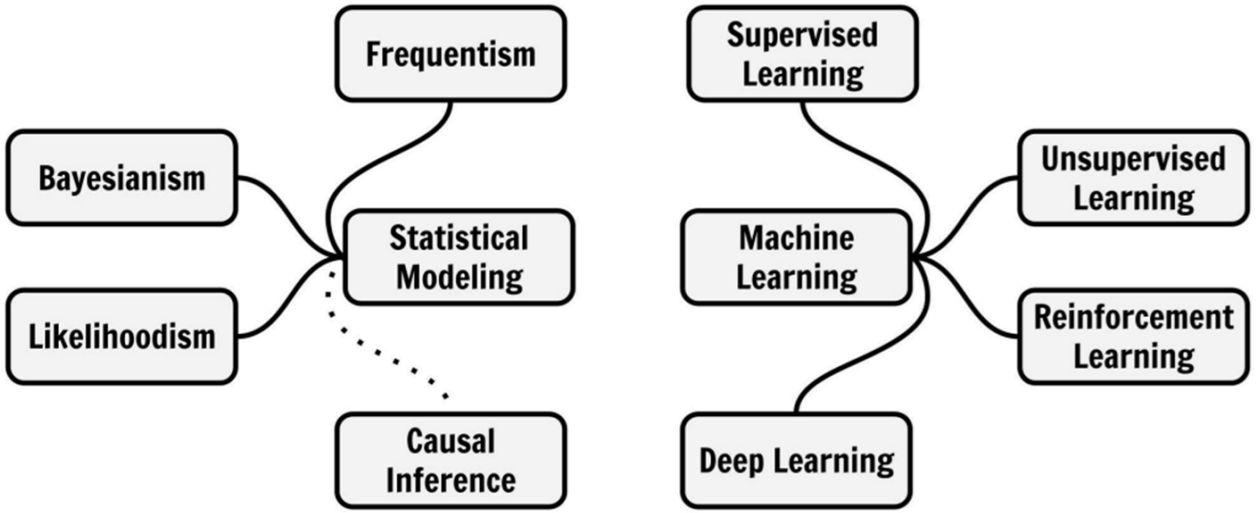
✗ Cuando se usa exclusivamente para decisiones, toda la información adicional sobre el posterior completo puede parecer sobrecarga innecesaria.

Profundizar más...





https://www.youtube.com/watch?v=FdnMWdICdRs&list=PLDcUM9US4XdPz-KxHM4XHt7uUVGWWVSus



MACHINE LEARNING

Aprender Algoritmos de los Datos

Flexibilidad vs. Modelado Estadístico

En machine learning, no hay tantas restricciones en el modelo como en el modelado estadístico.

- Los modelos son algoritmos, no hipótesis estadísticas
- El rendimiento se valora sobre la validez interna
- Un aprendiz puede usar variables aleatorias, pero no tiene que serlo

Diferencia con Estadísticos

Estadístico arquetípico:

- Usa la computadora por conveniencia y necesidad
- El punto de partida es la teoría estadística
- La computadora es solo una herramienta

Aprendizaje de máquina arquetípico:

- Comienza con la computadora
- Pregunta: "¿Cómo hacer útiles las computadoras?"

Medición del Éxito

El éxito de un modelo de ML se mide por qué tan bien se resolvió la tarea.

Ejemplos de métricas:

- Error de generalización para datos nuevos
- Exactitud (accuracy)
- Puntuación F1
- Homogeneidad de clusters

Enfoque Externo

Este enfoque externo se refleja en cómo funciona mucha investigación de ML:

1. Los investigadores inventan un nuevo algoritmo
2. Muestran que funciona comparándolo con otros en tareas de referencia (benchmarks)
3. La razón de por qué funciona bien se descubre después (si acaso)

Motivación Externa vs. Intrínseca

Machine Learning (Externa):

- Evaluación basada en rendimiento de la tarea
- Como juzgar comida por cómo sabe

Modelado Estadístico (Intrínseca):

- La razón para construir el modelo es importante
- Como juzgar comida por el proceso de cocción (ejemplo gallinas felices)

Entonces...

¿Está el *Machine Learning* condenado a respuestas poco satisfactorias?

¿Qué es el Aprendizaje Estadístico?

Algunas personas se refieren al machine learning como "aprendizaje estadístico".

Es machine learning visto a través del lente de la estadística y la probabilidad.



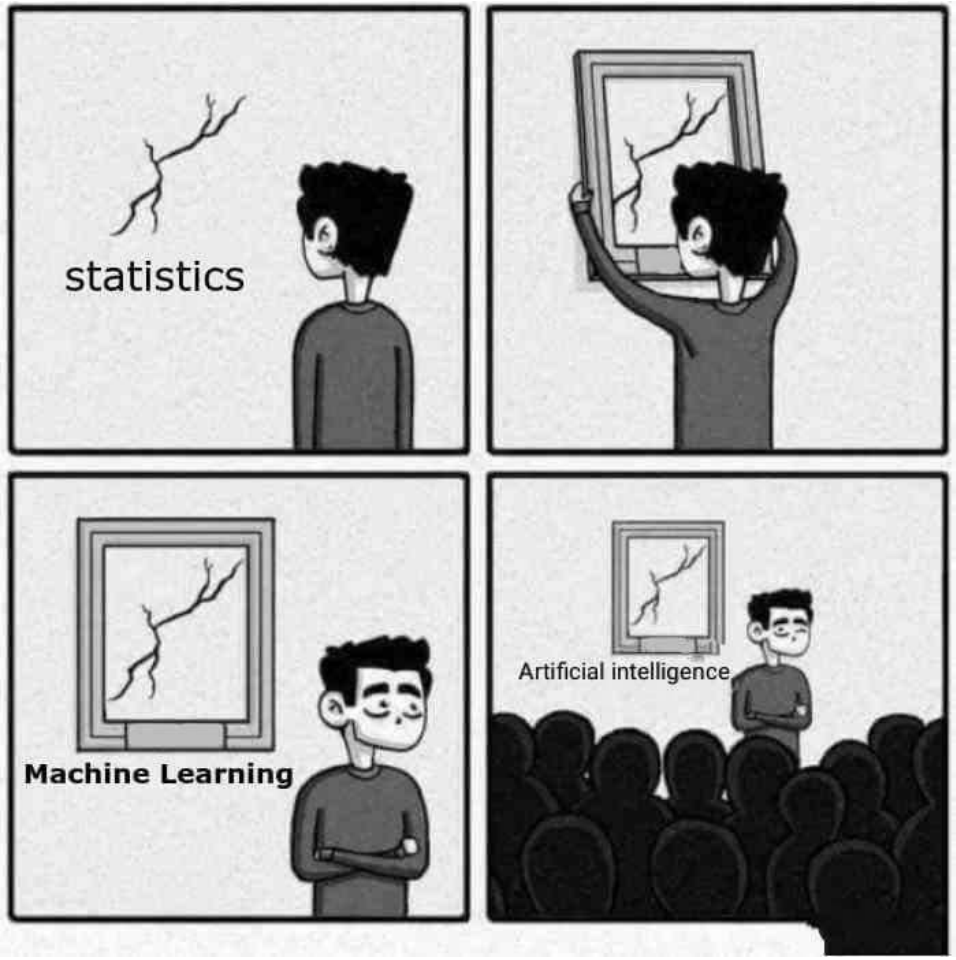
Elementos del Aprendizaje Estadístico

Los cursos de ML frecuentemente hablan de:

- Probabilidades condicionales
- Sesgo y varianza
- Distribuciones de probabilidad

Los investigadores usan el aprendizaje estadístico para derivar propiedades de modelos y algoritmos.

¿Es ML Solo un Rebrandeo?



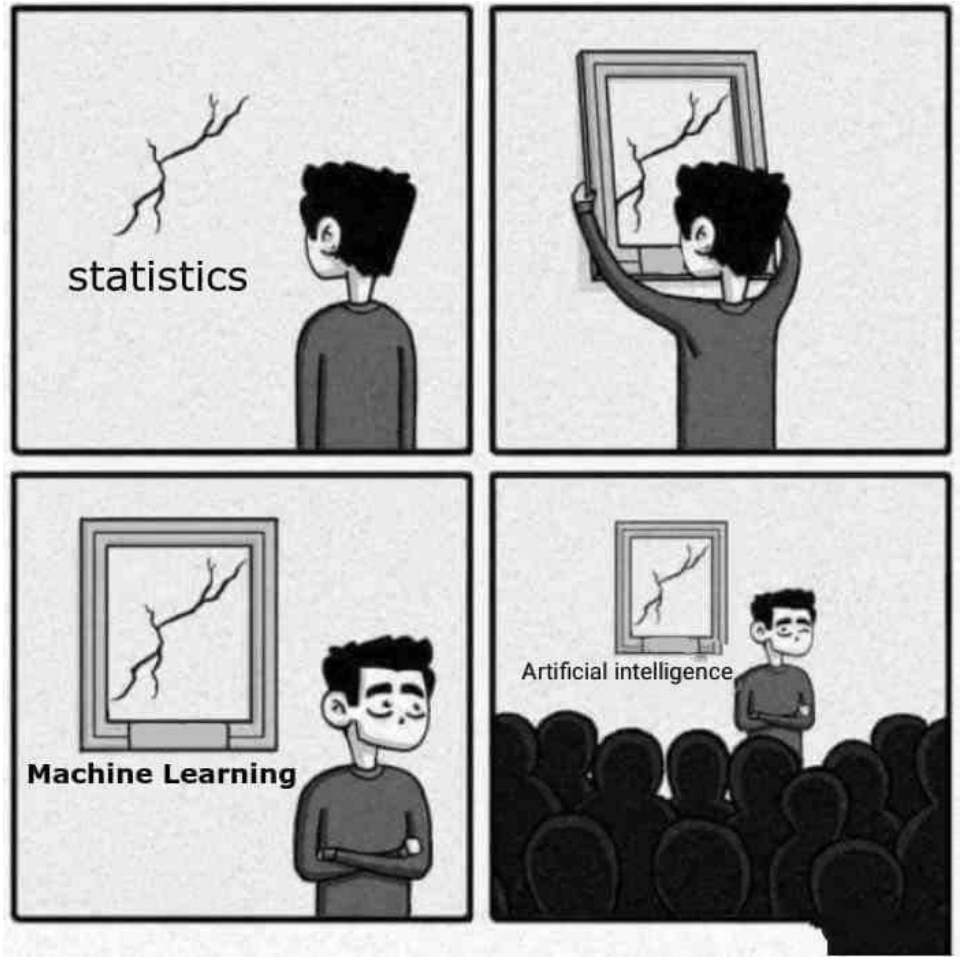
¿Es ML Solo un Rebrandeo?

Podemos distinguir:

- La mentalidad del modelado estadístico

- El lenguaje de la estadística

El aprendizaje estadístico significa aplicar el lenguaje de la estadística al ML, pero las mentalidades de modelado no son las mismas.



Dos Enfoques, Mismo Modelo

Estadístico:

- Ajusta regresión logística guiada por hipótesis
- Interpreta significancia de coeficientes

Aprendiz de máquina:

- Afina y compara diez algoritmos
- Termina con random forest para clasificación

Ambos podrían describirse con lenguaje estadístico, pero la mentalidad es muy diferente.

Fortalezas

✓ Orientado a tareas y, por lo tanto, pragmático.

✓ Una mentalidad orientada a computadoras en un mundo orientado a computadoras.

✓ Machine learning está predestinado para automatizar tareas y construir productos digitales.

Limitaciones

✗ No tan fundamentado e impulsado por hipótesis como el modelado estadístico.

✗ Una cantidad confusa de enfoques y tareas.

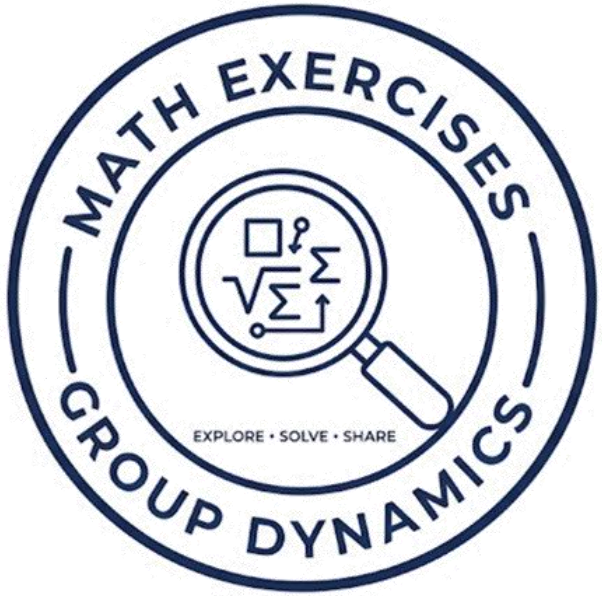
✗ Los modelos que resuelven tareas bien no son necesariamente los mejores para obtener insights.

✗ Frecuentemente requiere muchos datos y es computacionalmente intensivo.

(10 min) Break



Dinámica Grupal: ¿Qué mentalidad es?



- Los grupos van participando en orden numérico.
- El profesor lee el caso (10 en total)
- **5 segundos** de discusión silenciosa
- Sólo se responde “Frecuentista”, “Bayesiano” o “Aprendizaje Automático”
- El grupo en turno responde primero:
  - Respuesta correcta: +10
  - Respuesta incorrecta: -20
  - Pasar: +5

Caso 1

Queremos saber si el nuevo medicamento tiene un efecto significativo

Caso 2

Necesito un modelo que prediga correctamente qué clientes van a cancelar

Caso 3

Dado lo que sabíamos antes y lo que muestran los datos, hay un 73% de probabilidad de que el tratamiento funcione.

Caso 4

Ajustamos una regresión lineal a los datos y el coeficiente de X resultó ser 3.2

Caso 5

Este modelo tuvo la mejor precisión en datos que nunca había visto

Caso 6

Incorporamos los resultados de 3 estudios anteriores como información previa antes de analizar nuestros datos

Caso 7

Un banco construye un modelo para decidir a quién dar préstamos.

Caso 8

Un investigador tiene pocos datos (n=12) pero mucha literatura previa sobre el tema. Decide incorporar esa información en su análisis

Caso 9

Una empresa de retail quiere saber si su nueva estrategia de precios aumentó las ventas. Comparan ventas antes y después del cambio

Caso 10

Usamos MCMC para obtener muestras de la distribución del parámetro

Caso 11

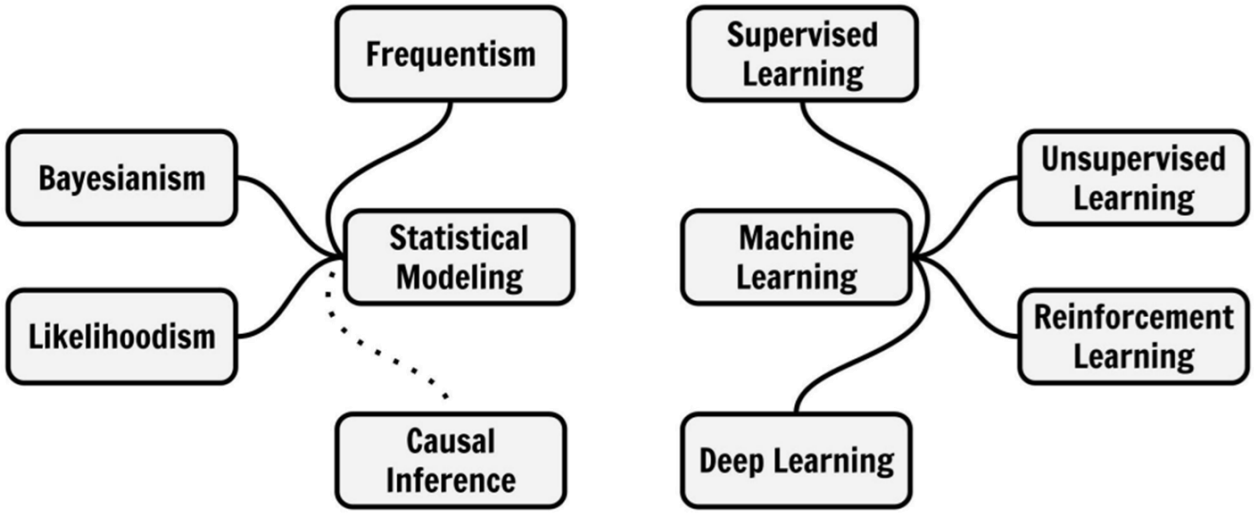
Un epidemiólogo estima la tasa de transmisión de una enfermedad y reporta un intervalo de [1.8, 2.4] con 95% de probabilidad de contener el valor real

Caso 12

Necesito cuantificar mi incertidumbre sobre el parámetro en términos de probabilidad

Caso 13

Comparamos dos modelos y elegimos el que mejor se ajustó a los datos



APRENDIZAJE SUPERVISADO

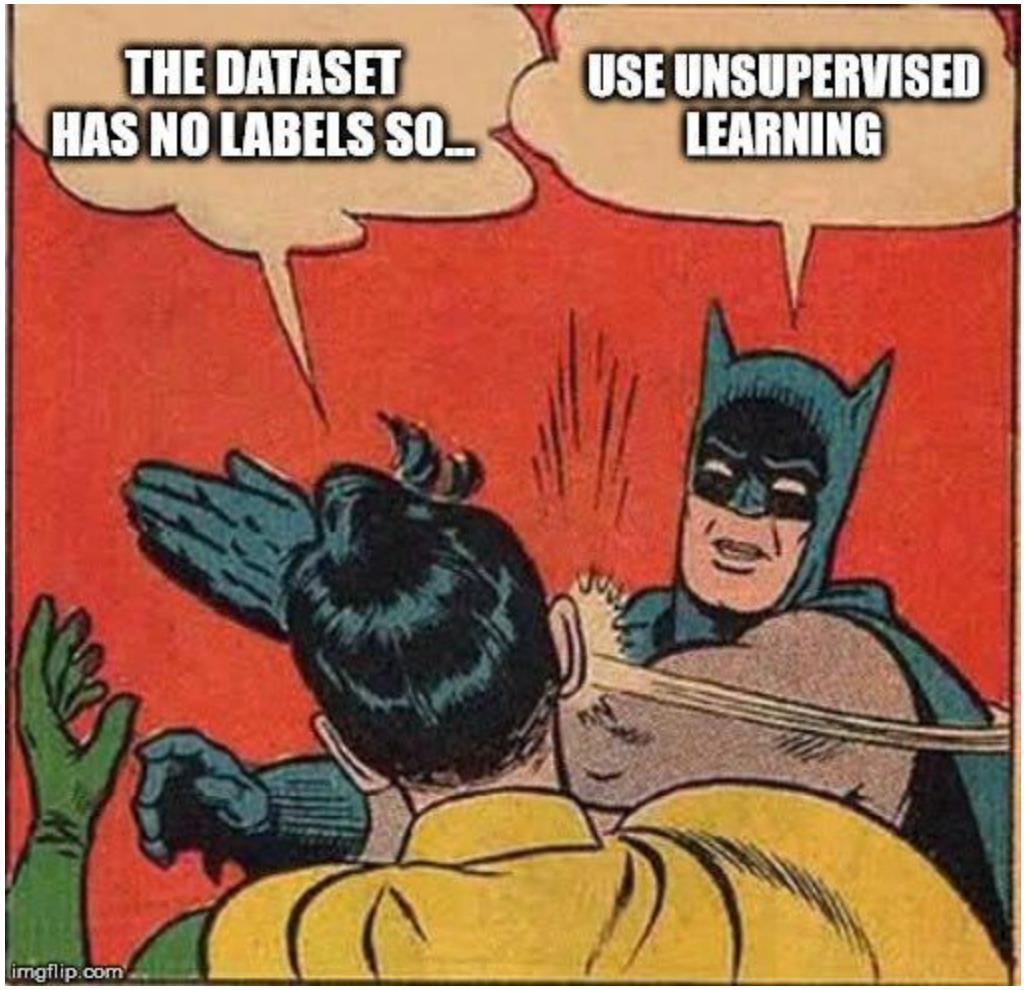
Predecir Nuevos Datos

¿”etiquetado” vs “no etiquetado”?

Aprendizaje auto-supervisado ?

Aprendizaje profundo?

Active Learning?



Aprendizaje por refuerzo?

Aprendizaje contrastivo?

Aprendizaje generativo?

Aprendizaje semi-supervisado?



Premisa del Aprendizaje Supervisado

Premisa: El mundo se aborda mejor haciendo predicciones.

Consecuencia: Aprender modelos predictivos de datos y evaluarlos con datos no vistos.

¿Cuál sería un mejor nombre?

Todo Es un Problema de Predicción

En aprendizaje supervisado de máquinas, todo es una tarea de predicción:

- Regresión
- Clasificación

"Predicción" significa proponer valores para una cantidad para la cual existe una verdad fundamental (al menos para los datos de entrenamiento).

¿Qué No Es Predicción?

Asignar puntos de datos a un cluster NO es predicción porque no hay verdad fundamental para los clusters.

Predicción puede significar:

- Asignar una clase
- Un valor numérico (regresión)
- Un tiempo de supervivencia

Ejemplos de Aplicaciones

- Puntajes de crédito: probabilidad de repagar un préstamo
- Mantenimiento predictivo: predecir tiempo hasta falla
- Pronóstico de demanda: estimar demanda de un producto
- Clasificación de imágenes: detectar cáncer en imágenes CT

Diversidad de Datos de Entrada

Los datos de entrada (features) pueden ser muy diversos:

- Texto
- Imagen
- Serie temporal
- Secuencia de ADN
- Video
- Hoja de cálculo tradicional



El Modelo como Función de Predicción

Un modelo en aprendizaje supervisado es esencialmente la función de predicción.

Una **hipótesis** es una función $f : \mathcal{X} \to \mathcal{T}$ que podríamos usar para hacer predicciones (recordemos que $\mathcal{X}$ es el espacio de entrada y $\mathcal{T}$ es el espacio objetivo).

El **espacio de hipótesis** $\mathcal{H}$ para un modelo o algoritmo de aprendizaje automático en particular es el conjunto de hipótesis que puede representar.



Metáfora del Bosque Oscuro

Piensa en el espacio de hipótesis ($\mathcal{H}$) como un bosque oscuro con infinitas funciones de diferentes formas, parámetros y tipos.

Los algoritmos de aprendizaje supervisado iluminan caminos a través del bosque para encontrar la mejor función de predicción.

La **pérdida (*loss*)** mide qué tan cerca están la predicción y la verdad fundamental.

Aunque la función globalmente mejor podría no estar en el camino iluminado, la función encontrada puede ser localmente óptima.



¿Interpolación vs Exploración (Search)?

(dar ejemplos de modelos)

Clases de Modelos

Cada algoritmo de ML tiene su propio procedimiento para buscar en el espacio de hipótesis ($\mathcal{H}$) :

- Árboles de decisión
- Máquinas de vectores de soporte
- Modelos de regresión lineal
- Random forests
- Boosting
- Redes neuronales



Ejemplos de Búsqueda

Mínimos cuadrados: Función lineal → Solo buscar el mejor multiplicador

Árboles de decisión: Funciones escalonadas → Encontrar mejores puntos de corte

Redes neuronales: Aproximadores universales → Encontrar buena configuración de pesos



Tipos de algoritmos

Si el espacio de hipótesis $\mathcal{H}$ de un algoritmo puede definirse usando un conjunto finito de parámetros, denotado θ, decimos que **el algoritmo es paramétrico**.

- En regresión lineal, θ = (w, b)
- Otros ejemplos: regresión logística, redes neuronales, k-means y modelos de mezcla gaussiana

Si los miembros de $\mathcal{H}$ se definen en términos de los datos, decimos que el **algoritmo es no paramétrico**.

- En k-vecinos más cercanos (k-nearest neighbors), la hipótesis aprendida se define en términos de los datos de entrenamiento
- Otros ejemplos: procesos gaussianos, árboles de decisión, estimación de densidad por kernel
- Estos modelos a veces pueden entenderse como si tuvieran un número infinito de parámetros



El Problema del Sobreajuste

El mayor problema de la búsqueda: sobreajuste (***overfitting***).

Si el modelo depende solo de datos de entrenamiento, no está claro qué tan bien predecirá datos nuevos.

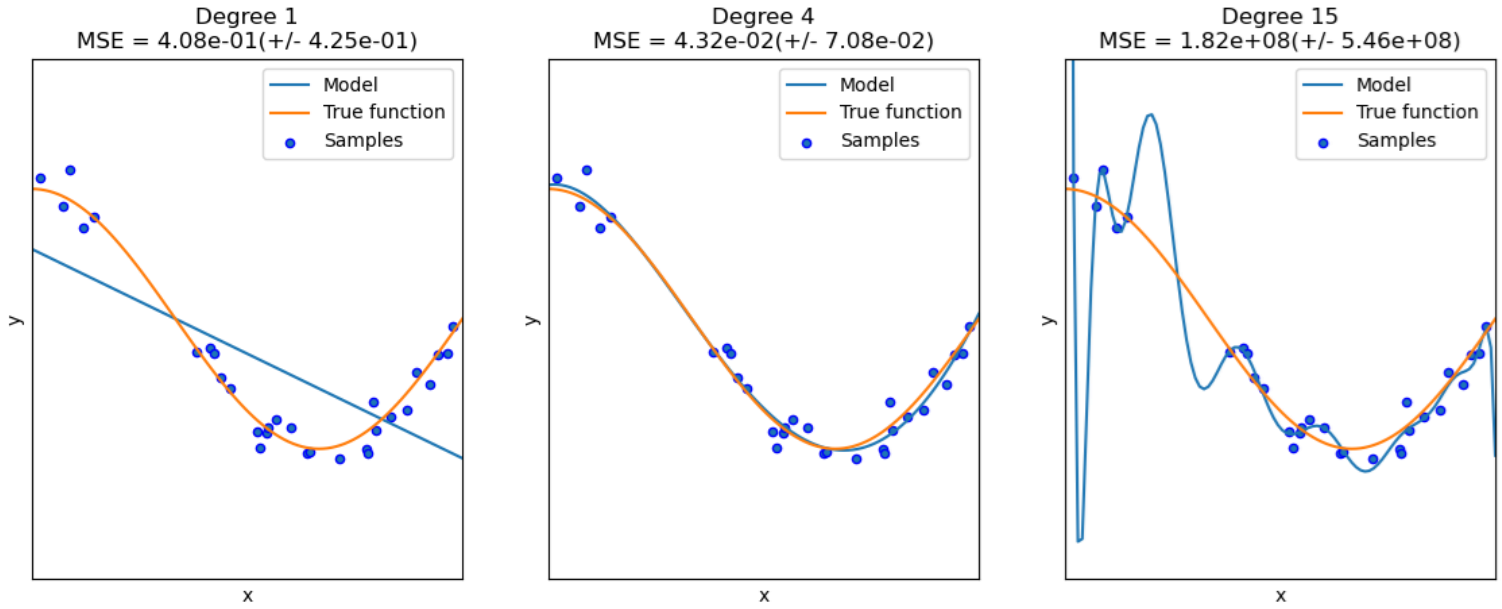
Cuando el modelo memoriza perfectamente los datos de entrenamiento, predecirá mal datos nuevos.

¿Qué es sobreajuste?

Subajuste vs. Sobreajuste

Sobreajuste (*overfitting*): El modelo copia la aleatoriedad de los datos de entrenamiento

Subajuste (*underfitting*): El espacio de hipótesis es muy restringido; el modelo no es lo suficientemente flexible



Balance Entre Extremos

Aprender un modelo supervisado significa caminar en una línea fina entre subajuste y sobreajuste.

Claves para el balance:

- Regularización
- Ajuste de hiperparámetros

Hiperparámetros

La mayoría de los algoritmos tienen hiperparámetros que controlan la flexibilidad del modelo.

Ejemplo - Árboles de decisión:

- Profundidad del árbol
- Árbol muy corto → subajuste
- Árbol muy profundo → sobreajuste

Analogía del Concurso de Cocina

Imagina entrar a un concurso de cocina. Un jurado evaluará tus platillos.

El jurado es la prueba definitiva de tus habilidades culinarias — una prueba de qué tan bien tus habilidades generalizan a nuevos puntos de datos.

- ¿Qué pasa si tu supuesta habilidad en la cocina está sobreajustada al gusto de tu familia?
- Si tu familia ama la sal más que nada, el jurado diría: "¿Cocinaste esto con agua de mar?"

Validación Previa

Para evitar la vergüenza, decides validar tus habilidades antes de la prueba definitiva.

Cocinas para personas que nunca han probado tus platillos y adaptas tus recetas basándote en su retroalimentación.

Evaluación Rigurosa

La evaluación rigurosa es esencial en aprendizaje supervisado.

Recomendación: Decidir la evaluación **ANTES** de entrenar los modelos.

Si un modelo generaliza bien se computa con una métrica de evaluación fuera de muestra.

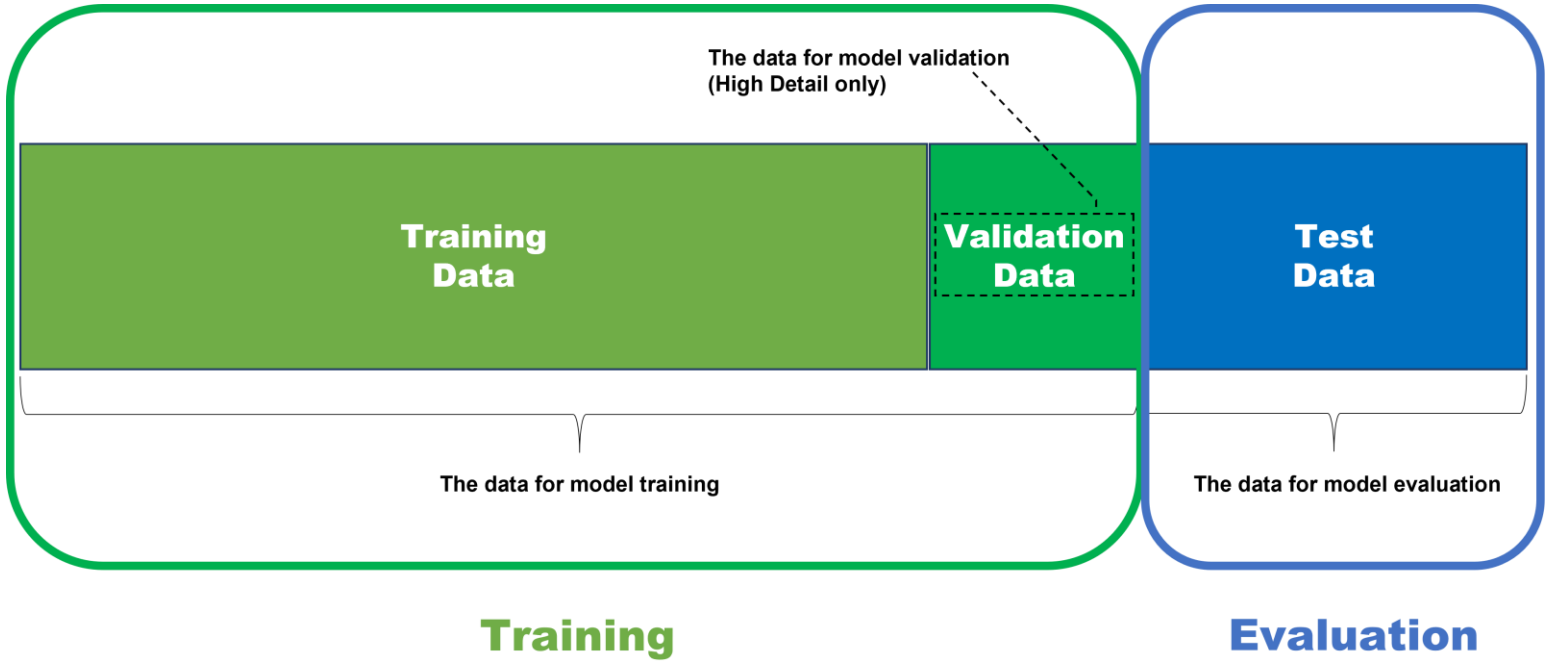
Datos 'Quemados'

Si los datos de prueba se usan para entrenamiento o influyen en decisiones de cualquier forma, los datos están "quemados".

Ya no mostrarán el verdadero rendimiento del modelo — probablemente serán demasiado optimistas.

(dar un ejemplo no tan obvio)

División de Datos

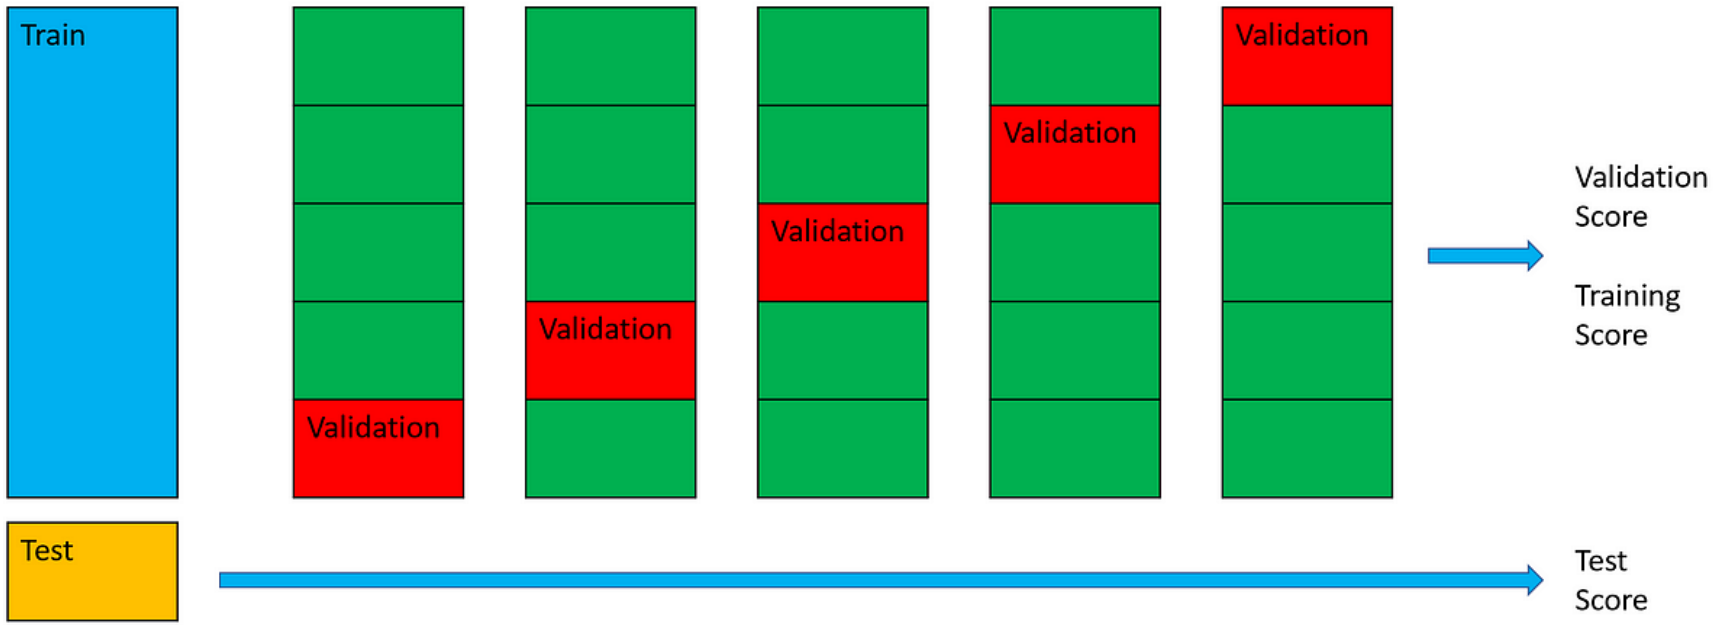


- Entrenamiento: Para ajustar el modelo
- Validación: Para comparar modelos y ajustar hiperparámetros
- Prueba: Solo para evaluación final

¿Cómo sabemos cual división es la correcta?

Validación Cruzada

- En la versión más simple, los datos se dividen una vez antes del entrenamiento.
- En la práctica, técnicas como validación cruzada se usan para dividir los datos múltiples veces y reutilizarlos eficientemente.



Comparación con Modelado Estadístico

Modelado estadístico:

- Hacer muchos supuestos
- Elegir las distribuciones correctas
- Decidir qué variables usar
- Examinar gráficos de diagnóstico

Aprendizaje supervisado:

- Objetivo de optimización claro
- Proceso automatizable

Enfoque del Modelado Estadístico

$$X \rightarrow [\text{Naturaleza (proceso)}] \rightarrow Y$$

$$X \rightarrow [\text{Modelo Estadístico}] \rightarrow Y$$

Los modeladores estadísticos llenan la caja con un modelo estadístico.

Si el modelo representa bien el proceso generador de datos, se pueden interpretar los parámetros como parámetros de la naturaleza.

Enfoque del Aprendizaje Supervisado

$$X \rightarrow [\text{Caja Negra}] \rightarrow Y$$

La naturaleza se ve como incognoscible. No se intenta hacer ingeniería inversa del proceso generador de datos.

El modelo debe imitar las salidas de la naturaleza, sin importar si el mecanismo interno es un sustituto razonable.

Analogía Culinaria

Supón que quieres recrear un platillo de un restaurante:

Modelador estadístico: Intentaría encontrar una receta plausible, aunque el resultado final no sea perfecto.

Aprendiz supervisado: Solo le interesaría el resultado final; no importa si fue exactamente la misma receta.

Fortalezas

✓ La mentalidad más directa cuando se trata de hacer predicciones.

✓ La elección de la función de pérdida permite adaptar el modelo a la tarea.

✓ El aprendizaje supervisado es altamente automatizable.

✓ Tiene un enfoque de evaluación muy coherente y convincente.

Limitaciones

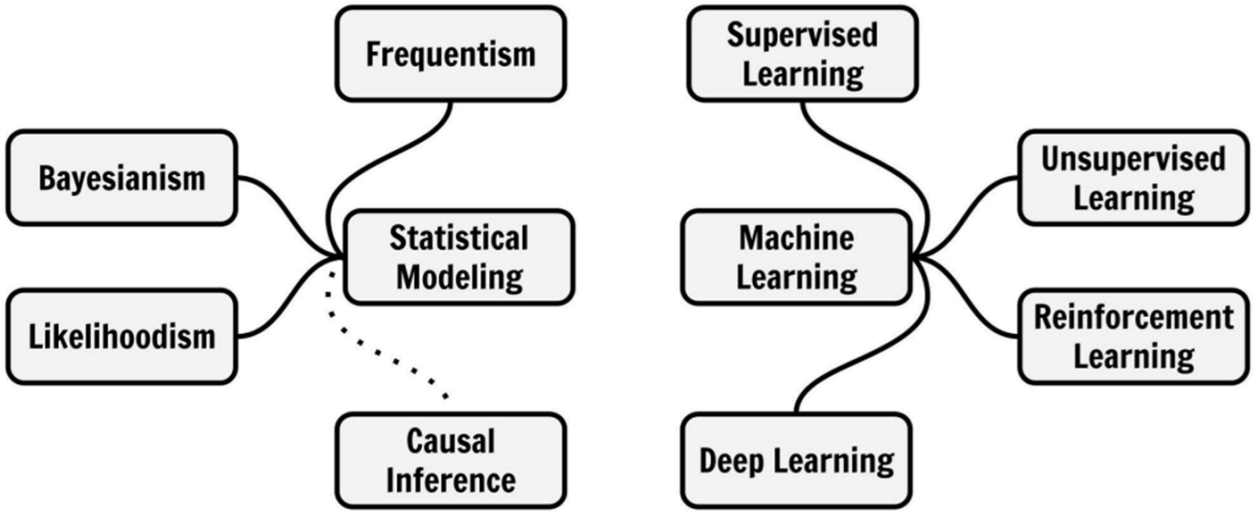
✗ Frecuentemente produce modelos no interpretables (aunque existen métodos para interpretarlos).

✗ No es tan impulsado por hipótesis como el modelado estadístico.

✗ La cuantificación de incertidumbre no es prioridad (como sí lo es en inferencia bayesiana).

✗ Depender ciegamente de errores de generalización puede fallar de formas tontas.

✗ Se suponía que ML liberaría a la humanidad del trabajo tedioso... y aquí estamos etiquetando datos.



APRENDIZAJE NO SUPERVISADO

Encontrar Patrones Ocultos

Premisa del Aprendizaje No Supervisado

Premisa: El mundo se aborda mejor identificando patrones.

Consecuencia: Encontrar patrones ocultos en datos usando clustering, reducción de dimensionalidad y otros algoritmos.

¿Cuál sería un mejor nombre?

Ejemplo - Agencia de Viajes

Tip Top Travel tiene una enorme base de datos con el historial de reservas de sus clientes.

Saben sorprendentemente poco sobre los patrones generales en sus datos:

- ¿Hay ciertos tipos de clientes?
- ¿Los clientes que viajan a Noruega también les gusta Suecia?

Análisis de Clusters

Un análisis de clusters podría identificar grupos de clientes con comportamientos de viaje similares.

Junto con expertos de dominio, se pueden nombrar los clusters:

- "Familias buscando relajación"
- "Aventureros"

Definición

Aprendizaje no supervisado significa descubrir patrones ocultos en los datos.

Un conjunto de datos se convierte en un cofre del tesoro potencialmente lleno de ***insights*** valiosos.

En contraste, para el aprendiz supervisado arquetípico, los patrones son solo un medio para un fin: buenas predicciones.

¿Qué es *Insight*?

(dar ejemplos)

Características del Aprendizaje No Supervisado

Es una mentalidad de machine learning:

- Orientada a tareas: Clustering, detección de anomalías, minería de reglas de asociación
- Orientada a computadoras: Motivada por tener una computadora, no por una teoría
- Motivada externamente: Completar la tarea es más importante que seguir una "receta" particular

Lenguaje de Distribuciones de Probabilidad

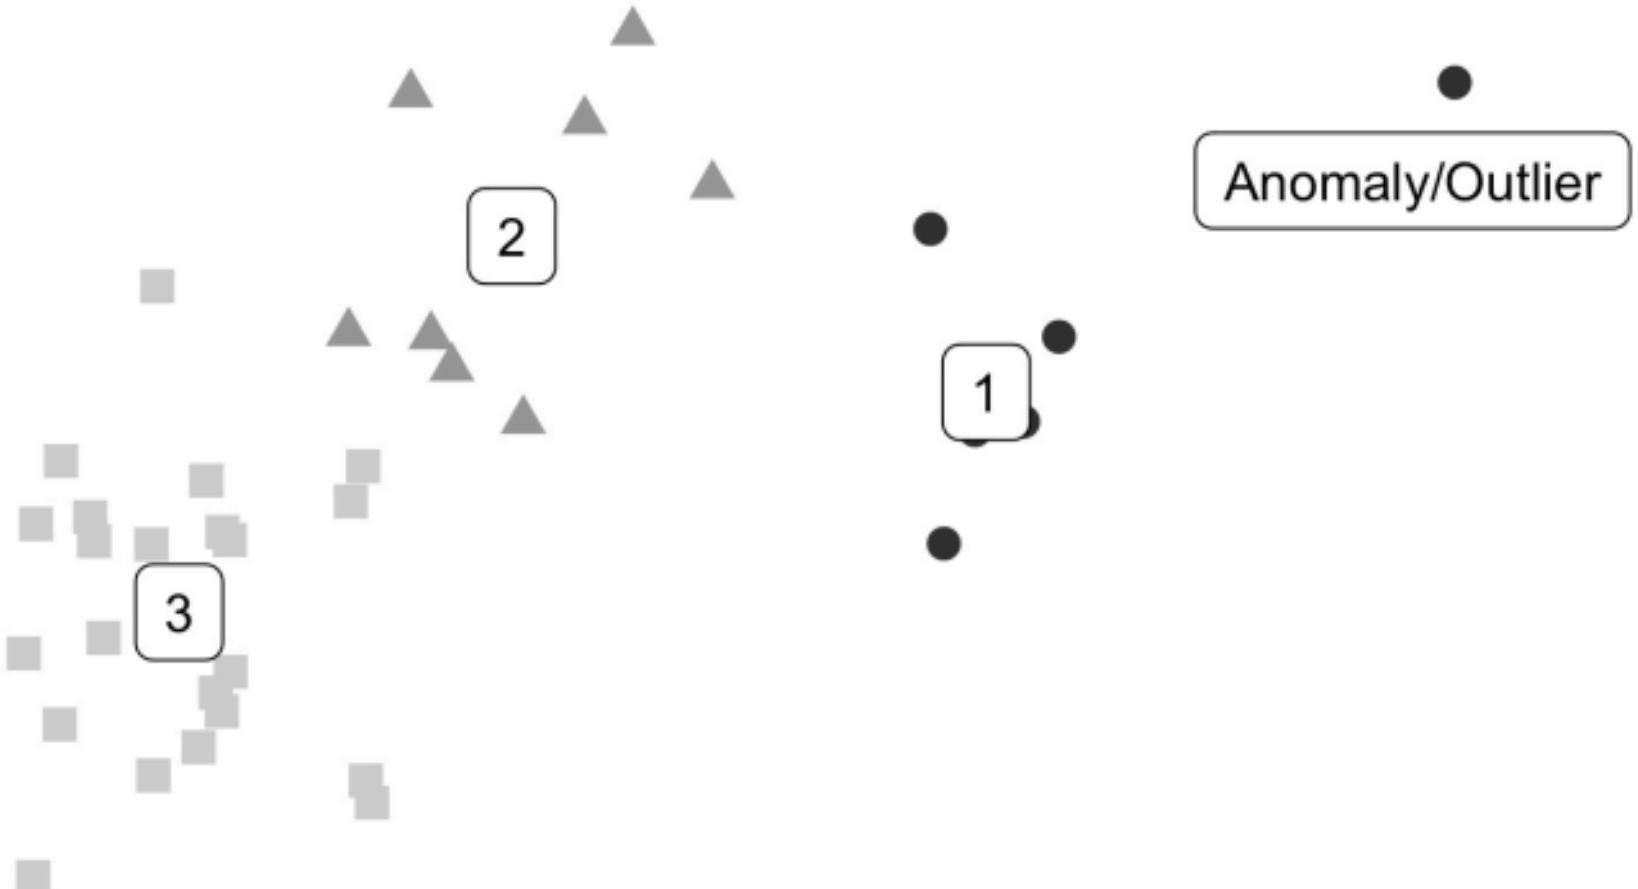
El aprendizaje no supervisado revela aspectos de la distribución de los datos:

Clustering: Encuentra modos de la distribución

Detección de anomalías: Encuentra puntos de datos extremos

Reglas de asociación: Encuentra modos en distribuciones binarias

Reducción de dimensionalidad: Encuentra descripciones de menor dimensión


Anomaly/Outlier
2
1
3

Aprender Sin Maestro

El aprendizaje no supervisado a veces se llama "aprender sin maestro":

- No hay verdad fundamental para corregir el modelo
- Es más como: "Aquí hay algunos datos. Por favor encuentra algo interesante."

Si el modelador encuentra 10 clusters, no puede probar que son los clusters **"correctos".**



Una Mentalidad Abierta

El aprendizaje no supervisado es, en muchos sentidos, una mentalidad abierta:

- Abierta a sorpresas
- Abierta a descubrir patrones ocultos
- La palabra "patrón" esconde un popurrí de significados

El rango de métodos es enorme, incluso para una mentalidad de ML.

Optimización Sin Verdad Fundamental

El aprendizaje no supervisado también involucra optimización.

Sin embargo, hay más libertad en el objetivo de optimización porque no hay verdad fundamental.

Lo mismo aplica para métricas de rendimiento y benchmarks.

Ambigüedad en la Evaluación

Ejemplo en análisis de clusters:

- Pureza del cluster
- Puntuación de silueta
- Varios índices
- Gráficos de codo

En aprendizaje supervisado, las métricas usualmente coinciden en cuándo alcanzar su mínimo: cuando el objetivo se predice perfectamente. Un lujo que no existe en aprendizaje no supervisado.

Clustering y Detección de Anomalías

Clustering y detección de anomalías son dos caras de una moneda:

Ambos preguntan dónde está la masa de los datos.

Clusters

Los clusters son regiones en el espacio de características con alta concentración de puntos de datos.

En términos de probabilidad, estas regiones son modos de la distribución de datos.

Los puntos dentro de un cluster son similares en sus valores de características.

Métodos de Clustering

Hay muchos enfoques diferentes:

- Clustering jerárquico
- K-means
- K-medoids
- DB-SCAN
- PRIM
- Modelos de mezcla gaussiana
- Mapas auto-organizados



Problema de Escalas

Si las características se miden en diferentes escalas (dinero y color), es arbitrario cómo deben ponderarse.

El aprendizaje supervisado no tiene este problema: la ponderación está "supervisada" por la relación entre características y verdad fundamental.

Detección de Anomalías

Ejemplo - Ciberseguridad:

- Proteger la empresa de amenazas cibernéticas
- Miles de empleados dejan huellas digitales en la red
- Algunas reglas detectan ataques simples
- ¿Qué pasa con comportamientos que no siguen patrones simples o ataques nuevos?

Métodos de Detección de Anomalías

Los valores atípicos (outliers) son puntos de datos en regiones con poco o ningún otro dato.

Métodos:

- Isolation forests
- Pruebas estadísticas
- Máquinas de vectores de soporte de una clase
- Modelos ocultos de Markov

Aprendizaje de Reglas de Asociación

Ejemplo - Canastas de compras:

- {levadura, harina, sal}
- {cerveza, papas fritas}
- {sándwich, papas fritas}
- {cebollas, tomates, queso, cerveza, papas fritas}

Objetivo: Identificar patrones. ¿La gente que compra harina frecuentemente compra levadura?

Ejemplo de Regla de Asociación

Una regla de asociación podría ser:

{cerveza} ⇒ {papas fritas}

Significa que las personas que compran cerveza frecuentemente compran papas fritas.

Esto es nuevamente un caso de describir la distribución de datos.



Reducción de Dimensionalidad

Tener muchas características puede ser una maldición.

La maldición es que la densidad de datos decrece exponencialmente con cada característica adicional.

Soluciones para la Reducción

Opción 1: Remover características basándose en medidas teórico-informativas como correlación estadística.

Opción 2: Mapear los datos a un espacio de menor dimensión:

- PCA (Análisis de Componentes Principales)
- Factorización de matrices no negativas
- Escalamiento multidimensional
- t-SNE

Ejemplo de Reducción

Si cada punto de datos representa una fruta, características como altura, ancho y peso podrían mapearse a una nueva dimensión que representa el volumen de la fruta.

¿Será esta reducción siempre útil?

Más Tareas

El aprendizaje no supervisado incluye más tareas:

- Análisis arquetípico
- Variables latentes
- Análisis factorial
- Y más

El aprendizaje no supervisado es el pájaro colorido entre las mentalidades de modelado.

Fortalezas

✓ Encontrar patrones ocultos que otras mentalidades (como aprendizaje supervisado) perderían.

✓ La mentalidad general es abierta en términos de tareas, evaluación y nuevos descubrimientos.

✓ El mundo es desordenado. A veces los modeladores tienen datos y una sensación de que podrían ser útiles, pero no tienen un objetivo específico. El aprendizaje no supervisado permite sumergirse en los datos sin demasiados supuestos.

✓ Como mentalidad más exploratoria, el aprendizaje no supervisado es un buen punto de partida para analizar datos con una mentalidad diferente posteriormente.

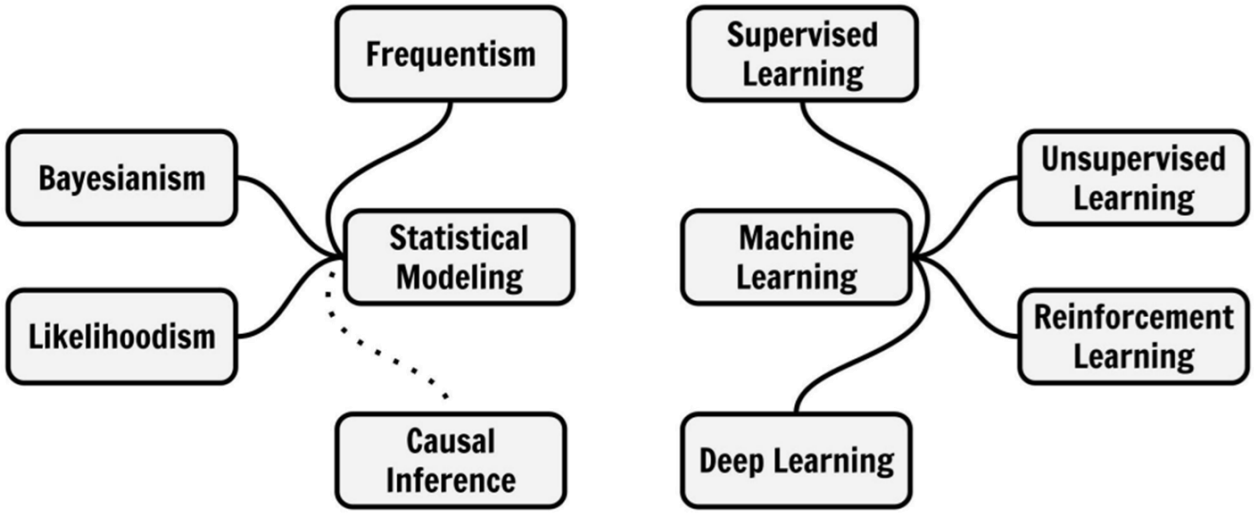
Limitaciones

✗ Una limitación mayor es la falta de verdad fundamental, lo que hace la evaluación ambigua. Como resultado, hay muchos métodos con frecuentemente diferentes resultados.

✗ La falta de verdad fundamental también significa que hay poca guía sobre cómo ponderar las diferentes características.

✗ El aprendizaje no supervisado es un buen enfoque para la maldición de la dimensionalidad, pero aún así puede sufrir mucho por ella. Cuantas más características, más difícil se vuelve la interpretación de clusters.

✗ No hay garantía de que se descubrirán patrones significativos.



DEEP LEARNING

(Para el final del curso)

Problema: Control de Calidad en Fábrica de Focos

Una fábrica produce focos LED. Históricamente, la **tasa de defectos es 5%** (0.05). El gerente sospecha que una nueva máquina está produciendo **más defectos**.

Datos recolectados: De una muestra de **n = 200 focos**, encontramos **15 defectuosos**.

Pregunta: ¿La tasa de defectos ha aumentado?

Problema 1: Supuestos Frecuentistas

1. Los focos son independientes entre sí
2. Cada foco tiene la misma probabilidad de ser defectuoso
3. La muestra es aleatoria y representativa

Parámetro	Valor
Muestra (n)	200
Defectuosos (k)	15
Proporción muestral ($\hat{p}$)	15/200 = 0.075 (7.5%)
Proporción histórica (p_o)	0.05 (5%)

$$H_0 : p = 0.05 \quad \text{(No hay cambio)}$$

$$H_1 : p > 0.05 \quad \text{(Aumentó la tasa)}$$

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

$$Z = \frac{0.075 - 0.05}{\sqrt{\frac{0.05 \times 0.95}{200}}} = \frac{0.025}{\sqrt{0.0002375}} = \frac{0.025}{0.0154} = 1.62$$

Solución final

Decisión

- **Valor crítico** ($\alpha = 0.05$, una cola): $Z_{crítico} = 1.645$
- **P-value:** $P(Z > 1.62) = 0.053$

Conclusión frecuentista: Como $Z = 1.62 < 1.645$ (o p-value = $0.053 > 0.05$), **NO rechazamos H_0**. No hay evidencia suficiente para afirmar que la tasa aumentó.

Problema 2: Supuestos Bayesiano

1. Los mismos supuestos de independencia
2. Prior sobre p: Necesitamos especificar nuestra creencia inicial
3. Modelo generativo: Los datos siguen una distribución Binomial

$$k \sim \text{Binomial}(n, p)$$

$$p \sim \text{Beta}(\alpha, \beta) \quad \text{(Prior)}$$

Elección del Prior

Opción A: Prior informativo (basado en historial de la fábrica)

Sabemos que históricamente p ≈ 0.05 con poca variación. Usamos:

$$p \sim Beta(5, 95)$$

Esto tiene media = 5/(5+95) = 0.05 y está concentrado alrededor de 5%.

Opción B: Prior débilmente informativo

$$p \sim Beta(1, 1) = Uniforme(0, 1)$$

Actualización Bayesiana

La distribución **Beta es conjugada** con Binomial, entonces:

$$\text{Posterior: } p \mid k \sim Beta(\alpha + k, \beta + n - k)$$

Con Prior informativo Beta(5, 95):

$$p \mid datos \sim Beta(5 + 15, 95 + 185) = Beta(20, 280)$$

Resultados

Estadístico	Valor
Media posterior	20/300 = **0.067** (6.7%)
Moda posterior	(20-1)/(300-2) = **0.064** (6.4%)
Intervalo creíble 95%	**[0.042, 0.095]**
P(p > 0.05 | datos)	**0.89** (89%)

Dado los datos y nuestro conocimiento previo, hay 89% de probabilidad de que la tasa de defectos sea mayor a 5%. La tasa más probable está alrededor de 6.5%.

Preguntas Vibe Quest

- El Teorema Central del Límite promete que la normalidad emerge de sumar cualquier distribución. ¿Qué tan rápido ocurre esto? Experimenta con distribuciones extrañas y encuentra cuántas muestras necesitas antes de que aparezca la campana gaussiana.
- Frecuentistas y bayesianos cuantifican la incertidumbre de formas filosóficamente opuestas. ¿Puedes demostrar computacionalmente la diferencia entre un intervalo de confianza del 95% y un intervalo de credibilidad del 95%?
- En aprendizaje supervisado, un modelo demasiado simple subajusta y uno demasiado complejo sobreajusta. Explora cómo diferentes niveles de complejidad del modelo (desde una línea recta hasta un polinomio de grado alto) afectan la capacidad de generalización, y encuentra donde el error total se minimiza. Haz diversos ejemplos con modelos “grandes”.