Pontificia Universidad Católica del Perú
Facultad de Ciencias e Ingeniería
Departamento Académico de Ingeniería



1INF02 APRENDIZAJE DE MÁQUINA

Reducción de Dimensionalidad

Prof. Rodrigo Uribe

Organización de las Clases

(10 min) Preguntas y consultas.

(30 min) Respuesta *Vibe Quest.*

(25 min) Motivación e intuición general detrás de la reducción de dimensionalidad.



(10 min) Break

(55 min) Principios matemáticos detrás de PCA y ejemplos.

(20 min) Ejercicio de PCA.

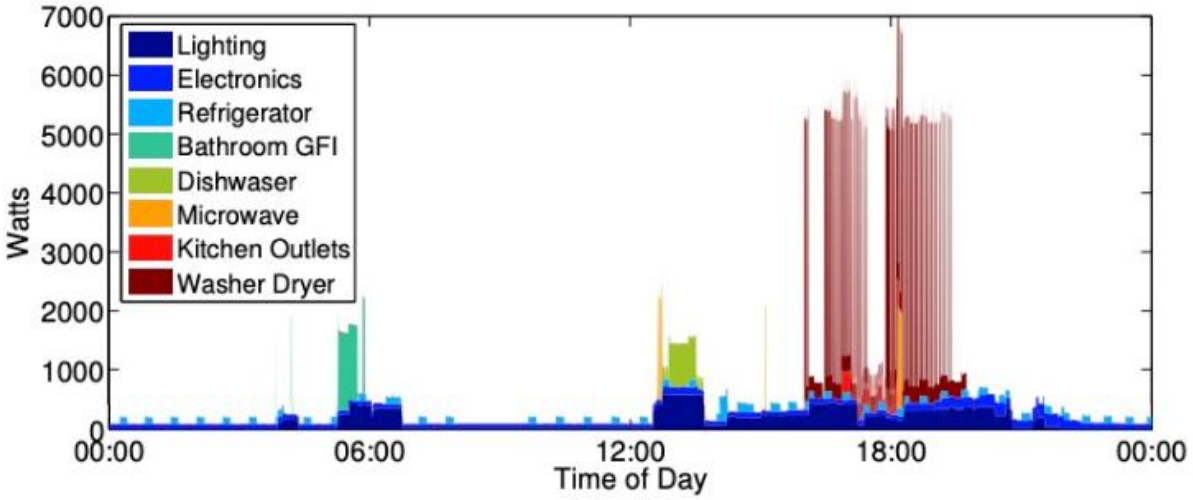
(10 min) Preguntas *Vibe Quest.*

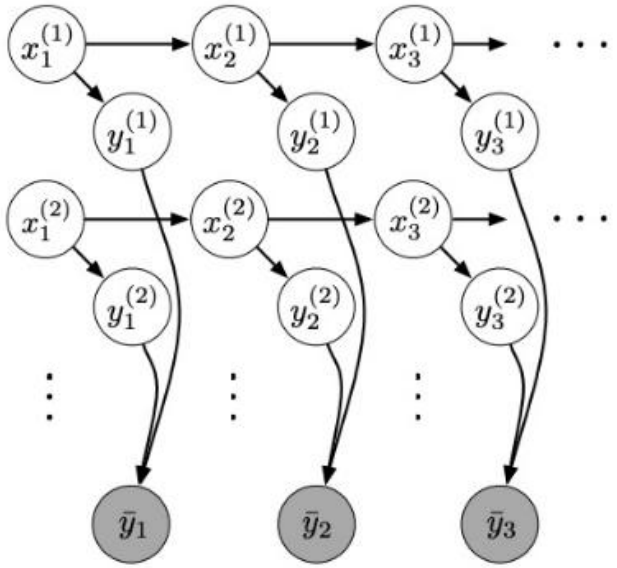
Respuestas Vibe Quest

- Compara desagrupamiento por celdas y desagrupamiento poligonal utilizando el mismo conjunto de datos, visualizando cómo cambian los pesos individuales y las estadísticas globales al modificar la geometría del dominio y la densidad de muestreo.
- Explora soft K-means variando el parámetro β y visualiza cómo cambian las responsabilidades, los centroides y la suavidad de las fronteras entre clusters, mostrando la transición continua entre asignaciones suaves y asignaciones duras.
- Ajusta un modelo de mezcla gaussiana (GMM) con diferentes valores de K y distintos tipos de covarianza, y visualiza simultáneamente las densidades aprendidas, las responsabilidades posteriores y la log-verosimilitud para analizar cómo el modelo representa la estructura probabilística de los datos.
- Compara K-means, soft K-means y GMM sobre el mismo conjunto de datos, visualizando simultáneamente asignaciones, densidades y fronteras de decisión para evidenciar las diferencias entre una visión geométrica y una visión probabilística del clustering.

Motivación

- Desagregación de energía





Kolter and Johnson, "REDD: A public data set for energy disaggregation research"

Ejemplo: desglosar el consumo total de energía de un hogar en componentes individuales (iluminación, electrónicos, refrigerador, etc.)

Motivación

- Modelado del cambio en temas científicos a lo largo del tiempo

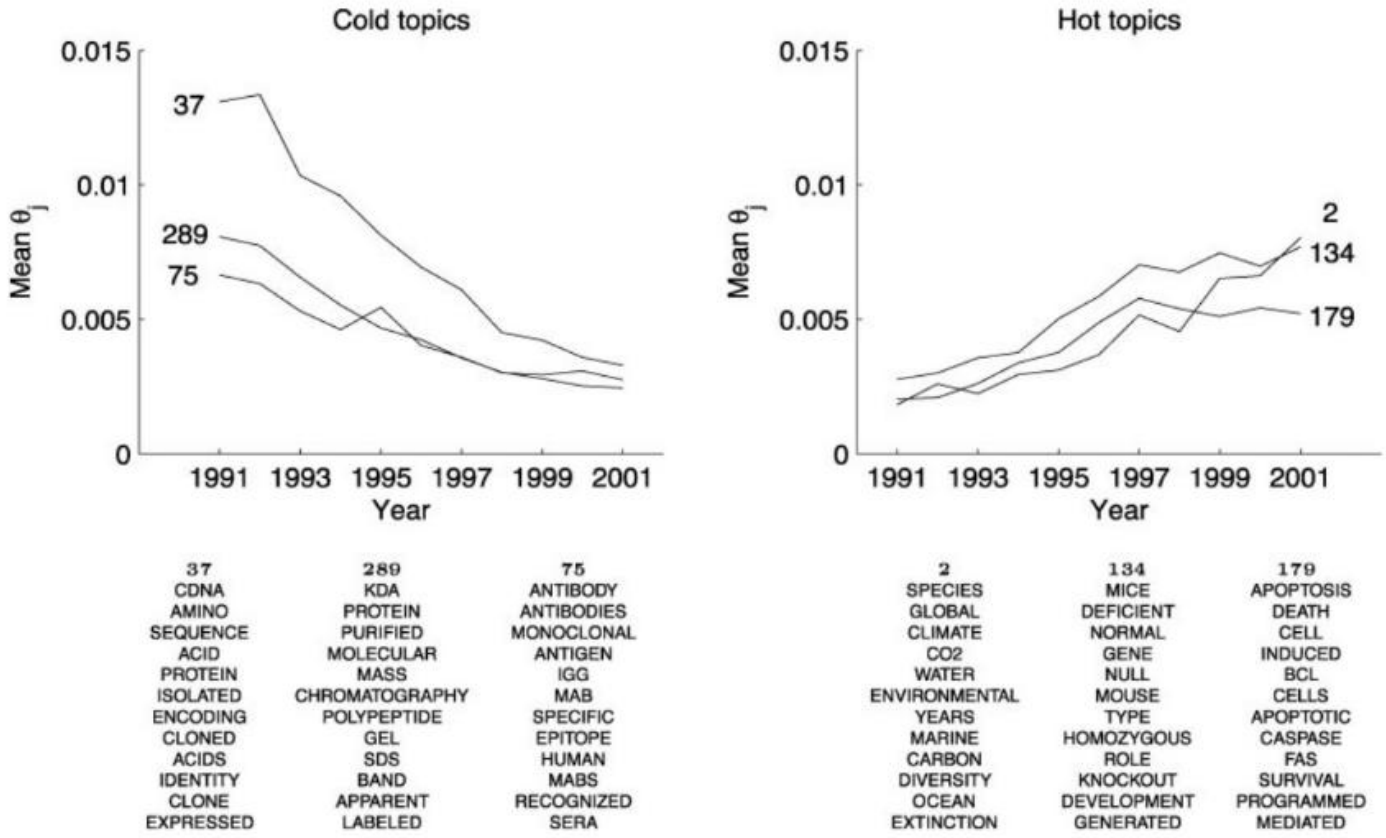
217	274	126	63	200	209
INSECT	SPECIES	GENE	STRUCTURE	FOLDING	NUCLEAR
MYB	PHYLOGENETIC	VECTOR	ANGSTROM	NATIVE	NUCLEUS
PHEROMONE	EVOLUTION	VECTORS	CRYSTAL	PROTEIN	LOCALIZATION
LENS	EVOLUTIONARY	EXPRESSION	RESIDUES	STATE	CYTOPLASM
LARVAE	SEQUENCES	TRANSFER	STRUCTURES	ENERGY	EXPORT
42	**2**	**280**	**15**	**64**	**102**
NEURAL	SPECIES	SPECIES	CHROMOSOME	CELLS	TUMOR
DEVELOPMENT	GLOBAL	SELECTION	REGION	CELL	CANCER
DORSAL	CLIMATE	EVOLUTION	CHROMOSOMES	ANTIGEN	TUMORS
EMBRYOS	CO2	GENETIC	KB	LYMPHOCYTES	HUMAN
VENTRAL	WATER	POPULATIONS	MAP	CD4	CELLS

A generalized[3] fundamental[146] theorem[267] of natural[280] selection[280] is derived[233] for populations[280] incorporating[149] both genetic[280] and cultural[280] transmission[25]. The phenotype[3] is determined[17] by an arbitrary[3] number[287] of multiallelic[3] loci[3] with two[271]-factor[60] epistasis[280] and an arbitrary[149] linkage[3] map[3], as well as by cultural[280] transmission[25] from the parents[280]. Generations[280] are discrete[69] but partially[275] overlapping[146], and mating[280] may be nonrandom[280] at either the genotypic[280] or the phenotypic[280] level[199] (or both). I show[25] that cultural[280] transmission[25] has several[173] important[173] implications[17] for the evolution[280] of population[280] fitness[280], most notably[230] that there is a time[72] lag[72] in the response[213] to selection[280] such that the future[257] evolution[280] depends[105] on the past selection[280] history[280] of the population[280].

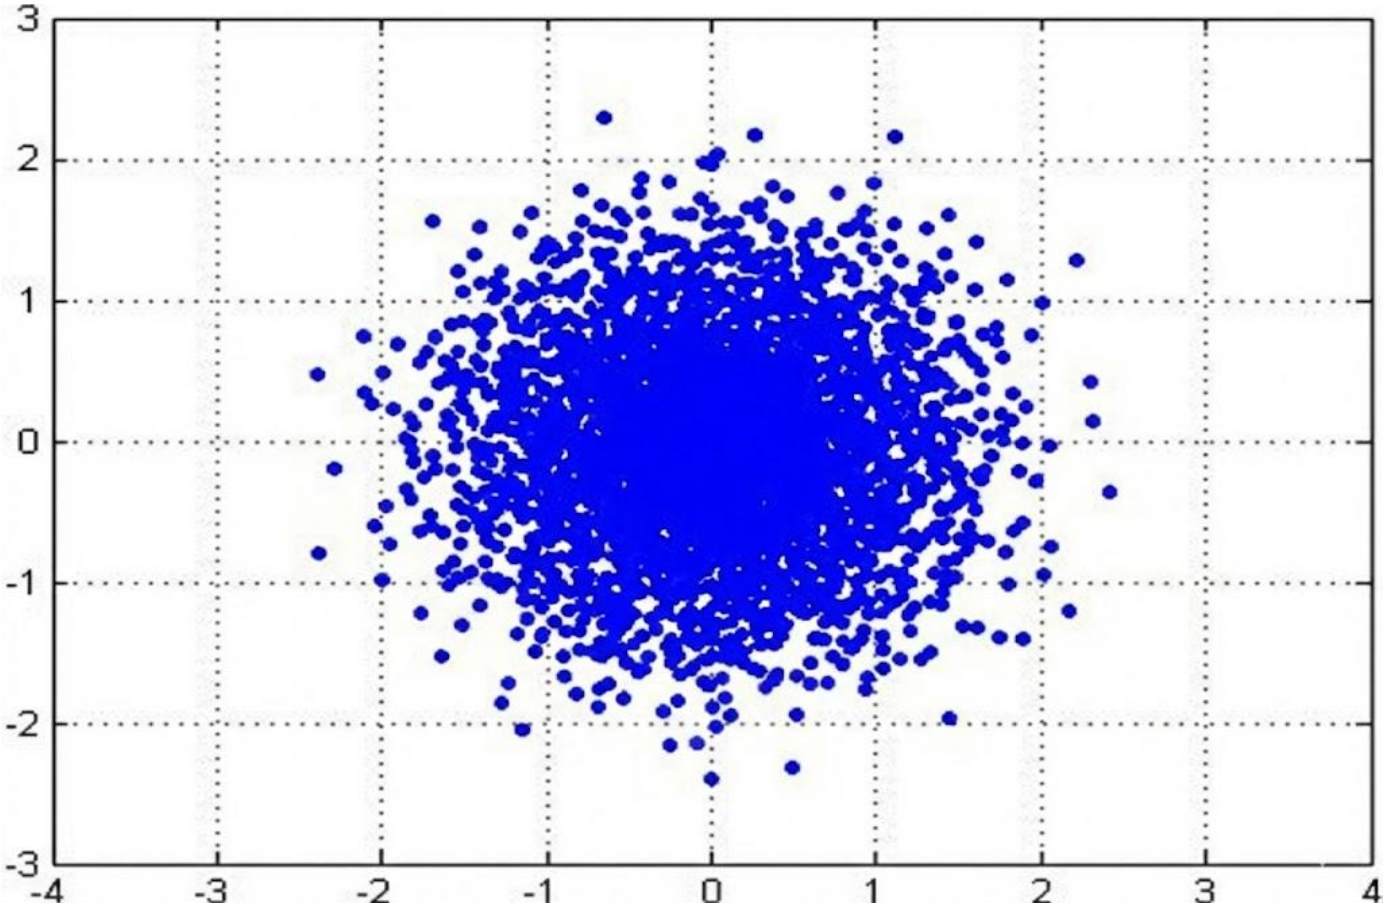
Los modelos de temas pueden descubrir automáticamente grupos de palabras que tienden a co-ocurrir

Motivación

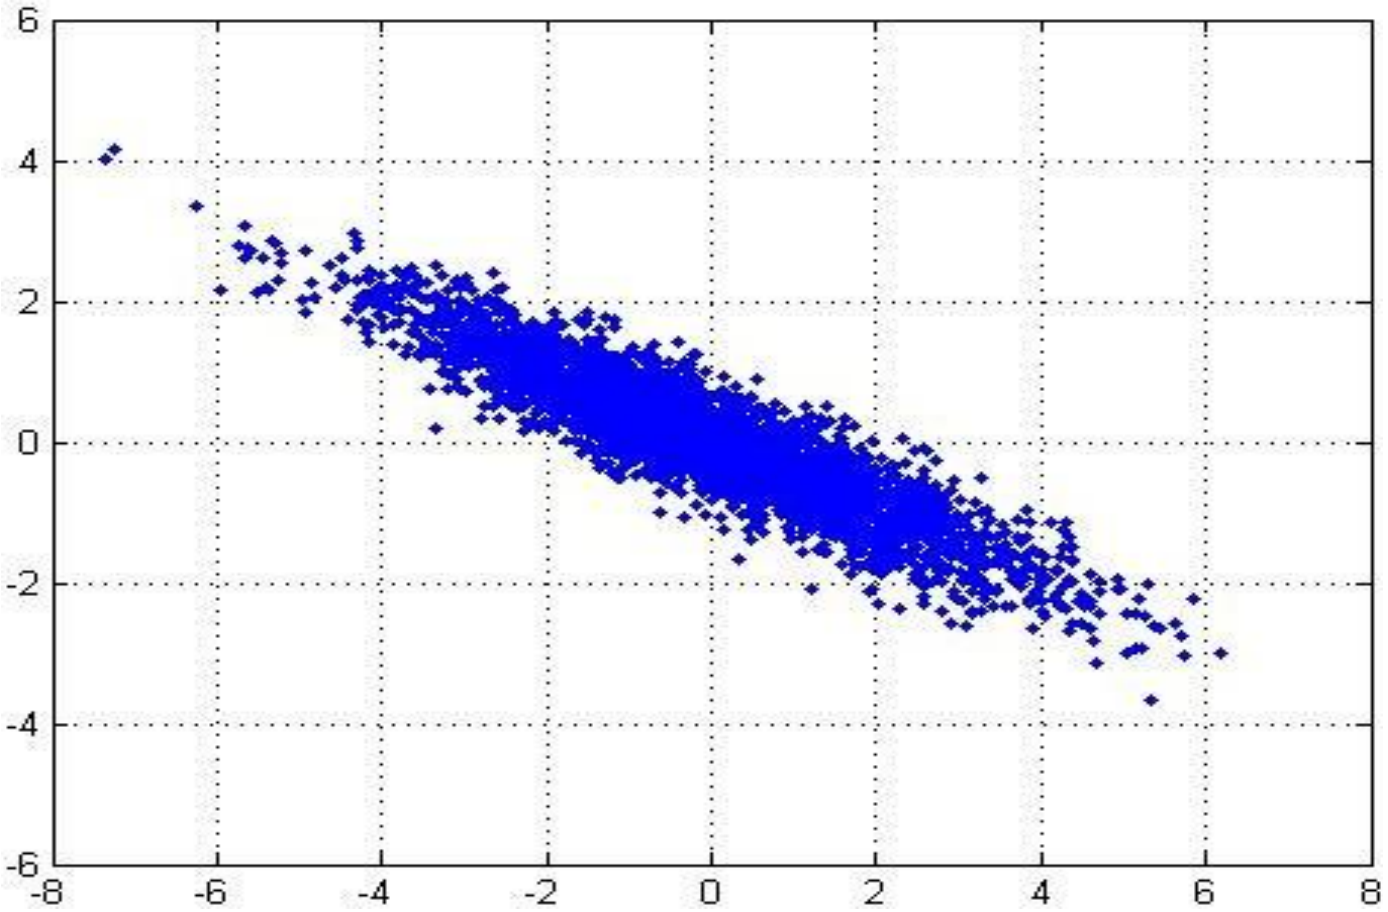
- Temas Cambiantes



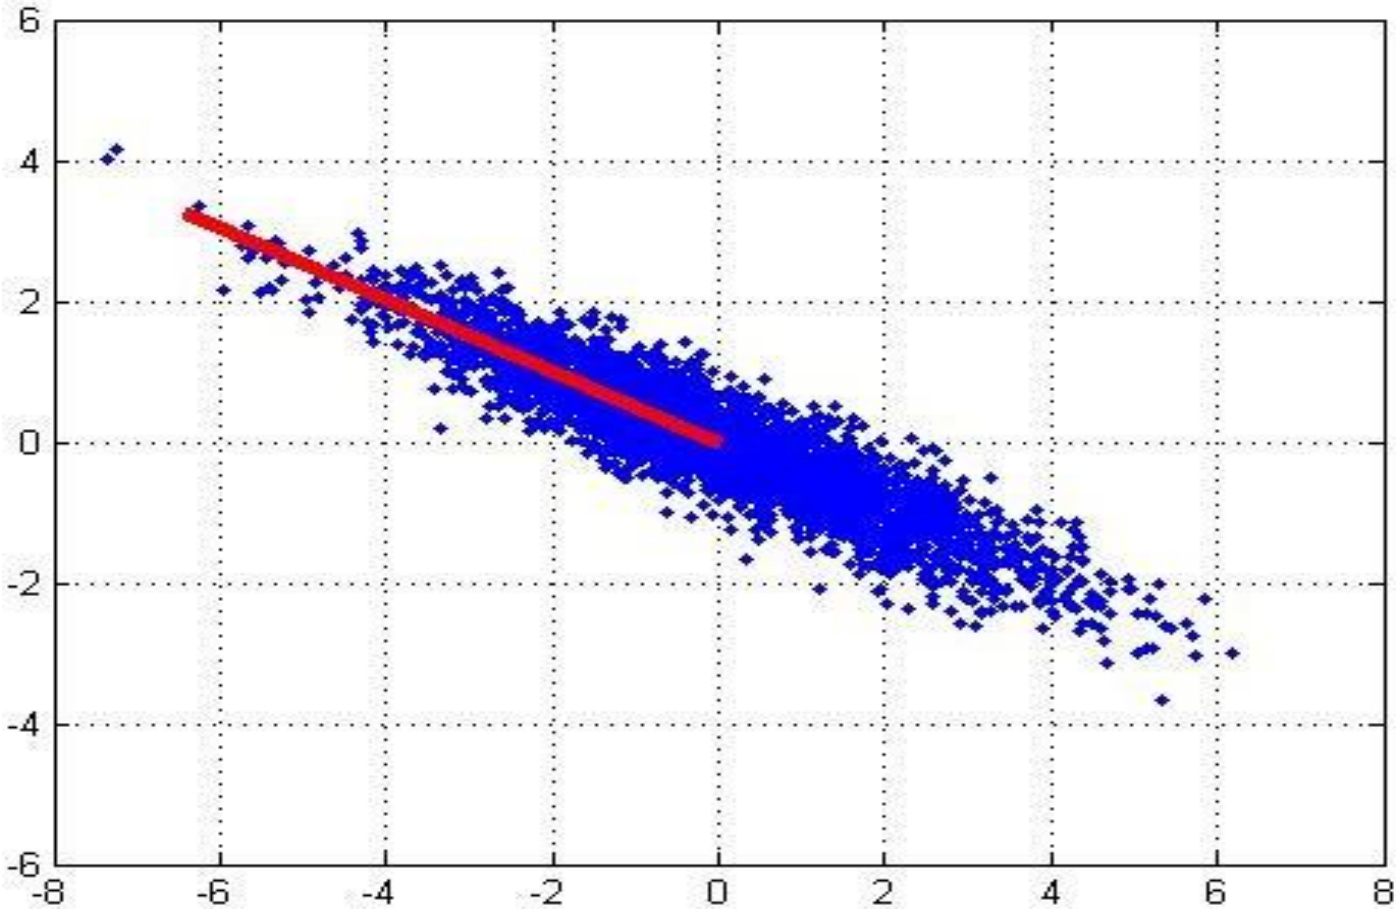
¿Cómo se podrá reducir las dimensiones?



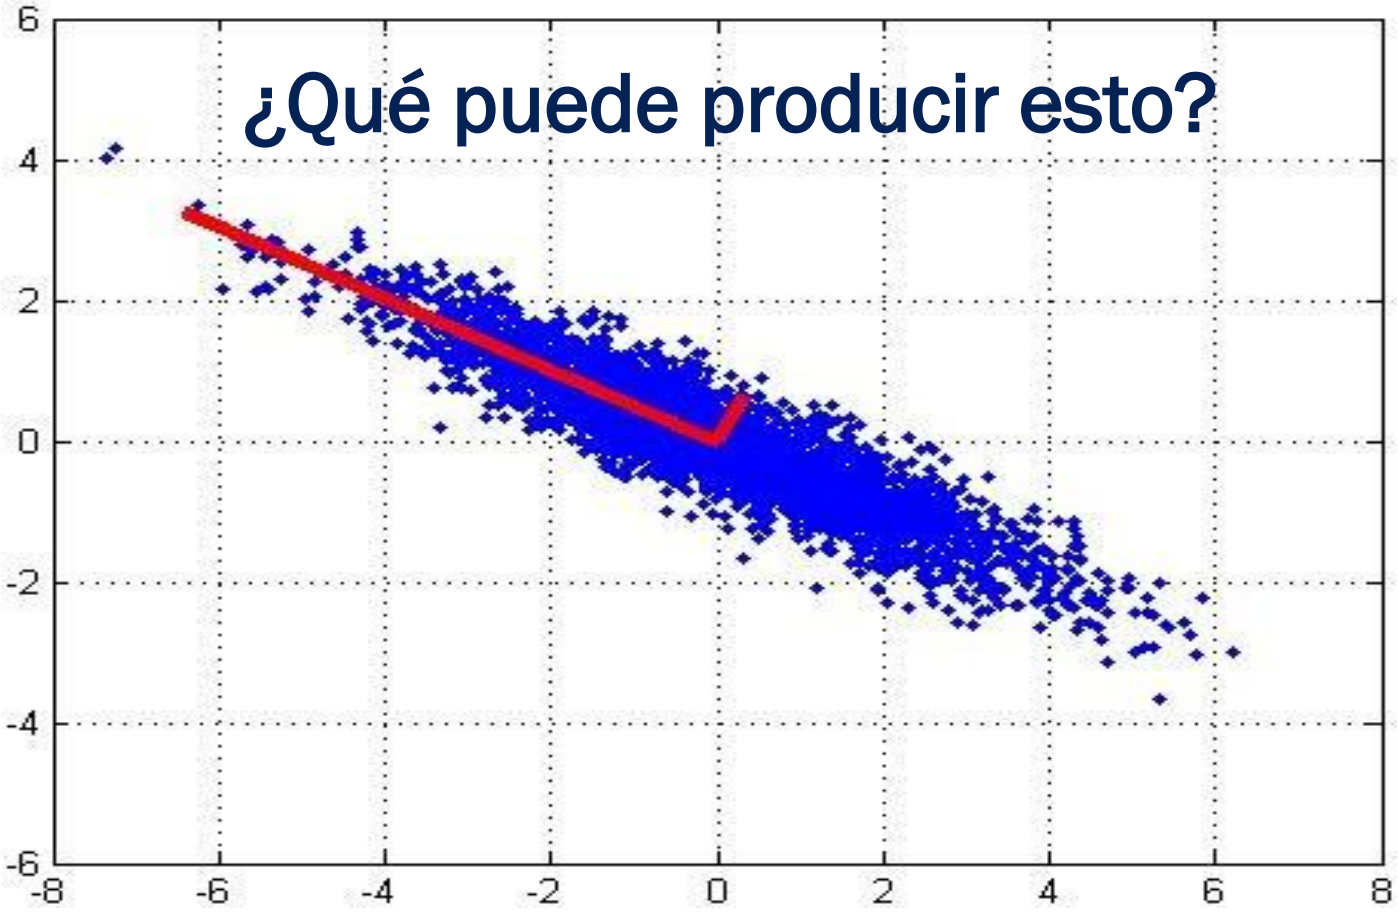
¿Cómo se podrá reducir las dimensiones?



Eje 1



Eje 2



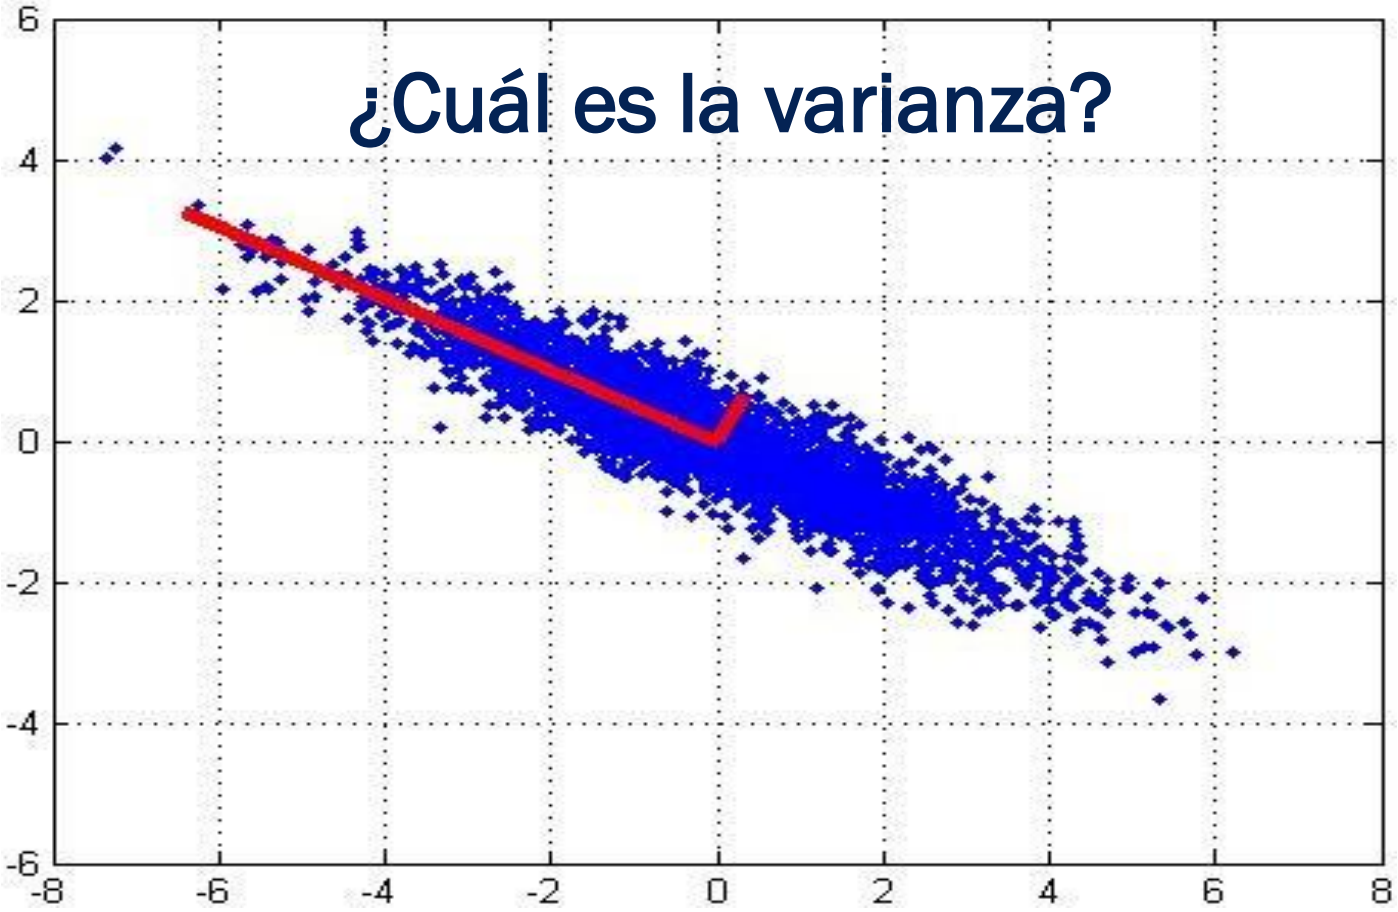
Técnicas para manejar la dimensionalidad

PCA, Kernel PCA, ICA: potentes técnicas de aprendizaje no supervisado para extraer estructuras ocultas (potencialmente baja dimensionalidad) de conjuntos de datos de alta dimensionalidad.

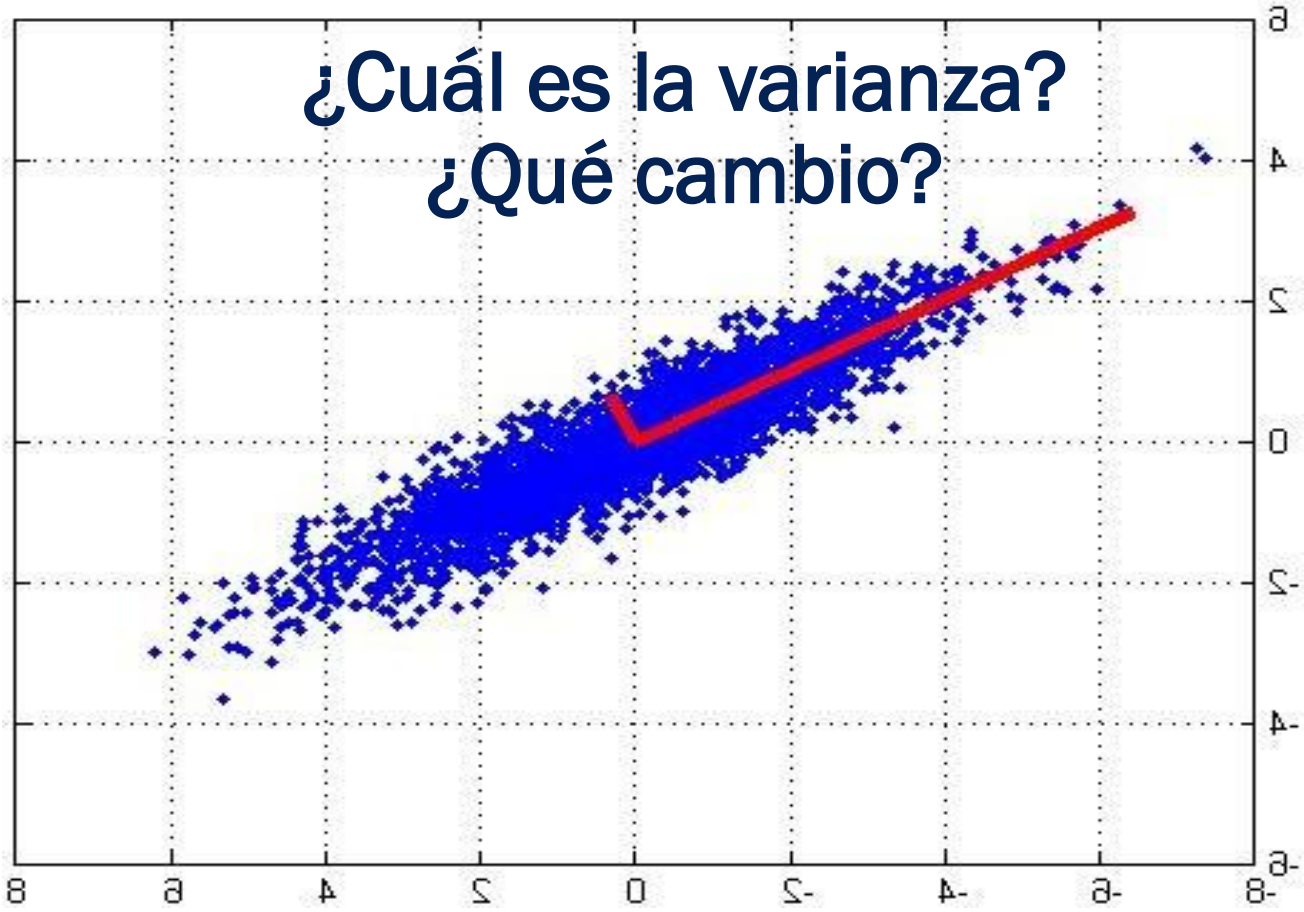
Útil para :

- Visualización
- Más eficiente usar de recursos (tiempo, memoria...)
- Estadístico: menos dimensiones mejor generalización
- Eliminación de ruido (mejorando datos calidad)
- Más tratamiento por máquina aprendiendo algoritmos

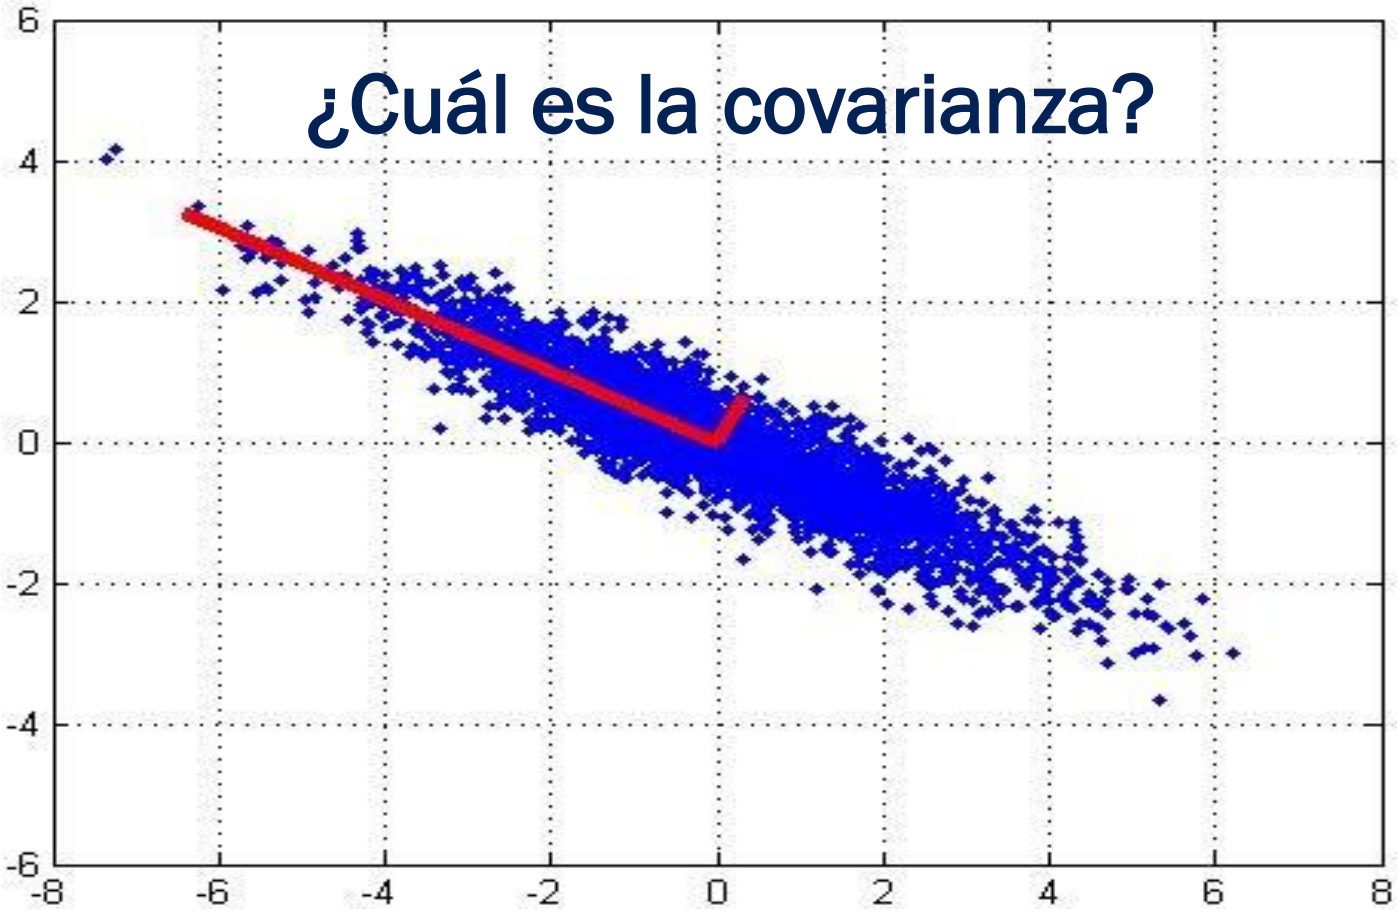
Recordatorio: Varianza



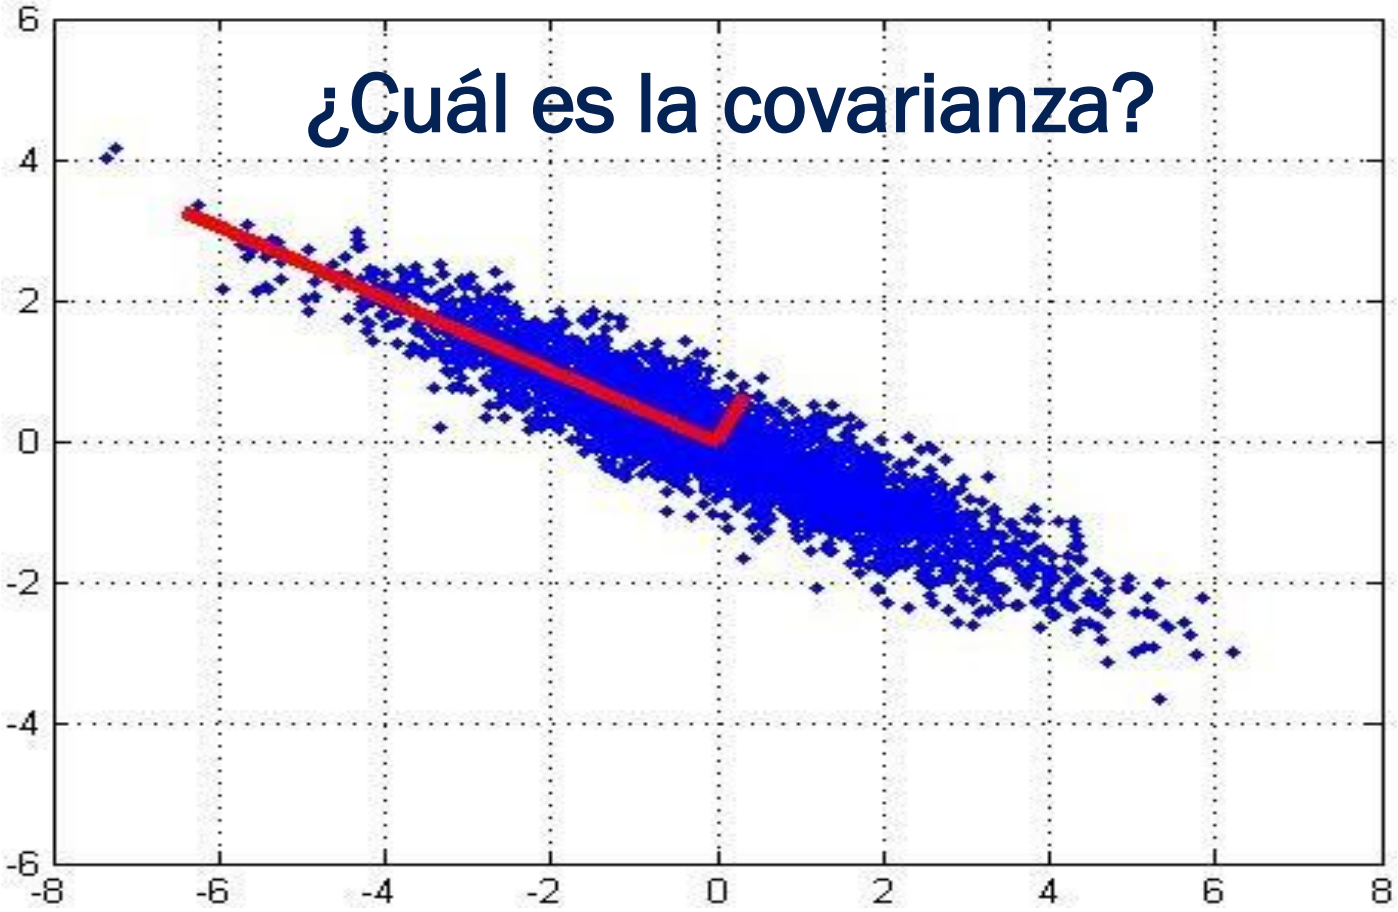
Recordatorio: Varianza



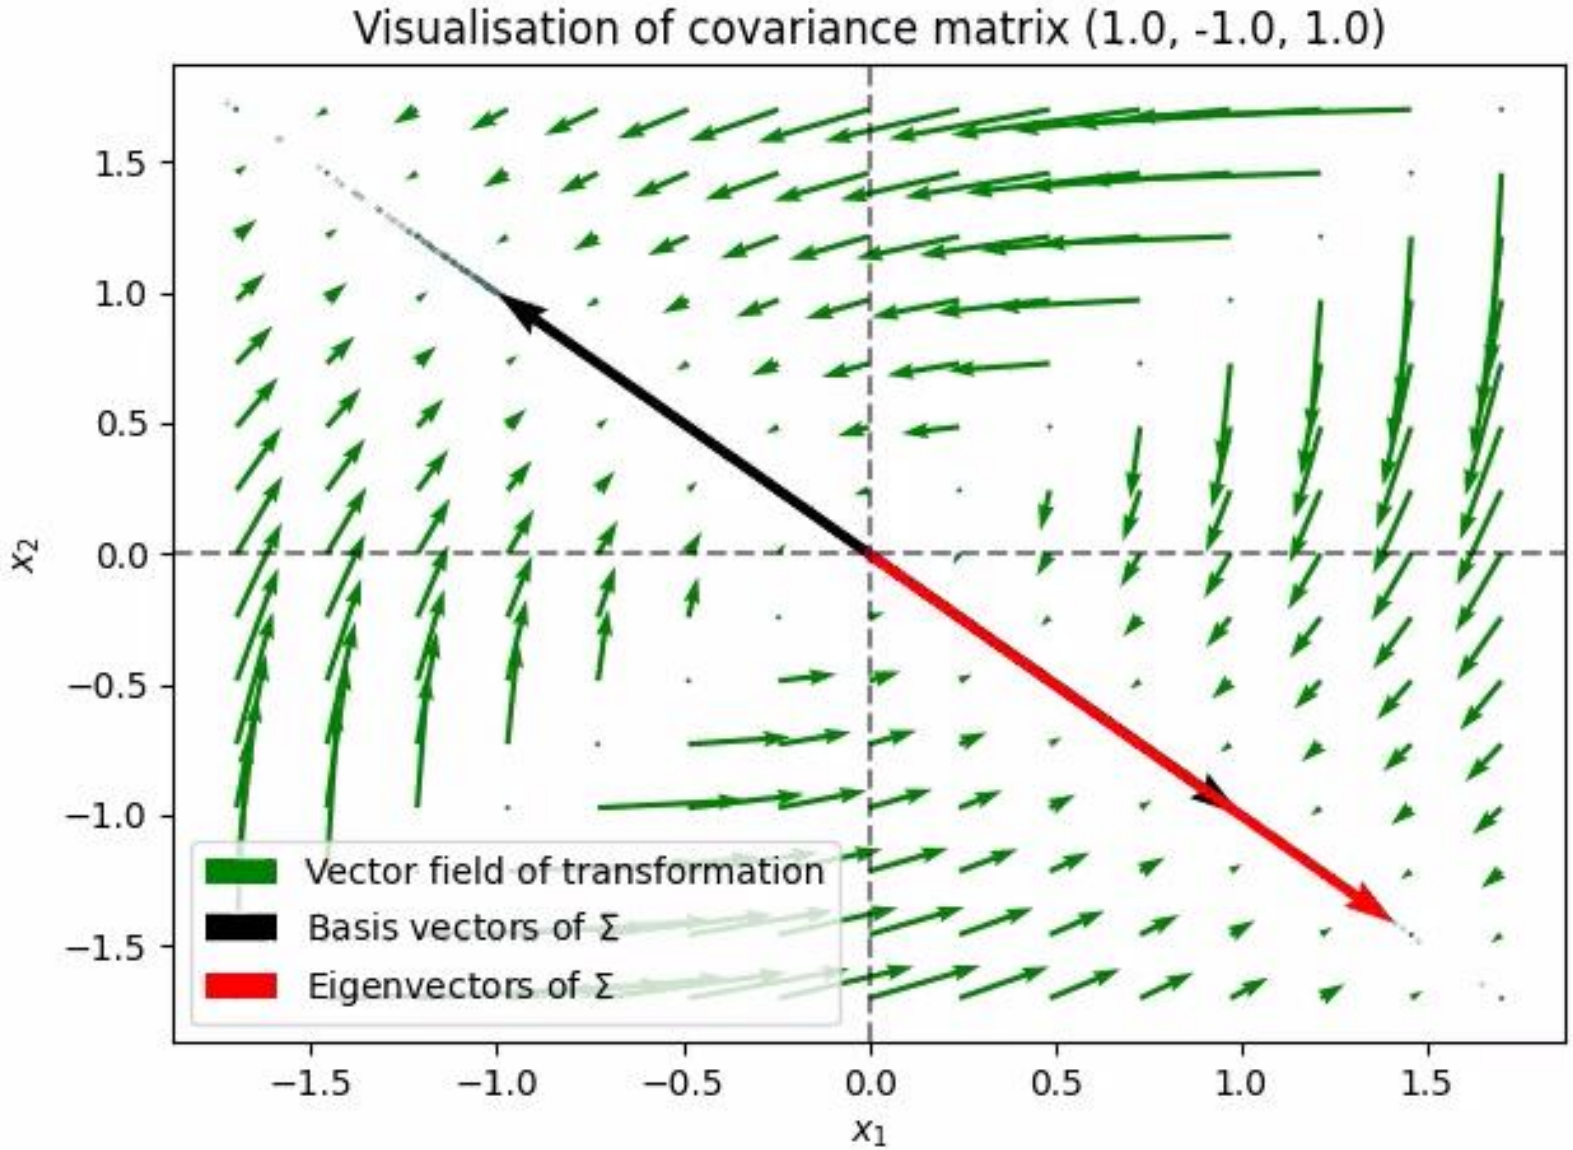
Recordatorio: Covarianza



Recordatorio: Covarianza

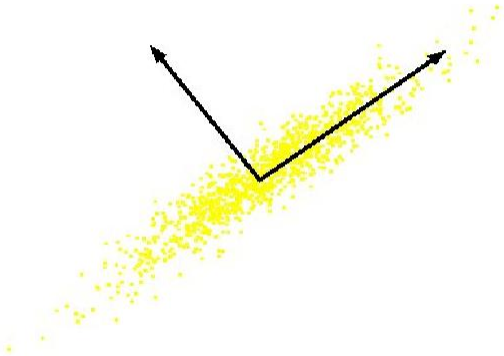


$$r^2 = \left(\frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y} \right)^2$$


Visualisation of covariance matrix (1.0, -1.0, 1.0)
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
x_2
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
x_1
Vector field of transformation
Basis vectors of Σ
Eigenvectors of Σ

Análisis de componentes principales (PCA)

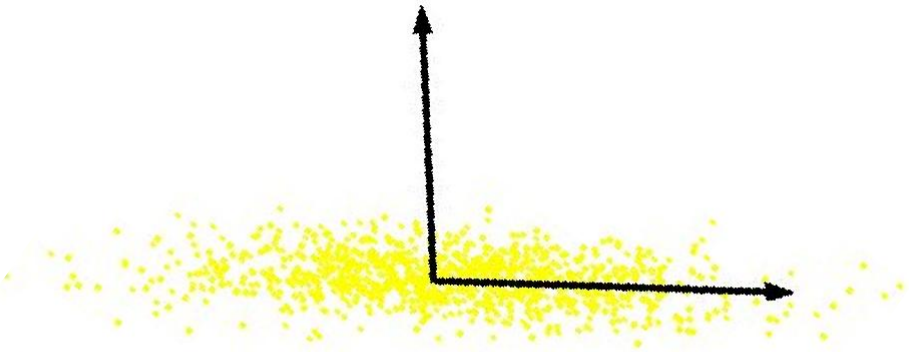
Qué es PCA : Técnica no supervisada para extraer la estructura de varianza del conjunto de datos de alta dimensionalidad



- PCA es un proyección ortogonal o transformación de los datos en un subespacio (posiblemente de menor dimensión) de forma que se maximice la varianza de los datos proyectados

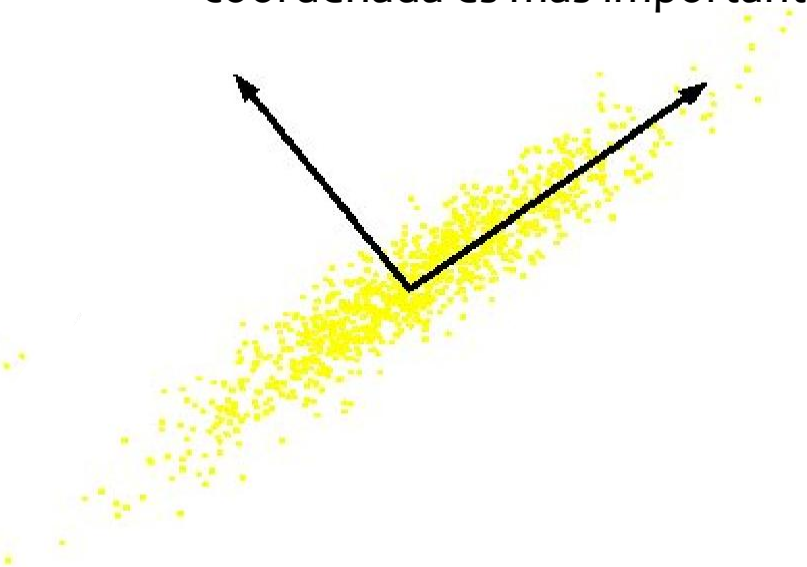
Análisis de componentes principales (PCA)

Intrínsecamente de menor dimensión que la dimensión del espacio.



Solo una característica relevante

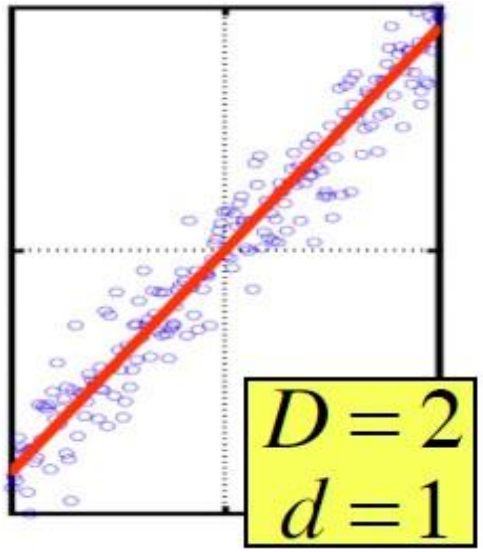
Si rotamos los datos, nuevamente solo una coordenada es más importante.

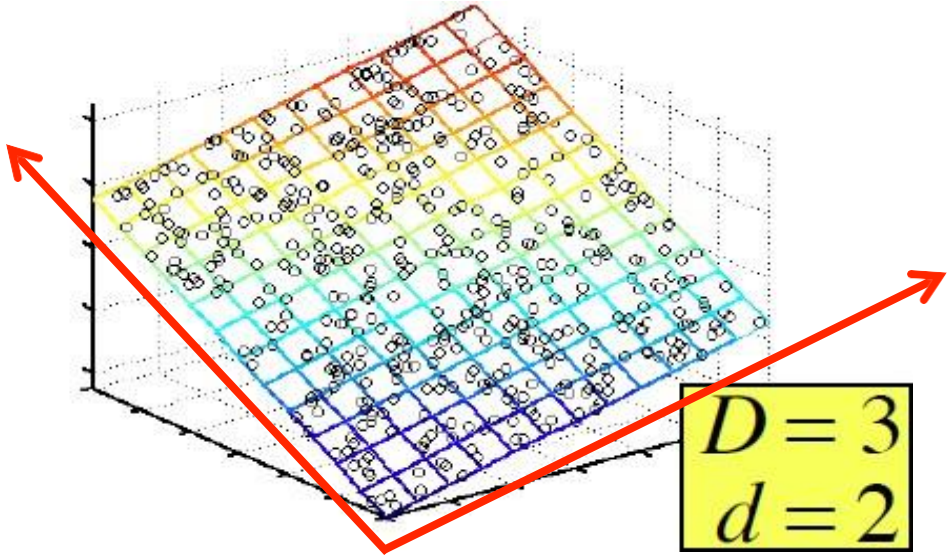


Ambas características son relevantes

¿Podemos transformar las características de modo que solo necesitemos preservar una característica latente?

Análisis de componentes principales (PCA)





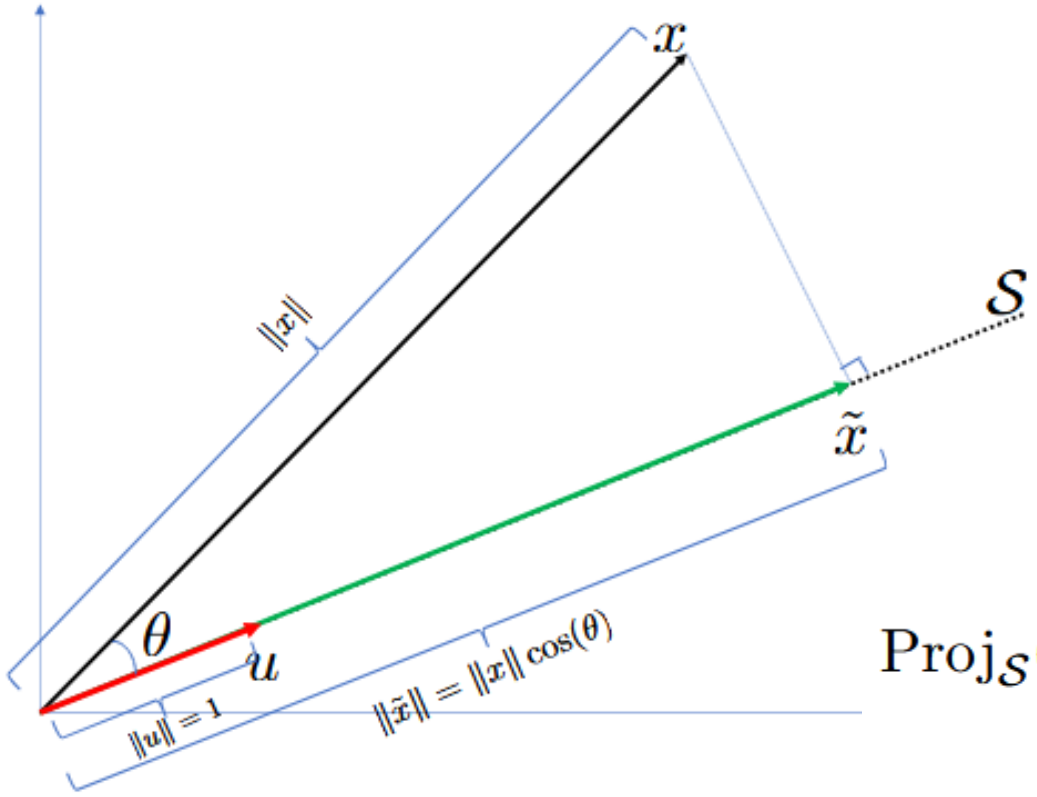
En el caso en que los datos se encuentren sobre o cerca de una subespacio lineal de baja dimensión d, los ejes de ese subespacio constituyen una representación efectiva de los datos.

Identificar esos ejes se conoce como **Análisis de Componentes Principales (PCA),** y puede obtenerse utilizando herramientas clásicas de cálculo matricial, como la descomposición en valores propios (Eigen) o la descomposición en valores singulares (SVD, por sus siglas en inglés).

¿Cómo implementarían el PCA?

Proyección Euclidiana

Proyección sobre un subespacio 1-D



El subespacio S es la línea a lo largo del vector unitario u

- {u} es una base para S: cualquier punto en S puede escribirse como zu para algún z

$$\text{Proj}_{\mathcal{S}}(\mathbf{x}) = \underbrace{\mathbf{x}^\top \mathbf{u}}_{\text{length of proj}} \cdot \underbrace{\mathbf{u}}_{\text{direction of proj}} = \|\tilde{\mathbf{x}}\|\mathbf{u}$$

Subespacios Generales

¿Cómo proyectar sobre un subespacio K-dimensional?

- Idea: elegir una base ortonormal $\{u_1, u_2, ..., u_k\}$ para S (todos vectores unitarios y ortogonales entre sí)
- Proyectar sobre cada vector unitario individualmente y sumar las proyecciones

Matemáticamente, la proyección es:

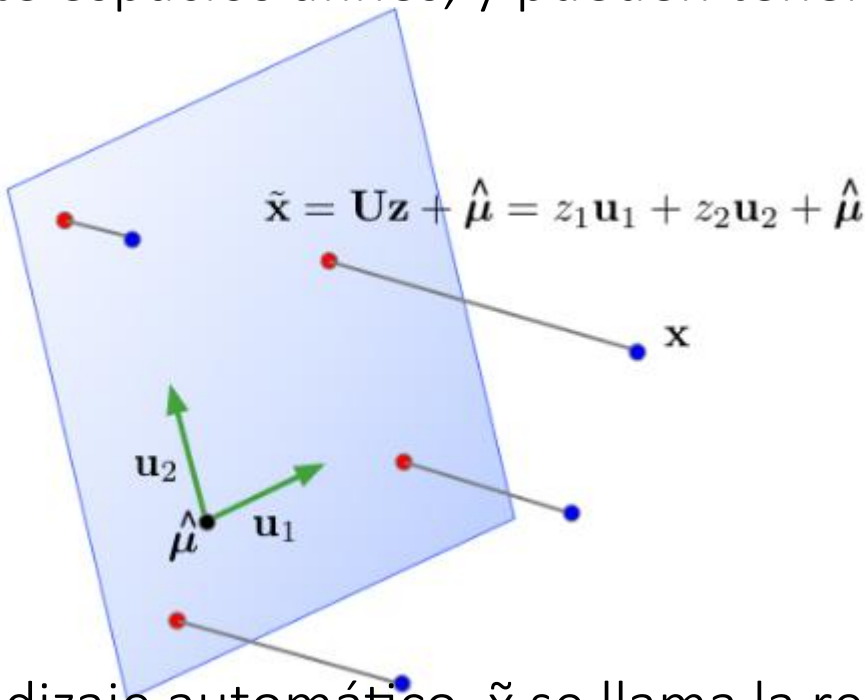
$$\text{Proj}_{\mathcal{S}}(\mathbf{x}) = \sum_{i=1}^{K} z_i \mathbf{u}_i \quad \text{where} \quad z_i = \mathbf{x}^\top \mathbf{u}_i.$$

En forma vectorial:

$$\text{Proj}_{\mathcal{S}}(\mathbf{x}) = \mathbf{U}\mathbf{z} \quad \text{where} \quad \mathbf{z} = \mathbf{U}^\top \mathbf{x}$$

Proyectando al subespacio

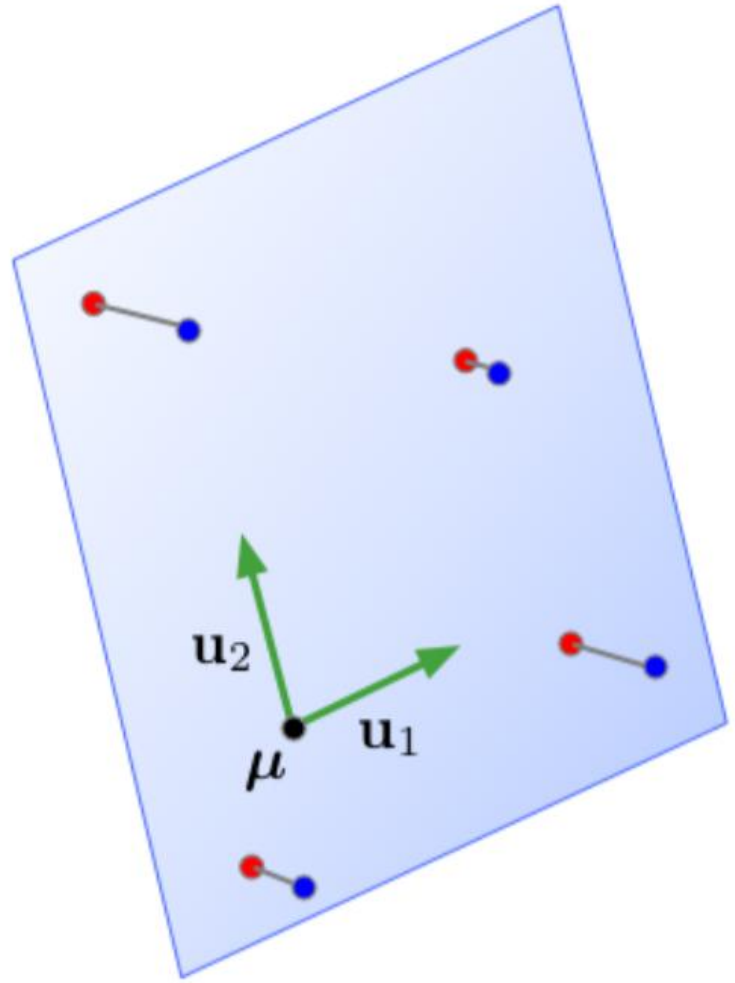
- Hasta ahora, asumimos que el subespacio pasa por 0.
- En terminología matemática, los "subespacios" que queremos proyectar son realmente espacios afines, y pueden tener un origen arbitrario $\hat{\mu}$.



$$\mathbf{z} = \mathbf{U}^\top(\mathbf{x} - \hat{\boldsymbol{\mu}})$$

- En aprendizaje automático, $\tilde{x}$ se llama la reconstrucción de x.
- z es su representación, o código.

- Si tenemos un subespacio K-dimensional en un espacio de entrada D-dimensional, entonces $x \in \mathbb{R}^D$ y $z \in \mathbb{R}^K$.
- Si los puntos x están cerca de sus reconstrucciones, podemos aproximar distancias usando los vectores de código z.
- Si $K \ll D$, es mucho más barato trabajar con z que con x.
- Un mapeo a un espacio más fácil de manipular o visualizar se llama representación
- Aprender tal mapeo es aprendizaje de representaciones
- Mapear datos a un espacio de baja dimensión se llama reducción de dimensionalidad



Aprendiendo un subespacio

¿Cómo elegir un buen subespacio S?

- El origen $\hat{\mu}$ es la media empírica de los datos
- Necesitamos elegir una matriz D × K con columnas ortonormales U

Dos criterios:

- Minimizar el error de reconstrucción

$$\min_{\mathbf{U}} \frac{1}{N} \sum_{i=1}^{N} \|\mathbf{x}^{(i)} - \tilde{\mathbf{x}}^{(i)}\|^2$$

- Maximizar la varianza de los vectores de

$$\max_{\mathbf{U}} \frac{1}{N} \sum_{i} \|\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}}\|^2$$

- Nota: ¡Los datos y su reconstrucción tienen las mismas medias! **(ejercicio)**

ejercicio

$$\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} x^{(i)}$$

$$\tilde{x}^{(i)} = \hat{\mu} + UU^{\top}(x^{(i)} - \hat{\mu})$$

$$\frac{1}{N}\sum_{i=1}^{N} \tilde{x}^{(i)} = \frac{1}{N}\sum_{i=1}^{N}\left[\hat{\mu} + UU^{\top}(x^{(i)} - \hat{\mu})\right]$$

$$= \frac{1}{N}\sum_{i=1}^{N}\hat{\mu} + \frac{1}{N}\sum_{i=1}^{N}\left[UU^{\top}(x^{(i)} - \hat{\mu})\right]$$

$$\frac{1}{N}\sum_{i=1}^{N}\hat{\mu} = \hat{\mu}$$

$$\frac{1}{N}\sum_{i=1}^{N} UU^{\top}(x^{(i)} - \hat{\mu}) = UU^{\top}\left(\frac{1}{N}\sum_{i=1}^{N}(x^{(i)} - \hat{\mu})\right)$$

$$\frac{1}{N}\sum_{i=1}^{N}(x^{(i)} - \hat{\mu}) = \hat{\mu} - \hat{\mu} = 0$$

¿Cómo cumplimos con los objetivos de minimización?

Minimizar el error de reconstrucción

$$\min_{\mathbf{U}} \frac{1}{N} \sum_{i=1}^{N} \|\mathbf{x}^{(i)} - \tilde{\mathbf{x}}^{(i)}\|^2$$

Maximizar la varianza de los vectores de

$$\max_{\mathbf{U}} \frac{1}{N} \sum_{i} \|\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}}\|^2$$

(10 min) Break



¡Estos dos criterios son equivalentes!

Es decir, mostraremos:

$$\frac{1}{N}\sum_{i=1}^{N}\|\mathbf{x}^{(i)}-\tilde{\mathbf{x}}^{(i)}\|^2 = \text{const} - \frac{1}{N}\sum_{i}\|\tilde{\mathbf{x}}^{(i)}-\hat{\boldsymbol{\mu}}\|^2$$

- Recordar $\tilde{\mathbf{x}}^{(i)} = \hat{\boldsymbol{\mu}} + \mathbf{U}\mathbf{z}^{(i)}$ and $\mathbf{z}^{(i)} = \mathbf{U}^\top(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})$.

Observación 1: Como las columnas de U son ortogonales, $U^TU = I$:

$$\|\tilde{\mathbf{x}}-\hat{\boldsymbol{\mu}}\|^2 = \|\mathbf{U}\mathbf{z}\|^2 = \mathbf{z}^\top\mathbf{U}^\top\mathbf{U}\mathbf{z} = \mathbf{z}^\top\mathbf{z} = \|\mathbf{z}\|^2.$$

$\Longrightarrow$ La norma de la reconstrucción centrada es igual a la norma de la representación.

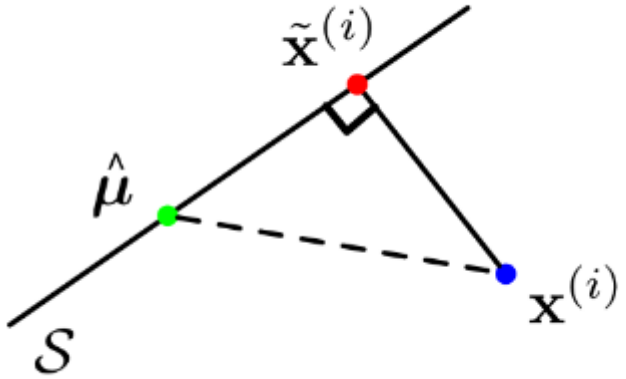
Teorema de Pitágoras

Observación 1: $\|\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}}\|^2 = \|\mathbf{z}^{(i)}\|^2$ $\qquad \frac{1}{N}\sum_i \|\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}}\|^2 = \frac{1}{N}\sum_i \|\mathbf{z}^{(i)}\|^2$

- Varianza de reconstrucciones = varianza de vectores de código

Observación 2: Ortogonalidad de $(\tilde{x}^{(i)} - \hat{\mu})$ y $(\tilde{x}^{(i)} - x^{(i)})$

(Dos vectores a, b son ortogonales $\Leftrightarrow a^T b = 0$)



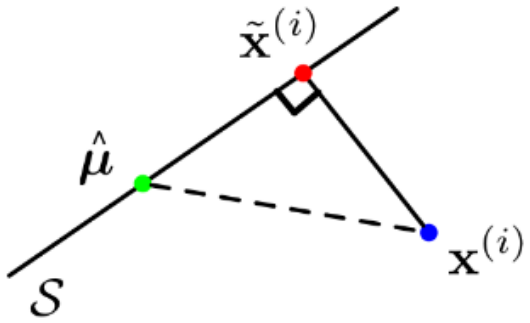
$$
\begin{aligned}
&(\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}})^\top (\tilde{\mathbf{x}}^{(i)} - \mathbf{x}^{(i)}) \\
&= (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})^\top \mathbf{U}\mathbf{U}^\top (\hat{\boldsymbol{\mu}} - \mathbf{x}^{(i)} + \mathbf{U}\mathbf{U}^\top (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})) \\
&= (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})^\top \mathbf{U}\mathbf{U}^\top (\hat{\boldsymbol{\mu}} - \mathbf{x}^{(i)}) + (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})^\top \mathbf{U}\mathbf{U}^\top (\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}) \\
&= 0
\end{aligned}
$$

Teorema de Pitágoras

El Teorema de Pitágoras nos dice:

$$\|\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}}\|^2 + \|\mathbf{x}^{(i)} - \tilde{\mathbf{x}}^{(i)}\|^2 = \|\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}\|^2 \quad \text{para cada i}$$

Promediando sobre los datos:



$$\underbrace{\frac{1}{N}\sum_{i=1}^{N}\|\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}}\|^2}_{\text{projected variance}} + \underbrace{\frac{1}{N}\sum_{i=1}^{N}\|\mathbf{x}^{(i)} - \tilde{\mathbf{x}}^{(i)}\|^2}_{\text{reconstruction error}}$$

$$= \underbrace{\frac{1}{N}\sum_{i=1}^{N}\|\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}\|^2}_{\text{constant}}$$

Por lo tanto:

varianza proyectada = constante - error de reconstrucción

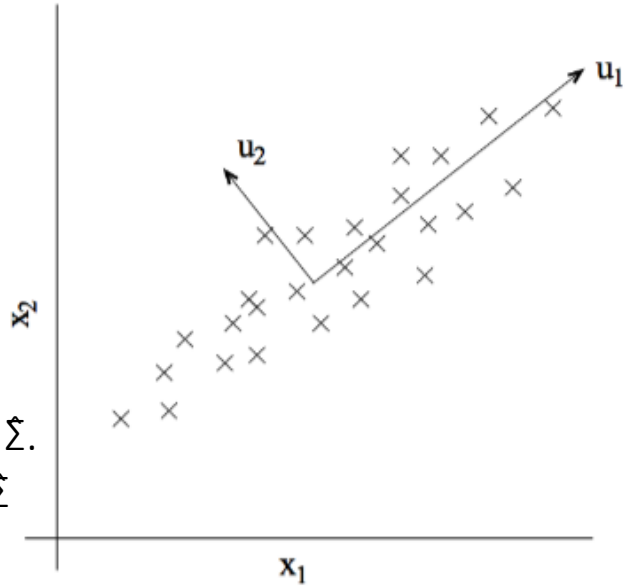
¡Maximizar la varianza es equivalente a minimizar el error de reconstrucción!

Análisis de componentes principales (PCA)

Elegir un subespacio para maximizar la varianza proyectada, o minimizar el error de reconstrucción, se llama análisis de componentes principales (PCA).

- Considerar la matriz de covarianza empírica:

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{N}\sum_{i=1}^{N}(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})^{\top}$$



- $\hat{\Sigma}$ es simétrica y semidefinida positiva.
- El subespacio PCA óptimo está generado por los K vectores propios principales de $\hat{\Sigma}$.
- Más precisamente, elegir los primeros K de cualquier eigenbase ortonormal para $\hat{\Sigma}$
- El caso general es complicado, pero lo mostraremos para K = 1

Estos vectores propios se llaman componentes principales, análogos a los ejes principales de una elipse.

- Para K = 1, ajustamos un vector unitario u, y el código es un escalar $z^{(i)} = \mathbf{u}^\top(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})$ Maximicemos la varianza proyectada:

$$\frac{1}{N}\sum_i \|\tilde{\mathbf{x}}^{(i)} - \hat{\boldsymbol{\mu}}\|^2 = \frac{1}{N}\sum_i [z^{(i)}]^2 = \frac{1}{N}\sum_i (\mathbf{u}^\top(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}}))^2$$

$$= \frac{1}{N}\sum_{i=1}^{N} \mathbf{u}^\top(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})^\top \mathbf{u} \qquad (\mathbf{a}^\top\mathbf{b})^2 = \mathbf{a}^\top\mathbf{b}\mathbf{b}^\top\mathbf{a}$$

$$= \mathbf{u}^\top\left[\frac{1}{N}\sum_{i=1}^{N}(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})^\top\right]\mathbf{u}$$

$$= \mathbf{u}^\top\hat{\boldsymbol{\Sigma}}\mathbf{u}$$

$$= \mathbf{u}^\top\mathbf{Q}\boldsymbol{\Lambda}\mathbf{Q}^\top\mathbf{u} \qquad \text{Spectral Decomposition } \hat{\boldsymbol{\Sigma}} = \mathbf{Q}\boldsymbol{\Lambda}\mathbf{Q}^\top$$

$$= \mathbf{a}^\top\boldsymbol{\Lambda}\mathbf{a} \qquad \text{for } \mathbf{a} = \mathbf{Q}^\top\mathbf{u}$$

$$= \sum_{j=1}^{D}\lambda_j a_j^2$$

Resumen

- La reducción de dimensionalidad busca encontrar una representación de baja dimensión de los datos.
- PCA proyecta los datos sobre un subespacio que maximiza la varianza proyectada, o equivalentemente, minimiza el error de reconstrucción.
- El subespacio óptimo está dado por los vectores propios principales de la matriz de covarianza empírica.
- PCA produce un conjunto de características decorrelacionadas.

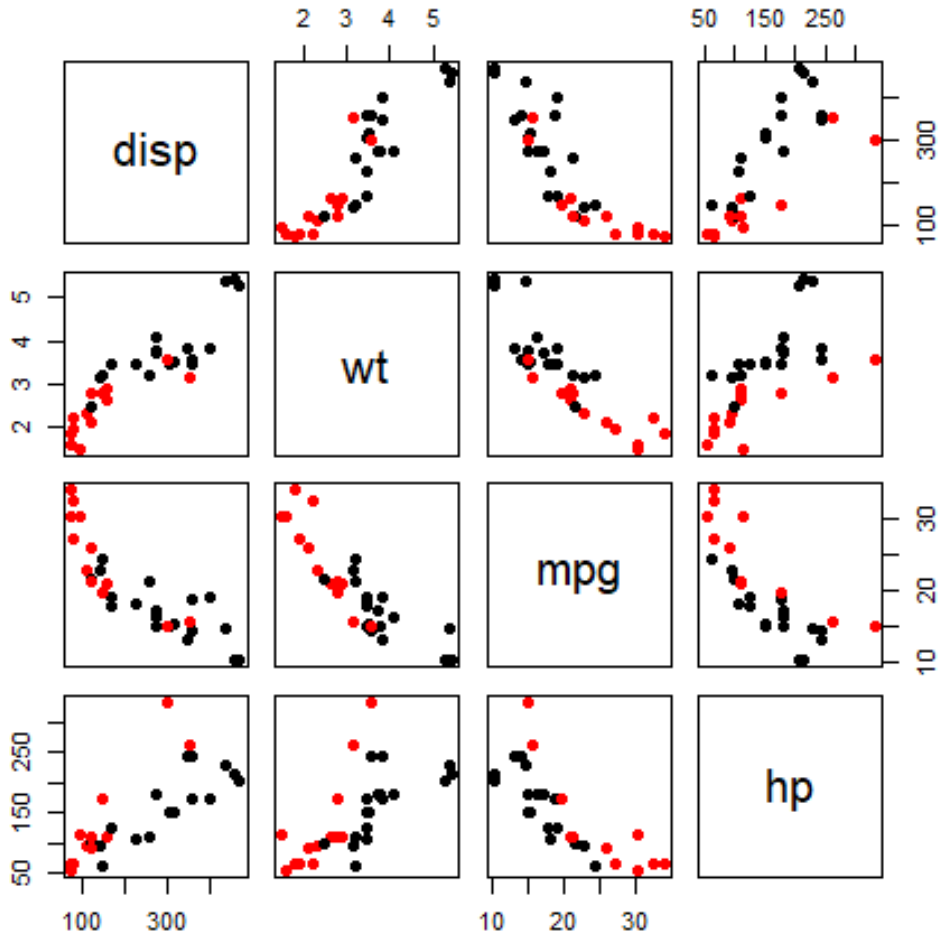
  - Hecho interesante: las dimensiones de z están decorrelacionadas
  - Si la matriz de covarianza es diagonal, esto significa que las características están no correlacionadas.
  - Por esto se inventó PCA (¡en 1901!).

Demo

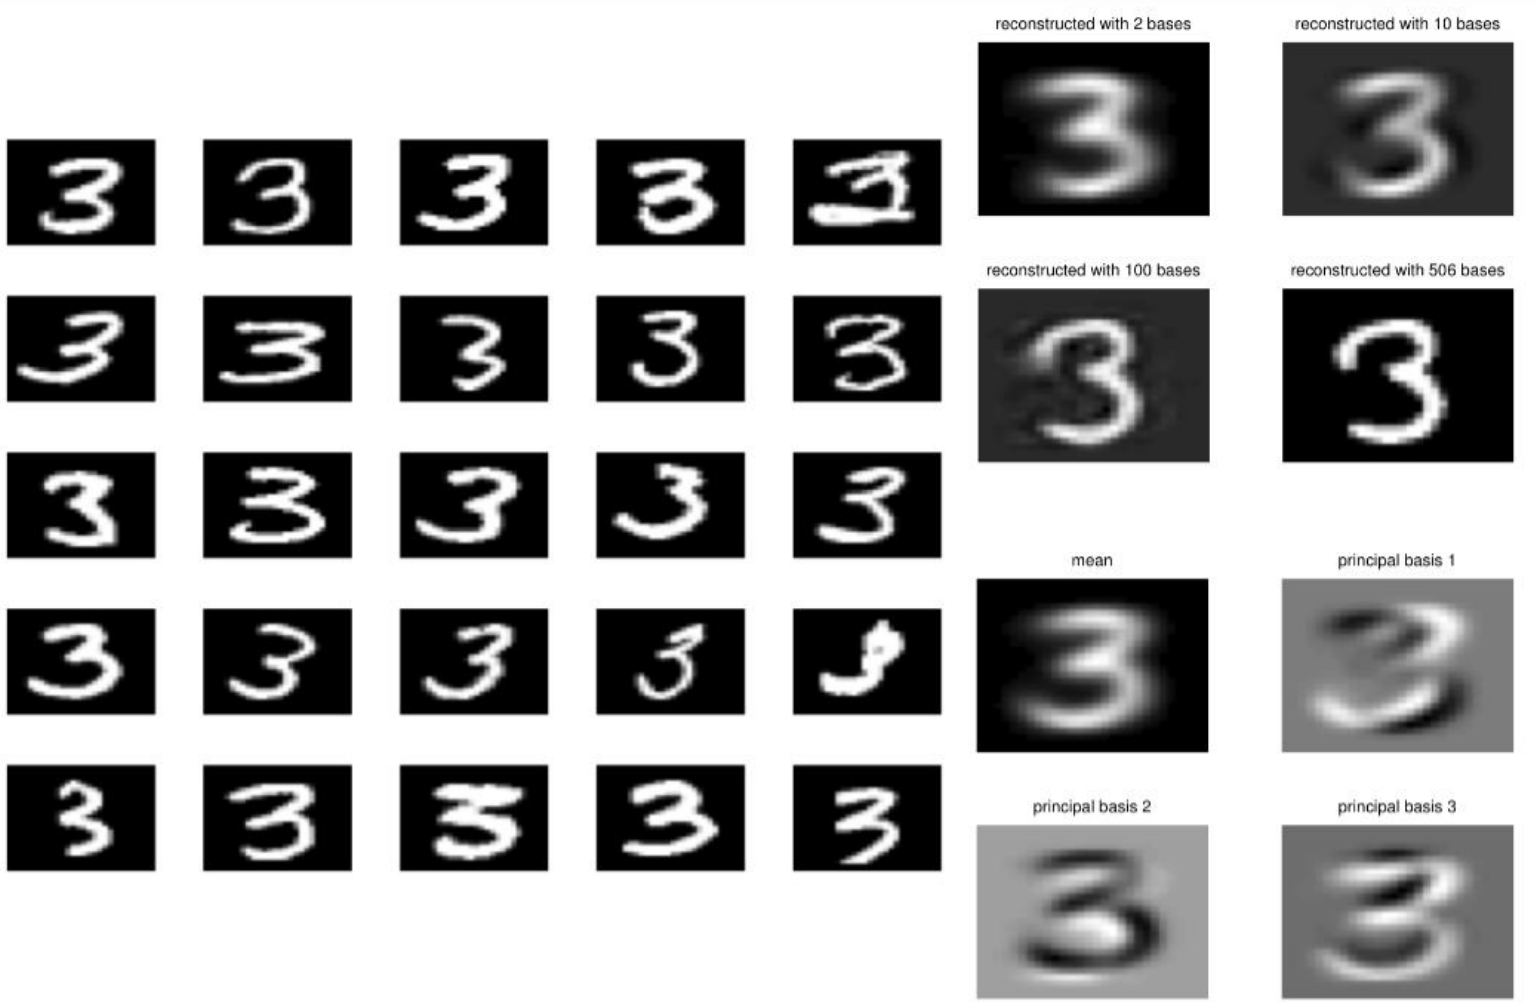

PCA (Principal Component Analysis) Visualizer
Data
PCA
Explorer
Secondary Plot
Info
Data Panel
Add Points
Group A (Blue)
Groups are for coloring only — PCA ignores labels
x
y
Add Point
Click on the plot to add points directly
Data Points
(-0.68, -0.76)
(2.09, 0.73)
(1.50, 0.45)
(0.66, 0.14)
(2.40, 1.22)
(2.13, 1.56)
Show Mean Point
Show Data Ellipse
Compute
Compute PCA
Status: Computed
Step-Through
Step 6 of 6: Reconstruction
Reconstruct data from reduced dimensions — the gap is the information lost
1
2
3
4
5
6
Prev
Play
Next
Reset to Step 1
Playback Speed
1.5s
PCA — Step 6: Reconstruction
Group A
Group B
Mean
PC1
PC2
Feature y
3
2
1
0
−1
−2
−2
0
2
4

¿Cuál es un problema de PCA?

Relaciones no siempre son lineales



Aplicando PCA a dígitos



Aplicando PCA a rostros

- Consideremos ejecutar PCA en 2429 imágenes en escala de grises de 19x19 (datos CBCL)
- Se pueden obtener buenas reconstrucciones con solo 3 componentes



- PCA para pre-procesamiento: se puede aplicar un clasificador a la representación latente
  - Para reconocimiento facial, PCA con 3 componentes obtiene 79% de precisión en la discriminación cara/no-cara en datos de prueba vs. 76.8% para un modelo de mezcla gaussiana (GMM) con 84 estados. (Cubriremos los GMM más adelante en el curso).
- También puede ser bueno para visualización

Aplicando PCA a rostros: Base aprendida

- Componentes principales de imágenes de rostros ("eigenfaces")



Aplicado a expresiones: subespacio feliz





Aplicado a expresiones: subespacio disgusto





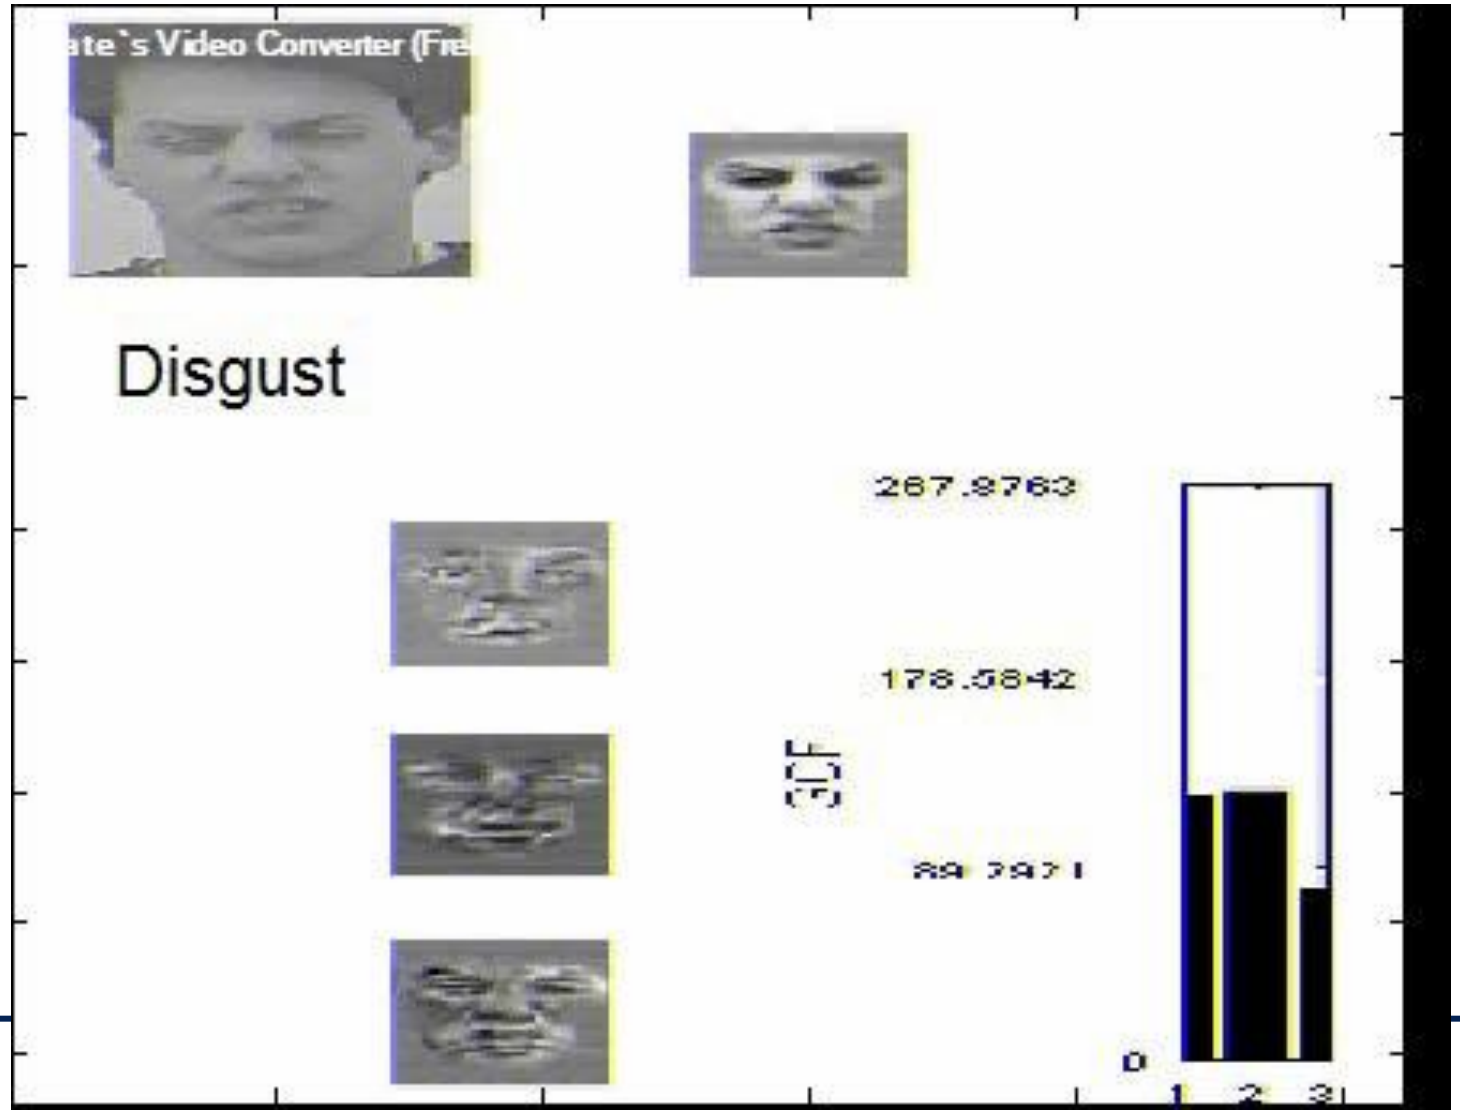
Ejemplos de reconocimiento de expresiones



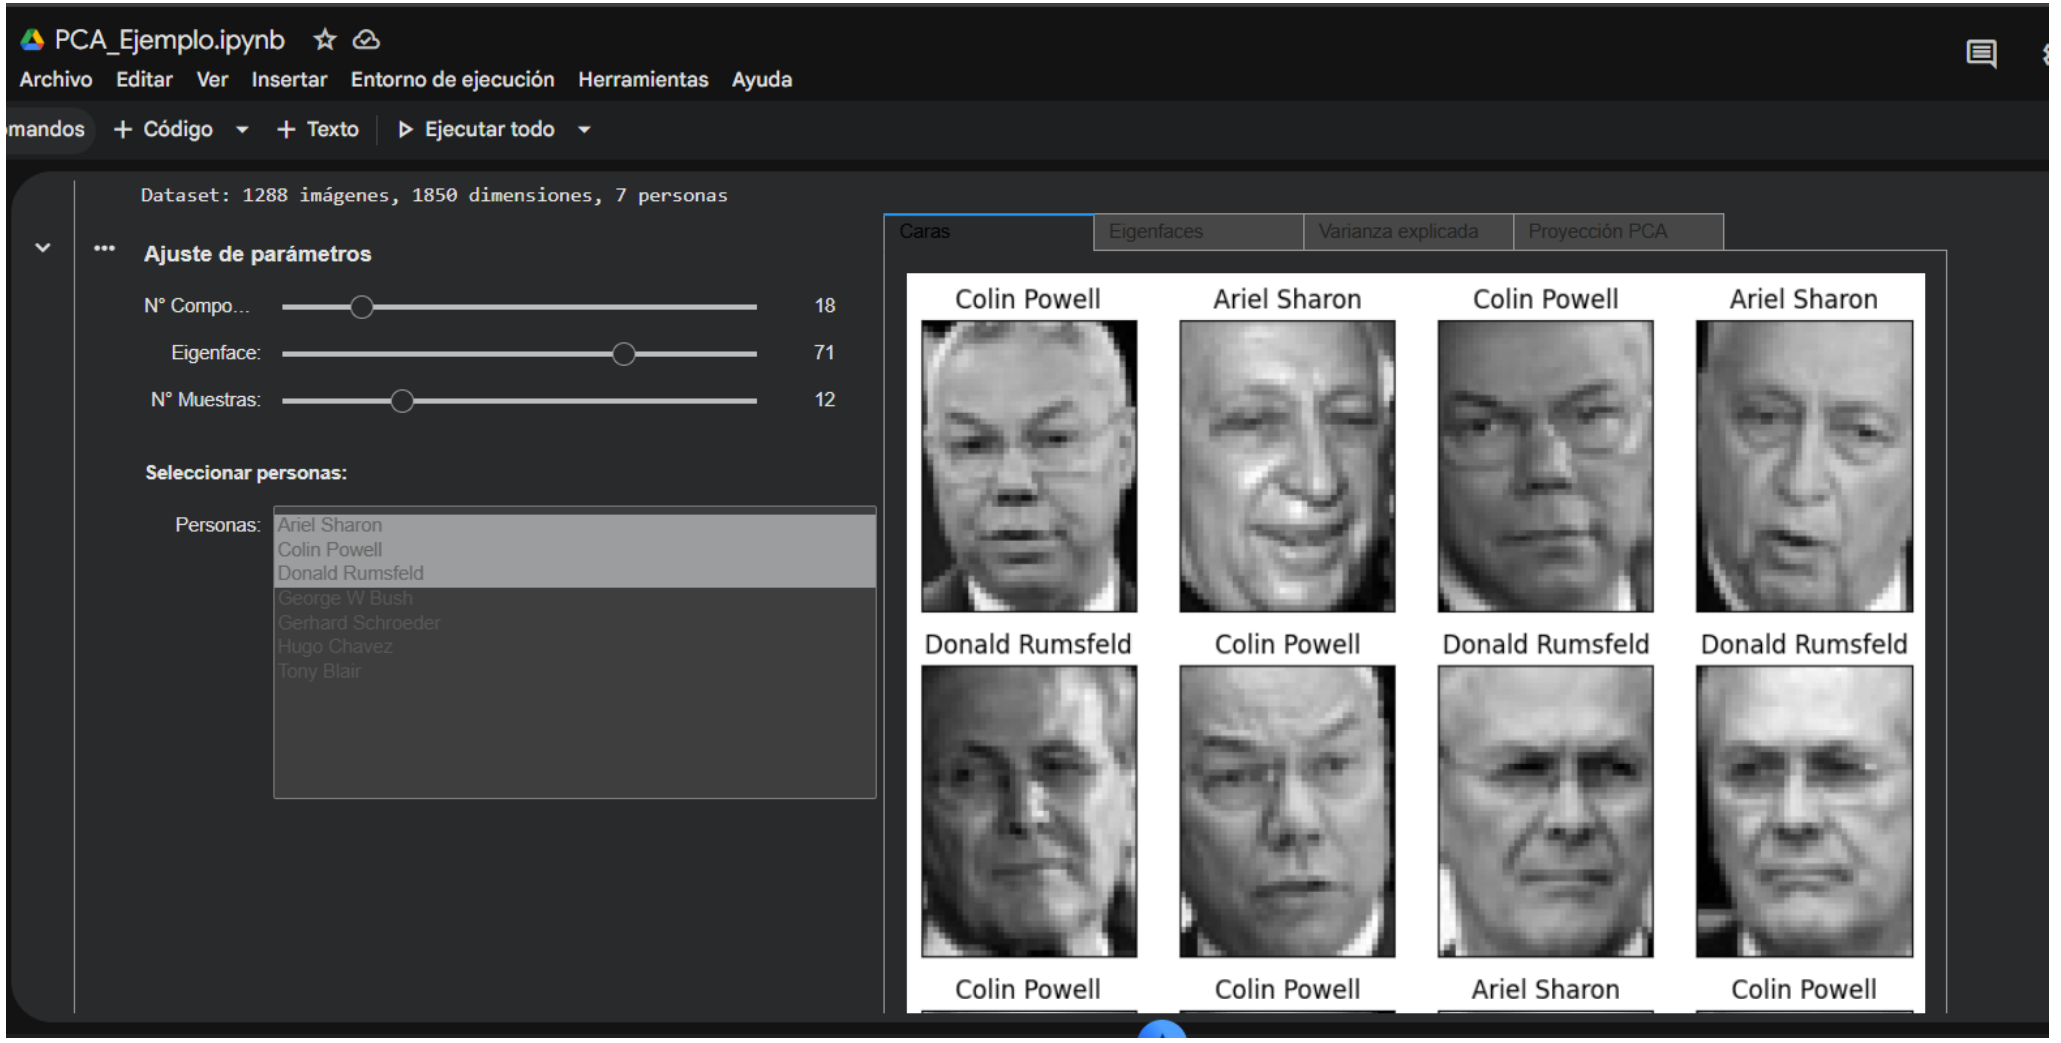
Ejemplos de reconocimiento de expresiones



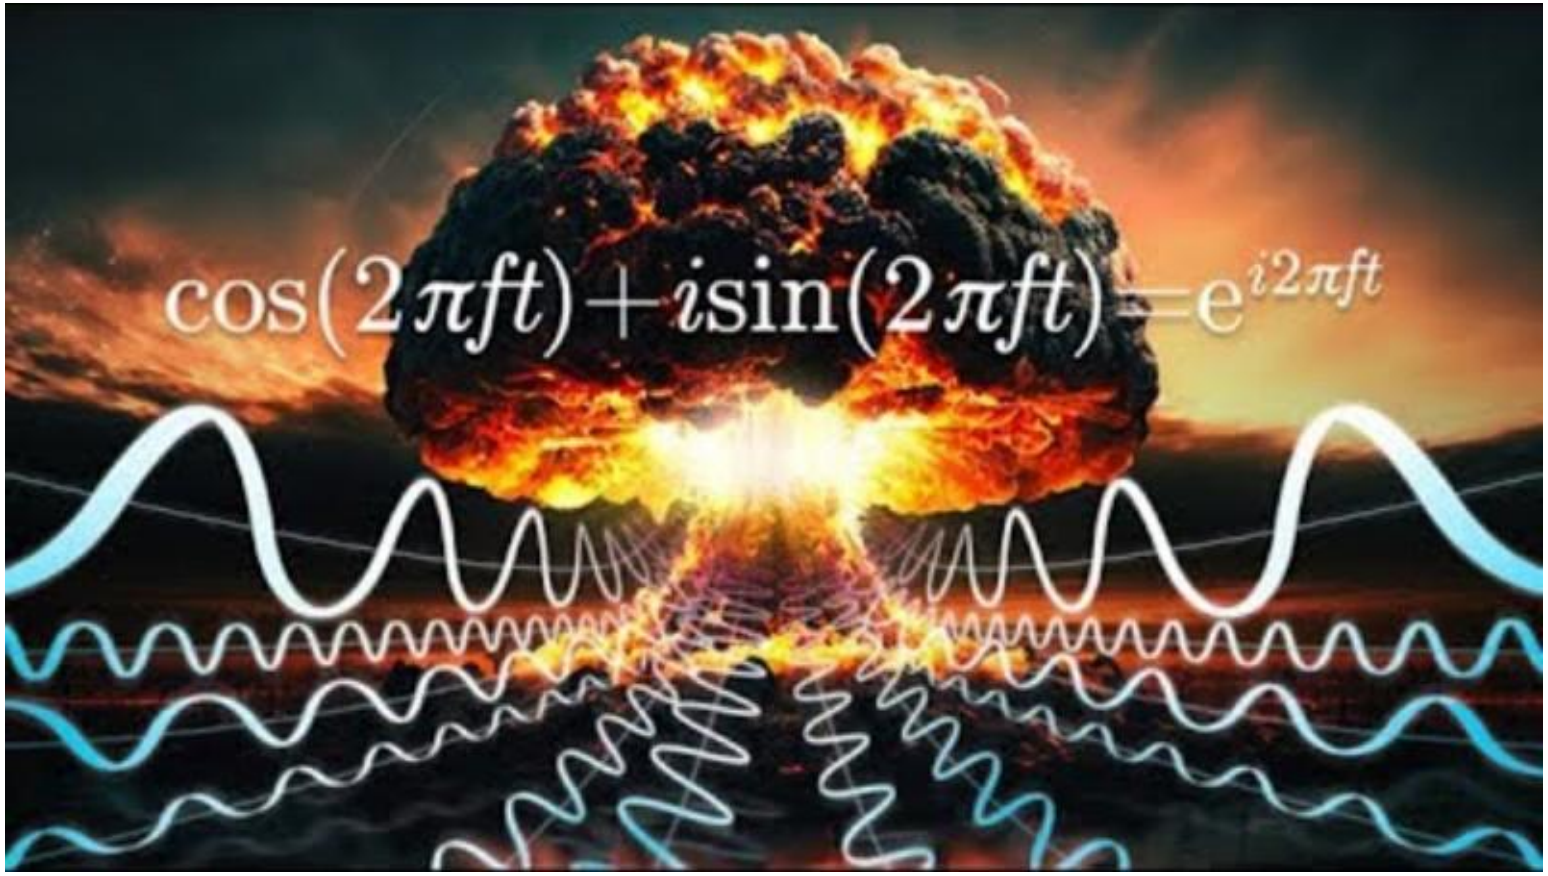
Ejemplos de reconocimiento de expresiones



Demo PCA


PCA_Ejemplo.ipynb
Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda
mandos + Código + Texto ▷ Ejecutar todo
Dataset: 1288 imágenes, 1850 dimensiones, 7 personas
Ajuste de parámetros
N° Compo... 18
Eigenface: 71
N° Muestras: 12
Seleccionar personas:
Personas:
Ariel Sharon
Colin Powell
Donald Rumsfeld
George W Bush
Gerhard Schroeder
Hugo Chavez
Tony Blair
Caras
Eigenfaces
Varianza explicada
Proyección PCA
Colin Powell
Ariel Sharon
Colin Powell
Ariel Sharon
Donald Rumsfeld
Colin Powell
Donald Rumsfeld
Donald Rumsfeld
Colin Powell
Colin Powell
Ariel Sharon
Colin Powell

El Algoritmo Más Importante De Todos Los Tiempos



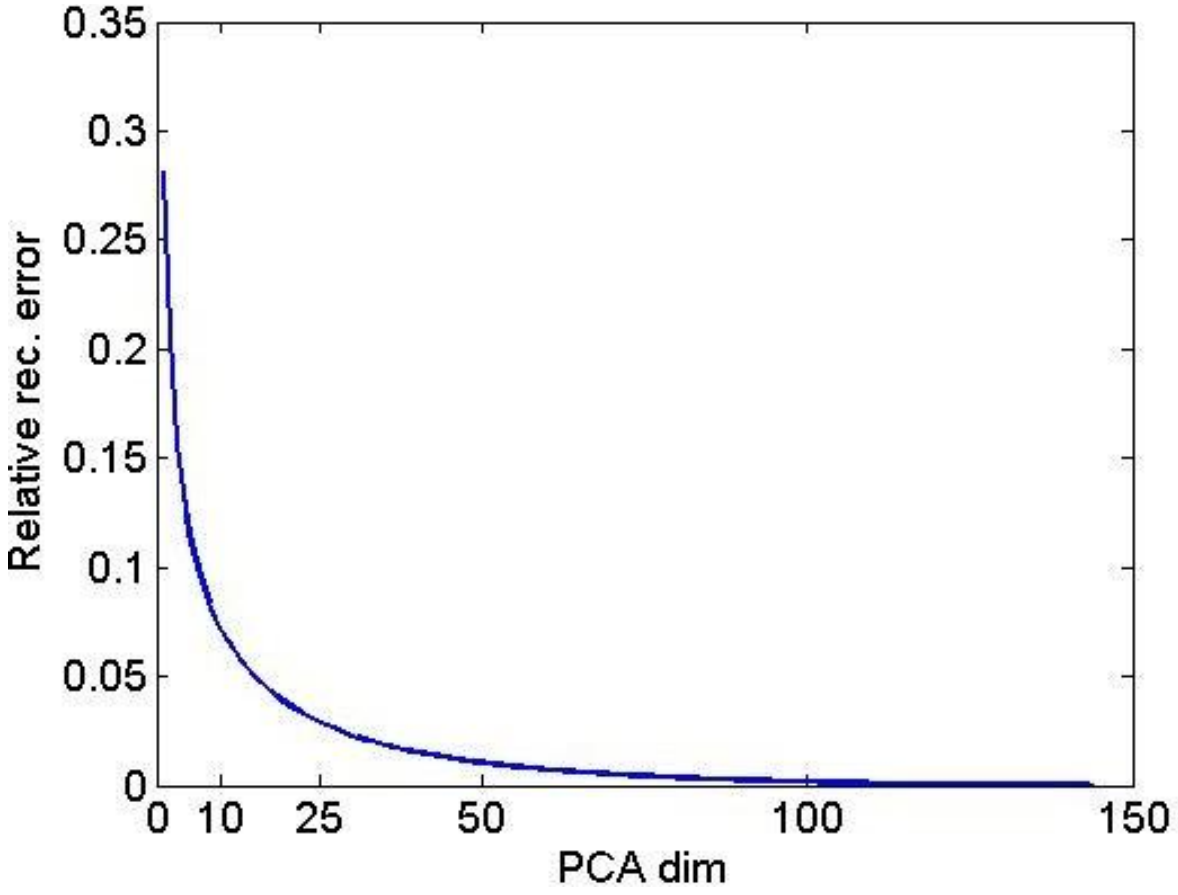
https://youtu.be/2Xkv-W9tOXU?si=wb90GEBGONfM7Xih&t=1247

Compresión de Imágenes

- Dividir el original 372x492 imagen en parches:
- Cada parche es un instancia eso contiene 12x12 píxeles en una cuadrícula
- Vista cada uno como un 144 -D vector



Compresión de Imágenes



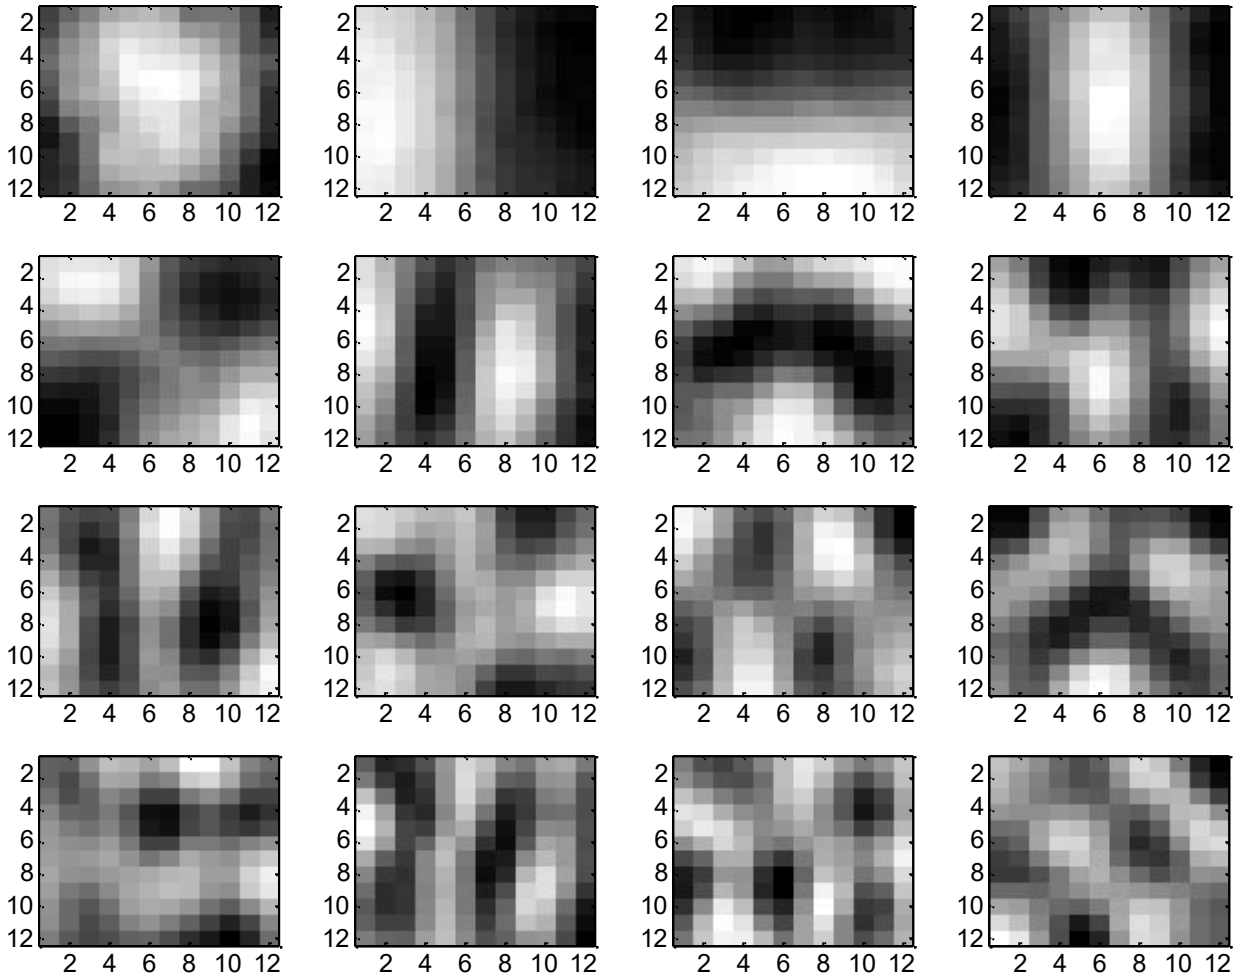
Compresión de Imágenes: 144 a 66D



Compresión de Imágenes: 144 a 16D



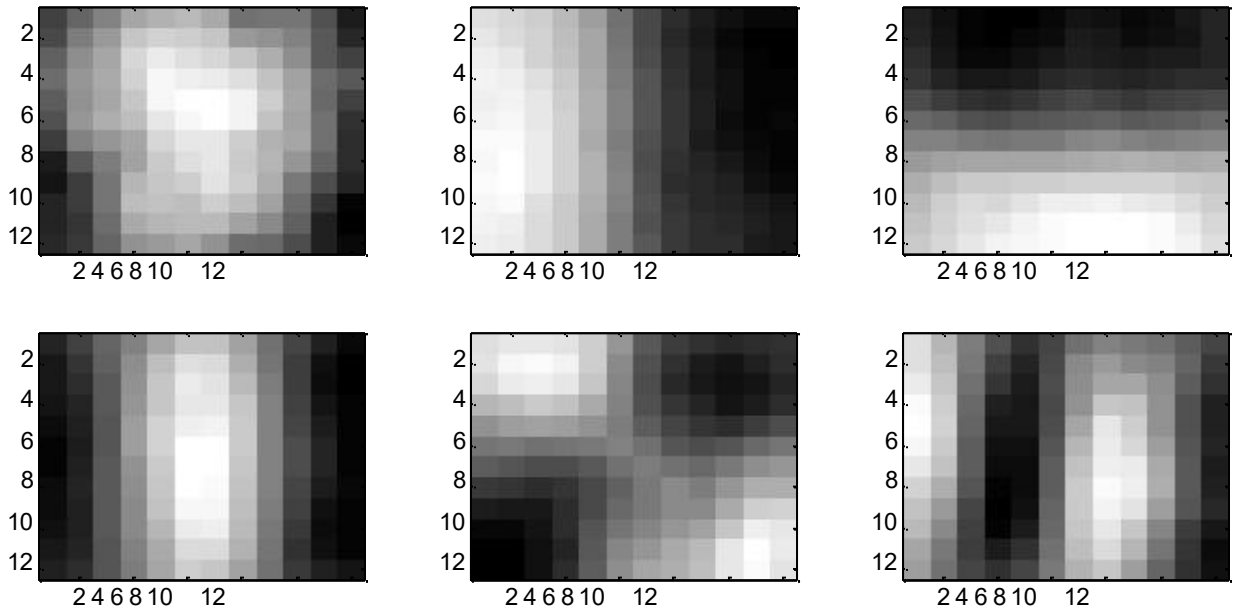
Los 16 vectores propios de esa imagen



Compresión de Imágenes: 144 a 6D



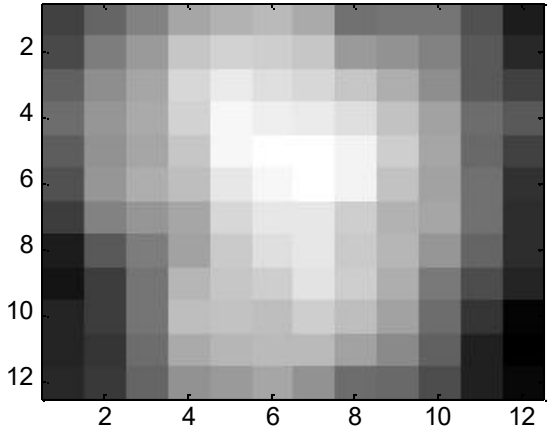
Los 6 vectores propios de esa imagen

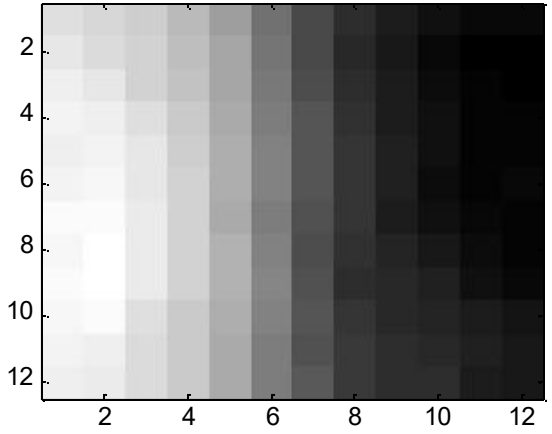


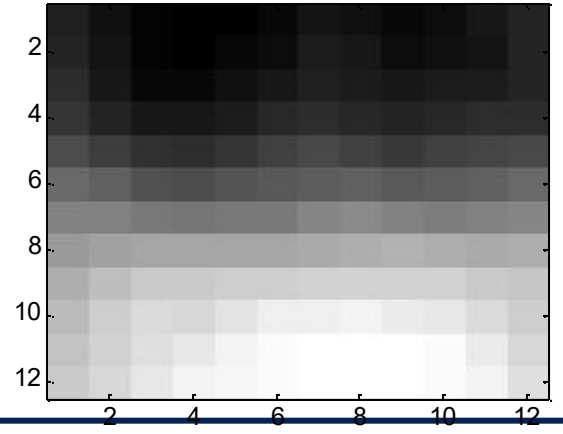
Compresión de Imágenes: 144 a 3D



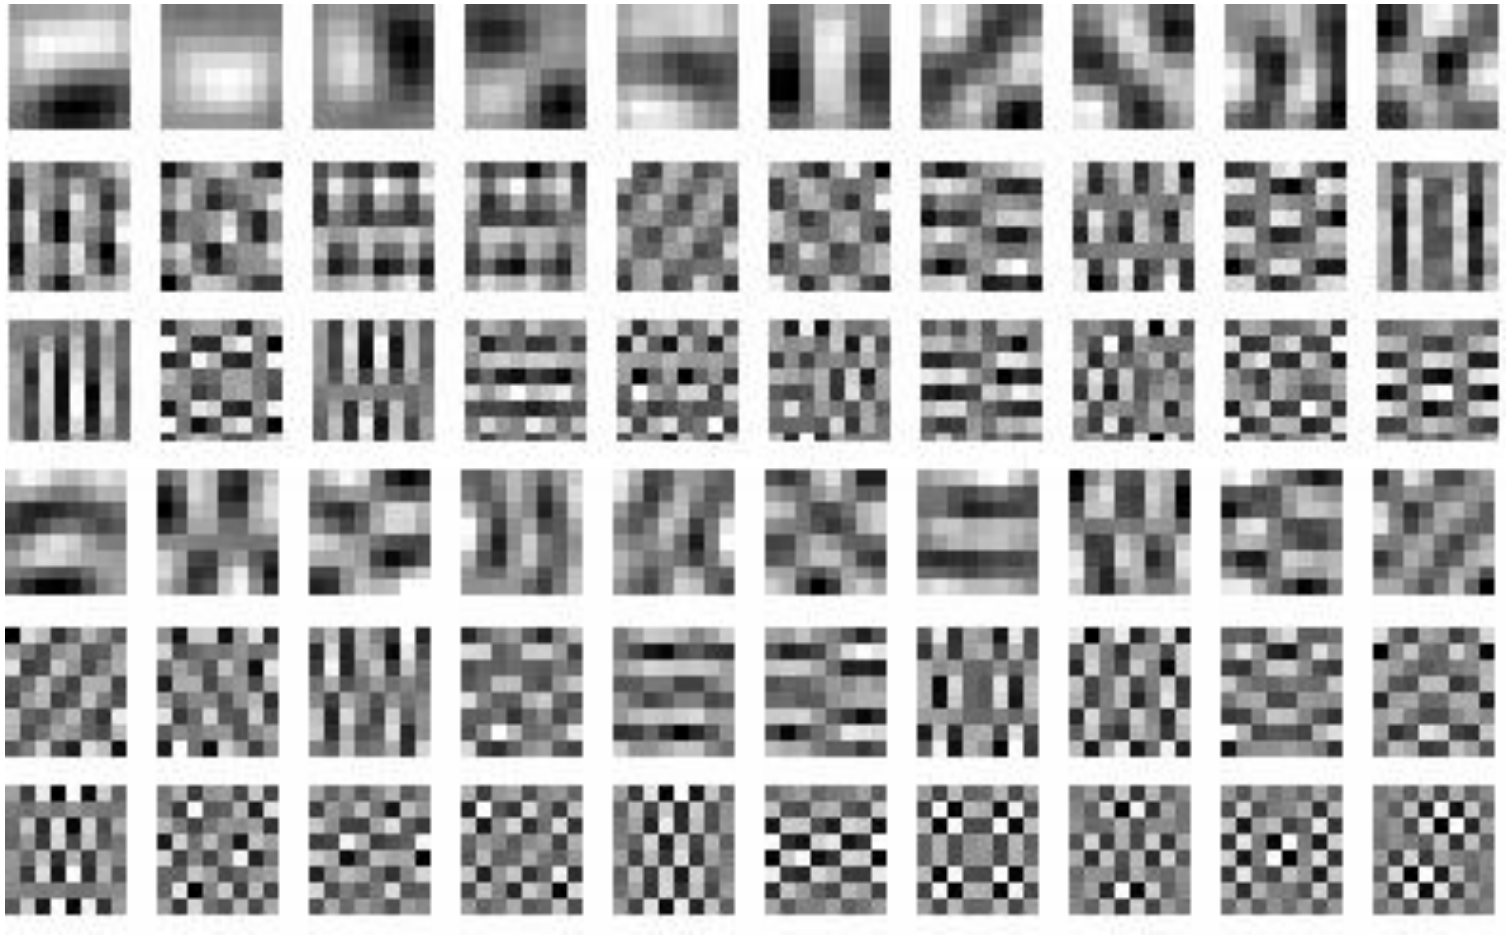
Los 3 vectores propios de esa imagen



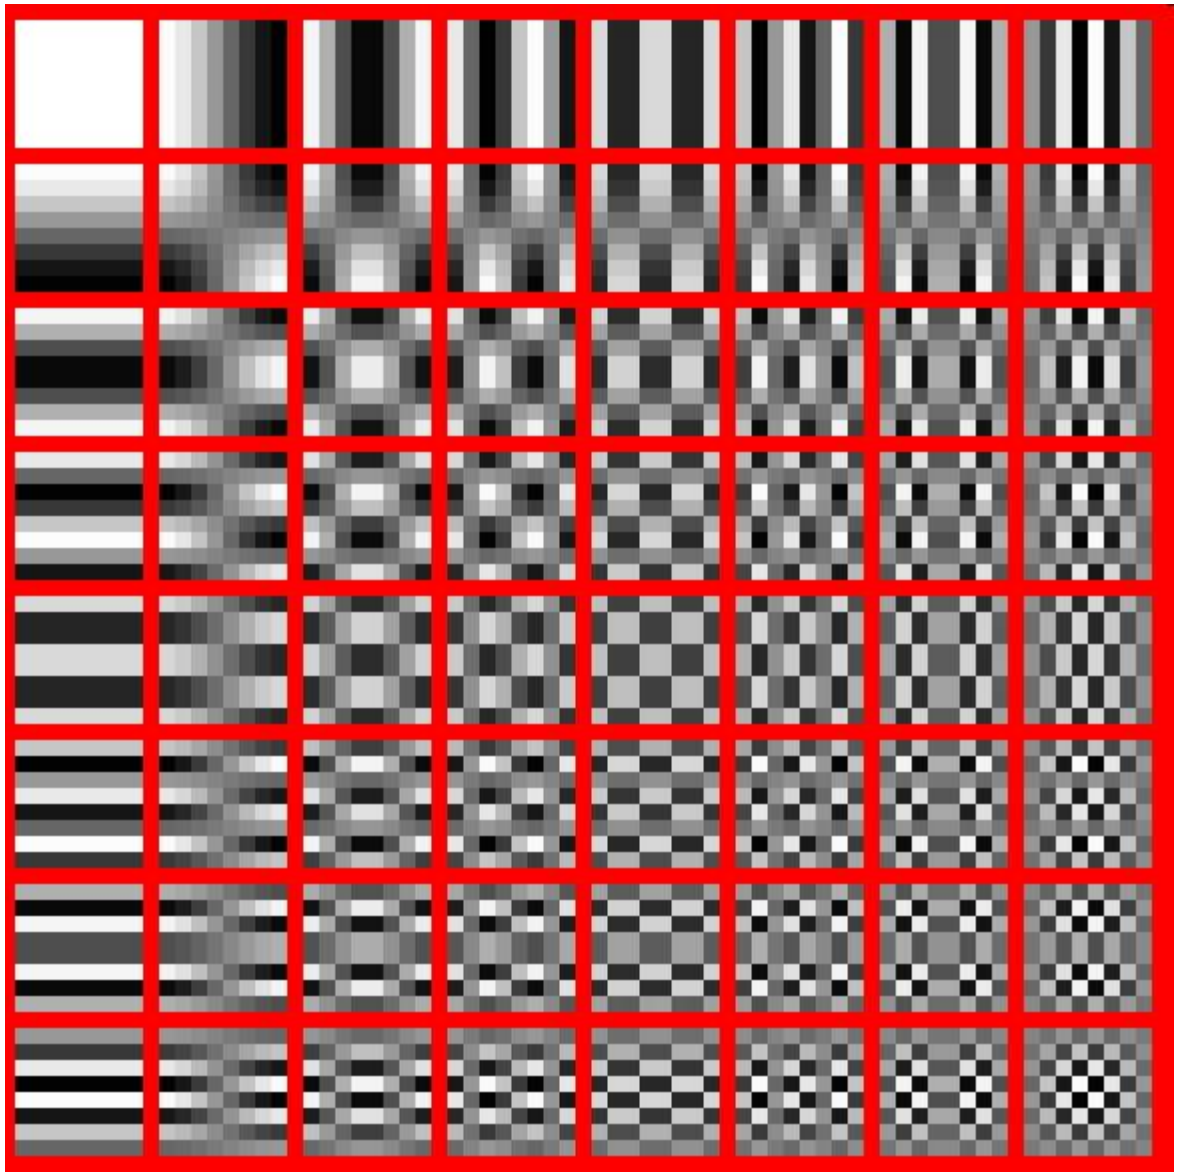




Los 60 vectores propios más comunes



Aspecto como el discreto coseno bases de ¡JPG!...



Esta técnica llega a “encontrar” la distribución natural que ayuda a reducir o “comprimir” los datos. Similar a las distribuciones tradicionales.

http://en.wikipedia.org/wiki/Discrete_cosine_transform

Problema: Cálculo de PCA

- Se consideran los siguientes **4 puntos en** $\mathbb{R}^2$:

$$x^{(1)} = (1, 1),\ x^{(2)} = (2, 2),\ x^{(3)} = (3, 3),\ x^{(4)} = (4, 4)$$

- Se desea aplicar **Análisis de Componentes Principales (PCA)** para reducir la dimensión de los datos de 2 a $K = 1$.

Solución: Cálculo de PCA

- La media empírica se define como:

$$\hat{\mu} = \frac{1}{N}\sum_{i=1}^{N} x^{(i)}$$

- En este caso:

$$\hat{\mu} = \frac{1}{4}[(1, 1) + (2, 2) + (3, 3) + (4, 4)] = (2.5,\ 2.5)$$

Solución: Cálculo de PCA

- La matriz de covarianza empírica está dada por:

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{N}\sum_{i=1}^{N}(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})(\mathbf{x}^{(i)} - \hat{\boldsymbol{\mu}})^{\top}$$

- Calculamos un término como ejemplo:

$$\begin{pmatrix}-1.5\\-1.5\end{pmatrix}(-1.5 \quad -1.5) = \begin{pmatrix}2.25 & 2.25\\2.25 & 2.25\end{pmatrix}$$

- Sumando los cuatro términos y dividiendo por 4, obtenemos:

$$\hat{\Sigma} = \begin{pmatrix}1.25 & 1.25\\1.25 & 1.25\end{pmatrix}$$

Solución: Cálculo de PCA

- Buscamos soluciones de:

$$\hat{\Sigma}u = \lambda u$$

- Los **autovalores** son:

$$\lambda_1 = 2.5, \lambda_2 = 0$$

- Los **autovectores normalizados** asociados son:

$$u_1 = \frac{1}{\sqrt{2}}(1, 1), u_2 = \frac{1}{\sqrt{2}}(1, -1)$$

Solución: Cálculo de PCA

- Como se desea $K = 1$, se elige el autovector correspondiente al **mayor autovalor**:

$$\boxed{u_1 = \frac{1}{\sqrt{2}}(1, 1)}$$

- Este vector define la **primera componente principal**.

Solución: Cálculo de PCA

- La proyección de un punto centrado $\tilde{x}$sobre la componente principal es:

$$z = u_1^\top (x - \hat{\mu})$$

- Ejemplo, para el punto $x = (4, 4)$:
  1. Centrado: $x - \hat{\mu} = (1.5, 1.5)$
  2. Proyección:

$$z = \frac{1}{\sqrt{2}}(1, 1) \cdot (1.5, 1.5) = \frac{3}{\sqrt{2}}$$

- Así, el punto bidimensional se representa ahora con **un solo número**.

Preguntas Vibe Quest

- ¿En qué situaciones maximizar la varianza (el objetivo de PCA) podría llevarnos a perder información crucial para nuestro problema específico?
- ¿Qué tipos de relaciones no lineales o estructuras topológicas complejas se pierden inevitablemente en PCA, y cómo podríamos detectar que esta pérdida es significativa para nuestro análisis?
- ¿Hasta qué punto podemos atribuir significado real a los componentes principales, y qué peligros existen al interpretar estas construcciones matemáticas como fenómenos causales subyacentes?
- ¿De qué manera el Análisis de Componentes Principales representa una extensión natural de conceptos estadísticos clásicos como la varianza y correlación, y en qué sentido constituye una ruptura filosófica con los paradigmas tradicionales de inferencia estadística?